

REPORTE INSTITUCIONAL · HITO 0

REPORTE INSTITUCIONAL DEL HITO 0: DIAGNÓSTICO, RECONSTRUCCIÓN CONCEPTUAL Y AGENDA DE VALIDACIÓN DE LA MEDICIÓN DE LOS ATRIBUTOS DE INNOVACIÓN Y EMPRENDIMIENTO

Facultad de Ingeniería

Universidad de Santiago de Chile

DIAGNÓSTICO · RECONSTRUCCIÓN CONCEPTUAL · AGENDA DE VALIDACIÓN



RESUMEN EJECUTIVO

El **Hito 0** fue concebido como una medición diagnóstica de ingreso para caracterizar las condiciones iniciales con que los estudiantes comienzan su trayectoria formativa respecto de diez atributos institucionales de innovación y emprendimiento. Su finalidad es **formativa y curricular**: aportar una línea de base que permita orientar apoyos, decisiones pedagógicas y procesos de mejora del sistema de formación. No corresponde a una prueba de selección, certificación, exclusión ni clasificación permanente de estudiantes. Esta distinción es central porque el valor de una medición de ingreso depende no solo de producir puntajes, sino de que las interpretaciones y usos derivados de ellos estén suficientemente respaldados por evidencia.

Este reporte documenta un proceso de reconstrucción metodológica en tres niveles. Primero, realiza un **diagnóstico retrospectivo** de la primera aproximación institucional aplicada a la cohorte 2026. Segundo, reconstruye sustantivamente los diez atributos como variables de medición mediante progresiones de desarrollo y juicio experto. Tercero, define una **agenda de validación** para transformar esa arquitectura conceptual en nuevas tareas, espacios de puntuación y modelos de medición que deberán ser sometidos a procesos de respuesta, pilotaje y contraste psicométrico antes de una aplicación institucional ampliada.

En la primera aproximación, la **prueba individual en línea** estuvo compuesta por diez ítems dicotómicos y fue analizada en una muestra de 991 estudiantes. El instrumento representaba nominalmente ocho de los diez atributos, pero seis de ellos mediante un solo ítem. Además, se verificó una desalineación relevante entre el atributo declarado y la demanda efectiva de uno de los ítems. El 55,0 % de los estudiantes obtuvo entre 8 y 10 aciertos y 93 estudiantes —9,38 % de la muestra— alcanzaron el puntaje máximo. Bajo el modelo de Rasch, las dificultades se localizaron completamente en valores negativos, entre $-3,337$ y $-0,274$ logits, y la máxima información del conjunto se concentró aproximadamente en $\theta = -1,15$. Este patrón muestra que la prueba estuvo mejor focalizada hacia niveles bajos y medios-bajos que hacia la zona alta del continuo. La confiabilidad EAP fue 0,508 y la WLE 0,319, valores que indican precisión insuficiente para sostener interpretaciones individuales finas. La estructura factorial tampoco proporcionó una base estable para interpretar el instrumento como diez medidas diferenciadas ni como una única dimensión sustantiva claramente establecida.

La **situación de desempeño grupal** fue analizada en 221 grupos calificados mediante ocho criterios ordinales vinculados nominalmente con cinco atributos. El puntaje conjunto mostró una consistencia global alta y una precisión razonable bajo el Partial Credit Model (EAP = 0,811; WLE = 0,782), pero estos resultados no equivalen a evidencia de medición diferenciada de los atributos. El CFA unidimensional mostró ajuste insuficiente y la diferencia entre omega total (0,924) y omega jerárquico (0,595) reforzó la necesidad de cautela frente a una interpretación de dimensión general fuerte. El análisis PCM permitió caracterizar la focalización de los criterios y el funcionamiento de sus categorías: las cuatro categorías alcanzaron una región modal propia en los ocho criterios examinados, aunque C07 presentó una región modal comparativamente estrecha para la categoría 2. El diseño de aplicación, además, no permitió separar adecuadamente los efectos de evaluador, grupo y sección, por lo que las diferencias observadas entre evaluadores no pueden atribuirse directamente a severidad individual.

En conjunto, el diagnóstico de ambos instrumentos mostró una conclusión convergente: **la primera aproximación permitió describir patrones agregados y detectar problemas relevantes de cobertura, focalización, precisión y estructura, pero no permitió producir una estimación confiable y diferenciada de los diez atributos institucionales**. Un ítem aislado no equivale a una medida de un atributo; un criterio grupal no puede transformarse automáticamente en una inferencia individual; y una alta consistencia del puntaje agregado no demuestra que exista una estructura unidimensional fuerte ni habilita subpuntuaciones por atributo.

A partir de este diagnóstico, el proyecto retrocedió deliberadamente desde los instrumentos hacia la **especificación de los constructos**. Se construyeron diez progresiones iniciales de desarrollo y se sometieron a juicio de cinco especialistas, quienes completaron 300 valoraciones correspondientes a diez atributos × seis criterios × cinco expertos. La V de Aiken media descriptiva de las 60 celdas atributo × criterio fue 0,748. El juicio experto no se utilizó como una certificación de “mapas validados”, sino como evidencia de contenido para identificar necesidades diferenciadas de revisión. Claridad fue, en promedio, el criterio menos favorable, mientras que la distinción entre niveles fue el más favorable. Teoría de innovación y emprendimiento y Diseño presentaron las señales cuantitativas más claras de necesidad de revisión prioritaria.

La triangulación de evidencia cuantitativa, comentarios cualitativos y literatura focalizada condujo a una arquitectura revisada en la que **no todos los atributos conservan la misma estructura dimensional**. Cuatro atributos fueron reespecificados estructuralmente: Diseño pasó a tres strands interdependientes; Comunicación, a dos strands; Teoría de innovación y emprendimiento, a dos progresiones relacionadas; y Economía y gestión, a dos strands interdependientes. Los seis atributos restantes mantuvieron una estructura unidimensional, aunque con distintos grados de refinamiento conceptual y de formulación. En todos los casos, las versiones resultantes deben entenderse como **hipótesis de medición revisadas**, no como estructuras psicométricamente demostradas.

El principal producto alcanzado hasta esta etapa, por tanto, **no es un nuevo test terminado**, sino una arquitectura de medición más explícita y defendible. Los diez atributos cuentan ahora con definiciones más delimitadas, progresiones cualitativas hipotetizadas, fronteras conceptuales frente a atributos vecinos y decisiones de refinamiento trazables. Esta arquitectura permite avanzar hacia una fase de diseño en la que las tareas y categorías de puntuación se deriven de las progresiones, en lugar de construirse directamente a partir del nombre general de cada atributo.

La fase siguiente deberá concentrarse en **Items Design, Outcome Space, procesos de respuesta, pilotaje y Measurement Model**. Antes de una aplicación ampliada será necesario comprobar que las nuevas tareas generan la evidencia prevista, que las categorías de respuesta son interpretables y funcionales, que la estructura interna es compatible con las hipótesis de medición, que la precisión resulta suficiente para el nivel de reporte pretendido, que los diseños de evaluación permiten estudiar adecuadamente los efectos de evaluador y que las interpretaciones no introducen inequidades ni etiquetamientos injustificados.

Desde una perspectiva institucional, el criterio rector es que los resultados del Hito 0 deben traducirse en **información accionable sobre condiciones iniciales y necesidades susceptibles de intervención**, no en etiquetas fijas sobre los estudiantes. Cuanto mayores sean las consecuencias de una decisión basada en el Hito 0, mayor deberá ser la evidencia requerida para justificarla. Mientras esa evidencia continúe en desarrollo, el uso más defendible es diagnóstico, criterial, formativo y orientado a la mejora de las oportunidades de aprendizaje.

En síntesis, el proyecto ha permitido transformar una primera experiencia de medición en una agenda sistemática de construcción y validación. El avance central consiste en haber desplazado la pregunta desde “cómo asignar una puntuación a diez atributos” hacia una pregunta más exigente: **qué significa cada atributo, cómo puede variar entre estudiantes que ingresan a Ingeniería, qué evidencia permite observar responsablemente esas diferencias y qué interpretaciones pueden sostenerse sin exceder la evidencia disponible**. Esa arquitectura constituye la base para el siguiente ciclo de desarrollo del Hito 0.

Índice general

PARTE I CONTEXTO Y FUNDAMENTOS

1. Antecedentes institucionales 7
2. Fundamentos de la medición diagnóstica 11

PARTE II PRIMERA APROXIMACIÓN INSTITUCIONAL: DIAGNÓSTICO RETROSPECTIVO

3. Primera aproximación institucional 22
4. Metodología del diagnóstico retrospectivo 25
5. Resultados de la prueba individual en línea 31
6. Resultados de la situación de desempeño grupal 37
7. Inferencias que permite y no permite sostener la primera aproximación 44

PARTE III CONSTRUCCIÓN INICIAL DE LOS CONSTRUCT MAPS

8. Estrategia de rediseño basada en Construct Maps 49
9. Arquitectura inicial de los diez Construct Maps 53
10. Paso hacia la evidencia de contenido 55

PARTE IV JUICIO EXPERTO Y EVIDENCIA DE CONTENIDO

11. Propósito y diseño del juicio experto 57
12. Metodología del análisis cuantitativo 59
13. Metodología del análisis cualitativo 61
14. Resultados cuantitativos del juicio experto 65
15. Resultados del análisis cualitativo 67
16. Triangulación cuantitativa–cualitativa 68
17. Diagnóstico por atributo 69
18. Matriz global de priorización 72
19. Interpretación global del juicio experto 73
20. Transición hacia el refinamiento de los Construct Maps 73

PARTE V REFINAMIENTO Y REESPECIFICACIÓN DE LOS CONSTRUCT MAPS

21. Lógica general del refinamiento 76
22. Trazabilidad global de los cambios 78

23. Teoría de innovación y emprendimiento 79
24. Diseño 83
25. Liderazgo 88
26. Economía y gestión 92
27. Trabajo grupal e individual 96
28. Comunicación 99
29. Interacción con usuarios reales 103
30. Seguridad y riesgos 106
31. Ética y profesionalismo 109
32. Trabajo inter y multidisciplinario 112
33. Arquitectura resultante de los diez atributos 115
34. Implicaciones metodológicas del refinamiento 118
35. Transición hacia la siguiente fase 119

PARTE VI DESARROLLO DE LA NUEVA MEDICIÓN Y AGENDA DE VALIDACIÓN

36. De los Construct Maps a la evidencia observable 122
37. Items Design 123
38. Outcome Space 125
39. Consideraciones especiales para Diseño 127
40. Procesos de respuesta 127
41. Pilotaje de la nueva medición 128
42. Measurement Model 129
43. Análisis psicométricos del pilotaje 130
44. Diseño del reporte de resultados del Hito 0 131
45. Agenda de validación 132
46. Hoja de ruta 133
47. Riesgos metodológicos a controlar 135
48. Estado actual del sistema 135
49. Conclusión de la Parte VI 136

PARTE VII CIERRE INSTITUCIONAL: APRENDIZAJES, LIMITACIONES, RECOMENDACIONES Y CONCLUSIONES

50. Síntesis del proceso desarrollado 138
51. Principales aprendizajes del proceso 138

52.	Qué cambió en la arquitectura del Hito 0	140	57.	Criterios para considerar el sistema preparado para una aplicación ampliada	144
53.	Limitaciones del trabajo realizado	141	58.	Qué no debería hacerse	145
54.	Implicaciones para la Facultad	142	59.	Contribución institucional del proyecto	145
55.	Recomendaciones institucionales	143	60.	Conclusiones generales	146
56.	Hoja de ruta consolidada	144	61.	Estado final del proyecto al cierre del reporte	147

PARTE I

CONTEXTO Y FUNDAMENTOS

1. Antecedentes institucionales

2. Fundamentos de la medición diagnóstica

1. Antecedentes institucionales

La Facultad de Ingeniería de la Universidad de Santiago de Chile implementó, a partir de la cohorte 2020, una innovación curricular en los planes de estudio de las ingenierías civiles. Esta innovación introdujo tres cambios estructurales relevantes para comprender el origen del Hito 0. Primero, el perfil de egreso quedó organizado mediante desempeños integrales comunes — compartidos por todas las carreras de la Facultad — y desempeños disciplinares específicos de cada especialidad. Segundo, el perfil de egreso incorporó diez atributos de innovación y emprendimiento, transversales a los planes de estudio, que las asignaturas deben contribuir a desarrollar a lo largo de la trayectoria formativa. Tercero, se creó una línea formativa específica, denominada Trayectoria de Innovación y Emprendimiento, destinada a articular progresivamente el desarrollo de dichos atributos.

Para responder a exigencias externas de aseguramiento de la calidad y a un interés institucional por sostener decisiones curriculares con evidencia, la Facultad diseñó un Modelo de Evaluación del Perfil de Egreso. Este modelo distribuye tres hitos evaluativos a lo largo de la trayectoria formativa —ubicados en el cuarto, octavo y onceavo semestre— cuyo propósito es recoger información que permita monitorear el logro del perfil de egreso, tanto en sus desempeños integrales y disciplinares como en los atributos de innovación y emprendimiento.

En este marco surgió la necesidad de una medición adicional, previa a los tres hitos evaluativos del perfil de egreso: una evaluación diagnóstica centrada específicamente en los atributos de innovación y emprendimiento en el momento de ingreso a la universidad. Esta necesidad respondió a una constatación relevante: buena parte de estos atributos no son enteramente nuevos para el estudiantado que ingresa, pues distintos aspectos de comunicación, trabajo colaborativo, diseño o pensamiento crítico ya forman parte, en mayor o menor medida, de la formación escolar previa. Sin una línea base, cualquier lectura posterior del desarrollo de estos atributos durante la trayectoria universitaria carecería de un punto de comparación fundamentado. Así se estableció el **Hito 0**: el punto inicial del sistema de seguimiento del perfil

de egreso, concebido como una medición diagnóstica destinada a caracterizar el perfil de ingreso del estudiantado y a orientar, en conjunto con la coordinación y el cuerpo docente, las decisiones formativas posteriores.

El Hito 0 se ha aplicado en al menos dos oportunidades documentadas: una versión piloto en 2023 y una segunda aplicación, ampliada y posteriormente sometida a un proceso de análisis y rediseño más exhaustivo, en la cohorte de ingreso 2026. En ambas ocasiones se seleccionó como espacio de aplicación la asignatura de primer semestre "Introducción al Diseño en Ingeniería", por ser la primera asignatura de la Trayectoria de Innovación y Emprendimiento y, por tanto, el punto curricular más temprano y pertinente para observar el estado inicial de estos atributos.

Este reporte se inscribe en una iniciativa institucional de mejora continua, calidad y transparencia, orientada al uso de evidencia válida y confiable para fortalecer las prácticas curriculares y el diseño formativo de la Facultad. En consecuencia, y esto debe quedar explícito desde esta primera sección, **el Hito 0 no debe interpretarse como una prueba de selección de estudiantes, un mecanismo de exclusión, un procedimiento de certificación, una calificación de ingreso, ni como un "nivel 1" del perfil de egreso que deba alcanzarse o superarse**. Su función es distinta: establecer una línea base diagnóstica que permita comprender con qué condiciones iniciales llega el estudiantado respecto de los atributos institucionales, para que esa información pueda utilizarse formativamente, no clasificatoriamente.

1.1. Propósito del Hito 0

El Hito 0 debe entenderse como una medición orientada a caracterizar las condiciones iniciales del estudiantado respecto de atributos considerados relevantes para su trayectoria formativa en Ingeniería, no como un instrumento de decisión sobre las personas evaluadas individualmente. Esta distinción es importante porque orienta tanto el tipo de inferencias que resulta legítimo extraer de sus resultados como el tipo de decisiones institucionales que esos resultados pueden razonablemente sustentar.

De acuerdo con la documentación institucional disponible, disponer de esta línea base diagnóstica puede contribuir, entre otros propósitos, a:

- identificar patrones iniciales en el desarrollo de los atributos de innovación y emprendimiento dentro de una cohorte de ingreso;
- orientar decisiones formativas de la coordinación de asignatura y del cuerpo docente respecto de qué aspectos requieren mayor énfasis en la planificación didáctica;
- aportar evidencia empírica para el diseño y ajuste curricular de la línea formativa de Innovación y Emprendimiento;
- establecer una referencia inicial frente a la cual interpretar, en el futuro, los resultados de los hitos evaluativos posteriores del perfil de egreso; y
- mejorar progresivamente el propio sistema de evaluación diagnóstica, en la medida en que la experiencia acumulada en cada aplicación permite identificar limitaciones de los instrumentos y del enfoque de medición empleado.

Este último punto es central para comprender la naturaleza de este reporte. El proceso documentado aquí no consiste en aplicar un instrumento ya validado y reportar sus resultados, sino en examinar críticamente qué inferencias permitió sostener la aproximación inicial del Hito 0 y en reconstruir, sobre esa base, una arquitectura de medición más explícita y mejor fundamentada. El Hito 0, en este sentido, es tanto un procedimiento de diagnóstico del estudiantado como un objeto en desarrollo y perfeccionamiento continuo.

No se atribuyen al Hito 0, en este reporte, usos distintos de los documentados en los antecedentes institucionales disponibles. En particular, no se presenta como mecanismo de selección, filtro de ingreso, ni como equivalente temprano de una evaluación de egreso.

1.2. Los diez atributos institucionales

El perfil de egreso de las ingenierías civiles de la Facultad incorpora diez atributos de innovación y emprendimiento, que las asignaturas del plan de estudios deben contribuir a desarrollar a lo largo de la trayectoria formativa:

- | | |
|---|---|
| 1. Comunicación. | 2. Trabajo grupal e individual. |
| 3. Interacción con usuarios reales. | 4. Diseño. |
| 5. Teoría de innovación y emprendimiento. | 6. Seguridad y riesgos. |
| 7. Liderazgo. | 8. Economía y gestión. |
| 9. Ética y profesionalismo. | 10. Trabajo inter y multidisciplinario. |

Es necesario precisar el estatus de esta lista antes de continuar. Se trata de diez **atributos institucionalmente definidos** por la Facultad para su sello formativo particular, no de una taxonomía universal de competencias de innovación y emprendimiento ni de diez dimensiones cuya independencia psicométrica se encuentre ya demostrada. La literatura sobre competencias de innovación y emprendimiento ofrece marcos alternativos —y no plenamente coincidentes entre sí— que organizan este dominio de maneras distintas. El marco EntreComp, por ejemplo, agrupa competencias en torno a la identificación de oportunidades, la acción y la movilización de recursos (Bacigalupo et al., 2016), mientras que el marco FINCODA

propone una organización distinta, centrada en el desarrollo y evaluación de competencias de innovación en contextos de educación superior (Marín-García et al., 2016). La existencia de estos marcos alternativos, cada uno con su propia lógica de agrupación, **ilustra que el dominio puede organizarse de más de una manera teóricamente defendible**: la lista de diez atributos constituye una decisión institucional particular, coherente con el sello formativo que la Facultad ha querido otorgar a sus programas, y no una derivación directa de un consenso disciplinar externo.

Cuando estos atributos fueron definidos originalmente por la Facultad, no contaban con

definiciones operacionales propias construidas específicamente para el contexto universitario. En consecuencia, su primera especificación tomó como referente las definiciones y objetivos de aprendizaje disponibles en las Bases Curriculares de 3.º y 4.º medio del Ministerio de Educación de Chile (2019). Este mismo referente curricular ha continuado utilizándose en las etapas posteriores del proyecto como criterio de plausibilidad para el nivel de ingreso a la universidad: al formular las progresiones de desarrollo propuestas para cada atributo, se ha buscado que las manifestaciones iniciales hipotetizadas sean razonables para un estudiante recién egresado de la educación media y no exijan formación universitaria previa.

Declarar que la Facultad valora el desarrollo de estos diez atributos es una decisión institucional legítima y necesaria; no equivale, sin embargo, a haber definido qué varía entre estudiantes respecto de cada uno de ellos, ni a haber establecido qué evidencias observables permitirían distinguir niveles de desarrollo cualitativamente diferentes. Esa distancia —entre declarar un atributo relevante y especificarlo como variable medible— es precisamente el problema que aborda la siguiente subsección.

1.3. El desafío de pasar de atributos a medición

Nombrar un atributo institucional no determina automáticamente su estructura como variable de

medición. Este punto es central para todo el desarrollo posterior del reporte.

Cuando la Facultad declara que valora, por ejemplo, el "Liderazgo" o el "Diseño" como atributos del perfil de egreso, esa declaración no especifica por sí misma: qué característica concreta varía entre distintos estudiantes respecto de ese atributo; qué queda comprendido dentro del constructo y qué queda explícitamente fuera de él —es decir, sus fronteras conceptuales, incluyendo la distinción respecto de atributos vecinos con los que podría confundirse—; cuál es la variable subyacente que se pretende representar, más allá del nombre genérico del atributo; cómo podría progresar razonablemente esa variable entre el ingreso a la universidad y etapas posteriores de la formación; cuáles serían formas cualitativamente diferentes de desempeño observables en torno a esa progresión; ni qué evidencia —qué tipo de respuesta, actuación, producto o interacción— permitiría ubicar razonablemente a una persona en una posición determinada de esa variable.

Resolver estas preguntas exige distinguir con claridad tres niveles que, en el uso cotidiano, suelen confundirse bajo una misma palabra:

atributo institucional → constructo de medición → evidencia observable.

El **atributo institucional** es la denominación amplia definida por la Facultad como parte de su sello formativo —por ejemplo, "Comunicación"—. El **constructo de medición** es la especificación sustantiva de ese atributo como una variable susceptible de representar diferencias interpretables entre personas: una definición delimitada, una hipótesis sobre cómo progresa cualitativamente y una explicitación de qué queda dentro y fuera de su alcance. La **evidencia observable** es aquello que efectivamente puede recogerse —una respuesta, una decisión, una explicación, una actuación, un producto, una interacción— y que permite, mediante inferencia,

ubicar a una persona en una posición de esa variable.

El desafío central que enfrenta el Hito 0, y que motiva el desarrollo metodológico documentado en este reporte, consiste en transformar los diez atributos institucionales —definidos hasta ahora principalmente como declaraciones curriculares amplias— en constructos suficientemente especificados como para permitir, en etapas posteriores, el diseño coherente de tareas, categorías de respuesta y modelos de medición. Como se mostrará en la parte siguiente de este reporte, la primera aproximación institucional del Hito 0 operó principalmente mediante la asociación directa entre atributos, criterios de

evaluación e ítems o preguntas, sin explicitar todavía esta cadena completa entre constructo, progresión y evidencia diferenciada por nivel. Reconocer esa distancia —entre nombrar un atributo y operacionalizarlo como constructo— es el punto de partida conceptual de todo el trabajo de rediseño que se documenta en las partes siguientes.

1.4. Medición e interpretación del perfil de ingreso

Las evaluaciones diagnósticas aplicadas al inicio de la educación superior pueden proporcionar una **línea de base** sobre las condiciones con las que los estudiantes comienzan su trayectoria formativa. En distintos contextos institucionales, este tipo de evaluación se ha utilizado para caracterizar conocimientos disciplinares, habilidades y antecedentes relevantes para el aprendizaje, haciendo visible la heterogeneidad de las cohortes de ingreso y permitiendo identificar áreas de mayor y menor preparación (Bruna-Jofré et al., 2023; Sánchez-Mendiola et al., 2023). Desde esta perspectiva, el valor del diagnóstico no reside únicamente en producir un puntaje inicial, sino en generar información que pueda orientar decisiones formativas posteriores.

La utilidad institucional de esa línea de base depende, por tanto, de su conexión con acciones concretas. Los resultados pueden contribuir a identificar fortalezas y necesidades, diseñar estrategias de acompañamiento o nivelación, revisar prácticas pedagógicas y ajustar apoyos a las características efectivamente observadas en los estudiantes. En Chile existen antecedentes recientes que ilustran esta orientación. Cruz et al. (2024), en el contexto de la formación inicial docente, muestran el desarrollo de pruebas diagnósticas de ingreso diseñadas para producir información útil para el mejoramiento de la formación y el diseño de apoyos; por otra parte, la Ficha de Caracterización Única (FCU) de la Subsecretaría de Educación Superior busca caracterizar a estudiantes que ingresan al primer año de la educación superior técnico-profesional para orientar programas de acompañamiento vinculados con permanencia, progresión académica y titulación oportuna (Subsecretaría de Educación Superior, 2025). Estos antecedentes refuerzan una idea central para el Hito 0: **medir el perfil de ingreso tiene sentido en la medida en que permite reducir la distancia entre las**

condiciones efectivamente observadas en los estudiantes y los supuestos con los que la institución organiza sus oportunidades de aprendizaje.

Sin embargo, la utilidad de una medición de ingreso no depende solo de la calidad técnica del instrumento, sino también de las **interpretaciones y decisiones que se construyen a partir de sus resultados**. Los Standards for Educational and Psychological Testing establecen que la validez se refiere al respaldo que la evidencia y la teoría proporcionan a interpretaciones de puntajes para usos específicos; por ello, una misma puntuación puede requerir argumentos de validación distintos según se utilice para retroalimentar, asignar apoyos, clasificar o restringir oportunidades (AERA, APA, & NCME, 2014). Las consecuencias de una decisión no constituyen por sí solas evidencia de validez o invalidez, pero adquieren relevancia cuando permiten identificar amenazas al significado de los puntajes o efectos asociados al uso que se pretende justificar.

Esta precaución es especialmente importante cuando una evaluación inicial deja de cumplir una función exclusivamente formativa y comienza a intervenir en decisiones de placement, derivación o clasificación. La evidencia experimental sobre sistemas de multiple measures assessment muestra que las reglas de asignación pueden modificar el acceso a cursos de nivel universitario y los resultados académicos posteriores, de modo que la precisión y pertinencia de las clasificaciones tienen consecuencias reales sobre las oportunidades de los estudiantes (Kopko & Daniels Sarica, 2025). De manera convergente, la literatura sobre analítica del aprendizaje advierte que inferir capacidades o riesgo académico a partir de datos estudiantiles puede introducir problemas relacionados con la confiabilidad de los datos, la privacidad, la equidad y el **etiquetamiento de los estudiantes** (Marcotte et al., 2025).

Para este proyecto, estas consideraciones tienen una consecuencia directa: los resultados del perfil de ingreso deben interpretarse prioritariamente como evidencia sobre **condiciones iniciales y necesidades susceptibles de intervención**, y no como atributos fijos, diagnósticos deterministas o límites permanentes del potencial de una persona. Cuanto mayores sean las consecuencias

asociadas a una interpretación —por ejemplo, asignación obligatoria a nivelación, clasificación de riesgo, exclusión de oportunidades o decisiones curriculares de alto impacto—, mayor deberá ser también la evidencia que respalde la validez, precisión, equidad y pertinencia de esa decisión. Este principio orienta el alcance inferencial adoptado en el Hito 0 y justifica que, mientras la evidencia disponible sea todavía limitada, los resultados se utilicen principalmente con fines diagnósticos, formativos y de mejora del sistema de enseñanza.

Con el propósito institucional, el alcance inferencial y las cautelas de uso ya explicitados, la Figura 1 resume el **recorrido completo del proyecto de reconstrucción del Hito 0**. Su ubicación en este punto permite leerla como una síntesis del problema y de la estrategia de trabajo, en lugar de enfrentar al lector, desde la primera página, con etapas metodológicas que todavía no han sido introducidas.




Figura 1. Recorrido general del proyecto de reconstrucción del Hito 0. Se distinguen las etapas ya realizadas —primera aproximación institucional, diagnóstico retrospectivo, construcción de progresiones iniciales, juicio experto, triangulación y refinamiento— de las correspondientes al siguiente ciclo de desarrollo —Items Design, Outcome Space, procesos de respuesta y pilotaje, Measurement Model y aplicación ampliada—. La retroalimentación inferior representa el carácter iterativo del proceso: la evidencia producida en una etapa posterior puede exigir revisar decisiones adoptadas en etapas previas, incluidas las propias hipótesis sobre los constructos.

2. Fundamentos de la medición diagnóstica

Esta sección presenta, de manera breve pero suficiente, el marco conceptual sobre el cual se

apoyan las decisiones metodológicas adoptadas en el resto del reporte. No pretende constituir una revisión bibliográfica exhaustiva, sino introducir los conceptos indispensables para comprender por qué el proyecto adoptó un enfoque de construct modelling y el BEAR Assessment System como

arquitectura de rediseño. Estos conceptos se establecen una sola vez, en esta parte, y se utilizan sin volver a definirse a lo largo del resto del documento.

2.1. Qué significa medir en este proyecto

Desde la perspectiva adoptada en este proyecto, principalmente a partir de Wilson (2023) y Wilson y Gochyyev (2013), medir no consiste simplemente en asignar puntajes o calificaciones a respuestas o actuaciones. Medir implica construir una **variable**: una representación ordenada de diferencias entre personas respecto de una característica que interesa observar, junto con un procedimiento que permita, a partir de evidencia observable, ubicar razonablemente a cada persona en una posición de esa variable.

Esta perspectiva constructiva de la medición exige, como mínimo, cuatro operaciones articuladas: **identificar una característica o variable** que se pretende representar; **representar diferencias entre personas** respecto de esa variable, asumiendo que no todas se encuentran en la misma posición ni exhiben el mismo nivel de desarrollo; **establecer qué observaciones pueden proporcionar evidencia** pertinente sobre esa variable, distinguiendo lo que efectivamente indica algo sobre el constructo de lo que constituye ruido, artefacto de la tarea o factor irrelevante; y **construir una relación interpretable entre respuestas y posiciones sobre la variable**, de modo que sea posible explicar, no solo describir, por qué una determinada actuación se interpreta como evidencia de un nivel de desarrollo determinado y no de otro.

Un aspecto central de esta perspectiva es que buena parte de los atributos que interesa evaluar en el Hito 0 —comunicación, liderazgo, diseño, juicio ético, entre otros— constituyen **constructos latentes**: no se observan directamente, sino que se infieren a partir de evidencias observables (Wilson & Gochyyev, 2013). Lo que efectivamente puede recogerse en una situación de evaluación son respuestas, decisiones, explicaciones, actuaciones, productos o interacciones; el constructo mismo —la capacidad o disposición subyacente— se infiere a partir de esas manifestaciones, y no se confunde con ellas. Esta distinción entre constructo y evidencia es la misma que se introdujo en la sección 1.3 al distinguir entre atributo

institucional, constructo de medición y evidencia observable, y constituye uno de los principios que atraviesan todo el desarrollo metodológico de este reporte.

2.2. Validez y respaldo de las inferencias

De acuerdo con los Standards for Educational and Psychological Testing (American Educational Research Association [AERA], American Psychological Association [APA], & National Council on Measurement in Education [NCME], 2014), la validez se refiere al grado en que la evidencia y la teoría respaldan las **interpretaciones de los puntajes para usos propuestos**. La validación, por tanto, no consiste en declarar que un instrumento es válido en términos absolutos, sino en reunir y evaluar evidencia pertinente para sostener —o cuestionar— las inferencias concretas que se pretende extraer de sus resultados y los usos asociados a ellas. Si un mismo puntaje se interpreta de maneras distintas o se utiliza para fines diferentes, cada interpretación y uso requiere su propia justificación.

Los Standards organizan las principales fuentes de evidencia de validación en cinco ámbitos complementarios:

- **Evidencia basada en el contenido de la prueba.** Examina la relación entre el contenido efectivamente incluido —temas, redacción, formatos de ítem o tarea, condiciones de administración y reglas de puntuación cuando son pertinentes— y el constructo o dominio que se pretende representar. La pregunta central es si el conjunto de tareas cubre de manera suficientemente pertinente y representativa el dominio previsto, con una complejidad adecuada y sin introducir demandas ajenas al constructo. Los juicios de especialistas y los análisis de correspondencia entre especificaciones, tareas y dominio son procedimientos habituales para reunir esta evidencia.
- **Evidencia basada en los procesos de respuesta.** Examina si los procesos que efectivamente ponen en juego las personas evaluadas al comprender y resolver las tareas son coherentes con los procesos presupuestos por la interpretación del constructo. En evaluaciones de desempeño, esta fuente incluye también los procesos de quienes

observan o califican: si deben aplicar determinados criterios, es relevante verificar que sus juicios se basen en esos criterios y no en características irrelevantes para la interpretación prevista.

- **Evidencia basada en la estructura interna.** Examina si las relaciones observadas entre ítems, tareas, criterios o componentes del instrumento son coherentes con la estructura que presupone la interpretación de los puntajes. Una interpretación unidimensional requiere evidencia compatible con una estructura suficientemente homogénea; si se proponen varios componentes o subpuntuaciones, las relaciones entre ellos deben ser compatibles con su carácter distintivo y con el modelo conceptual que los sustenta.
- **Evidencia basada en las relaciones con otras variables.** Examina si los puntajes se relacionan con variables externas de la forma prevista por la teoría y por el uso propuesto. Esto puede incluir relaciones con otras medidas del mismo constructo o de constructos relacionados —evidencia convergente—, relaciones más débiles con constructos conceptualmente distintos —evidencia discriminante— y, cuando corresponde, asociaciones con criterios externos relevantes para una interpretación predictiva o concurrente.
- **Evidencia vinculada con las consecuencias de las pruebas.** Las consecuencias previstas o imprevistas del uso de los puntajes deben examinarse cuando forman parte de las afirmaciones asociadas al uso propuesto o cuando pueden revelar problemas en el significado de los puntajes, por ejemplo, infrarrepresentación del constructo o influencia de factores irrelevantes. Los Standards advierten, sin embargo, que una consecuencia favorable o desfavorable no constituye por sí sola una demostración de validez o invalidez: es necesario investigar la fuente de esa consecuencia y su relación con la interpretación que se pretende sostener.

Estas fuentes no operan como una lista de comprobación independiente ni tienen que aportar el mismo peso en todos los contextos. La validación exige **integrar** la evidencia relevante en función de las afirmaciones concretas que

sustentan la interpretación y el uso de los puntajes. En el Hito 0, esta lógica implica acumular evidencia progresivamente y revisar las interpretaciones cuando aparezcan resultados incompatibles con las hipótesis de medición.

Los Standards tratan además la **confiabilidad/precisión** y la **imparcialidad (fairness)** como fundamentos técnicos centrales para el uso de los puntajes. En este reporte se examinan de manera explícita porque condicionan la calidad y el alcance de las inferencias, pero se distinguen de las cinco fuentes de evidencia de validación organizadas en el capítulo de validez. Del mismo modo, el funcionamiento de las categorías de puntuación se utiliza aquí como diagnóstico específico del modelo y de la escala, principalmente vinculado con la estructura interna y la calidad del sistema de puntuación, y no como una categoría adicional de validez por sí misma.

2.3. Teoría Clásica de los Tests: confiabilidad y error de medición

La **Teoría Clásica de los Tests (TCT)** constituye un marco histórico y todavía vigente para describir la consistencia de los puntajes y cuantificar el error de medición. Wilson (2023) la caracteriza como un enfoque centrado en el puntaje (score-focused approach): su atención principal se dirige a las propiedades estadísticas del puntaje agregado y a la consistencia con que ese puntaje puede reproducirse. Esta tradición se remonta a Spearman (1904) y fue sistematizada posteriormente por desarrollos como los de Kuder y Richardson (1937), Cronbach (1951) y Lord y Novick (1968).

La formulación clásica básica expresa el puntaje observado como la suma de un puntaje verdadero y un componente de error:

$$X = T + E$$

donde X es el **puntaje observado**, T el **puntaje verdadero** y E el **error de medición**. El puntaje verdadero es un concepto teórico: corresponde al valor esperado del puntaje de una persona a través de administraciones equivalentes bajo condiciones comparables, no a una cantidad directamente observable. El error representa la variación no sistemática que hace que una

observación particular se aparte de ese valor esperado (Lord & Novick, 1968; Wilson, 2023).

Bajo los supuestos clásicos, la varianza observada puede expresarse como:

$$\sigma_X^2 = \sigma_T^2 + \sigma_E^2$$

y la **confiabilidad** como la proporción de la varianza observada atribuible a diferencias verdaderas:

$$\rho_{XX'} = (\sigma_T^2) / (\sigma_X^2) = 1 - (\sigma_E^2) / (\sigma_X^2).$$

Esta formulación permite interpretar la confiabilidad como un resumen de la contribución relativa del error al puntaje. No implica, sin embargo, que la confiabilidad sea una propiedad fija del instrumento con independencia de su aplicación. Su magnitud depende del conjunto de ítems, de la población evaluada, de las condiciones de administración y de la fuente de error que el procedimiento de estimación logre representar.

Dentro de esta tradición se desarrollaron distintos índices de consistencia. Kuder y Richardson (1937) propusieron procedimientos para pruebas con puntuación dicotómica —entre ellos KR-20— y Cronbach (1951) generalizó esta lógica mediante el coeficiente alfa. La fórmula de Spearman-Brown (Brown, 1910; Spearman, 1910) mostró además que la consistencia de un puntaje puede aumentar al incorporar más ítems semejantes. Este resultado es útil para comprender una de las limitaciones señaladas por Wilson (2023): un coeficiente de confiabilidad elevado puede obtenerse aumentando la longitud de una prueba sin que ello garantice, por sí solo, una mejor representación sustantiva del constructo. Por esta razón, **consistencia, unidimensionalidad y validez no son equivalentes**.

La TCT permite también expresar la incertidumbre en las unidades del puntaje mediante el **error estándar de medición (EEM o SEM)**. En su forma clásica:

$$SEM = S_X \sqrt{1 - r_{XX'}},$$

donde S_X es la desviación estándar de los puntajes observados y $r_{XX'}$ un coeficiente de confiabilidad. El SEM clásico proporciona un resumen global de la precisión. Los modelos de respuesta al ítem, en cambio, permiten estimar la precisión de manera **condicional** a la posición de la persona sobre el continuo latente: la información disponible y el error estándar pueden variar sustantivamente entre regiones de la escala.

Esta diferencia es particularmente relevante para el diagnóstico desarrollado en este reporte. Los coeficientes KR-20, alfa y omega permiten describir la consistencia del puntaje agregado desde una perspectiva clásica; los modelos Rasch y PCM permiten, adicionalmente, estudiar la relación entre personas, ítems o umbrales sobre una escala común y examinar dónde el instrumento entrega mayor o menor información. Ambos enfoques son, por tanto, **complementarios**, siempre que se mantenga claro qué pregunta responde cada uno. Un coeficiente de consistencia global no demuestra que exista una única dimensión sustantiva ni autoriza a producir subpuntuaciones diferenciadas con uno o dos indicadores por atributo; de manera análoga, una estimación precisa bajo un modelo de respuesta al ítem no compensa una representación insuficiente del contenido.

En el Hito 0, esta distinción orienta la lectura de los resultados de la Parte II: la TCT se utiliza para describir consistencia y error de los puntajes, mientras que los modelos Rasch/PCM se utilizan como herramientas diagnósticas para examinar focalización, funcionamiento de ítems o categorías y precisión condicional. Ninguna de estas fuentes de evidencia se interpreta aisladamente como demostración de validez, en concordancia con el marco de inferencias y usos presentado en la sección 2.2.

2.4. Construct modelling

Para abordar el desafío descrito en la sección 1.3 —pasar de atributos institucionales amplios a variables susceptibles de medición—, el proyecto adopta el enfoque de **construct modelling** propuesto por Wilson (2023). Este enfoque organiza la construcción de medidas comenzando por una especificación sustantiva y explícita de aquello que se pretende medir, antes de avanzar hacia decisiones de formato, de ítem o de puntuación. La idea central puede resumirse en

un principio simple pero con consecuencias metodológicas importantes:

el problema de la medición comienza antes de escribir un ítem.

Es decir, antes de decidir si una tarea será de selección múltiple, de respuesta abierta, de desempeño individual o grupal, es necesario haber resuelto con suficiente claridad qué variable se pretende representar, cómo se hipotetiza que progresa cualitativamente y qué evidencia sería pertinente para ubicar a una persona sobre ella.

nombre del atributo → variable → progresión → evidencia → tareas → puntuación → modelo → interpretación.

Cada eslabón de esta cadena depende del anterior y lo hace más específico. El nombre del atributo —por ejemplo, "Diseño"— se convierte en una variable delimitada solo cuando se explicita qué característica varía entre personas; esa variable se convierte en una progresión solo cuando se hipotetizan formas cualitativamente distintas de manifestarse; esa progresión orienta el diseño de tareas solo cuando se ha determinado qué situaciones podrían generar evidencia pertinente sobre ella; y así sucesivamente, hasta llegar a un modelo de medición capaz de sostener una interpretación fundamentada de los resultados. Este enfoque constituye el fundamento directo de la reorientación metodológica documentada en las partes siguientes de este reporte: el desplazamiento desde una asociación directa entre atributos e ítems hacia una arquitectura que articula explícitamente constructo, progresión, evidencia, tarea, puntuación, modelo e interpretación.

2.5. Construct Maps y waypoints

El instrumento conceptual central del construct modelling para especificar un constructo es el **Construct Map** [mapa de constructo]. Un Construct Map: representa una **hipótesis sustantiva** sobre una variable, no una descripción ya demostrada empíricamente; describe **formas cualitativamente diferentes de manifestación** de esa variable, es decir, actuaciones o respuestas que no solo difieren en cantidad, sino en su naturaleza; **ordena provisionalmente** esas

Formular primero el ítem y solo después preguntarse qué mide, en cambio, invierte esta lógica y tiende a producir instrumentos donde la correspondencia entre lo que se declara medir y lo que efectivamente se observa resulta débil o parcial —precisamente la dificultad que el diagnóstico de la Parte II de este reporte documentará para la primera aproximación institucional del Hito 0—.

El construct modelling permite reorganizar el trabajo de rediseño del Hito 0 según la siguiente secuencia:

formas, desde manifestaciones menos desarrolladas hacia manifestaciones más desarrolladas; **establece qué significa progresar** sobre el constructo, es decir, qué cambia cualitativamente entre una posición y la siguiente; y **orienta el diseño posterior** de tareas capaces de generar evidencia pertinente y de categorías de puntuación coherentes con esa progresión.

Dentro de un Construct Map, cada punto cualitativamente distinguible de la progresión se denomina **waypoint**. Es importante precisar, desde esta primera parte del reporte, qué **no** son los waypoints, pues su malinterpretación es una fuente frecuente de confusión al trabajar con este tipo de instrumentos: no son calificaciones ni notas; no son cursos ni unidades curriculares; no son etapas de un proceso institucional o administrativo; no se asume que estén necesariamente equidistantes entre sí, es decir, la distancia conceptual entre un waypoint y el siguiente no tiene por qué ser igual a la distancia entre otro par de waypoints; y no representan, por el solo hecho de estar formulados, categorías psicométricas ya verificadas empíricamente.

Los waypoints son, en cambio, **puntos cualitativamente distinguibles de una progresión hipotetizada**. Su formulación constituye una hipótesis de trabajo, sujeta a revisión mediante evidencia de contenido, procesos de respuesta y contraste psicométrico posterior. Esta distinción —entre un waypoint

como hipótesis sustantiva revisable y un waypoint como categoría ya demostrada— es uno de los principios metodológicos que se sostiene de manera consistente a lo largo de todo este reporte, particularmente al presentar los diez Construct Maps desarrollados para el Hito 0 en partes posteriores del documento.

Un Construct Map describe además, cuando el constructo lo requiere, más de una **progresión relacionada** dentro de un mismo atributo: cada una de esas progresiones se denomina **strand**, y corresponde a una dimensión o subconstructo distinguible dentro de un constructo

multidimensional más amplio, representado mediante su propia secuencia de waypoints (Wilson, 2023). Este caso —introducido aquí solo terminológicamente— se desarrolla en detalle en la Parte V de este reporte, a propósito de los cuatro atributos que efectivamente requirieron más de una progresión.

La Figura 2 fija, mediante un ejemplo abstracto no vinculado a ningún atributo real del Hito 0, la forma visual estándar que adoptará un Construct Map cada vez que se presente un mapa concreto más adelante en este reporte.

Variable progresiva [genérica]




Figura 2. Estructura genérica de un Construct Map: una progresión hipotetizada de cuatro waypoints (W1-W4) cualitativamente distinguibles, entre una manifestación mínima pero sustantiva del constructo (W1) y su forma más desarrollada dentro del perfil de ingreso (W4). La disposición gráfica no está a escala y no representa distancias conocidas entre waypoints; los waypoints son hipótesis sustantivas revisables, no categorías de puntuación ya definidas.

2.6. BEAR Assessment System

Para organizar de manera coherente el proceso completo de rediseño —desde la especificación del constructo hasta la obtención de evidencia empírica sobre su funcionamiento— el proyecto adopta el **BEAR Assessment System** (Wilson, 2023) como arquitectura metodológica general. Este sistema articula cuatro componentes:

1. Construct Map. Define qué se pretende medir y formula una hipótesis sobre cómo progresa cualitativamente esa variable, según lo descrito en la sección anterior.

2. Items Design [diseño de ítems]. Define las situaciones, tareas y oportunidades de observación mediante las cuales se intentará obtener evidencia pertinente sobre el constructo especificado en el Construct Map. Un mismo Construct Map puede admitir formatos de tarea distintos, y no todos los atributos requieren necesariamente el mismo tipo de instrumento.

3. Outcome Space [espacio de resultados]. Define cómo las respuestas o actuaciones efectivamente observadas se organizan y puntúan de manera coherente con la variable postulada en el Construct Map, estableciendo reglas de decisión, categorías de respuesta y, cuando corresponde, ejemplos de referencia que permitan aplicar esas categorías de manera consistente.

4. Measurement Model [modelo de medición]. Permite contrastar empíricamente la relación entre las personas evaluadas, las tareas aplicadas, las categorías de respuesta obtenidas y la estructura de medición postulada por el Construct Map, aportando evidencia sobre si esa estructura resulta sostenible o requiere ser revisada.

Un aspecto que debe quedar explícito desde esta primera parte del reporte es que estos cuatro componentes mantienen entre sí una relación **iterativa**, no estrictamente lineal ni secuencial en un solo sentido. El desarrollo de un componente puede generar evidencia que obligue a revisar componentes anteriores: por ejemplo, evidencia obtenida mediante el Measurement Model puede mostrar que la estructura hipotetizada en el Construct Map no resulta sostenible, o que las categorías definidas en el Outcome Space no logran capturar adecuadamente las diferencias cualitativas que el Construct Map pretende representar. Esta lógica iterativa es coherente con la perspectiva de acumulación progresiva de evidencias de validez descrita en la sección 2.2, y explica por qué el trabajo documentado en este reporte no se presenta como un proceso cerrado, sino como un desarrollo que continuará revisándose a medida que se incorpore nueva evidencia.

Como se detallará en las partes siguientes de este reporte, el trabajo realizado hasta la fecha se ha concentrado principalmente en el primer componente del sistema —la especificación y revisión de los Construct Maps de los diez atributos institucionales—, aunque el diagnóstico de la primera aproximación del Hito 0 y los análisis psicométricos ya realizados sobre esa primera aproximación aportan evidencia relevante para orientar las decisiones de rediseño en los componentes posteriores.

La Figura 3 sintetiza los cuatro componentes del sistema y su relación iterativa, y señala en cuál de ellos se concentra el trabajo documentado hasta la fecha en este reporte.




Figura 3. Los cuatro componentes del BEAR Assessment System (Wilson, 2023) y su relación iterativa: Construct Map, Items Design, Outcome Space y Measurement Model. El sistema iterativo permite que la evidencia producida en un componente posterior obligue a revisar decisiones adoptadas en un componente anterior. El desarrollo documentado en este reporte se concentra, hasta la fecha, en el componente Construct Map (Partes III a V); los tres componentes restantes constituyen el siguiente ciclo de desarrollo (Parte VI).

2.7. Estrategia general del proyecto

La Figura 1 sintetiza el recorrido general del proyecto y la Figura 3 representa la lógica iterativa del BEAR Assessment System. Con esos dos referentes ya establecidos, esta sección se concentra en precisar **qué trabajo cuenta con evidencia disponible y qué componentes permanecen proyectados**.

Hasta el momento de este reporte, el diagnóstico psicométrico de la primera aproximación institucional, la especificación sustantiva de los diez atributos, el juicio experto y el refinamiento derivado de su triangulación cuentan con desarrollo documentado. En cambio, el diseño de nuevas tareas, la construcción de espacios de resultados, el estudio sistemático de procesos de respuesta, el pilotaje y el modelo de medición definitivo corresponden al ciclo siguiente y deberán contrastarse empíricamente.

El documento se organiza, por ello, en **tres planos** que conviene distinguir: un **primer plano**, correspondiente a la primera aproximación institucional del Hito 0 y a su diagnóstico psicométrico retrospectivo (Parte II); un **segundo plano**, correspondiente a la reconstrucción sustantiva de los diez constructos mediante progresiones de desarrollo, juicio experto y refinamiento (Partes III, IV y V); y un **tercer plano**, correspondiente a la arquitectura de medición todavía proyectada —Items Design, Outcome Space, procesos de respuesta, pilotaje y Measurement Model— (Parte VI). Ningún resultado del tercer plano debe leerse como si ya estuviera ejecutado: expresiones como "se propone", "deberá examinarse", "constituye la siguiente etapa" o "hipótesis pendiente de contraste empírico" indican deliberadamente su carácter prospectivo.

La Figura 4 sintetiza esta cadena conceptual completa, desde el atributo institucional hasta la interpretación de resultados.




Figura 4. Cadena conceptual que organiza el paso de un nombre institucional de atributo a una interpretación defendible de resultados, siguiendo el enfoque de construct modelling (Wilson, 2023).

La parte siguiente de este documento retoma el primer eslabón de esta secuencia: el diagnóstico detallado de la primera aproximación institucional del Hito 0, examinando qué inferencias permitió sostener y cuáles quedaron fuera de su alcance.

Referencias de la PARTE I

- American Educational Research Association, American Psychological Association, & National Council on Measurement in Education. (2014). Standards for educational and psychological testing. American Educational Research Association.
- Bacigalupo, M., Kampylis, P., Punie, Y., & Van den Brande, G. (2016). EntreComp: The entrepreneurship competence framework. Publications Office of the European Union. <https://doi.org/10.2791/593884>
- Brown, W. (1910). Some experimental results in the correlation of mental abilities. *British Journal of Psychology*, 3, 296-322.
- Bruna-Jofré, C. E., Espinoza-Parcet, C. F., Fernández-Branada, C. A., & Labraña-Cabrera, C. G. (2023). Diseño, implementación y resultados del rediseño de pruebas diagnósticas disciplinares institucionales en la Universidad de Concepción, Chile. *Formación Universitaria*, 16(5), 27-40. <https://doi.org/10.4067/S0718-50062023000500027>
- Cronbach, L. J. (1951). Coefficient alpha and the internal structure of tests. *Psychometrika*, 16(3), 297-334. <https://doi.org/10.1007/BF02310555>
- Cruz, S., Jimenez, D., Sun, Y., Kaiser, G., & Varas, L. (2024). Design and validation of initial diagnostic tests for preservice teachers as a tool for teacher education effectiveness. *Journal of Curriculum Studies*, 56(4), 392-412. <https://doi.org/10.1080/00220272.2024.2322490>
- Kopko, E. M., & Daniels Sarica, H. (2025). The long-term effectiveness of multiple measures assessment: Evidence from a randomized controlled trial. *Journal of Research on Educational Effectiveness*, 19(2), 327-350. <https://doi.org/10.1080/19345747.2025.2505172>
- Kuder, G. F., & Richardson, M. W. (1937). The theory of the estimation of test reliability. *Psychometrika*, 2(3), 151-160. <https://doi.org/10.1007/BF02288391>
- Lord, F. M., & Novick, M. R. (1968). Statistical theories of mental test scores. Addison-Wesley.
- Marcotte, K., Yang, P., Millis, M. A., Vercler, C. J., Sebok-Syer, S. S., Krumm, A. E., & George, B. C. (2025). Ethical considerations of using learning analytics in medical education: A critical review. *Advances in Health Sciences Education*, 30(1), 87-101. <https://doi.org/10.1007/s10459-024-10402-7>
- Marin-Garcia, J. A., Andreu-Andrés, M. A., Atares-Huerta, L., Aznar-Mas, L. E., García-Carbonell, A., González-Ladrón-de-Guevara, F., Montero Fleta, B., Pérez-Peñalver, M. J., & Watts, F. (2016). Proposal of a framework for innovation competencies development and assessment (FINCODA). WPOM—Working Papers

- on Operations Management, 7(2), 119-126. <https://doi.org/10.4995/wpom.v7i2.6472>
- Ministerio de Educación de Chile. (2019). Bases Curriculares 3.° y 4.° medio. Unidad de Currículum y Evaluación.
- Sánchez-Mendiola, M., Manzano-Patiño, A. P., García-Minjares, M., Buzo Casanova, E., Herrera Penilla, C. J., Goytia-Rodríguez, K., & Martínez-González, A. (2023). Large-scale diagnostic assessment in first-year university students: Pre- and transpandemic comparison. *Educational Assessment, Evaluation and Accountability*, 35, 503-523. <https://doi.org/10.1007/s11092-023-09410-9>
- Spearman, C. (1904). The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1), 72-101. <https://doi.org/10.2307/1412159>
- Spearman, C. (1910). Correlation calculated from faulty data. *British Journal of Psychology*, 3, 271-295.
- Subsecretaría de Educación Superior. (2025). Informe Ficha de Caracterización Única (FCU) 2025. Ministerio de Educación de Chile. <https://educacionsuperior.mineduc.cl/fcu/>
- Wilson, M. (2023). *Constructing measures: An item response modeling approach* (2nd ed.). Routledge. <https://doi.org/10.4324/9781003286929>
- Wilson, M., & Gochyyev, P. (2013). Psychometrics. In T. Teo (Ed.), *Handbook of quantitative methods for educational research* (pp. 3-30). Sense Publishers. https://doi.org/10.1007/978-94-6209-404-8_1

PARTE II

PRIMERA APROXIMACIÓN INSTITUCIONAL: DIAGNÓSTICO RETROSPECTIVO

Esta parte examina la aplicación del Hito 0 a la cohorte de ingreso 2026, la instancia efectivamente sometida al diagnóstico psicométrico retrospectivo documentado a continuación. El proyecto conserva evidencia de una aplicación piloto anterior (2023), con una arquitectura de instrumentos comparable pero no idéntica; esa aplicación no forma parte del diagnóstico retrospectivo aquí documentado y se menciona solo cuando resulta necesaria para explicar el origen de un procedimiento todavía vigente en 2026.

3. Primera aproximación institucional

4. Metodología del diagnóstico retrospectivo

5. Resultados de la prueba individual en línea

6. Resultados de la situación de desempeño grupal

7. Inferencias que permite y no permite sostener la primera aproximación

3. Primera aproximación institucional

3.1. Diseño general

La primera aproximación institucional del Hito 0 sometida a diagnóstico retrospectivo se aplicó a la cohorte de ingreso 2026 en la asignatura de primer semestre "Introducción al Diseño en Ingeniería", el mismo espacio curricular utilizado en la aplicación piloto de 2023. Su finalidad, consistente con lo descrito en la Parte I, fue diagnóstica: obtener una línea base sobre los diez atributos institucionales de innovación y emprendimiento en el momento de ingreso, no calificar ni seleccionar estudiantes.

Se aplicaron dos instrumentos, deliberadamente distintos en formato y unidad de análisis: una **prueba individual en línea**, de aplicación asincrónica a través del campus virtual, con preguntas de selección única sobre casos; y una **situación de desempeño grupal presencial**, aplicada durante una sesión de laboratorio, en la que los grupos de estudiantes resolvían un caso y eran evaluados mediante una escala de apreciación por él o la docente de su sección.

Esta bifurcación en dos instancias no fue arbitraria: la documentación institucional disponible indica que respondió a la constatación de que ciertos atributos —trabajo en equipo, liderazgo, comunicación oral— resultan más observables en una situación de desempeño grupal que mediante preguntas cerradas individuales, mientras que otros atributos —identificación de conceptos, reconocimiento de elementos en un caso— podían explorarse de manera más eficiente mediante un instrumento de aplicación masiva. En consecuencia, los diez atributos institucionales no fueron distribuidos de manera uniforme entre ambos instrumentos, sino asignados según esta lógica de pertinencia.

El sistema de puntuación también difiere entre instrumentos. La prueba individual se puntuó de manera dicotómica: 1 punto por respuesta correcta y 0 por respuesta incorrecta o no respondida, ítem por ítem. La situación de desempeño grupal se puntuó mediante una escala ordinal de cuatro niveles —Óptimo, Satisfactorio, Base y Por mejorar—, recodificada para el análisis como 3, 2, 1 y 0 puntos respectivamente.

La unidad de análisis también es distinta y no debe confundirse entre instrumentos: en la prueba individual, la unidad es el estudiante; en la situación de desempeño grupal, la unidad es el grupo, evaluado como conjunto por una persona docente. Esta distinción tiene consecuencias metodológicas importantes que se retoman en las secciones 4 y 6: los resultados del instrumento grupal no permiten, sin evidencia adicional, generar afirmaciones sobre estudiantes individuales dentro de cada grupo.

Es necesario distinguir, desde esta descripción inicial, entre **lo que institucionalmente se pretendía medir** —los diez atributos declarados por la Facultad, tal como se presentaron en la Parte I— y **la demanda efectiva de las tareas** efectivamente utilizadas en cada instrumento. Esta distinción se desarrolla con detalle en la sección 4.2 y constituye uno de los hallazgos centrales del diagnóstico. Por ahora basta señalar que ambos instrumentos fueron contruidos mediante tablas de especificaciones que vincularon atributos, objetivos curriculares tomados de las Bases Curriculares de 3.º y 4.º medio, criterios de evaluación y preguntas o criterios observables, pero que, como se mostrará más adelante, no todas las preguntas o criterios terminaron demandando exactamente lo que su etiqueta declarada sugiere.

La Figura 5 compara de un vistazo el diseño de ambos instrumentos y su cobertura nominal de los diez atributos institucionales.

Prueba individual en línea		Situación de desempeño grupal	
Modalidad:	asincrónica, campus virtual	Modalidad:	presencial, sesión de laboratorio
Unidad de análisis:	estudiante	Unidad de análisis:	grupo
Formato:	10 ítems de selección única	Formato:	8 criterios de apreciación
Puntuación:	0/1	Puntuación:	0-3
Cobertura nominal:	8 atributos	Cobertura nominal:	5 atributos

Cobertura nominal por atributo

Atributo	Prueba individual	Situación grupal
Comunicación (COM)	●	●
Trabajo grupal e individual (TG)	●	●
Interacción con usuarios reales (UR)	●	●
Diseño (DI)	●	○
Teoría de innovación y emprendimiento (IE)	●	○
Seguridad y riesgos (SR)	●	○
Liderazgo (LG)	○	●
Economía y gestión (EG)	●	○
Ética y profesionalismo (EP)	●	○
Trabajo inter y multidisciplinario (IM)	○	●

Figura 5. Diseño comparado de los dos instrumentos de la primera aproximación institucional del Hito 0 y su cobertura nominal de los diez atributos, cohorte de ingreso 2026.

3.2. Prueba individual en línea

Registros y muestra analítica. Los registros de aplicación de la evaluación virtual contenían **1132 registros** de apertura. De estos, **1022** llegaron a un estado de intento finalizado. La muestra analítica primaria, definida como los registros con al menos ocho respuestas completadas, quedó constituida por **991 estudiantes**. Los registros de control correspondientes muestran una correlación perfecta (1,000) entre el puntaje total reconstruido para el diagnóstico y la calificación original registrada en la plataforma institucional, lo que respalda la fidelidad del proceso de recodificación frente al registro institucional. No se identificaron estudiantes con más de un intento elegible dentro de la muestra primaria.

Formato y puntuación. El instrumento consta de **10 ítems de selección única**, recodificados 0/1 (incorrecto/correcto) para el análisis. La clave de corrección utilizada corresponde directamente a las respuestas correctas registradas en la exportación detallada de la plataforma institucional.

Correspondencia atributo-ítem. Los diez ítems representan nominalmente ocho atributos: seis atributos cuentan con un solo ítem y dos —Diseño y Teoría de innovación y emprendimiento— con dos ítems cada uno. La correspondencia es: I01 Comunicación; I02 Interacción con usuarios reales; I03 Economía y gestión; I04 Trabajo grupal e individual; I05 Diseño; I06 Ética y profesionalismo; I07 Diseño; I08 Seguridad y riesgos; I09 Teoría de innovación y emprendimiento —innovación—; e I10 Teoría de innovación y emprendimiento —emprendimiento—. Liderazgo y Trabajo inter y multidisciplinario no fueron cubiertos nominalmente por este instrumento virtual.

Demanda efectiva de las preguntas. La revisión del instrumento original confirmó una desalineación relevante en I04: aunque nominalmente se adscribió a Trabajo grupal e individual, la pregunta exigía **identificar las disciplinas presentes o pertinentes en el caso**, una demanda más próxima a Trabajo inter y multidisciplinario. Los dos ítems de Diseño (I05 e I07) pedían seleccionar soluciones frente a problemas o casos, mientras que I09 e I10 se orientaban respectivamente al reconocimiento de

innovación y emprendimiento. Esta revisión refuerza una distinción central del diagnóstico: la cobertura nominal de un atributo no equivale

necesariamente a una representación adecuada del constructo.

Tabla 1. Trazabilidad atributo-ítem del instrumento virtual

ID	Atributo nominal	Demanda efectiva verificada	Tipo de respuesta
I01	Comunicación	Identificar la idea central del texto o caso	Selección única
I02	Interacción con usuarios reales	Identificar los usuarios presentes en el caso	Selección única
I03	Economía y gestión	Reconocer elementos de economía y gestión relevantes para el caso	Selección única
I04	Trabajo grupal e individual	Identificar las disciplinas presentes o pertinentes en el caso; demanda desalineada respecto del atributo nominal	Selección única
I05	Diseño	Seleccionar una solución para el problema presentado	Selección única
I06	Ética y profesionalismo	Reconocer aspectos éticos implicados en la situación	Selección única
I07	Diseño	Seleccionar una solución frente al problema del caso de relaves	Selección única
I08	Seguridad y riesgos	Reconocer aspectos de seguridad y riesgo presentes en el caso	Selección única
I09	Teoría de innovación y emprendimiento — innovación	Reconocer elementos asociados con innovación	Selección única
I10	Teoría de innovación y emprendimiento — emprendimiento	Reconocer elementos asociados con emprendimiento	Selección única

Aleatorización. Los registros de aplicación muestran que la mayoría de los ítems rotaron de posición entre distintos estudiantes dentro de bloques, con la excepción del ítem I05, que aparece siempre en la posición 5 (proporción de aparición = 1,0), es decir, sin evidencia de aleatorización. Esta observación se describe como una característica del diseño de aplicación; no se evaluó su eventual efecto sobre los resultados.

3.3. Situación de desempeño grupal

Grupos, evaluadores y puntuaciones. La muestra analítica quedó constituida por **221 grupos**, calificados por **25 evaluadores** anonimizados, distribuidos en 2 secciones. Cada grupo recibió una puntuación en cada uno de los ocho criterios, es decir, $221 \times 8 = 1768$ puntuaciones individuales de criterio, agregadas posteriormente en las matrices analíticas.

Estructura final: ocho criterios, cinco atributos nominales. La correspondencia entre criterios y atributos institucionales utilizada de manera consistente en el proceso analítico y corroborada en la documentación institucional es la siguiente: Comunicación (C01, C02); Trabajo

grupal e individual (C03); Interacción con usuarios reales (C04, C05); Liderazgo (C06); Trabajo inter y multidisciplinario (C07, C08). Es decir, **cinco atributos nominales, con una o dos oportunidades de observación cada uno, y ninguna representación en este instrumento** de Diseño, Teoría de innovación y emprendimiento, Seguridad y riesgos, Economía y gestión ni Ética y profesionalismo —atributos cubiertos, cuando lo son, por el instrumento virtual—.

Escala. Los ocho criterios se calificaron mediante una escala de apreciación de cuatro niveles ordinales —Óptimo (O), Satisfactorio (S), Base (B), Por mejorar (PM)—, recodificada para el análisis como 3, 2, 1 y 0 puntos respectivamente.

Modalidad de evaluación. La planificación institucional previa contemplaba modalidades diferenciadas —heteroevaluación docente para algunos atributos y auto/coevaluación para Trabajo grupal e individual y Liderazgo—. Sin embargo, la base analítica de la cohorte 2026 contiene, para los ocho criterios, **una única puntuación grupal por criterio asignada por una persona evaluadora identificada.** En

consecuencia, los análisis de esta parte se refieren exclusivamente a esa heteroevaluación grupal efectivamente registrada, sin atribuir al conjunto de datos modalidades de evaluación que no están representadas en él.

Unidad de análisis. La unidad de análisis es el grupo, no el estudiante individual. Las

puntuaciones de los ocho criterios describen el desempeño observado en la actuación grupal; no existe, en la base analizada, información que permita descomponer esa puntuación en contribuciones individuales de cada integrante.

Tabla 2. Trazabilidad atributo-criterio de la situación de desempeño grupal

ID	Atributo nominal	Evidencia o actuación evaluada	Escala
C01	Comunicación	Exposición clara y eficaz de los resultados del caso	0-3 (PM/B/S/O)
C02	Comunicación	Identificación de ideas clave del caso (demanda próxima a comprensión del caso, más que a comunicación propiamente)	0-3 (PM/B/S/O)
C03	Trabajo grupal e individual	Trabajo en equipo, asignación de roles y respeto de opiniones (criterio que condensa tres criterios previstos en la especificación original)	0-3 (PM/B/S/O)
C04	Interacción con usuarios reales	Identificación de los usuarios presentes en el caso	0-3 (PM/B/S/O)
C05	Interacción con usuarios reales	Descripción de la participación de los usuarios en el caso	0-3 (PM/B/S/O)
C06	Liderazgo	Evidencia de rol conductivo/de liderazgo del grupo	0-3 (PM/B/S/O)
C07	Trabajo inter y multidisciplinario	Identificación de disciplinas presentes en el caso	0-3 (PM/B/S/O)
C08	Trabajo inter y multidisciplinario	Fundamentación de la presencia de las disciplinas detectadas	0-3 (PM/B/S/O)

4. Metodología del diagnóstico retrospectivo

Esta sección describe los procedimientos analíticos efectivamente ejecutados en el diagnóstico retrospectivo de la primera aproximación institucional del Hito 0. Su propósito es documentar de manera trazable cómo se prepararon los datos, cómo se examinó la representación del contenido, qué procedimientos se utilizaron para estudiar la estructura interna, la consistencia y la precisión de las puntuaciones, cómo se modeló el funcionamiento de ítems y categorías, y qué análisis descriptivos se emplearon para examinar la sensibilidad de los resultados a la composición del conjunto de evaluadores. La interpretación se restringe a la evidencia producida por estos procedimientos y no incorpora técnicas que no estén reflejadas en los resultados finales.

Esta organización es coherente con una concepción de la validez como acumulación de evidencia para respaldar interpretaciones y usos específicos de las puntuaciones, y no como una propiedad global y binaria de un instrumento (American Educational Research Association [AERA], American Psychological Association [APA], & National Council on Measurement in Education [NCME], 2014). En consecuencia, los análisis de esta sección se entienden como fuentes complementarias de evidencia y de diagnóstico sobre la primera aproximación del Hito 0, sin atribuir a ninguna de ellas, por separado, capacidad suficiente para demostrar la validez de las inferencias pretendidas.

4.1. Preparación y depuración

Las bases originales corresponden a dos fuentes institucionales: la exportación detallada de respuestas de la plataforma virtual utilizada para la prueba individual y la exportación del formulario en línea mediante el cual el cuerpo

docente registró las puntuaciones de la situación presencial de desempeño grupal.

Ambas bases se procesaron mediante procedimientos dedicados que permitieron reconstruir los registros de intento y transformarlos en matrices analíticas adecuadas al tipo de respuesta de cada instrumento: puntuaciones dicotómicas 0/1 para la prueba individual y puntuaciones ordinales 0-3 para la situación presencial. En el instrumento virtual, los intentos incompletos se trataron aplicando el criterio de inclusión definido para la muestra analítica primaria: disponer de al menos ocho respuestas completadas.

La preparación de datos incluyó además la seudonimización de estudiantes, grupos y evaluadores mediante identificadores anónimos. La tabla que permite vincular esos identificadores con las identidades originales se mantuvo exclusivamente en un repositorio privado, separado de los archivos destinados al análisis y a la difusión. Este procedimiento responde al principio general de minimizar la exposición de información identificable durante el procesamiento analítico.

Como control de fidelidad de la recodificación, se comparó el puntaje total reconstruido para la prueba individual con la calificación original registrada en la plataforma institucional. La correlación entre ambos registros fue 1,000, lo que respalda que la reconstrucción analítica reprodujo exactamente el puntaje institucional disponible. También se generaron registros de control del flujo de depuración que documentaron el número de registros originales, los intentos finalizados, la muestra analítica final y la ausencia de estudiantes con más de un intento elegible dentro de la muestra primaria.

No se identificaron operaciones de depuración adicionales a las aquí descritas. En particular, no se reconstruyó ni calculó retrospectivamente ningún estadístico que no proviniera de los resultados efectivamente generados por el proceso analítico institucional.

4.2. Representación del contenido

Antes de examinar la estructura estadística de los instrumentos, el diagnóstico revisó la correspondencia entre cuatro niveles que no deben darse por equivalentes: **atributo nominal**,

indicador o criterio, demanda efectiva de la tarea y evidencia observable producida. Esta revisión no sustituyó el juicio experto posterior ni pretendió constituir, por sí sola, una validación de contenido. Su función fue establecer la trazabilidad entre aquello que los instrumentos declaraban medir y aquello que efectivamente solicitaban hacer a estudiantes o grupos.

Esta distinción es metodológicamente relevante porque la evidencia basada en el contenido no depende únicamente del nombre asignado a un ítem, sino de la relación entre el contenido y los procesos que la tarea exige y el constructo cuya interpretación se pretende sostener (AERA et al., 2014; Sireci & Faulkner-Bond, 2014). En otras palabras, la adscripción nominal de una pregunta a un atributo es una decisión de especificación; que la respuesta a esa pregunta constituya evidencia pertinente sobre el atributo es una cuestión que requiere justificación sustantiva y, posteriormente, evidencia empírica.

En el instrumento virtual, la especificación original formuló 13 criterios de evaluación, de los cuales 10 fueron finalmente operacionalizados como preguntas. Los diez ítems representaban nominalmente ocho atributos: seis mediante un único ítem y dos —Diseño y Teoría de innovación y emprendimiento— mediante dos ítems cada uno. La revisión de la demanda efectiva confirmó, además, al menos una desalineación sustantiva: el ítem I04 fue adscrito a Trabajo grupal e individual, pero la tarea exigía identificar las disciplinas presentes o pertinentes en un caso, demanda conceptualmente más próxima a Trabajo inter y multidisciplinario.

La cobertura nominal tampoco equivale a amplitud suficiente de representación. En la mayoría de los atributos existía solo una o dos oportunidades de observación, y las tareas se concentraban predominantemente en acciones de identificación, reconocimiento o selección. En esas condiciones, la respuesta a un único ítem puede proporcionar información sobre una actuación particular, pero difícilmente representa por sí sola la variedad de manifestaciones cualitativas que supone un constructo amplio. Por ello, el diagnóstico distingue deliberadamente entre **cobertura nominal** —que un atributo aparezca asociado a uno o más ítems— y **cobertura efectiva** —que las tareas generen evidencia

suficientemente pertinente y variada para sostener inferencias sobre ese constructo—.

En la situación de desempeño grupal, los ocho criterios se distribuyeron entre cinco atributos nominales, nuevamente con una o dos oportunidades de observación por atributo. El análisis de trazabilidad identificó discrepancias adicionales entre la etiqueta declarada y la demanda de la tarea. C02, adscrito a Comunicación, solicitaba identificar ideas clave del caso, demanda más próxima a comprensión del contenido que a comunicación propiamente tal. C03 condensaba en un único criterio tres aspectos previstos originalmente para Trabajo grupal e individual. Liderazgo, operacionalizado mediante C06, fue incorporado como criterio observable en una etapa posterior a la especificación inicial.

En ambos instrumentos, por tanto, la correspondencia entre atributo declarado, indicador y evidencia producida no fue equivalente para todos los atributos. Para algunos casos, la tarea recogía de manera razonable una manifestación vinculada con la etiqueta declarada; para otros, existía una distancia documentable entre lo nominal y lo efectivamente demandado. Esta distinción constituye una condición interpretativa para los resultados posteriores de estructura interna, precisión y modelamiento: ningún resultado estadístico puede compensar una representación de contenido insuficiente o desalineada si la inferencia pretendida excede aquello que las tareas permiten observar (AERA et al., 2014).

4.3. Estructura interna

La estructura interna se examinó con el propósito de determinar si las relaciones observadas entre ítems o criterios resultaban coherentes con las estructuras de puntuación que se pretendía interpretar. Dado que los datos no eran continuos, se utilizaron matrices de asociación adecuadas a su nivel de medición: **correlaciones tetracóricas** para los diez ítems dicotómicos de la prueba individual y **correlaciones policóricas** para los ocho criterios ordinales de la situación presencial. El uso de correlaciones policóricas o tetracóricas, en lugar de correlaciones de Pearson aplicadas directamente a categorías, es consistente con la literatura metodológica sobre análisis factorial de

variables categóricas y ordinales (Flora & Curran, 2004; Holgado-Tello et al., 2010).

Sobre las matrices correspondientes se aplicaron los siguientes procedimientos:

- la medida de adecuación muestral de Kaiser-Meyer-Olkin (KMO) y la prueba de esfericidad de Bartlett, como diagnósticos preliminares de si la matriz contenía asociación suficiente para proceder con análisis factorial;
- análisis paralelo, comparando los autovalores observados con los obtenidos bajo datos aleatorios de estructura equivalente, como orientación para decidir cuántos factores explorar;
- análisis factorial exploratorio (AFE), mediante extracción por mínimos residuos (minres) y rotación oblimin, permitiendo correlación entre factores, en concordancia con recomendaciones metodológicas para explorar estructuras latentes cuando los factores pueden relacionarse (Fabrigar et al., 1999);
- análisis factorial confirmatorio (CFA) de un modelo unidimensional, estimado mediante **WLSMV (Weighted Least Squares Mean and Variance Adjusted; mínimos cuadrados ponderados ajustados por media y varianza)**, un estimador diseñado para trabajar de manera robusta con indicadores categóricos u ordinales.

El análisis paralelo se utilizó como **criterio orientador**, no como una regla automática de retención factorial. Su fundamento es contrastar los autovalores observados con aquellos que pueden surgir por variación aleatoria, reduciendo la dependencia de reglas simples como conservar factores únicamente porque su autovalor supera 1 (Horn, 1965; Hayton et al., 2004). La cantidad sugerida por el análisis paralelo, por tanto, se interpretó junto con la estabilidad y la interpretabilidad sustantiva de las soluciones factoriales.

Para el CFA categórico se utilizó **WLSMV** (Weighted Least Squares Mean and Variance Adjusted), es decir, un estimador de mínimos cuadrados ponderados con ajuste de la media y la varianza. Su elección responde a que los indicadores analizados eran dicotómicos u ordinales: en este contexto, WLSMV permite estimar el modelo a partir de la estructura de

asociación apropiada para variables categóricas y aplicar correcciones robustas al estadístico de ajuste y a sus errores estándar. La evidencia metodológica disponible muestra que los enfoques robustos basados en correlaciones policóricas/tetracóricas son más apropiados que tratar categorías ordenadas como si fueran variables continuas sin atender a su distribución y escala de respuesta (Flora & Curran, 2004; Holgado-Tello et al., 2010).

Los principales indicadores examinados fueron las cargas factoriales y su heterogeneidad, las comunales, las cargas cruzadas, la presencia de soluciones inadmisibles o inestables —incluidos casos Heywood— y, en el CFA, los índices globales CFI, TLI, RMSEA y SRMR. Los casos Heywood se consideraron señales de que una solución requería especial cautela, ya que estimaciones como comunales iguales o superiores a 1 pueden reflejar problemas de identificación, especificación o estabilidad de la solución factorial y no deben interpretarse como evidencia sustantiva de un factor bien definido.

La interpretación de los índices de ajuste siguió un principio deliberadamente no mecánico. CFI, TLI, RMSEA y SRMR aportan información útil sobre distintos aspectos del ajuste, pero no deben convertirse en reglas binarias independientes del contexto del modelo, del tamaño y naturaleza de los indicadores o de la plausibilidad sustantiva de la solución. Aunque Hu y Bentler (1999) propusieron combinaciones de índices y valores orientadores en condiciones específicas, la literatura posterior ha advertido contra transformar esos valores en "reglas de oro" universales (Marsh et al., 2004). Asimismo, distintos índices pueden conducir a evaluaciones discordantes de un mismo modelo, por lo que su lectura debe complementarse con parámetros locales y con la coherencia teórica de la estructura interpretada (Lai & Green, 2016).

En consecuencia, un ajuste global aparentemente favorable del CFA no se consideró suficiente, por sí solo, para sostener que una estructura fuera homogénea si las cargas factoriales eran muy heterogéneas o si la solución exploratoria mostraba inestabilidad, factores definidos prácticamente por un único indicador, cargas cruzadas importantes o casos Heywood. De manera recíproca, una solución exploratoria con mejor ajuste estadístico no se trató

automáticamente como una nueva taxonomía sustantiva de atributos. El objetivo de estos análisis fue contrastar la coherencia de la estructura observada con las inferencias pretendidas, no reemplazar las definiciones institucionales mediante una clasificación emergente exclusivamente estadística.

4.4. Consistencia y precisión

El diagnóstico distinguió dos nociones relacionadas, pero no equivalentes: **consistencia interna** y **precisión de la medición**. Esta distinción se apoya en el marco de Teoría Clásica de los Tests presentado en la sección 2.3 y en su articulación con los modelos de respuesta al ítem: los coeficientes clásicos resumen propiedades del puntaje agregado, mientras que los modelos Rasch/PCM permiten examinar además cómo varía la precisión a lo largo del continuo.

La consistencia interna describe el grado en que un conjunto de ítems o criterios covaría y puede resumirse mediante coeficientes como KR-20, alfa de Cronbach, alfa ordinal u omega. Sin embargo, la magnitud de un coeficiente de consistencia interna depende de supuestos sobre la estructura de las puntuaciones y no constituye, por sí misma, demostración de unidimensionalidad, validez o precisión individual. La literatura ha documentado extensamente las limitaciones de interpretar el alfa como indicador general de "calidad" de una escala y recomienda considerar estimadores alternativos, como omega, cuando la estructura de cargas no satisface los supuestos restrictivos que subyacen al uso convencional del alfa (Dunn et al., 2014; McNeish, 2018).

La precisión de la medición, en cambio, se refiere a cuánto error acompaña a las estimaciones de posición de una persona o grupo sobre la variable modelada. En modelos de rasgo latente esta precisión puede resumirse mediante confiabilidades derivadas de estimadores como EAP (expected a posteriori) o WLE (weighted likelihood estimate), además de examinarse mediante errores estándar de medición y la información disponible a lo largo del continuo. Consistencia interna y precisión pueden estar relacionadas, pero responden a preguntas diferentes y no deben tratarse como sinónimos.

Para el instrumento virtual se calcularon KR-20, alfa de Cronbach, alfa basado en correlaciones tetracóricas, omega total, omega jerárquico de

carácter exploratorio y confiabilidades EAP y WLE derivadas del modelo Rasch. Para la situación presencial se calcularon alfa de Cronbach, alfa ordinal —apropiado para datos categóricos ordenados cuando se trabaja con asociaciones policóricas (Gadermann et al., 2012)—, omega total, omega jerárquico y confiabilidades EAP y WLE derivadas del Partial Credit Model. Las estimaciones EAP y WLE corresponden, respectivamente, a enfoques bayesianos de estimación posterior y de máxima verosimilitud ponderada para posiciones sobre el rasgo latente (Bock & Mislevy, 1982; Warm, 1989).

La inclusión de varios coeficientes no se utilizó para seleccionar retrospectivamente aquel que ofreciera el valor más favorable. Su propósito fue describir el comportamiento del conjunto de puntuaciones desde perspectivas complementarias. En especial, alfa y omega no se interpretaron como pruebas de que los instrumentos midieran un único constructo homogéneo: esa hipótesis se examinó separadamente mediante la evidencia de estructura interna.

Un principio central para la interpretación fue que **una consistencia interna global adecuada no demuestra que puedan obtenerse estimaciones confiables para cada atributo por separado**. Un coeficiente calculado sobre el total de ítems o criterios describe la covariación conjunta de ese total. No proporciona, por sí mismo, una base para desagregar el instrumento en subpuntuaciones cuando varios atributos cuentan con una sola o dos oportunidades de observación. Con uno o dos indicadores, la limitación no es únicamente estadística: también es de representación, porque resulta difícil sostener que una puntuación tan estrecha capture la amplitud de un constructo institucional complejo. Por ello, la consistencia del total y la precisión de las estimaciones globales se interpretaron separadamente de la posibilidad —mucho más exigente— de reportar niveles diferenciados por atributo.

4.5. Funcionamiento de ítems y categorías

Para el instrumento virtual se estimó un **modelo Rasch dicotómico**, en el que la probabilidad de responder correctamente un ítem depende de la posición de la persona sobre la variable y de la dificultad del ítem, expresadas en una misma escala. Este modelamiento se utilizó para

examinar las dificultades de los diez ítems, sus estadísticos de ajuste infit y outfit, la distribución conjunta de personas e ítems y la focalización del instrumento respecto de la población evaluada (Rasch, 1980; Wilson, 2023).

La focalización persona-ítem es particularmente relevante en una medición diagnóstica porque no basta con que los ítems “funcionen” en términos generales: deben cubrir el rango del continuo que efectivamente presenta la población de ingreso. Cuando las dificultades se concentran muy por debajo de la posición media de las personas, el instrumento puede distinguir razonablemente entre niveles bajos y medios, pero pierde información en la zona media-alta y alta porque una proporción creciente de participantes responde correctamente a casi todos los ítems. En tales condiciones, diferencias reales entre estudiantes de mayor desempeño pueden quedar comprimidas por falta de tareas suficientemente exigentes.

Para la situación de desempeño grupal se estimó un **Partial Credit Model (PCM)**. El PCM extiende la lógica Rasch a respuestas con categorías ordenadas y permite que la localización de los pasos o umbrales entre categorías difiera de un criterio a otro (Masters, 1982). Esta característica resulta pertinente para escalas de apreciación en las que la transición entre, por ejemplo, “Base” y “Satisfactorio” no tiene por qué ubicarse en el mismo punto del continuo para todos los criterios.

Se examinaron los parámetros de localización y de paso de cada criterio, los umbrales derivados y los estadísticos infit/outfit. Es importante distinguir entre el **orden sustantivo declarado** de las categorías, los **parámetros de paso** del PCM y los **umbrales Thurstonianos acumulativos**. Que una rúbrica denomine cuatro niveles en orden creciente no garantiza automáticamente que cada categoría tenga un funcionamiento empírico adecuado. La frecuencia de uso, las curvas de probabilidad de categoría, las medidas asociadas a cada categoría y los diagnósticos de ajuste proporcionan evidencia más directa sobre ese funcionamiento (Linacre, 2002; Wilson, 2023). Los umbrales Thurstonianos, por su parte, son especialmente útiles para interpretar localización y focalización sobre una escala común.

Por tanto, el análisis de ítems y categorías no se interpretó como una confirmación independiente

de los atributos institucionales. Su función fue examinar si las tareas y las categorías de respuesta de la primera aproximación se comportaban de forma compatible con una medición útil para el propósito diagnóstico, prestando particular atención a la focalización, al ajuste y al aprovechamiento efectivo de las categorías disponibles.

4.6. Sensibilidad a evaluadores

La situación de desempeño grupal fue calificada por 25 evaluadores en 221 grupos. Sin embargo, el diseño no proporcionó un cruce suficiente entre evaluadores y grupos: la mayoría de los evaluadores no calificó un número suficiente de grupos en común con otros evaluadores, ni existió una doble corrección sistemática de las mismas actuaciones. Esta característica impide separar estadísticamente, con el diseño disponible, la severidad o indulgencia del evaluador de las características de los grupos y de las condiciones particulares de aplicación.

Los modelos de facetas múltiples permiten, bajo diseños adecuadamente conectados, estimar efectos de evaluador y distinguir patrones como severidad, indulgencia u otros efectos sistemáticos de calificación (Myford & Wolfe, 2003, 2004). No obstante, esa separación depende de que exista suficiente conectividad entre las facetas —por ejemplo, respuestas calificadas por más de un evaluador o conjuntos de respuestas comunes que enlacen a los evaluadores—. Cuando ese enlace es insuficiente, las estimaciones de los efectos de evaluador y de desempeño quedan confundidas y los ajustes por severidad pueden resultar inestables o no identificables de manera defendible (Wind et al., 2016).

Ante esta limitación de diseño, el diagnóstico no estimó un modelo completo de severidad de evaluadores. En su lugar, utilizó dos procedimientos complementarios de carácter **descriptivo y no causal**.

Primero, se calcularon intervalos de Wilson al 95 % para las proporciones de grupos ubicados en cada nivel de la rúbrica por criterio. El intervalo de Wilson es una alternativa bien establecida al intervalo normal de Wald para proporciones binomiales y presenta un comportamiento de cobertura más adecuado, especialmente cuando las proporciones se aproximan a los extremos o cuando los tamaños efectivos de muestra no son

muy grandes (Wilson, 1927; Brown et al., 2001; Newcombe, 1998). En este diagnóstico, esos intervalos cuantifican la incertidumbre asociada a las proporciones observadas; **no** estiman acuerdo interevaluador ni severidad.

Segundo, se realizó un **bootstrap por evaluador con 2000 remuestras**, remuestreando los grupos dentro de cada evaluador para examinar cuánto variaban los porcentajes por nivel y criterio ante cambios en la composición observada de las calificaciones. El objetivo fue evaluar la sensibilidad de las distribuciones agregadas a la composición del conjunto de evaluadores, no atribuir causalmente las diferencias a evaluadores particulares. El remuestreo dentro de agrupaciones es consistente con la lógica general del bootstrap para datos con estructura agrupada (Field & Welsh, 2007).

Este alcance debe mantenerse explícito. El bootstrap empleado no compara la misma actuación calificada por evaluadores distintos y, por tanto, no produce un coeficiente de acuerdo interevaluador. Tampoco permite concluir que una diferencia entre distribuciones se deba a la severidad individual de quien calificó: evaluador, grupo y condiciones de aplicación no se encuentran suficientemente separados por el diseño. En consecuencia, cualquier variación observada se reporta como **sensibilidad descriptiva de las distribuciones a la composición del conjunto de evaluadores**, no como estimación de severidad.

La principal implicación metodológica es prospectiva. Si una etapa futura del Hito 0 requiere distinguir efectos de evaluador de diferencias reales en el desempeño, el diseño deberá incorporar un cruce o enlace suficiente entre evaluadores y respuestas antes de aplicar modelos de facetas. El modelamiento estadístico no puede recuperar una separación que el diseño de recolección de datos no hizo identificable.

4.7. Procedimiento analítico y documentación

Los análisis se realizaron en R. Se utilizaron los paquetes **psych** para estadísticos descriptivos, estimaciones de consistencia y análisis factorial exploratorio; **lavaan** (Rosseel, 2012) para el análisis factorial confirmatorio con estimador WLSMV; y **TAM** para los modelos Rasch dicotómico y Partial Credit Model.

El flujo analítico comprendió preparación y recodificación de datos, estadísticos descriptivos, análisis de consistencia y precisión, examen de estructura interna, modelamiento de ítems o categorías y consolidación de resultados. La selección de cada procedimiento respondió al tipo de dato y a la pregunta analítica correspondiente; ningún estadístico individual se utilizó como sustituto de las demás fuentes de evidencia.

La interpretación presentada en el reporte se limita a resultados efectivamente obtenidos y documentados. Esta restricción es metodológicamente importante: los análisis retrospectivos permiten caracterizar qué evidencia produjo la primera aproximación institucional y qué inferencias puede o no sostener, pero no autorizan a atribuir al instrumento propiedades que no fueron evaluadas o que el diseño de aplicación no permite identificar.

5. Resultados de la prueba individual en línea

5.1. Cobertura del contenido

Como se desarrolló en la sección 4.2, el instrumento virtual asoció sus diez ítems a ocho atributos nominales declarados, de los cuales seis quedaron representados por un único ítem y dos por dos ítems. Las demandas predominantes de las tareas correspondieron a identificación, reconocimiento y selección a partir de un caso o video presentado, más que a producción, argumentación o resolución extendida.

Esta configuración obliga a distinguir con precisión entre dos afirmaciones que, en el uso corriente, suelen confundirse:

afirmar que "el ítem I04 pertenece al atributo Trabajo grupal e individual"

no es equivalente a demostrar que

"la respuesta a I04 proporciona evidencia suficiente para ubicar al estudiante sobre una variable de Trabajo grupal e individual".

La primera es una decisión de etiquetado, adoptada en la tabla de especificaciones. La segunda es una afirmación empírica, que exige mostrar que la tarea efectivamente demanda algo sustantivamente relacionado con el atributo declarado y que la respuesta —correcta o incorrecta— permite distinguir niveles de desarrollo cualitativamente diferentes de ese atributo. El caso de I04, documentado en la sección 3.2, ilustra precisamente el punto en que ambas afirmaciones se desacoplan: el ítem fue etiquetado como Trabajo grupal e individual, pero su demanda efectiva —identificar disciplinas presentes en el caso— corresponde más bien a Trabajo inter y multidisciplinario. Con solo uno o dos ítems por atributo en la mayoría de los casos, y sin evidencia adicional de que cada ítem individual cubra adecuadamente la variedad de manifestaciones posibles de su atributo declarado, la cobertura efectiva del contenido resulta considerablemente más restringida que la sugerida por el recuento nominal de ocho atributos representados.

5.2. Distribución del desempeño

Dificultad clásica (proporción de respuestas correctas) por ítem:

Tabla 3. Dificultad clásica (proporción de respuestas correctas) por ítem

Ítem	Proporción correcta
I01	0,620
I02	0,885
I03	0,685
I04	0,560
I05	0,666
I06	0,695
I07	0,560
I08	0,849
I09	0,930
I10	0,954

Los ítems I09 e I10 muestran las proporciones de acierto más altas del instrumento (0,930 y 0,954, respectivamente), consistente con lo señalado institucionalmente sobre las preguntas asociadas

a Teoría de innovación y emprendimiento. Los ítems I04 e I07 muestran las proporciones más bajas (0,560 ambos).

La correlación ítem-total corregida osciló entre 0,135 (I03) y 0,364 (I09) —rango moderado a bajo—, lo que ya anticipa, antes de examinar la estructura factorial, que la contribución de los distintos ítems a una eventual dimensión común no es homogénea.

Respecto de la distribución del puntaje total, el indicador de mayor relevancia interpretativa verificado es la **proporción de estudiantes con puntaje máximo (10/10): 93 de 991 estudiantes, es decir, 9,38 %**.

La Figura 6 presenta la distribución completa de puntajes obtenidos en la prueba individual en línea, coherente con la focalización de dificultades descrita en el apartado siguiente.




Figura 6. Distribución del puntaje total de la prueba individual en línea (n = 991, muestra analítica primaria, cohorte de ingreso 2026). El 55,00 % de los estudiantes obtuvo entre 8 y 10 aciertos, consistente con la concentración de dificultades en la zona fácil del continuo documentada en la Figura 7.

Un puntaje alto en este instrumento no debe interpretarse como dominio de los diez atributos institucionales: como se estableció en la sección 5.1, el instrumento cubre nominalmente ocho de los diez atributos, mediante uno o dos ítems de identificación/reconocimiento cada uno.

5.3. Estructura interna

Factorabilidad. KMO = 0,796; prueba de Bartlett $\chi^2(45) = 2538,69$, $p < 0,001$ —ambos indicadores respaldan que la matriz de correlaciones tetracóricas es adecuada para un análisis factorial—.

Análisis paralelo. El análisis paralelo sobre la matriz tetracórica sugirió **retener tres factores**. Este resultado se utiliza como orientación exploratoria sobre la estructura interna y no como una taxonomía sustantiva alternativa de los atributos institucionales.

Análisis factorial exploratorio (AFE). La solución de un factor mostró $RMSEA = 0,084$ y $TLI = 0,873$. La solución de tres factores —la explorada con mayor detalle en el diagnóstico— mostró un ajuste aparentemente mejor ($RMSEA = 0,045$; $TLI = 0,964$), pero **una estructura inestable**: uno de los factores (MR2) quedó definido casi exclusivamente por un único ítem (I04, carga 0,86, resto de los ítems con cargas cercanas a cero en ese factor); el ítem I09 presentó una carga de 1,027 en otro factor —un **caso Heywood**, con comunalidad estimada de 0,997—; y se observaron cargas cruzadas relevantes en los ítems I08 e I06.

Análisis factorial confirmatorio (CFA) unidimensional. El modelo de un solo factor, estimado con WLSMV, mostró índices de ajuste global aparentemente adecuados: $CFI = 1,000$; $TLI = 1,000$; $RMSEA = 0,000$; $SRMR = 0,044$. Sin embargo, las cargas factoriales estandarizadas resultaron **heterogéneas**, con un rango de 0,255 (I03) a 0,877 (I10).

Estos resultados deben interpretarse conjuntamente. El ajuste global del CFA no basta para concluir que los diez ítems constituyen una dimensión homogénea si las contribuciones de los indicadores son muy desiguales y la solución exploratoria alternativa presenta inestabilidad. A su vez, la solución de tres factores tampoco ofrece una estructura sustantivamente clara que permita reinterpretar los factores como atributos diferenciados. En consecuencia, la estructura interna no aporta una base suficiente para sostener una medición diferenciada de los atributos ni para asumir sin reservas una única dimensión general homogénea.

5.4. Consistencia y precisión

Tabla 4. Consistencia y precisión de la prueba individual en línea

Indicador	Valor verificado
KR-20	0,525
Alfa de Cronbach	0,524
Alfa tetracórico	0,764
Omega total	0,813
Omega jerárquico	0,639
Confiabilidad EAP (Rasch)	0,508
Confiabilidad WLE (Rasch)	0,319

Las dos estimaciones de precisión del modelo Rasch —**EAP = 0,508** y **WLE = 0,319**— convergen en mostrar una precisión limitada, especialmente para distinguir posiciones individuales con suficiente estabilidad.

Implicación para el uso diagnóstico. La combinación de un KR-20 de 0,525 con confiabilidades EAP/WLE moderada-baja —especialmente $WLE = 0,319$ — indica que, incluso considerando el puntaje total del instrumento como una medida general de desempeño en el conjunto de tareas cubiertas, la precisión es limitada para distinguir con confianza entre estudiantes individuales. Esta limitación se suma, y no sustituye, a la limitación de cobertura descrita en 5.1: aun con mayor precisión, seguiría sin existir base suficiente para desagregar el puntaje en ocho estimaciones diferenciadas por atributo con uno o dos ítems cada una.

5.5. Modelo Rasch

Las dificultades Rasch estimadas para los 10 ítems se ubicaron entre **-3,337 y -0,274 logits**. El ítem I10 presentó la menor dificultad (-3,337), mientras que I04 e I07 compartieron la mayor dificultad estimada del conjunto (-0,274). En consecuencia, **las diez dificultades se localizaron en valores negativos respecto del punto de referencia $\theta=0$ de la escala**.

En el modelo Rasch, personas e ítems se expresan en una métrica común. Una dificultad de -0,274 logits, por ejemplo, se encuentra por encima de -1 en el eje porque es un valor más próximo a

cero; no debe confundirse el signo negativo con una posición “más baja” que cualquier otro valor negativo. Más sustantivamente, que ningún ítem se ubique en posiciones positivas indica que el conjunto de tareas está focalizado hacia regiones bajas y medias-bajas del continuo definido por este instrumento. El valor $\theta=0$ se utiliza aquí como **referencia de la escala**, no como una afirmación de que corresponda exactamente al promedio empírico de la cohorte.

Esta focalización tiene consecuencias directas para la precisión. La función de información del conjunto alcanza su máximo aproximadamente en **$\theta=-1,15$** . La prueba entrega, por tanto, su mayor información alrededor de esa zona y pierde precisión a medida que la posición estimada se aleja de ella, especialmente hacia valores positivos altos. En ese tramo, la ausencia de ítems de dificultad comparable reduce la capacidad del instrumento para distinguir entre estudiantes situados en la zona superior del continuo. Esta lectura es consistente con la concentración de

puntajes altos observada en la sección 5.2 y con la confiabilidad WLE limitada reportada en la sección 5.4.

En cuanto al ajuste de los ítems, solo I09 e I10 mostraron señales estadísticamente significativas tras corrección de Holm, ambas asociadas a **sobreajuste** (outfit = 0,719 y 0,629, respectivamente). Estos resultados indican respuestas más predecibles por el modelo de lo esperado, pero no constituyen por sí solos una razón para considerar esos ítems “mejores”: el ajuste debe leerse junto con su contenido, su elevada facilidad y la focalización global del instrumento.

La Figura 7 integra estas evidencias en una sola representación: el panel A compara la distribución WLE de los 991 estudiantes con las dificultades de los diez ítems sobre la misma escala logit, mientras que el panel B muestra la información y el error estándar de medición de manera condicional a θ .

A. Mapa persona-ítem de la prueba individual

Posiciones WLE de 991 estudiantes y dificultades Rasch de I01–I10



**B. Información y precisión condicional del instrumento**Función de información y SEM del conjunto de diez ítems; máxima información cerca de $\theta = -1,15$ 

Figura 7. Focalización y precisión condicional de la prueba individual bajo el modelo de Rasch. El panel A presenta la distribución de las posiciones WLE de 991 estudiantes y las dificultades estimadas de los diez ítems sobre una escala común en logits. El panel B muestra la función de información del instrumento y el error estándar de medición (SEM) a lo largo del continuo. Las dificultades se concentran entre $-3,337$ y $-0,274$ logits y la máxima información se ubica aproximadamente en $\theta = -1,15$, lo que muestra una mejor focalización hacia la zona baja-media que hacia posiciones altas del continuo.

La lectura conjunta de ambos paneles permite precisar el problema de focalización. En el panel A, **ninguno de los diez ítems presenta dificultad positiva**: incluso los ítems más difíciles, I04 e I07, se sitúan en $-0,274$ logits, mientras que I10 se localiza en $-3,337$ logits. La distribución WLE de los estudiantes se extiende hacia posiciones superiores a la localización de todos los ítems, de modo que en la zona media-alta y alta existen estudiantes pero no tareas de dificultad comparable que aporten suficiente información para diferenciarlos. Este desajuste es

coherente con la concentración de puntajes altos observada previamente —93 de 991 estudiantes, 9,38 %, alcanzaron 10/10— y sugiere que el instrumento resultó relativamente fácil para una fracción relevante de la cohorte.

El panel B muestra la consecuencia métrica de esa focalización: la información del conjunto alcanza su máximo alrededor de $\theta = -1,15$, mientras que el SEM es menor en esa misma región y aumenta a medida que la posición estimada se aleja de ella. Hacia valores positivos, la caída de información indica que diferencias reales entre estudiantes de

desempeño alto se traducen en estimaciones menos precisas. Por tanto, la principal conclusión de la Figura 7 no es simplemente que los ítems sean "fáciles", sino que **la prueba concentra su capacidad de medición en una región inferior a aquella donde se ubica una parte relevante de la cohorte**. Para un rediseño orientado a diagnóstico de ingreso, este patrón respalda la incorporación de tareas de mayor dificultad y mayor riqueza de evidencia en la zona media-alta y alta del continuo.

La **Figura 8** complementa la Figura 7 mostrando cómo el puntaje total observado se transforma en una posición WLE bajo el modelo de Rasch. Los once puntajes posibles, de 0 a 10 aciertos, se asocian con posiciones estimadas que se extienden aproximadamente desde $-5,10$ hasta $2,07$ logits. La relación es monótona —a mayor puntaje, mayor posición estimada—, pero las distancias entre posiciones WLE asociadas a puntajes consecutivos no son constantes. En la zona central los incrementos son relativamente graduales, mientras que en los extremos, especialmente entre 9 y 10 aciertos, la separación aumenta.

Este comportamiento debe leerse junto con la focalización y la precisión condicional presentadas en la Figura 7. La ampliación de las distancias en el extremo superior no implica que un punto adicional represente allí una ganancia sustantiva excepcionalmente grande; refleja la transformación no lineal del puntaje bruto a la escala logit y la menor información disponible cuando existen pocas tareas adecuadamente localizadas en esa región. El tamaño de los puntos representa la frecuencia de estudiantes para cada puntaje y hace visible la concentración de observaciones en la zona alta, incluido el grupo de 93 estudiantes que obtuvo 10/10. En conjunto, ambas figuras muestran que el instrumento ordena el desempeño de manera coherente, pero ofrece menor resolución para distinguir diferencias dentro de la zona superior.




Figura 8. Relación entre puntaje observado y posición estimada (WLE) en la prueba individual en línea bajo el modelo de Rasch. Se representan los once puntajes posibles (0-10) y la posición WLE correspondiente para 991 estudiantes; el tamaño de los puntos indica la frecuencia de estudiantes en cada puntaje. La mayor separación entre posiciones estimadas en los extremos, particularmente en el superior, es coherente con la menor información disponible en esas regiones. Esta figura complementa la evidencia de focalización e información condicional presentada en la Figura 7.

5.6. Interpretación integrada de la prueba individual

¿Qué información sí proporcionó el instrumento? Permitió describir patrones agregados de respuesta en la cohorte 2026: qué ítems resultaron relativamente más fáciles o más difíciles, qué proporción de estudiantes alcanzó el puntaje máximo, y una estimación general —aunque de precisión limitada— de un desempeño conjunto sobre el subconjunto de contenidos cubiertos. También aportó señales claras sobre problemas de diseño del instrumento: la desalineación del ítem I04, la inestabilidad de la solución factorial de tres dimensiones, y la concentración de dificultades en la zona baja del continuo.

¿Qué información no permitió obtener? No permitió sostener estimaciones diferenciadas y confiables de cada uno de los ocho atributos nominalmente cubiertos, y menos aún de los diez atributos institucionales en su totalidad —dos de los cuales (Liderazgo y Trabajo inter y multidisciplinario, este último representado más bien de forma indirecta y desalineada en I04) no cuentan con representación directa en este instrumento—. Tampoco permitió distinguir niveles de desarrollo cualitativamente diferentes

dentro de un atributo, dado que cada ítem se puntuó de manera dicotómica (correcto/incorrecto) y la mayoría de los atributos contó con un único ítem.

¿Era razonable pretender producir estimaciones diferenciadas para ocho o diez atributos con este instrumento? La evidencia reunida en esta sección indica que no: con uno o dos ítems dicotómicos por atributo, ninguna combinación de análisis psicométricos posteriores —por sofisticados que sean— puede generar por sí sola la información necesaria para sostener ocho o diez mediciones diferenciadas. Este es un límite de **cobertura** (número de oportunidades de observación por atributo), no únicamente de **precisión** (estabilidad de las estimaciones) ni exclusivamente de **estructura interna** (inestabilidad de la solución factorial). Los tres tipos de problema —cobertura, precisión y estructura— están documentados en esta sección y son, en gran medida, independientes entre sí, aunque se refuerzan mutuamente en sus consecuencias.

La conclusión de esta sección no es que "el instrumento virtual fue malo", sino, de manera más precisa, que **la evidencia que produjo era insuficiente para las inferencias diagnósticas diferenciadas por atributo que institucionalmente se pretendía sostener con él.**

6. Resultados de la situación de desempeño grupal

6.1. Cobertura del contenido

Como se estableció en la sección 3.3, los ocho criterios de la situación de desempeño grupal se distribuyeron entre **cinco atributos nominales**, con una o dos oportunidades de observación por atributo. La evidencia que produce este instrumento es, además, evidencia **grupal**: describe la actuación observada del conjunto, calificada por una persona docente, y no permite —sin información adicional— distinguir la contribución de cada integrante del grupo. Esta distinción entre evidencia de grupo y evidencia individual es central para toda la interpretación de esta sección y, en particular, para evitar transformar directamente criterios grupales en

puntuaciones individuales (regla que se retoma en la sección 7).

6.2. Distribución del desempeño

Media por criterio (escala 0–3): el rango observado va de 1,548 (C05, "Describe la participación de los usuarios") a 2,235 (C07, "Identifica la presencia de disciplinas"). La correlación criterio-total corregida osciló entre 0,438 (C04) y 0,657 (C02).

Distribución por niveles de la rúbrica: a modo de ejemplo de los patrones observados, C07 concentró 53,85 % de los grupos en el nivel Óptimo, mientras que C05 concentró 38,91 % en el nivel Base y solo 14,48 % en Óptimo. La distribución completa por nivel y criterio no se reproduce íntegramente en este reporte para evitar redundancia.

Estos porcentajes describen la distribución observada de puntuaciones grupales por criterio; no deben interpretarse todavía como "niveles de desarrollo" de los atributos institucionales en un sentido fuerte, porque —como se desarrollará en la Parte III de este reporte— esa interpretación requeriría contar primero con una arquitectura de constructo (Construct Map) explícita para cada atributo, de la que la primera aproximación carecía.

6.3. Estructura interna

CFA unidimensional. El modelo de un solo factor, estimado con WLSMV sobre las correlaciones policóricas de los ocho criterios, mostró: CFI = 0,871; TLI = 0,819; **RMSEA = 0,212**; SRMR = 0,134. En conjunto, estos índices indican un **ajuste insuficiente** del modelo unidimensional: los datos no respaldan que la actuación grupal observada en los ocho criterios pueda representarse adecuadamente mediante una sola dimensión latente.

Análisis paralelo. El análisis paralelo sobre la matriz policórica sugirió **tres factores**, coherente con la solución explorada posteriormente mediante AFE. Como en el instrumento virtual, este resultado informa sobre la estructura interna de las respuestas y no redefine por sí mismo los atributos institucionales.

Análisis factorial exploratorio. KMO = 0,786; Bartlett $\chi^2(28) = 913,10$ ($p < 0,001$). La solución de tres factores mostró un ajuste

considerablemente mejor que la solución de un factor ($RMSEA = 0,117$; $TLI = 0,904$) y produjo tres agrupaciones empíricas:

- **Factor 1:** C01 (0,752), C03 (0,944), C06 (0,809) — reúne criterios nominalmente asociados a Comunicación, Trabajo grupal e individual y Liderazgo.
- **Factor 2:** C02 (0,538), C04 (0,785), C05 (0,764) — reúne un criterio nominalmente de Comunicación (C02, cuya demanda efectiva es más próxima a comprensión del caso) junto con los dos criterios de Interacción con usuarios reales.
- **Factor 3:** C07 (0,567), C08 (1,006, **caso Heywood**, comunalidad estimada = 1,00) — coincide con los dos criterios de Trabajo inter y multidisciplinario.

Esta reagrupación empírica no debe interpretarse automáticamente como una nueva taxonomía de atributos. La covariación observada puede reflejar, entre otras posibilidades, solapamientos reales entre criterios, características de la tarea común, efectos del método de observación compartido o el número limitado de oportunidades de observación por atributo. Con el diseño disponible no es posible separar estas explicaciones de manera concluyente.

La Figura 9 muestra de manera directa la discrepancia entre los cinco atributos nominales declarados para los ocho criterios y las tres agrupaciones que emergen del análisis factorial exploratorio, sin que ello implique que esta segunda agrupación deba reemplazar a la primera.




Figura 9. Comparación entre la estructura nominal de cinco atributos declarada institucionalmente para los ocho criterios de la situación de desempeño grupal (izquierda) y la estructura empírica de tres factores obtenida mediante análisis factorial exploratorio (derecha). Solo el Factor 3 —que coincide exactamente con los dos criterios nominales de Trabajo inter y multidisciplinario— reproduce de manera directa la estructura declarada; los Factores 1 y 2 reagrupan criterios provenientes de tres y dos atributos nominales distintos, respectivamente. Esta agrupación exploratoria no debe interpretarse como una nueva taxonomía de atributos (sección 6.3).

6.4. Consistencia y precisión

Tabla 5. Consistencia y precisión de la situación de desempeño grupal

Indicador	Valor verificado
Alfa de Cronbach	0,810
Alfa ordinal	0,855
Omega total	0,924
Omega jerárquico	0,595
Confiabilidad EAP (PCM)	0,811
Confiabilidad WLE (PCM)	0,782

Las confiabilidades EAP = 0,811 y WLE = 0,782 indican una precisión razonable **para el puntaje conjunto modelado bajo el PCM**. No deben interpretarse como confiabilidad diferenciada de cada uno de los cinco atributos nominales, pues varios de ellos cuentan con una o dos

oportunidades de observación y la estructura interna analizada en 6.3 no respalda una representación unidimensional fuerte del conjunto.

La diferencia entre omega total (0,924) y omega jerárquico (0,595), considerada junto con el ajuste insuficiente del CFA unidimensional, refuerza la misma cautela: **una consistencia global alta no equivale a una única dimensión general fuerte ni habilita, por sí sola, subpuntuaciones interpretables por atributo**. Los índices de la Tabla 5 deben leerse como descriptores del comportamiento agregado de los ocho criterios.

La Figura 10 complementa estos índices mostrando el error estándar de medición en seis tramos del continuo de habilidad grupal. Se trata de una síntesis discretizada de la precisión; la Figura 11 complementa esta lectura mediante el mapa grupo-umbrales y permite examinar la focalización del puntaje conjunto.




Figura 10. Error estándar de medición según tramos de habilidad grupal. El EEM es menor en los tramos centrales del continuo (0,456; 0,436; 0,501) y aumenta hacia los extremos, alcanzando 0,750 para $\theta < -2$ y 1,126 para $\theta \geq 2$. Los tamaños de grupo incluidos bajo cada tramo describen la distribución de casos observados y deben considerarse al interpretar los extremos, pero no constituyen la causa matemática del patrón del SEM.

El patrón de la Figura 10 muestra que la precisión del puntaje grupal es mayor en la zona central y menor en los extremos. Esta lectura descriptiva es coherente con el análisis condicional del PCM presentado a continuación, aunque ambas representaciones cumplen funciones distintas: la

Figura 10 facilita una comunicación por bandas de habilidad, mientras que la Figura 11 permite localizar con mayor precisión dónde se concentra la información del modelo.

6.5. Partial Credit Model, parámetros de paso y umbrales Thurstonianos

Para los ocho criterios ordinales se estimó un **Partial Credit Model (PCM)** mediante la parametrización PCM2 de TAM. Los parámetros de localización de criterio (μ_i) se ubicaron entre **-1,302 (C03) y -0,141 (C05)**. En cuanto al ajuste global por criterio, C08 presentó inicialmente una señal de desajuste ($p = 0,010$), pero esta no se mantuvo significativa después de la corrección de Holm (p corregido = 0,229). Este resultado no elimina las cautelas derivadas de la estructura interna: el PCM se utiliza aquí como una **representación de trabajo del puntaje conjunto** para examinar categorías, focalización y precisión, no como demostración de que los ocho criterios formen una única dimensión sustantiva bien definida.

La auditoría de las salidas de TAM permitió aclarar una distinción que es importante para interpretar correctamente los resultados. La parametrización PCM2 entrega, además de la localización general de cada criterio, dos coeficientes libres denominados step1 y step2 . Esos coeficientes pertenecen a la parametrización interna $\text{item} + \text{item} \times \text{step}$ y **no equivalen directamente a los tres umbrales acumulativos que pueden representarse para una escala de cuatro categorías**. Wilson (2023) distingue expresamente los step parameters — vinculados a comparaciones entre categorías adyacentes en el PCM— de los **umbrales Thurstonianos**, definidos mediante probabilidades acumulativas.

Para cada criterio con puntuaciones 0-3, `TAM::tam.threshold()` produjo tres umbrales Thurstonianos. El umbral T_k representa la posición de θ en la que la probabilidad acumulada de obtener puntuaciones por debajo de k y la probabilidad de obtener k o una categoría

superior son ambas 0,50. En este caso, los cortes se interpretan como:

- **T1:** 0 | 1-3;
- **T2:** 0-1 | 2-3;
- **T3:** 0-2 | 3.

Los 24 umbrales se distribuyeron entre **-3,113 y 1,761 logits**. Los T1 se localizaron entre -3,113 y -1,518; los T2 entre -1,230 y -0,041; y los T3 entre -0,237 y 1,761. C05 presentó el T3 más alto (1,761), mientras que C07 presentó el T3 más bajo (-0,237); en la zona inferior, C06 y C03 mostraron los T1 más bajos (-3,113 y -3,009).

Es importante precisar el alcance de esta información. Los umbrales Thurstonianos aparecen en orden creciente por su propia definición acumulativa; por tanto, observar $T1 < T2 < T3$ **no constituye, por sí solo, una prueba de que las categorías funcionen óptimamente ni un diagnóstico independiente de “ausencia de desorden”**. Su valor principal en este análisis es interpretativo: permiten localizar sobre una métrica común los sucesivos cortes acumulativos y compararlos con la distribución de los grupos. Una evaluación más fuerte del funcionamiento de cada categoría requeriría examinar además las curvas de probabilidad o curvas características de categorías y los diagnósticos de ajuste correspondientes (Wilson, 2023).

La Figura 11 utiliza precisamente esta función interpretativa de los umbrales. Presenta, sobre una misma escala logit, la distribución WLE de los 221 grupos y los 24 umbrales Thurstonianos de C01-C08, organizados en los tres cortes acumulativos T1, T2 y T3. Esta disposición permite examinar directamente la **focalización** del sistema de puntuación: dónde se concentran los grupos y qué regiones del continuo quedan cubiertas por los cortes entre categorías.

Mapa grupo-umbrales de la situación de desempeño grupal

Distribución WLE de los grupos y 24 umbrales Thurstonianos de C01–C08 sobre una escala común en logits




Figura 11. Focalización de la situación de desempeño grupal mediante el mapa grupo-umbrales bajo el Partial Credit Model. La distribución WLE de 221 grupos y los 24 umbrales Thurstonianos de los ocho criterios se representan sobre una escala común en logits. Los cortes acumulativos corresponden a T1 = 0 | 1-3, T2 = 0-1 | 2-3 y T3 = 0-2 | 3. La figura se utiliza para examinar localización y cobertura del continuo; el orden creciente de los umbrales no constituye, por sí solo, evidencia suficiente sobre el funcionamiento de las categorías.

La comparación entre la distribución WLE y los umbrales muestra que una parte importante de los cortes —especialmente los T2— se ubica en la región baja-media, donde también se concentra una proporción relevante de los grupos. La cobertura se vuelve más limitada hacia posiciones positivas altas: aunque algunos T3 alcanzan esa región, en particular C05 con T3 = 1,761 logits, el número de cortes disponibles disminuye. En el extremo inferior, C06 y C03 presentan los T1 más bajos (-3,113 y -3,009), mientras que C07 presenta el T3 más bajo (-0,237), lo que evidencia diferencias relevantes entre criterios en la localización de sus cortes acumulativos.

El análisis continuo de precisión realizado sobre el PCM complementa esta lectura: la información del puntaje conjunto alcanza su máximo aproximadamente en $\theta = -0,71$ y disminuye hacia

los extremos, mientras el SEM aumenta. Este patrón es coherente con el resumen por tramos presentado en la Figura 10 y refuerza la conclusión de que el puntaje conjunto está mejor focalizado en la zona baja-media y media que en el extremo superior.

Esta interpretación debe mantenerse subordinada a la evidencia de estructura interna. Dado que el CFA unidimensional mostró ajuste insuficiente, la escala θ del PCM no debe reificarse como si representara un único constructo sustantivo ya demostrado. La Figura 11 describe la focalización del **puntaje conjunto bajo el modelo ajustado**; no demuestra que los cinco atributos nominales estén diferenciadamente medidos ni que puedan reportarse como subpuntuaciones independientes.


La Figura 12 se mantiene **únicamente con una función de trazabilidad técnica**: documenta los dos parámetros step libres de la parametrización PCM2 recuperados del modelo estimado. No constituye una pieza central de evidencia sobre el funcionamiento de las categorías y no debe

utilizarse para sustituir los tres umbrales Thurstonianos acumulativos. Su inclusión permite dejar explícita la diferencia entre la parametrización interna del modelo y las representaciones interpretativas utilizadas para examinar focalización y categorías.

A. Parámetros de paso bajo PCM2

Criterio	step1 (PCM2)	step2 (PCM2)
C01	-1,415	-0,179
C02	-1,260	-0,099
C03	-1,551	0,121
C04	-0,914	-0,085
C05	-1,888	0,149
C06	-1,839	0,157
C07	-0,772	0,358
C08	-1,052	0,130

B. Localización de los parámetros de paso en el continuo



Nota. step1 y step2 corresponden a parámetros libres de la parametrización PCM2 y no equivalen a los tres umbrales Thurstonianos acumulativos.

Figura 12. Parámetros de paso estimados bajo la parametrización PCM2 para los ocho criterios de la situación de desempeño grupal. Se presentan step1 y step2 como parámetros libres de la parametrización del modelo. La figura tiene una finalidad de trazabilidad técnica: estos coeficientes no equivalen a los tres umbrales Thurstonianos acumulativos ni permiten, por sí solos, evaluar el funcionamiento de las cuatro categorías.

Los valores de step1 y step2 muestran que los criterios difieren en la localización de estos parámetros dentro de PCM2, pero esa variación debe interpretarse exclusivamente en el nivel de la parametrización. En particular, observar $\text{step1} < \text{step2}$ no demuestra que las cuatro categorías funcionen adecuadamente ni reemplaza el análisis de umbrales acumulativos o de curvas de probabilidad de categoría. Por esta razón, las conclusiones sustantivas sobre focalización y funcionamiento categorial deben apoyarse en los análisis específicos correspondientes, no en esta figura de trazabilidad.

La **Figura 13** presenta la relación entre el puntaje total observado en la situación de desempeño grupal y la posición WLE estimada bajo el Partial Credit Model. Los puntajes observados abarcan de 0 a 24 puntos y se traducen en posiciones aproximadas entre $-5,06$ y $3,52$ logits. No se observaron grupos con puntajes totales entre 1 y 3; esta discontinuidad corresponde a la

distribución empírica de la muestra y no a una restricción del modelo.

La relación es creciente, pero no lineal. En la zona central, diferencias de un punto en el puntaje total producen cambios relativamente graduales en la posición WLE, mientras que hacia los extremos las distancias entre posiciones sucesivas se amplían. En el extremo superior, este patrón es coherente con la menor cobertura de umbrales mostrada en la Figura 11 y con el aumento del error estándar resumido en la Figura 10. El tamaño de los puntos permite observar, además, dónde se concentran los 221 grupos dentro de la escala de puntaje.

La Figura 13 debe interpretarse como una representación de la transformación del puntaje conjunto a la métrica del PCM, **condicionada al modelo ajustado**. No aporta, por sí sola, evidencia de que los ocho criterios definan una única dimensión sustantiva ni habilita subpuntuaciones diferenciadas por atributo; esas

cautelos permanecen determinadas por la evidencia de estructura interna presentada en la sección 6.3.




Figura 13. Relación entre puntaje observado y posición estimada (WLE) en la situación de desempeño grupal bajo el Partial Credit Model. Se presentan los puntajes totales observados de 221 grupos y su posición WLE correspondiente; el tamaño de los puntos indica la frecuencia de grupos en cada puntaje. No se observaron grupos con puntajes 1-3. La mayor separación entre posiciones estimadas hacia los extremos es coherente con la precisión condicional del puntaje conjunto y, en particular, con la menor información relativa en la zona superior. La figura describe el comportamiento del puntaje conjunto bajo el PCM y no demuestra por sí misma unidimensionalidad sustantiva.

Para examinar directamente el **funcionamiento modelado de las cuatro categorías**, se

calcularon las curvas de probabilidad de categoría (CCC), es decir, $P(X_i=k|\theta)$, para los ocho criterios sobre una grilla común del continuo. El diagnóstico mostró que, dentro del rango de θ examinado, **las cuatro categorías alcanzan una región modal propia en los ocho criterios**: cada categoría llega a ser la respuesta más probable en algún intervalo del continuo. Este resultado aporta una evidencia más pertinente sobre la diferenciación categorial que el simple orden de los umbrales acumulativos.

La principal señal para inspección adicional se observó en **C07**, donde la categoría 2 (Satisfactorio) presenta una región modal comparativamente estrecha, aproximadamente entre $\theta=-0,80$ y $\theta=-0,75$. Esta señal no implica, por sí sola, que la categoría funcione inadecuadamente ni permite atribuir el patrón a los evaluadores. Indica, más acotadamente, que la zona en la que esa categoría domina frente a las restantes es reducida y que conviene revisar su formulación sustantiva y comprobar su estabilidad en nuevas aplicaciones.

La Figura 14 ilustra tres patrones contrastantes: C03, C05 y C07. Las líneas verticales punteadas corresponden a los umbrales Thurstonianos acumulativos y se incluyen solo como referencias de localización; no deben confundirse con los parámetros step de PCM2 ni con los puntos en que necesariamente se cruzan categorías adyacentes.




Figura 14. Funcionamiento de las categorías de puntuación bajo el Partial Credit Model. Se presentan las curvas de probabilidad de categoría para C03, C05 y C07 como ejemplos de patrones contrastantes. Las cuatro categorías alcanzan una región modal propia en los ocho criterios dentro del rango de habilidad examinado. C07 presenta la principal señal descriptiva para inspección adicional: la categoría 2 (Satisfactorio) posee una región modal comparativamente estrecha. Las líneas verticales punteadas indican los umbrales Thurstonianos acumulativos T1-T3.

6.6. Sensibilidad a evaluadores

Intervalos de Wilson (95 %). El margen máximo observado para $n = 221$ fue de **6,58 puntos porcentuales**, reportado como $\pm 6,6$ pp al redondear a un decimal.

Bootstrap por evaluador (2000 remuestras). La amplitud de los intervalos obtenidos mediante bootstrap por evaluador fue considerablemente mayor: **amplitud mediana de 16,9 puntos porcentuales y amplitud máxima de 23,5 puntos porcentuales** (en C03-Óptimo).

La diferencia entre ambas estimaciones indica que las distribuciones agregadas por criterio y nivel son sensibles a la composición del conjunto de evaluadores que calificó los grupos. Esta sensibilidad, sin embargo, **no constituye una estimación de severidad individual ni de acuerdo interevaluador**. El escaso cruce evaluador $\times$ grupo impide separar estadísticamente el efecto del evaluador de las características del grupo, de la sección o de las condiciones de aplicación. La interpretación respaldada es, por tanto, más acotada: **las distribuciones agregadas varían según la composición del conjunto de evaluadores, pero el diseño no permite atribuir esa variación causalmente a severidad individual**.

6.7. Interpretación integrada de la situación grupal

¿Qué evidencia proporcionaba este instrumento? Una descripción razonablemente consistente —en el sentido de covariación global entre criterios— del desempeño observado por 221 grupos en una actuación breve y acotada, evaluada por 25 docentes distintos, en torno a cinco atributos nominales representados por uno o dos criterios cada uno.

¿Qué podía interpretarse a nivel grupal? Patrones descriptivos agregados: qué criterios concentraron mayor proporción de niveles altos o bajos, y señales sobre la estructura de covariación entre criterios —en particular, la fuerte asociación observada entre Comunicación, Trabajo grupal e individual y Liderazgo (Factor 1 del AFE)—.

¿Qué no podía atribuirse a nivel individual? Ninguna de las puntuaciones de este instrumento puede desagregarse, sin evidencia adicional, en una contribución diferenciada de cada integrante

del grupo. Transformar una puntuación grupal en una calificación o nivel individual de cada estudiante no está respaldado por el diseño de esta evidencia.

¿Qué mostraban consistencia y precisión?

Una consistencia global alta (alfa ordinal = 0,855; omega total = 0,924), acompañada de una confiabilidad WLE razonable (0,782) para el desempeño grupal en su conjunto, pero con un omega jerárquico considerablemente menor (0,595) que advierte contra interpretar esa consistencia global como evidencia de una única dimensión fuerte subyacente a los cinco atributos.

7. Inferencias que permite y no permite sostener la primera aproximación

Esta síntesis no repite las cifras ya presentadas; construye una interpretación conjunta de ambos instrumentos a la luz de los principios de validez introducidos en la sección 2.2.

7.1. Inferencias respaldadas

La evidencia reunida en las secciones 5 y 6 permite sostener, con un respaldo razonable, los siguientes usos **descriptivos**: describir patrones agregados de respuesta en la prueba individual (proporción de acierto por ítem, distribución de puntaje total, proporción de puntajes máximos); identificar ítems relativamente más fáciles o más difíciles dentro del instrumento virtual, y criterios con mayor o menor concentración de niveles altos dentro del instrumento presencial; describir distribuciones agregadas por criterio en la situación grupal (medias, porcentajes por nivel); detectar y documentar problemas de cobertura del contenido (desalineaciones entre atributo declarado y demanda efectiva; número desigual de oportunidades de observación por atributo); e identificar señales de estructura interna y de funcionamiento de ítems/criterios (inestabilidad factorial, ajuste insuficiente del modelo unidimensional presencial, dificultades Rasch desplazadas hacia el extremo fácil) que, precisamente por señalar problemas, justifican y orientan el proceso de rediseño documentado en las partes siguientes de este reporte.

7.2. Inferencias insuficientemente respaldadas

La misma evidencia no permite sostener, con el diseño e instrumentos utilizados en esta primera aproximación: **producir una estimación confiable y diferenciada de cada uno de los diez atributos institucionales**, dado que solo tres atributos aparecen nominalmente en ambos instrumentos y, aun en esos casos, las demandas y unidades de análisis difieren; varios atributos cuentan con un único ítem o criterio, y Liderazgo y Trabajo inter y multidisciplinario carecen de representación nominal en el instrumento virtual; **interpretar la respuesta a un único ítem como una medición completa de un atributo**, porque una respuesta dicotómica aislada no puede, por construcción, representar una progresión cualitativa de niveles de desarrollo; **convertir directamente los criterios de la situación grupal en niveles individuales de cada estudiante**, porque la unidad de análisis del instrumento presencial es el grupo, no el estudiante, y no existe información que permita desagregar contribuciones individuales;

interpretar los factores exploratorios obtenidos (tanto en el instrumento virtual como en el presencial) como una taxonomía alternativa de atributos, porque, como se explicó en las secciones 5.3 y 6.3, esas agrupaciones pueden reflejar características del método, de la tarea o del número limitado de oportunidades de observación, y no necesariamente una estructura sustantiva distinta a la declarada; **atribuir las diferencias observadas entre evaluadores exclusivamente a severidad individual**, porque el diseño no separa evaluador, grupo, sección y condiciones de aplicación; y **utilizar el puntaje total de cualquiera de los dos instrumentos como representación suficiente del perfil de innovación y emprendimiento de un estudiante o de una cohorte**, porque ambos puntajes agregan evidencia de cobertura parcial y desigual sobre atributos institucionales declarados como distintos entre sí.

7.3. Matriz de inferencias

Tabla 6. Matriz de inferencias

Inferencia pretendida	Evidencia disponible	Nivel de respaldo	Principal limitación	Implicación
Describir el desempeño agregado de la cohorte en cada instrumento	Distribuciones de puntaje, proporciones de acierto, medias por criterio	Respaldada para uso descriptivo	Ninguna relevante a este nivel	Puede reportarse como línea base agregada
Comparar dificultad relativa entre ítems (virtual) o criterios (presencial)	Dificultades Rasch/PCM, proporciones de acierto, medias por criterio	Respaldada para uso descriptivo	Los valores describen el instrumento aplicado, no la "dificultad del atributo" en general	Útil para el rediseño de tareas, no para comparar atributos entre sí
Estimar el nivel de un estudiante en un atributo específico (virtual)	1–2 ítems dicotómicos por atributo	Insuficientemente respaldada	Cobertura mínima; imposibilidad de representar progresión cualitativa con 1 ítem	No debe reportarse como estimación por atributo
Estimar el nivel de un estudiante en un atributo específico (presencial)	Puntuación grupal en 1–2 criterios por atributo	No evaluable con el diseño disponible	Unidad de análisis es el grupo, no el individuo	No debe desagregarse a nivel individual sin evidencia adicional
Sostener una dimensión general única por instrumento	CFA unidimensional (ambos instrumentos)	Parcialmente respaldada (virtual) / Insuficientemente respaldada (presencial)	Cargas heterogéneas (virtual); RMSEA = 0,212 y ω jerárquico bajo (presencial)	El puntaje total no debe tratarse como medida homogénea de un constructo único
Interpretar agrupaciones del AFE como nueva taxonomía de atributos	AFE de 3 factores (ambos instrumentos)	No evaluable con el diseño disponible	Estructura exploratoria inestable o mezclada con método/tarea	No reespecificar atributos institucionales a partir de este análisis exploratorio
Atribuir diferencias entre evaluadores a severidad	Intervalos de Wilson y bootstrap por evaluador	No evaluable con el diseño disponible	Escaso cruce evaluador $\times$ grupo; ausencia de doble corrección	Reportar solo como sensibilidad de las distribuciones, no como severidad
Usar el puntaje total como perfil de innovación y emprendimiento	Puntaje total (ambos instrumentos)	Insuficientemente respaldada	Cobertura parcial y desigual de los diez atributos	No sustituye una medición diferenciada por atributo

7.4. Implicación para el rediseño

El conjunto de limitaciones documentado en esta parte —de cobertura, de estructura interna, de precisión y de diseño de evaluadores— no se resuelve agregando más ítems al instrumento virtual, cambiando su formato de selección única a otro formato, mejorando la redacción de la rúbrica presencial, o simplemente ensayando un modelo estadístico distinto sobre los mismos datos. Cada uno de esos ajustes operaría sobre síntomas —número de oportunidades, formato de tarea, modelo de puntuación— sin resolver el problema

que los antecede: la primera aproximación institucional del Hito 0 operó, en lo esencial, mediante una asociación directa entre atributo, criterio de evaluación e ítem o pregunta, sin haber explicitado antes, para cada uno de los diez atributos, qué variable se pretende representar ni cómo se espera que esa variable difiera cualitativamente entre estudiantes que ingresan a Ingeniería.

Por ello, la pregunta que debe responderse antes de continuar ajustando instrumentos no es "¿qué ítems agregar o cambiar?", sino:

¿qué variable representa realmente cada atributo y cómo esperamos que difiera cualitativamente entre estudiantes que ingresan a Ingeniería?

Responder esta pregunta —para cada uno de los diez atributos institucionales— es precisamente el propósito de la construcción de los **Construct Maps**, introducidos conceptualmente en la sección 2 de este reporte y desarrollados en la parte siguiente.

Referencias de la PARTE II

American Educational Research Association, American Psychological Association, & National Council on Measurement in Education. (2014). Standards for educational and psychological testing. American Educational Research Association.

Bock, R. D., & Mislevy, R. J. (1982). Adaptive EAP estimation of ability in a microcomputer environment. *Applied Psychological Measurement*, 6(4), 431-444. <https://doi.org/10.1177/014662168200600405>

Brown, L. D., Cai, T. T., & DasGupta, A. (2001). Interval estimation for a binomial proportion. *Statistical Science*, 16(2), 101-133. <https://doi.org/10.1214/ss/1009213286>

Dunn, T. J., Baguley, T., & Brunsden, V. (2014). From alpha to omega: A practical solution to the pervasive problem of internal consistency estimation. *British Journal of Psychology*, 105(3), 399-412. <https://doi.org/10.1111/bjop.12046>

Fabrigar, L. R., Wegener, D. T., MacCallum, R. C., & Strahan, E. J. (1999). Evaluating the use of exploratory factor analysis in psychological research. *Psychological Methods*, 4(3), 272-299. <https://doi.org/10.1037/1082-989X.4.3.272>

Field, C. A., & Welsh, A. H. (2007). Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 69(3), 369-390. <https://doi.org/10.1111/j.1467-9868.2007.00593.x>

Flora, D. B., & Curran, P. J. (2004). An empirical evaluation of alternative methods of estimation for confirmatory factor analysis with ordinal data. *Psychological Methods*, 9(4), 466-491. <https://doi.org/10.1037/1082-989X.9.4.466>

Gadermann, A. M., Guhn, M., & Zumbo, B. D. (2012). Estimating ordinal reliability for Likert-type and ordinal item response data: A conceptual, empirical, and practical guide. *Practical Assessment, Research, and Evaluation*, 17, Article 3. <https://doi.org/10.7275/n560-j767>

Hayton, J. C., Allen, D. G., & Scarpello, V. (2004). Factor retention decisions in exploratory factor analysis: A tutorial on parallel analysis. *Organizational Research Methods*, 7(2), 191-205. <https://doi.org/10.1177/1094428104263675>

Holgado-Tello, F. P., Chacón-Moscó, S., Barbero-García, I., & Vila-Abad, E. (2010). Polychoric versus Pearson correlations in exploratory and confirmatory factor analysis of ordinal variables. *Quality & Quantity*, 44(1), 153-166. <https://doi.org/10.1007/s11135-008-9190-y>

Horn, J. L. (1965). A rationale and test for the number of factors in factor analysis. *Psychometrika*, 30(2), 179-185. <https://doi.org/10.1007/BF02289447>

Hu, L.-t., & Bentler, P. M. (1999). Cutoff criteria for fit indexes in covariance structure analysis: Conventional criteria versus new alternatives. *Structural Equation Modeling: A Multidisciplinary Journal*, 6(1), 1-55. <https://doi.org/10.1080/10705519909540118>

- Lai, K., & Green, S. B. (2016). The problem with having two watches: Assessment of fit when RMSEA and CFI disagree. *Multivariate Behavioral Research*, 51(2-3), 220-239. <https://doi.org/10.1080/00273171.2015.1134306>
- Linacre, J. M. (2002). Optimizing rating scale category effectiveness. *Journal of Applied Measurement*, 3(1), 85-106.
- Marsh, H. W., Hau, K.-T., & Wen, Z. (2004). In search of golden rules: Comment on hypothesis-testing approaches to setting cutoff values for fit indexes and dangers in overgeneralizing Hu and Bentler's (1999) findings. *Structural Equation Modeling: A Multidisciplinary Journal*, 11(3), 320-341. https://doi.org/10.1207/S15328007SEM1103_2
- Masters, G. N. (1982). A Rasch model for partial credit scoring. *Psychometrika*, 47(2), 149-174. <https://doi.org/10.1007/BF02296272>
- McNeish, D. (2018). Thanks coefficient alpha, we'll take it from here. *Psychological Methods*, 23(3), 412-433. <https://doi.org/10.1037/met0000144>
- Myford, C. M., & Wolfe, E. W. (2003). Detecting and measuring rater effects using many-facet Rasch measurement: Part I. *Journal of Applied Measurement*, 4(4), 386-422.
- Myford, C. M., & Wolfe, E. W. (2004). Detecting and measuring rater effects using many-facet Rasch measurement: Part II. *Journal of Applied Measurement*, 5(2), 189-227.
- Newcombe, R. G. (1998). Two-sided confidence intervals for the single proportion: Comparison of seven methods. *Statistics in Medicine*, 17(8), 857-872. [https://doi.org/10.1002/\(SICI\)1097-0258\(19980430\)17:8%3C857::AID-SIM777%3E3.0.CO;2-E](https://doi.org/10.1002/(SICI)1097-0258(19980430)17:8%3C857::AID-SIM777%3E3.0.CO;2-E)
- Rasch, G. (1980). Probabilistic models for some intelligence and attainment tests. University of Chicago Press. (Original work published 1960)
- Rosseel, Y. (2012). lavaan: An R package for structural equation modeling. *Journal of Statistical Software*, 48(2), 1-36. <https://doi.org/10.18637/jss.v048.i02>
- Sánchez-Mendiola, M., Manzano-Patiño, A. P., García-Minjares, M., Buzo Casanova, E., Herrera Penilla, C. J., Goytia-Rodríguez, K., & Martínez-González, A. (2023). Large-scale diagnostic assessment in first-year university students: Pre- and transpandemic comparison. *Educational Assessment, Evaluation and Accountability*, 35, 503-523. <https://doi.org/10.1007/s11092-023-09410-9>
- Sireci, S., & Faulkner-Bond, M. (2014). Validity evidence based on test content. *Psicothema*, 26(1), 100-107. <https://doi.org/10.7334/psicothema2013.256>
- Warm, T. A. (1989). Weighted likelihood estimation of ability in item response theory. *Psychometrika*, 54(3), 427-450. <https://doi.org/10.1007/BF02294627>
- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158), 209-212. <https://doi.org/10.1080/01621459.1927.10502953>
- Wilson, M. (2023). *Constructing measures: An item response modeling approach* (2nd ed.). Routledge. <https://doi.org/10.4324/9781003286929>
- Wind, S. A., Engelhard, G., Jr., & Wesolowski, B. (2016). Exploring the effects of rater linking designs and rater fit on achievement estimates within the context of music performance assessments. *Educational Assessment*, 21(4), 278-299. <https://doi.org/10.1080/10627197.2016.1236676>

PARTE III

CONSTRUCCIÓN INICIAL DE LOS CONSTRUCT MAPS

Nota sobre el estado de esta versión. Esta parte presenta la arquitectura de los diez Construct Maps **inmediatamente anterior al juicio experto**, recuperada de los documentos preliminares de cada atributo y de las versiones archivadas utilizadas para su evaluación. La evidencia disponible confirma que, en esta etapa, los diez atributos fueron formulados como progresiones inicialmente unidimensionales de cuatro waypoints; las reespecificaciones posteriores se presentan exclusivamente en la Parte V.

8. Estrategia de rediseño basada en Construct Maps

9. Arquitectura inicial de los diez Construct Maps

10. Paso hacia la evidencia de contenido

8. Estrategia de rediseño basada en Construct Maps

8.1. Por qué el rediseño comenzó por los constructos

La Parte II de este reporte concluyó que las limitaciones documentadas en la primera aproximación del Hito 0 —de cobertura, de estructura interna, de precisión y de diseño de evaluadores— no podían resolverse agregando más preguntas al instrumento virtual, modificando la rúbrica de la situación grupal, cambiando el formato de aplicación, o ensayando modelos estadísticos distintos sobre los mismos datos. El problema identificado era anterior a cualquiera de esos ajustes: **los diez atributos institucionales no estaban todavía especificados como variables de medición con una progresión cualitativa explícita**. La primera aproximación había operado mediante una asociación directa entre atributo, criterio de evaluación e ítem o pregunta, sin explicitar antes, para cada atributo, qué variable se pretendía representar ni cómo se esperaba que esa variable difiriera cualitativamente entre estudiantes que ingresan a Ingeniería.

Por esta razón, el equipo del proyecto decidió volver al primer componente del BEAR Assessment System, introducido conceptualmente en la sección 2.6: el **Construct Map**. Antes de diseñar nuevos instrumentos, era necesario responder, para cada uno de los diez atributos, un conjunto de preguntas sustantivas: ¿qué se pretende medir? ¿qué varía entre estudiantes respecto de este atributo? ¿qué significa mostrar un desarrollo relativamente menor o mayor? ¿qué formas cualitativamente diferentes pueden distinguirse a lo largo de esa variable? ¿qué queda fuera del constructo, es decir, qué características relacionadas no deben confundirse con él? ¿y qué tipo de evidencia futura permitiría observarlo? Responder estas preguntas, atributo por atributo, es precisamente el trabajo que se documenta en esta parte del reporte.

8.2. Unidad de análisis conceptual: Construct Maps person-side

La documentación metodológica del sistema utilizado para construir y someter a juicio los mapas formula explícitamente esta distinción: "El mapa describe posiciones posibles de las personas en el atributo. Los ítems o tareas se diseñan después para producir evidencia sobre esas posiciones." Los diez Construct Maps del Hito 0 fueron, por tanto, formulados explícitamente como **person-side Construct Maps**: mapas que describen diferencias hipotetizadas entre personas respecto de una variable, no una secuencia de tareas ni un banco de ítems.

Esta distinción —entre **person-side** e **item-side**— es central para comprender qué tipo de documento se está examinando en esta parte. Un Construct Map person-side no debe responder la pregunta "¿qué tan difícil es una tarea?", que corresponde al componente posterior de Items Design (sección 2.6, retomado en la sección 8.11 y desarrollado en la Parte VI). Debe responder, en cambio, la pregunta "¿qué formas cualitativamente diferentes del atributo podría manifestar un estudiante?". Cada uno de los diez mapas presentados en esta parte describe, en consecuencia, posiciones posibles de las personas —no un conjunto de preguntas—, y las eventuales tareas capaces de generar evidencia sobre esas posiciones constituyen un desarrollo posterior.

8.3. Fuentes utilizadas para construir los mapas

La construcción inicial combinó antecedentes institucionales, principios de construct modelling, referentes curriculares para calibrar el perfil de ingreso y literatura conceptual pertinente a cada dominio. Los documentos preliminares de los diez mapas permiten identificar referentes específicos utilizados para delimitar o contrastar cada atributo; su función fue sustantiva y orientadora, no la de convertir marcos de egreso o estándares profesionales en expectativas directas para estudiantes de ingreso.

A. Referentes conceptuales documentados en la construcción inicial.

Tabla 7. Referentes conceptuales documentados en la construcción inicial

Atributo	Referentes conceptuales documentados
Comunicación	ABET; CDIO Syllabus; BEAR/ <i>construct modelling</i> de Wilson
Trabajo grupal e individual	ABET; CDIO; BEAR/ <i>construct modelling</i> ; antecedentes institucionales del diagnóstico inicial
Interacción con usuarios reales	ABET; CDIO; ISO 9241-210 sobre diseño centrado en las personas; Design Council/Double Diamond; BEAR
Diseño	Design Thinking; ABET; CDIO; BEAR/ <i>construct modelling</i> ; posteriormente profundizado con literatura específica de diseño
Teoría de innovación y emprendimiento	Oslo Manual; EntreComp; Wilson & Sloane; Wilson
Seguridad y riesgos	ABET; ISO 31000; ISO 12100; NIOSH Hierarchy of Controls; Wilson & Sloane; Wilson
Liderazgo	ABET; CDIO; literatura sobre desarrollo de liderazgo; Wilson & Sloane; Wilson
Economía y gestión	ABET; CDIO; EntreComp; marcos de competencia financiera; Wilson & Sloane; Wilson
Ética y profesionalismo	ABET; códigos y marcos de ética profesional en ingeniería; Wilson & Sloane; Wilson
Trabajo inter y multidisciplinario	CDIO; literatura sobre convergencia e interdisciplinariedad; Wilson & Sloane; Wilson

Nota: la tabla identifica familias de referentes documentadas en la construcción inicial. Su presencia no implica que todos funcionaran como estándares de logro ni que cada uno determine directamente la estructura final del Construct Map.

B. Marcos transversales de innovación y emprendimiento. EntreComp (Bacigalupo et al., 2016), FINCODA (Marin-Garcia et al., 2016) y el Oslo Manual (OECD/Eurostat, 2018) ofrecieron cobertura conceptual transversal para interpretar oportunidades, acción, recursos, creatividad, colaboración, implementación y creación de valor. Estos marcos no definieron mecánicamente los diez atributos; sirvieron para contrastar y delimitar las denominaciones institucionales.

C. Antecedentes institucionales y curriculares. Se utilizaron la definición institucional de los diez atributos, la Trayectoria de Innovación y Emprendimiento y las tablas de especificaciones de la primera aproximación del Hito 0. Estas últimas funcionaron como antecedente crítico: el diagnóstico retrospectivo mostró precisamente qué debía superarse al pasar de una asociación atributo-pregunta a una variable de medición explícita.

D. Bases Curriculares de 3.º y 4.º medio. Las Bases Curriculares se utilizaron como referente de **plausibilidad del perfil de ingreso**, no como definición final de los constructos ni como estándar obligatorio de logro. Esta función permitió calibrar los extremos superiores y advertir cuando ciertas oportunidades de aprendizaje dependían de trayectorias electivas o Técnico-Profesionales.

La secuencia de trabajo puede sintetizarse como: **atributos institucionales y diagnóstico previo → búsqueda y contraste de referentes conceptuales → formulación de Construct Maps person-side → calibración para perfil de ingreso → juicio experto.**

8.4. Principios de construcción de medidas utilizados

Los mapas se construyeron siguiendo los principios de construct modelling introducidos en la sección 2.4, derivados principalmente de Wilson (2023). En términos operativos, cada Construct Map debía: representar una **característica interpretable**, no una lista de contenidos o temas; contener una **variable progresiva** explícita, formulada como una frase que describe qué cambia a lo largo del continuo; **diferenciar cualitativamente posiciones**, describiendo waypoints que representan formas distintas de actuar o pensar, no solamente "más" o "menos" de lo mismo; **mantener coherencia entre definición y waypoints**; **evitar confundir cantidad de comportamiento con calidad de desarrollo** —por ejemplo, no interpretar mayor cantidad de intervención, de contacto o de menciones como evidencia automática de mayor desarrollo del atributo—; **permitir posteriormente diseñar oportunidades de observación**; y **formular hipótesis**

susceptibles de contraste empírico, y no afirmaciones ya validadas.

8.5. Hipótesis inicial de unidimensionalidad sustantiva

En su construcción inicial, los diez atributos fueron formulados **provisionalmente como progresiones unidimensionales**: cada mapa presenta una única variable progresiva y un único conjunto ordenado de cuatro waypoints (W1 a W4), sin subdivisiones internas —incluidos Diseño y Teoría de innovación y emprendimiento, que serían posteriormente reespecificados—.

Es indispensable presentar esta unidimensionalidad inicial en sus términos correctos: **una hipótesis sustantiva de trabajo**, no una propiedad ya demostrada del atributo. Construir inicialmente una progresión única permitía formular, para cada atributo, la pregunta: ¿qué variable dominante organiza las diferencias cualitativas entre estudiantes respecto de este atributo? Formular esa pregunta de manera unidimensional no cerraba, sin embargo, la posibilidad de que la evidencia posterior mostrara que la variable estaba mal definida, que existían varios componentes independientes, o que el atributo requería, en definitiva, una estructura multidimensional. De hecho, en al menos dos de los diez mapas —Economía y gestión y Ética y profesionalismo—, la propia frontera conceptual formulada en esta versión inicial anticipa explícitamente esta posibilidad como pregunta abierta dirigida al panel de expertos, dado que ambos atributos institucionales combinan dos nociones (economía y gestión; ética y profesionalismo) que podrían, en principio, no compartir una única capacidad dominante. No corresponde a esta parte del reporte anticipar qué determinó el juicio experto al respecto para estos ni para los demás atributos; esa evidencia se desarrolla en la Parte IV.

8.6. Principio de monotonicidad sustantiva

Los mapas se construyeron bajo el supuesto de que los waypoints debían organizarse de manera que una posición superior representara una transformación cualitativa coherente respecto de la posición anterior —el principio de **monotonicidad sustantiva**—. Este supuesto no implica que todo estudiante recorra exactamente los mismos pasos; no implica que los waypoints estén igualmente separados entre sí; no implica

que el desarrollo sea estrictamente lineal, ni que una persona no pueda ubicarse entre dos waypoints o mostrar evidencias mixtas; y no implica que cada waypoint constituya una etapa curricular obligatoria. La hipótesis sustantiva es, en cambio, más limitada y precisa: **las manifestaciones pueden ordenarse razonablemente desde formas cualitativamente menos desarrolladas hacia formas más desarrolladas respecto de una variable definida**. Esa ordenación es una hipótesis de trabajo, formulada para ser evaluada por juicio experto y, en etapas posteriores, contrastada empíricamente —no una secuencia ya demostrada.

8.7. Cuatro waypoints como decisión inicial de modelamiento

Los diez Construct Maps iniciales utilizaron, de manera uniforme, **cuatro waypoints**. El BEAR Assessment System no prescribe un número fijo de posiciones para todos los constructos, por lo que la elección de cuatro se entiende como una **decisión pragmática y parsimoniosa de modelamiento inicial**: disponer de suficientes posiciones para representar cambios cualitativos sin convertir el mapa en una taxonomía excesivamente fina antes de observar respuestas estudiantiles.

Los waypoints fueron formulados desde el inicio como **hipótesis revisables**. Su orden, distinguibilidad y eventual necesidad de combinar, dividir o reordenar posiciones deberán contrastarse mediante evidencia de contenido, procesos de respuesta y datos de aplicación. En consecuencia, el número cuatro no constituye una propiedad validada del constructo ni predetermina cuatro categorías de puntuación. El **Outcome Space** seguirá siendo una decisión posterior, informada por las respuestas efectivamente observadas y por la evidencia que produzcan las tareas.

8.8. Extremos del continuo y perfil de ingreso

Un aspecto central de la construcción de cada mapa fue delimitar cuidadosamente sus dos extremos, en función del propósito específico del Hito 0: caracterizar el **perfil de ingreso**, no representar toda la progresión hasta el perfil de egreso.

Extremo inferior. Cada mapa formula su primer waypoint como una **manifestación mínima pero sustantiva** del constructo. Este extremo no equivale automáticamente a ausencia, error, ignorancia o conducta completamente deficitaria: representa, en cambio, la forma más simple pero genuina en que el atributo puede manifestarse de manera reconocible. Por ejemplo, el primer waypoint inicial de Comunicación no describía ausencia de comunicación, sino "comunicar información, ideas o puntos de vista pertinentes de manera generalmente comprensible, aunque con organización y adecuación todavía limitadas"—una manifestación sustantiva, aunque menos desarrollada que las posiciones superiores—.

Extremo superior. Cada mapa formula su último waypoint como una manifestación relativamente sofisticada pero **plausible para un estudiante que ingresa a Ingeniería**, no como desempeño profesional ni como dominio disciplinar universitario. Cada mapa declara además explícitamente qué **no** exige el extremo superior—por ejemplo, en Diseño: no exige cálculos técnicos especializados, prototipos funcionales avanzados ni dominio disciplinar universitario—. Este criterio es fundamental para toda la arquitectura: el Hito 0 pretende diferenciar posiciones **dentro del perfil de ingreso**, y cualquier waypoint que exigiera experiencia profesional, dominio disciplinar universitario, experiencia empresarial avanzada o desempeño propio de un estudiante próximo al egreso excedería el propósito diagnóstico del instrumento.

8.9. Delimitación: qué incluye y qué no incluye cada constructo

Una parte sustantiva de la construcción de cada mapa consistió en establecer fronteras explícitas: qué constituye evidencia central del constructo, qué habilidades relacionadas pero distintas no deben confundirse con él, qué conocimientos especializados no son necesarios, qué características personales no deberían convertirse en indicadores indirectos, y qué resultados o productos no equivalen automáticamente al atributo. Algunos ejemplos ilustran esta lógica: **liderazgo ≠ cargo formal** (no requiere autoridad formal); **diseño ≠ calidad estética o técnica del producto** (el foco está en el proceso de decisión); **trabajo grupal ≠ simple presencia o coordinación de tareas sin integración** (se

distingue explícitamente de Liderazgo y de Trabajo inter y multidisciplinario); **comunicación ≠ conocimiento disciplinar del contenido comunicado**.

8.10. Fronteras entre los diez atributos

Los diez mapas incorporan, de manera consistente, una sección de frontera conceptual que busca evitar que una misma evidencia se utilice indiscriminadamente para sostener inferencias sobre varios atributos sin una lógica explícita. Las fronteras documentadas entre pares de atributos particularmente próximos entre sí son las siguientes: **Trabajo grupal e individual ↔ Liderazgo** (regulación de la propia contribución frente a influencia intencional sobre la dirección del colectivo); **Trabajo grupal e individual ↔ Trabajo inter y multidisciplinario** (coordinación social del equipo frente a integración epistemológica de áreas de conocimiento); **Diseño ↔ Interacción con usuarios reales** (proceso de decisión de diseño frente a obtención de evidencia de personas); **Diseño ↔ Economía y gestión** (proceso de decisión de diseño frente a viabilidad económica y organización de la implementación); **Teoría de innovación y emprendimiento ↔ Economía y gestión** (comprensión conceptual frente a planificación concreta de recursos y ejecución); **Ética y profesionalismo ↔ Seguridad y riesgos** (juicio normativo general frente a análisis causal del riesgo técnico); y **Comunicación ↔ comprensión o dominio del contenido comunicado** (organización, adaptación y regulación del mensaje, no conocimiento disciplinar ni calidad técnica del contenido). **Se deja registrado que la frontera explícita entre Diseño y Teoría de innovación y emprendimiento —par sugerido como posible zona de proximidad conceptual— no aparece formulada de manera igualmente directa en el texto de ambos mapas iniciales;** solo puede inferirse indirectamente a partir de sus respectivas definiciones.

No es necesario afirmar que estas fronteras estaban completamente resueltas en esta primera versión: como se mostrará en la Parte IV, varias de ellas fueron objeto de comentarios y observaciones específicas del panel de expertos. Lo que corresponde establecer en esta parte es que la construcción inicial de los mapas ya incorporaba, de manera explícita y no accidental,

un esfuerzo sistemático por delimitar estas fronteras antes de someter los mapas a juicio experto.

8.11. Relación entre Construct Map y futura evidencia

Durante la construcción inicial de los mapas también se consideraron, de manera preliminar, elementos que anticipan el componente posterior de Items Design: qué tipo de actuación podría hacer observable cada variable, qué contextos resultarían plausibles para el perfil de ingreso, qué conocimientos previos deberían evitarse para no contaminar la medición con ventajas curriculares desiguales, y qué tareas podrían eventualmente permitir distinguir entre waypoints adyacentes. Esta consideración se refleja, en cada uno de los diez mapas, en la insistencia reiterada en que los niveles superiores no deben depender de trayectorias formativas desiguales. Debe quedar claro, sin embargo, que estas consideraciones **no constituyen todavía el Items Design definitivo**: su función en esta fase fue exclusivamente comprobar que cada

constructo fuera **potencialmente observable**, no diseñar las tareas mismas. El diseño de ítems, escenarios y situaciones de desempeño corresponde a una etapa posterior del sistema BEAR, retomada conceptualmente en la sección 10 y desarrollada en la Parte VI.

9. Arquitectura inicial de los diez Construct Maps

Esta sección presenta la síntesis del estado de los diez mapas inmediatamente antes del juicio experto. El desarrollo íntegro de cada mapa inicial —definición completa, frontera conceptual, anclaje curricular con páginas específicas y descripción completa de cada waypoint— se reserva como anexo técnico; lo que se presenta a continuación es lo necesario para comprender, en la Parte V, qué cambió y por qué.

9.1. Tabla comparativa de los diez mapas iniciales

Tabla 8. Tabla comparativa de los diez mapas iniciales

Panel A. Atributo y variable progresiva inicial

Código	Atributo	Variable progresiva inicial
COM	Comunicación	Grado de control intencional sobre el mensaje según propósito, audiencia e interacción
TG	Trabajo grupal e individual	Grado de regulación de la propia contribución dentro de una estructura de interdependencias
UR	Interacción con usuarios reales	Grado en que la comprensión de usuarios y problemas está regulada por evidencia procedente de interacción con personas
DI	Diseño	Grado de control deliberado sobre decisiones de diseño mediante problema, criterios, alternativas y evidencia
IE	Teoría de innovación y emprendimiento	Coherencia conceptual de la representación de innovación y emprendimiento
SR	Seguridad y riesgos	Grado en que el estudiante representa relaciones entre peligro, exposición y daño, compara riesgos y selecciona o revisa medidas de control
LG	Liderazgo	Alcance y regulación de la influencia que ejerce el estudiante sobre la acción colectiva
EG	Economía y gestión	Grado en que el estudiante organiza y revisa la viabilidad de una iniciativa integrando recursos y condiciones de ejecución
EP	Ética y profesionalismo	Grado en que el estudiante identifica dimensiones éticas y profesionales, considera afectados y responsabilidades, compara cursos de acción y justifica decisiones revisables
IM	Trabajo inter y multidisciplinario	Grado en que el estudiante reconoce, relaciona, integra y revisa aportes provenientes de diferentes perspectivas de conocimiento

Panel B. Waypoints de los mapas iniciales

Código	W1	W2	W3	W4
COM	Comunicar información pertinente	Organizar el mensaje según un propósito	Adaptar el mensaje al contexto y la audiencia	Regular la comunicación mediante la interacción
TG	Contribuir al trabajo colectivo	Coordinar la propia contribución	Integrar contribuciones interdependientes	Regular las interdependencias del equipo
UR	Reconocer a las personas involucradas	Interpretar evidencia de usuarios	Contrastar supuestos mediante interacción directa	Regular la comprensión mediante evidencia de usuarios
DI	Proponer una solución inicial	Delimitar el desafío mediante criterios	Explorar y comparar decisiones de diseño	Regular iterativamente el diseño mediante evidencia
IE	Reconocer innovación y emprendimiento como idea o iniciativa	Diferenciar idea, innovación e implementación	Analizar iniciativas desde la creación de valor	Evaluar innovación y emprendimiento como procesos adaptativos
SR	Identificar peligros	Explicar cómo puede producirse el daño	Evaluar riesgos y seleccionar controles	Revisar la gestión del riesgo
LG	Mobilizar una acción puntual	Orientar la acción colectiva	Facilitar la acción colectiva	Regular y distribuir la influencia
EG	Identificar condiciones de viabilidad y ejecución	Organizar recursos y acciones para la implementación	Evaluar la viabilidad de alternativas	Reconfigurar la viabilidad y la ejecución
EP	Reconocer una preocupación ética o profesional	Relacionar afectados, consecuencias y responsabilidades	Evaluar cursos de acción responsable	Deliberar y revisar ante tensiones e incertidumbre
IM	Reconocer la necesidad de perspectivas diferentes	Diferenciar los aportes de distintas perspectivas	Integrar perspectivas	Evaluar y reconfigurar críticamente la integración

Nota. Los dos paneles forman parte de la misma Tabla 8. El Panel A presenta la variable progresiva inicial de cada atributo; el Panel B presenta los cuatro waypoints correspondientes, conservando el mismo código de identificación.

9.2. Síntesis comparativa de la arquitectura inicial

El examen conjunto de los diez mapas iniciales permite identificar patrones transversales, sin evaluar todavía cuáles resultaron mejor o peor valorados por el juicio experto —evaluación que corresponde a la Parte IV—.

Tipo de progresión formulada. Los diez atributos fueron formulados, sin excepción, como progresiones unidimensionales de cuatro waypoints. Ninguno presenta, en esta versión, subdivisiones internas o strands.

Elementos comunes a los diez mapas. Todos comparten una misma arquitectura retórica: una definición del constructo centrada en el estudiante que ingresa a Ingeniería; una variable progresiva formulada como una frase nominal (no un simple nombre de atributo); una frontera conceptual que declara explícitamente qué no mide el constructo, frecuentemente en relación con uno o más atributos vecinos; un anclaje curricular con referencias específicas y verificables a páginas de las Bases Curriculares; cuatro waypoints ordenados de menor a mayor desarrollo, con el

extremo inferior etiquetado uniformemente como manifestación inicial observable y el extremo superior como mayor desarrollo plausible dentro del perfil de ingreso; y tres transiciones explícitas entre waypoints adyacentes, formuladas como cambios cualitativos y no como incrementos de cantidad.

Proximidades conceptuales detectadas ya en esta etapa. Como se desarrolló en la sección 8.10, la construcción inicial ya identificó y intentó delimitar explícitamente varias zonas de proximidad conceptual entre atributos: Trabajo grupal e individual con Liderazgo y con Trabajo inter y multidisciplinario; Diseño con Interacción con usuarios reales y con Economía y gestión; Teoría de innovación y emprendimiento con Economía y gestión; y Ética y profesionalismo con Seguridad y riesgos.

Aspectos que requerían necesariamente evidencia externa antes de consolidarse. Al menos dos mapas —Economía y gestión y Ética y profesionalismo— incorporaron, en su propia frontera conceptual, una pregunta abierta dirigida explícitamente al panel de expertos sobre si sus cuatro waypoints sostenían efectivamente una

misma capacidad dominante, dado que ambos atributos institucionales combinan dos nociones distintas en su propia denominación. Esta es una señal documentada de que, ya en la fase de construcción, el equipo del proyecto reconocía que la hipótesis de unidimensionalidad no podía darse por sentada para todos los atributos por igual, y que su sostenibilidad dependería de evidencia todavía no disponible en esta etapa. **Se deja registrado, adicionalmente, un matiz de redacción particular en el mapa inicial de Liderazgo:** su waypoint superior ya incorporaba, en esta versión previa al juicio experto, un lenguaje próximo a "fortalecer la capacidad colectiva para decidir, actuar y reorganizarse", que anticipaba parcialmente, en el extremo superior de la progresión, un vocabulario cercano al que terminaría organizando el eje completo del mapa tras el refinamiento documentado en la Parte V —sin que ello implique que la variable progresiva completa hubiera sido reformulada ya en esta etapa inicial—.

La conclusión de esta sección es la siguiente: los diez Construct Maps constituyeron una primera arquitectura sustantiva e hipotética que permitía, por primera vez, someter explícitamente a evaluación no solo los nombres de los atributos, sino también su definición, variable progresiva, waypoints, orden y fronteras conceptuales.

10. Paso hacia la evidencia de contenido

Construir los diez Construct Maps no bastaba, por sí solo, para considerarlos adecuados. Cada mapa constituye, como se ha insistido a lo largo de esta parte, una **hipótesis sustantiva**: una propuesta razonada, pero todavía no contrastada, sobre qué varía entre estudiantes respecto de un atributo y cómo se organiza esa variación. Antes de avanzar hacia el diseño de tareas, escenarios y situaciones de desempeño capaces de generar evidencia empírica sobre estos constructos, era necesario obtener un primer tipo de evidencia de validez: la

evidencia basada en el **contenido**, introducida conceptualmente en la sección 2.2.

Para ello era necesario someter cada uno de los diez mapas al juicio de especialistas del dominio, y evaluar explícitamente si, a su juicio: el mapa representaba adecuadamente el atributo, sin omisiones sustantivas; la definición, los waypoints y las transiciones estaban formulados con claridad; el mapa mantenía unidad conceptual; la progresión propuesta entre waypoints resultaba plausible; los waypoints adyacentes se diferenciaban suficientemente entre sí como para ser reconocidos y, en el futuro, medidos; y el mapa resultaba adecuado para caracterizar a estudiantes que ingresan a Ingeniería.

Este procedimiento dio origen al proceso de **juicio experto**, cuyo diseño, resultados cuantitativos y análisis cualitativo se desarrollan en la parte siguiente de este reporte. Los diez mapas presentados en esta parte son, hasta este punto del reporte, hipótesis formuladas y no todavía evidencia contrastada.

Referencias de la PARTE III

- Bacigalupo, M., Kampylis, P., Punie, Y., & Van den Brande, G. (2016). EntreComp: The entrepreneurship competence framework. Publications Office of the European Union. <https://doi.org/10.2791/593884>
- Marin-Garcia, J. A., Andreu-Andrés, M. A., Atares-Huerta, L., Aznar-Mas, L. E., García-Carbonell, A., González-Ladrón-de-Guevara, F., Montero Fleta, B., Pérez-Peñalver, M. J., & Watts, F. (2016). Proposal of a framework for innovation competencies development and assessment (FINCODA). WPOM—Working Papers on Operations Management, 7(2), 119–126. <https://doi.org/10.4995/wpom.v7i2.6472>
- OECD/Eurostat. (2018). Oslo Manual 2018: Guidelines for collecting, reporting and using data on innovation (4th ed.). OECD Publishing. <https://doi.org/10.1787/9789264304604-en>
- Wilson, M. (2023). Constructing measures: An item response modeling approach (2nd ed.). Routledge. <https://doi.org/10.4324/9781003286929>

PARTE IV

JUICIO EXPERTO Y EVIDENCIA DE CONTENIDO

11. Propósito y diseño del juicio experto

13. Metodología del análisis cualitativo

15. Resultados del análisis cualitativo

17. Diagnóstico por atributo

19. Interpretación global del juicio experto

12. Metodología del análisis cuantitativo

14. Resultados cuantitativos del juicio experto

16. Triangulación cuantitativa–cualitativa

18. Matriz global de priorización

20. Transición hacia el refinamiento de los Construct Maps

11. Propósito y diseño del juicio experto

11.1. Propósito de la evaluación experta

La Parte III mostró que cada uno de los diez Construct Maps constituye una hipótesis sustantiva: una propuesta razonada, pero no contrastada, sobre qué varía entre estudiantes respecto de un atributo y cómo se organiza esa variación. Que el equipo del proyecto considerara plausibles estas definiciones y progresiones no bastaba para sostenerlas como base de un sistema de medición diagnóstica. Era necesario obtener evidencia externa e independiente que permitiera examinar, para cada mapa, su pertinencia de contenido, su claridad, su coherencia interna, la plausibilidad de su progresión, la diferenciación entre sus waypoints y su adecuación al perfil de ingreso.

El juicio experto constituyó, en este sentido, la primera fuente sistemática de **evidencia de validez basada en el contenido**, en los términos introducidos en la sección 2.2. La literatura metodológica concibe esta fuente de evidencia como un examen sistemático de la congruencia entre el dominio definido, los componentes de la evaluación y las interpretaciones previstas, combinando razonamiento sustantivo y procedimientos documentados de evaluación experta (Haynes et al., 1995; Sireci & Faulkner-Bond, 2014; AERA, APA, & NCME, 2014). Su propósito no fue certificar definitivamente los mapas, convertir la opinión de los especialistas en una verdad objetiva, ni seleccionar automáticamente mapas mediante una regla numérica. Su función fue aportar evidencia sistemática para **examinar, cuestionar y refinar** las hipótesis sustantivas construidas en la etapa anterior.

11.2. Panel de especialistas

El análisis definitivo del juicio experto se apoyó en un panel **intencional de cinco especialistas**, seleccionado por la pertinencia y complementariedad de su experiencia para examinar los diez Construct Maps. En estudios de evidencia de contenido, la utilidad del panel depende de que las personas convocadas posean conocimiento relevante para el dominio y de que su conformación y tarea se documenten

explícitamente; el número de jueces, por sí solo, no constituye garantía de validez (Lynn, 1986; Rubio et al., 2003; Sireci & Faulkner-Bond, 2014). Los perfiles cubrieron formación en innovación y emprendimiento, diseño industrial, evaluación educativa y analítica del aprendizaje, economía y estudios de futuros, y ciencias sociales aplicadas a educación e innovación.

Los años de experiencia declarados en la base primaria fueron **25, 30, 10, 0 y 5 años**, por lo que el rango documentado es de **0 a 30 años**. La mayoría de los integrantes pertenece a la propia universidad y el panel incluyó además una persona externa, de otra institución de educación superior, vinculada a evaluación de competencias por desempeño. No se identifica a los participantes por nombre; se describen por sus perfiles de experiencia, que son los antecedentes relevantes para interpretar la evidencia de contenido.

Cada participante completó una declaración de antecedentes —institución, formación profesional, grado académico, área principal de experiencia y años de experiencia— y confirmó haber leído el propósito y las instrucciones antes de emitir su juicio. El carácter intencional del panel está documentado, aunque no se cuenta con un protocolo prespecificado de reclutamiento que establezca umbrales formales de inclusión; por ello, no se atribuyen retrospectivamente criterios de selección más específicos que los efectivamente documentados.

11.3. Material presentado a los expertos

Para cada uno de los diez atributos, el panel recibió el Construct Map completo en su versión inicial, reconstruida en la Parte III de este reporte: nombre institucional del atributo, nombre propuesto para su medición, definición del constructo, variable progresiva, frontera conceptual (qué incluye y qué no incluye el atributo), un anclaje curricular referido a las Bases Curriculares de 3.º y 4.º medio, y los cuatro waypoints con su descripción y la lógica de transición entre ellos. El panel recibió además un marco metodológico introductorio —que explicaba qué es un Construct Map, la función de los waypoints y las transiciones, el carácter person-side del continuo, y su condición de hipótesis revisable— y orientaciones explícitas para emitir su juicio, entre ellas: evaluar el mapa como propuesta para estudiantes de ingreso y no como

estándar de egreso; prestar especial atención a la definición, los waypoints y las transiciones; y utilizar las Bases Curriculares como referencia de plausibilidad y no como estándar escolar obligatorio.

11.4. Criterios de evaluación

El panel evaluó cada uno de los diez Construct Maps mediante **seis criterios**, aplicados de manera idéntica a todos los atributos:

C1 — Relevancia y cobertura. Si el mapa representa los aspectos esenciales del atributo, sin omisiones sustantivas, y resulta pertinente para el propósito diagnóstico del Hito 0.

C2 — Claridad. Si la definición, los nombres de los waypoints, sus descripciones y las transiciones están expresados en lenguaje comprensible y sin ambigüedades innecesarias.

C3 — Coherencia y unidad del constructo. Si la definición, la variable que progresa, la frontera conceptual, los waypoints y las transiciones describen una misma capacidad dominante y se apoyan mutuamente.

C4 — Orden y progresión. Si los waypoints están ordenados de menor a mayor desarrollo y las transiciones representan cambios cualitativos plausibles.

C5 — Distinción entre waypoints. Si los waypoints adyacentes son suficientemente diferentes entre sí como para ser reconocidos y, posteriormente, medidos.

C6 — Adecuación al perfil de ingreso y al contexto. Si el mapa resulta apropiado para caracterizar estudiantes al ingreso a Ingeniería y su progresión es plausible considerando las oportunidades y expectativas de aprendizaje de la Educación Media, sin convertirlas en prerrequisitos ni exigir desempeño profesional.

Los seis criterios constituyen una **operacionalización específica para este proyecto**, no una escala estandarizada publicada. Su formulación articula principios de evidencia de contenido —representatividad/relevancia, claridad y adecuación al propósito y a la población objetivo— con principios propios del construct modelling: unidad de la variable, orden cualitativo de la progresión, diferenciación entre posiciones y posibilidad de generar evidencia observable para distinguirlas (Sireci & Faulkner-Bond, 2014; Wilson & Gochyyev, 2013; Wilson, 2023). Esta explicitación permite interpretar las valoraciones del panel como evidencia sobre aspectos definidos del mapa, y no como una aprobación global indiferenciada.

Es relevante señalar que el criterio C3 (Coherencia y unidad del constructo) fue el que, según las orientaciones entregadas al panel, debía examinar de manera más directa si los cuatro waypoints de un mapa representaban efectivamente el desarrollo de una misma capacidad —y no la combinación de habilidades relativamente independientes—, constituyéndose así en el criterio más directamente vinculado a la hipótesis de unidimensionalidad sustantiva introducida en la sección 8.5.

11.5. Escala de valoración y comentarios abiertos

Para cada uno de los seis criterios, el panel utilizó una **escala ordinal de cuatro niveles, sin categoría neutral**. El uso de escalas ordinales explícitas acompañado de comentarios abiertos permite combinar una síntesis cuantitativa del juicio con evidencia cualitativa sobre las razones de las valoraciones, práctica habitual en estudios de validez de contenido con especialistas (Aiken, 1985; Rubio et al., 2003):

Tabla 9. Escala de valoración y comentarios abiertos

Nivel	Etiqueta	Interpretación asociada
1	No cumple	Presenta problemas conceptuales o de formulación importantes; requiere reformulación sustantiva.
2	Cumple parcialmente	Incluye elementos pertinentes, pero existen omisiones, ambigüedades o problemas que requieren ajustes mayores.
3	Cumple adecuadamente	Es pertinente y comprensible; puede requerir ajustes menores que no modifican su estructura central.

Nivel	Etiqueta	Interpretación asociada
4	Cumple plenamente	Es claro, coherente y apropiado; no requiere cambios o solo correcciones mínimas de forma.

Adicionalmente, el panel disponía de una opción **N/A** ("no puedo evaluar"), reservada para cuando un especialista no contara con antecedentes o experiencia suficiente para juzgar un criterio determinado. Para cada uno de los diez atributos, el panel debía además formular una **recomendación global**, así como comentarios cualitativos abiertos, específicos por atributo y generales sobre el conjunto del sistema.

Las categorías de recomendación global efectivamente utilizadas fueron: **mantener**, **ajustes menores**, **ajustes mayores** y **reformular**.

12. Metodología del análisis cuantitativo

12.1. Estructura de los datos

El juicio experto generó un total de **cinco especialistas × diez atributos × seis criterios = 300 valoraciones**. Cada criterio se respondió mediante una escala ordinal de cuatro niveles —1 = No cumple, 2 = Cumple parcialmente, 3 = Cumple adecuadamente y 4 = Cumple plenamente—, sin categoría neutral. El formulario contempló además la opción **N/A** ("no puedo evaluar") para aquellos casos en que una persona especialista considerara que no disponía de antecedentes suficientes para emitir un juicio informado.

La revisión de la base confirmó que las 300 valoraciones previstas fueron efectivamente registradas y que ningún especialista utilizó la opción **N/A**. En términos descriptivos, esto indica que las cinco personas integrantes del panel se consideraron en condiciones de emitir una valoración sobre cada uno de los diez atributos y los seis criterios, incluidos aquellos más alejados de su área principal de especialización.

La unidad cuantitativa primaria del análisis fue la combinación **atributo × criterio**, evaluada por cinco especialistas. Esta definición es importante porque los seis criterios no representan repeticiones intercambiables de una misma pregunta, sino aspectos conceptualmente diferentes de los Construct Maps: relevancia y cobertura del contenido, claridad de la

formulación, coherencia o unidad, orden y progresión, distinción entre waypoints y adecuación al perfil de ingreso. Por ello, el análisis se realizó primero a nivel de criterio y solo posteriormente se utilizaron resúmenes descriptivos por atributo.

12.2. V de Aiken

Para sintetizar cuantitativamente las valoraciones de contenido se utilizó la **V de Aiken** (Aiken, 1985). Este coeficiente fue desarrollado para resumir valoraciones emitidas mediante escalas ordenadas y ha sido utilizado extensamente como índice de relevancia o adecuación de contenido en estudios basados en juicio experto.

Para un conjunto de n jueces que utiliza una escala de c categorías, la V puede expresarse como:

$$V = \sum s_i / [n(c - 1)]$$

donde $s_i = r_i - l$, r_i es la puntuación otorgada por el juez i y l es la puntuación mínima de la escala (Aiken, 1985). Con una escala de 1 a 4, el coeficiente varía entre 0 —cuando todas las valoraciones se ubican en la categoría mínima— y 1 —cuando todas se ubican en la categoría máxima—.

En este estudio, la V se interpreta como un **índice de relevancia o adecuación del contenido derivado de las valoraciones de especialistas**. No se la interpreta como un coeficiente específicamente diseñado para estimar acuerdo interevaluador, ni como un indicador de consistencia interna o de precisión de puntuaciones. Tampoco se la trata como una "prueba de validez" definitiva. Esta precisión es consistente con la concepción contemporánea de la validez: la evidencia basada en contenido es una fuente dentro de un argumento más amplio sobre la interpretación y el uso de las puntuaciones (AERA et al., 2014; Sireci & Faulkner-Bond, 2014).

La V de Aiken se calculó para cada una de las **60 celdas atributo × criterio**, utilizando las cinco valoraciones disponibles en cada celda. Esta constituye la unidad de interpretación principal

del coeficiente, porque permite identificar si una debilidad se concentra, por ejemplo, en claridad, progresión o adecuación al perfil, en lugar de diluirla en un único promedio.

Adicionalmente, para facilitar la comparación descriptiva entre mapas, se calculó para cada atributo el **promedio aritmético de sus seis V de criterio**. Este valor se denomina en el reporte **V media** o, de forma más precisa, **promedio descriptivo de las seis V de criterio**. No corresponde a una nueva V inferencial del Construct Map completo, ni a un coeficiente global independiente de validez. Su función es exclusivamente resumir la señal cuantitativa de los seis criterios sin reemplazar el análisis desagregado.

Esta distinción es importante: dos atributos con la misma V media pueden presentar perfiles de criterio muy diferentes. Uno puede mostrar seis valoraciones moderadamente favorables y otro cinco valoraciones altas junto con una debilidad muy localizada. La decisión de refinamiento no puede basarse únicamente en el promedio si se pretende identificar qué componente específico del mapa requiere revisión.

12.3. Intervalos de confianza de la V de Aiken

Para cada estimación de V se calculó además un **intervalo de confianza del 95 %**, siguiendo el procedimiento de intervalo de puntuación propuesto por Penfield y Giacobbi (2004) para el índice de relevancia de contenido de Aiken. La incorporación de intervalos de confianza responde a una necesidad fundamental: distinguir entre el valor puntual observado y el grado de precisión con que ese valor puede estimarse a partir de un panel de tamaño finito.

Con solo cinco especialistas, la incertidumbre alrededor de cada estimación es necesariamente considerable. En este proyecto, la amplitud promedio de los intervalos por celda atributo $\times$ criterio fue cercana a 0,40 en la escala 0-1. Por tanto, una V puntual no debe leerse con una precisión que el tamaño del panel no permite sostener. Penfield y Giacobbi (2004) muestran precisamente la utilidad de acompañar la V con un intervalo que represente la incertidumbre asociada a la estimación, en lugar de utilizar exclusivamente el valor observado.

Los intervalos se utilizaron con una finalidad interpretativa y no como un mecanismo automático de aceptación o rechazo. En particular, cuando dos valores puntuales difieren pero sus intervalos son amplios y se superponen de manera sustantiva, la evidencia disponible aconseja prudencia antes de convertir esa diferencia descriptiva en un orden jerárquico preciso entre mapas. La superposición de intervalos no se utilizó como una prueba formal de igualdad entre estimaciones; su función fue evidenciar que el nivel de precisión del panel no justifica interpretar pequeñas diferencias puntuales como distinciones concluyentes.

La misma cautela se aplica al promedio descriptivo de las seis V de criterio de un atributo. Promediar los seis coeficientes facilita la síntesis, pero no transforma automáticamente ese promedio en una estimación inferencial independiente ni elimina la incertidumbre de las valoraciones que lo componen.

12.4. Por qué no se utilizó un punto de corte automático

Una decisión metodológica central fue **no establecer una regla mecánica** del tipo “V inferior a un determinado valor implica rechazar el mapa” o “V igual o superior a ese valor implica aceptarlo”. Esta decisión responde tanto a las características concretas de los datos como al estatus que la evidencia de contenido ocupa dentro del proceso de validación.

En primer lugar, el panel estuvo compuesto por cinco especialistas. Aunque este tamaño permite obtener una señal experta útil, también produce intervalos de confianza relativamente amplios. Un punto de corte rígido aplicado a estimaciones poco precisas podría generar decisiones cualitativamente distintas a partir de diferencias numéricas pequeñas que no están suficientemente determinadas por la evidencia (Penfield & Giacobbi, 2004).

En segundo lugar, los seis criterios evaluaron **aspectos conceptualmente distintos** de cada Construct Map. Una V media relativamente favorable puede coexistir con un problema sustantivo localizado, por ejemplo, en la claridad de la variable progresiva, en la unidad conceptual del constructo o en la adecuación de un waypoint

superior al perfil de ingreso. Un único valor agregado no permite distinguir esas situaciones.

En tercer lugar, la evidencia cuantitativa se obtuvo en conjunto con comentarios abiertos. La evidencia basada en contenido incluye tanto la valoración sobre la representatividad y pertinencia como el razonamiento sustantivo que permite detectar omisiones, ambigüedades, solapamientos conceptuales o problemas de formulación que un promedio numérico no puede representar por sí solo (AERA et al., 2014).

Finalmente, la V de Aiken es una síntesis de valoraciones y no una frontera natural entre “válido” y “no válido”. La literatura no proporciona un único punto de corte universal cuya aplicación sea independiente del número de jueces, la escala, el propósito de la evaluación, la precisión de las estimaciones y las consecuencias de la decisión. Por esta razón, en este proyecto la V se utilizó como una **señal cuantitativa descriptiva dentro de una triangulación más amplia**, no como una regla automática para decidir qué mapas mantener, ajustar o reespecificar.

Esta decisión evita dos reducciones metodológicas: equiparar una estimación favorable con “validación” del Construct Map y equiparar una estimación menos favorable con evidencia suficiente para descartarlo. En ambos casos, la interpretación requiere integrar el criterio específico afectado, la incertidumbre estadística, la evidencia cualitativa y la coherencia sustantiva del constructo.

12.5. Estadísticos descriptivos complementarios

Además de la V de Aiken y sus intervalos de confianza, el análisis incorporó estadísticos descriptivos complementarios con el propósito de caracterizar la distribución de las valoraciones y examinar la robustez descriptiva de las señales observadas.

Se calcularon la media de las valoraciones por criterio y por atributo en la escala original de 1 a 4, la V mínima observada dentro de cada atributo —para identificar el criterio que concentró la evaluación menos favorable— y medidas descriptivas de la tendencia relativa de cada especialista a utilizar puntuaciones más altas o más bajas a lo largo del panel completo.

Estas diferencias de uso de la escala se interpretaron como **variabilidad descriptiva entre especialistas**, no como estimaciones formales de severidad. Con cinco jueces y sin un diseño destinado específicamente a separar efectos de evaluador, no corresponde atribuir automáticamente una tendencia de puntuación más baja a una “severidad” latente estimada con precisión. La terminología se mantiene, por tanto, en un nivel descriptivo.

Para los atributos con menor V media se realizó, además, un análisis de sensibilidad **leave-one-expert-out**: se recalculó la señal descriptiva excluyendo, una persona a la vez, a cada integrante del panel. Este procedimiento permitió examinar si la evaluación menos favorable dependía de una sola persona especialmente exigente. Los resultados mostraron que la señal se mantenía al excluir sucesivamente a cualquiera de las cinco personas especialistas.

Este análisis se interpreta exclusivamente como **análisis descriptivo de sensibilidad o robustez**. No genera una nueva medida de validez, no sustituye la V de Aiken y no convierte las muestras reducidas resultantes en estimaciones independientes. Su utilidad consiste en mostrar si una conclusión descriptiva cambia de manera radical cuando se retira una observación experta particular.

En conjunto, la V por criterio, sus intervalos de confianza, el promedio descriptivo por atributo, la V mínima, las medias en la escala original, la variabilidad entre especialistas y el análisis leave-one-out se utilizaron como componentes complementarios. Ninguno de ellos constituyó por sí solo una regla decisional. La interpretación final se realizó mediante la triangulación con los comentarios cualitativos y con la coherencia sustantiva de cada Construct Map.

13. Metodología del análisis cualitativo

13.1. Enfoque metodológico

Los comentarios abiertos del panel se examinaron mediante **análisis cualitativo de contenido con estrategia deductivo-inductiva**. El procedimiento tomó como referencia principal el enfoque de Schreier (2012), complementado con desarrollos metodológicos que distinguen formas

deductivas, dirigidas e inductivas de análisis de contenido cualitativo (Elo & Kyngäs, 2008; Hsieh & Shannon, 2005).

La estrategia combinó dos fuentes de categorías. La primera fue **deductiva**: antes de examinar el corpus completo ya existía una arquitectura conceptual derivada de los Construct Maps y de los seis criterios sometidos a juicio experto. Esto proporcionó categorías iniciales sobre definición del constructo, progresión, waypoints, fronteras, observabilidad, condiciones de aplicación y adecuación al perfil de ingreso. La segunda fuente fue **inductiva**: durante la lectura del corpus se admitieron categorías nuevas cuando los comentarios planteaban problemas, tensiones o implicaciones que no podían representarse adecuadamente mediante el marco inicial.

Esta combinación evita dos extremos. Un análisis exclusivamente deductivo podría forzar comentarios relevantes dentro de categorías definidas antes de conocer todas las observaciones del panel. Un análisis exclusivamente inductivo, en cambio, ignoraría que el juicio experto se diseñó expresamente para evaluar componentes específicos de una arquitectura de medición ya formulada. La estrategia híbrida permitió utilizar el marco teórico como punto de partida sin tratarlo como un sistema de codificación cerrado (Elo & Kyngäs, 2008; Hsieh & Shannon, 2005; Schreier, 2012).

El objetivo del análisis no fue calcular la frecuencia de “opiniones” como si cada unidad codificada constituyera un voto independiente. Su propósito fue identificar qué problemas sustantivos señalaba el panel, cómo se relacionaban esos problemas con componentes específicos de los mapas y qué convergencias, divergencias o excepciones debían considerarse en la posterior decisión de refinamiento.

13.2. Unidad de análisis

La unidad operativa de codificación fue la **unidad de significado**. Un comentario fuente podía contener una sola observación o varias observaciones conceptualmente diferentes. Cuando un mismo comentario abordaba, por ejemplo, la definición general del atributo y además cuestionaba el orden entre dos waypoints, ambos segmentos se trataron como unidades de

significado diferenciadas para efectos de codificación.

La distinción entre comentario fuente y unidad de significado es coherente con la literatura de análisis de contenido cualitativo, que diferencia el material contextual de origen de los segmentos textuales que contienen una idea suficientemente coherente para ser condensada, codificada y posteriormente agrupada en categorías (Graneheim & Lundman, 2004). La segmentación permite conservar la especificidad analítica sin asumir que todo el contenido de un comentario pertenece necesariamente a una sola categoría.

Antes de realizar cualquier conteo o segmentación se aplicó una regla de preparación de datos necesaria por la estructura particular del registro. Cuando un mismo comentario abierto aparecía repetido en las seis filas correspondientes a los seis criterios de un mismo atributo, y esa repetición provenía del formato de almacenamiento de las respuestas —no de una decisión del especialista de formular seis veces la misma observación—, el comentario se **deduplicó a una sola instancia por experto × atributo**.

Esta deduplicación no se presenta como una técnica general del análisis cualitativo, sino como una decisión de preparación destinada a preservar la unidad real de observación del corpus. Sin ella, una sola observación habría sido transformada artificialmente en seis ocurrencias idénticas, inflando cualquier conteo posterior y generando una falsa apariencia de recurrencia. Solo después de esta deduplicación se segmentaron los comentarios en unidades de significado.

La consecuencia interpretativa es importante: el número de unidades de significado no equivale al número de especialistas ni al número de comentarios fuente. Una persona especialista puede producir varias unidades dentro de un mismo comentario, y varias unidades pueden derivarse de una única observación compleja. Por ello, las frecuencias se utilizaron únicamente como apoyo descriptivo y no como sustituto de la lectura sustantiva del contenido.

13.3. Categorías de codificación

Las unidades de significado se organizaron inicialmente mediante un marco de categorías directamente relacionado con los componentes del juicio experto y con la arquitectura de los

Construct Maps. Las principales categorías deductivas fueron:

- **definición del constructo**, cuando el comentario cuestionaba o precisaba qué capacidad, disposición o variable debía representar el atributo;
- **progresión entre waypoints**, cuando la observación se refería a la lógica de cambio cualitativo a lo largo del continuo;
- **waypoints específicos**, incluyendo observaciones sobre el nivel inicial, los niveles intermedios o el nivel superior;
- **fronteras conceptuales entre atributos**, cuando el panel identificaba posibles solapamientos o confusiones entre constructos vecinos;
- **tareas o condiciones futuras de observación**, cuando la observación se refería a la forma en que la evidencia podría generarse en Items Design;
- **fairness y condiciones de aplicación**, cuando se señalaban riesgos de que la manifestación observable dependiera de oportunidades formativas, antecedentes o características irrelevantes al constructo.

El marco inicial se utilizó como guía y no como taxonomía inmutable. Schreier (2012) subraya que un marco de codificación debe ser conceptualmente pertinente para la pregunta de investigación, pero también suficientemente flexible para representar el material empírico. En la misma línea, los enfoques dirigidos de análisis de contenido permiten comenzar con categorías derivadas de teoría o investigación previa y ampliar el sistema cuando aparecen contenidos que no encajan adecuadamente en esas categorías (Hsieh & Shannon, 2005).

Por ello, se incorporaron categorías emergentes cuando la lectura de los comentarios reveló problemas o argumentos no anticipados por el marco inicial. La aparición de una categoría emergente no se interpretó automáticamente como evidencia de que el Construct Map debía cambiar: primero se examinó a qué nivel del sistema de medición correspondía la observación y qué relación guardaba con las demás fuentes de evidencia.

13.4. Estrategia deductivo-inductiva

La fase deductiva estuvo anclada en el diseño mismo del juicio experto. Las categorías sobre definición, progresión, diferenciación entre waypoints, fronteras, tareas y fairness se derivaron de la estructura de los Construct Maps y de los seis criterios de evaluación utilizados por el panel. Este anclaje permitió examinar de manera sistemática si los comentarios cualitativos aportaban razones o ejemplos que explicaran las valoraciones cuantitativas.

La fase inductiva comenzó cuando la lectura del corpus puso de manifiesto observaciones que no podían ser representadas de forma suficiente mediante las categorías predefinidas. Podía tratarse de una tensión no prevista entre componentes de un mapa, de una interpretación alternativa de la variable progresiva, de una dificultad específica para observar un nivel, o de una implicación correspondiente a una etapa posterior del sistema de medición.

El procedimiento fue, por tanto, iterativo: las categorías iniciales orientaron la primera lectura, pero el material podía ampliar o matizar el marco de codificación. Este tipo de combinación deductivo-inductiva es coherente con el análisis de contenido cualitativo cuando existe un marco conceptual previo que debe contrastarse con datos textuales sin impedir la aparición de significados no previstos (Elo & Kyngäs, 2008; Hsieh & Shannon, 2005; Schreier, 2012).

La incorporación de categorías emergentes se mantuvo vinculada a una regla de pertinencia: una categoría nueva debía representar un problema analíticamente relevante para comprender la adecuación, delimitación, progresión, observabilidad o uso futuro del Construct Map. No se creó una categoría independiente para cada formulación singular si esta podía representarse adecuadamente dentro de una categoría ya existente.

Asimismo, la presencia de una categoría en varios comentarios no se trató como prueba automática de importancia sustantiva. La recurrencia fue considerada una señal útil, pero la interpretación atendió también a la especificidad del argumento, a su relación con el mapa evaluado y a si la observación convergía o entraba en tensión con otros comentarios.

13.5. Convergencias, divergencias y casos negativos

El análisis cualitativo no se limitó a contar unidades de significado. Se examinó explícitamente la relación entre las distintas observaciones del panel, distinguiendo **convergencias, divergencias y casos negativos**.

Se consideró **convergencia** cuando varias personas especialistas, de manera independiente, identificaban un problema semejante en un mismo mapa. La convergencia aumentaba la relevancia analítica de una observación, especialmente cuando aparecía formulada desde perspectivas diferentes pero apuntaba a una misma dificultad conceptual o de progresión.

Se consideró **divergencia** cuando las personas especialistas ofrecían interpretaciones distintas de un mismo componente o proponían soluciones incompatibles entre sí. La divergencia no se trató como ruido que debiera eliminarse mediante mayoría. Por el contrario, podía revelar que el propio Construct Map admitía interpretaciones alternativas o que la formulación era insuficientemente precisa.

Se consideró **caso negativo** una observación que aportaba evidencia o un argumento contrario a una interpretación que, de otro modo, habría parecido dominante. El análisis de casos negativos constituye una estrategia de rigor cualitativo porque obliga a poner a prueba las interpretaciones emergentes frente a evidencia disconfirmatoria, reduciendo el riesgo de seleccionar únicamente los datos compatibles con la lectura inicial del equipo investigador (Miles et al., 2014; Morse, 2015; Morse et al., 2002).

La atención a los casos negativos es especialmente importante en este proyecto debido al tamaño reducido del panel. Una regla de mayoría podría invisibilizar un argumento conceptualmente fuerte formulado por una sola persona. Por ello, un comentario aislado no se convirtió automáticamente en una decisión de cambio, pero tampoco se descartó por su baja frecuencia. Se examinó su fundamento, su relación con la literatura y su capacidad para revelar una amenaza a la unidad, la progresión, las fronteras o la fairness del constructo.

Esta estrategia preserva la naturaleza argumentativa del juicio experto. Las unidades de significado aportan razones y diagnósticos, no votos intercambiables. La decisión posterior de refinamiento depende de la calidad y convergencia de la evidencia disponible, no de una suma mecánica de menciones.

13.6. Distinción entre niveles del sistema BEAR

No toda observación formulada por una persona especialista debía traducirse necesariamente en una modificación del Construct Map. Para evitar confundir problemas de naturaleza diferente, los comentarios se examinaron identificando el nivel del sistema de medición al que afectaban principalmente.

Se distinguieron observaciones relativas a:

1. la **definición o arquitectura del Construct Map**, cuando cuestionaban qué variable debía representarse, cómo progresaba o cuáles eran sus fronteras;
2. el futuro **Items Design**, cuando la observación se refería al tipo de tarea, situación o escenario necesario para provocar evidencia;
3. el futuro **Outcome Space**, cuando la preocupación se relacionaba con categorías de respuesta, criterios de puntuación o reglas de decisión;
4. condiciones de **fairness o aplicación**, cuando la observación señalaba oportunidades desiguales, conocimientos irrelevantes al constructo, sesgos de contexto o restricciones de acceso a la evidencia;
5. etapas posteriores de **validación empírica**, cuando el comentario planteaba una hipótesis que solo podría contrastarse mediante procesos de respuesta, pilotaje, estructura interna o un modelo de medición.

Esta distinción se deriva de la arquitectura del BEAR Assessment System, en la que Construct Map, Items Design, Outcome Space y Measurement Model son componentes relacionados pero conceptualmente diferenciados (Wilson, 2023). Mantenerlos separados resulta metodológicamente importante porque una dificultad de tarea no implica necesariamente un problema en la definición del constructo, del mismo modo que una categoría de puntuación

poco clara no demuestra que la progresión sustantiva sea incorrecta.

La clasificación por nivel funcionó como una regla operativa de análisis. Antes de modificar un Construct Map se examinó si el comentario afectaba realmente la hipótesis sustantiva sobre la variable y su progresión o si podía resolverse en una etapa posterior mediante una tarea diferente, una regla de puntuación más precisa o un diseño de aplicación más equitativo.

Este procedimiento permitió preservar la trazabilidad de las decisiones posteriores de refinamiento. Los comentarios cualitativos se utilizaron como evidencia para formular problemas y alternativas de modelamiento, pero la modificación de un mapa requirió integrarlos con la señal cuantitativa, la coherencia conceptual, la literatura específica del dominio y los principios generales del construct modelling.

14. Resultados cuantitativos del juicio experto

14.1. Resultado global del panel

El juicio experto reunió, como se indicó en la sección 12.1, **cinco especialistas** que

completaron la totalidad de las **300 valoraciones** previstas (diez atributos × seis criterios × cinco expertos), sin datos faltantes. La media global de valoración del panel, considerando las 300 valoraciones en la escala original de 1 a 4, se ubicó por sobre el punto intermedio de la escala, sin alcanzar de manera generalizada el nivel máximo: ningún atributo obtuvo una media de panel igual a 4, y todos los atributos obtuvieron una media de panel superior a 2,5. Este patrón general anticipa el resultado desagregado por atributo presentado en la sección 14.2: el juicio experto no describió, en conjunto, mapas gravemente deficientes, pero tampoco mapas ya plenamente satisfactorios sin necesidad de revisión.

14.2. V de Aiken por atributo

La siguiente tabla presenta los diez atributos ordenados de menor a mayor V de Aiken media (promedio descriptivo de las seis V de criterio correspondientes a cada mapa), junto con la V mínima observada dentro de cada atributo, la media del panel en la escala 1–4 y la recomendación integrada derivada de la triangulación.

Tabla 10. V de Aiken por atributo

Atributo	V media	V mínima (criterio)	Media del panel (1–4)	Recomendación integrada
Teoría de innovación y emprendimiento	0,589	0,467 (C2 Claridad)	2,77	Revisión conceptual prioritaria
Diseño	0,644	0,533 (C2 Claridad)	2,93	Revisión estructural focalizada
Liderazgo	0,722	0,667 (C2 Claridad; C3 Coherencia/unidad)	3,17	Revisión conceptual focalizada
Comunicación	0,733	0,667 (C3 Coherencia/unidad; C4 Orden/progresión)	3,20	Revisión focalizada
Ética y profesionalismo	0,767	0,667 (C6 Adecuación al perfil/contexto)	3,30	Deliberación conceptual
Seguridad y riesgos	0,778	0,667 (C6 Adecuación al perfil/contexto)	3,33	Mantener arquitectura con revisión focalizada
Trabajo grupal e individual	0,778	0,667 (C1 Relevancia/cobertura)	3,33	Revisión conceptual focalizada
Economía y gestión	0,789	0,600 (C2 Claridad)	3,37	Revisión focalizada prioritaria
Interacción con usuarios reales	0,800	0,667 (C3 Coherencia/unidad)	3,40	Revisión conceptual focalizada
Trabajo inter y multidisciplinario	0,878	0,867 (C1, C2, C3, C4 y C6)	3,63	Mantener con ajustes focalizados

Nota: la V media es un promedio descriptivo de seis estimaciones atributo × criterio; no corresponde a una V inferencial independiente del mapa completo ni a un coeficiente global de validez.

Considerando el conjunto de las 60 celdas atributo $\times$ criterio, la V mínima absoluta observada fue 0,467 (Claridad de Teoría de innovación y emprendimiento) y la V máxima absoluta fue 0,933, con una V media global de 0,748 sobre las 60 celdas.

14.3. Resultados por criterio

Considerando el promedio de cada uno de los seis criterios a través de los diez atributos, **Claridad (C2) fue, en promedio, el criterio menos favorable** del conjunto del panel, mientras que **Distinción entre waypoints (C5) fue, en promedio, el criterio más favorable**. Esta constatación tiene una implicación interpretativa importante para el conjunto de los diez mapas:

el problema transversal detectado por el panel no fue, en general, que los cuatro waypoints resultaran indistinguibles entre sí, sino que varias formulaciones — definiciones, descriptores de waypoints o transiciones— requerían mayor claridad conceptual o lingüística.

Esta observación no implica que la claridad haya sido el único problema identificado, ni que todos los atributos hayan mostrado el mismo patrón: como se detalla en la sección 14.2, Diseño, Teoría de innovación y emprendimiento y Economía y gestión registraron su valoración mínima precisamente en el criterio de Claridad, mientras que Diseño, adicionalmente, registró una señal desfavorable también en Orden y progresión, según se retoma en la sección 17.

14.4. Intervalos de confianza

Dado el tamaño del panel, los intervalos de confianza del 95 % calculados para cada V de Aiken resultaron relativamente amplios. A modo de ejemplo de los casos más extremos: el intervalo de confianza de la V mínima de Teoría de innovación y emprendimiento se extendió aproximadamente entre 0,25 y 0,85 en la escala 0–1, y el de Diseño entre aproximadamente 0,30 y 0,89; en el extremo opuesto, el intervalo de confianza de la V mínima de Trabajo inter y multidisciplinario —el atributo con mejor señal cuantitativa global— se ubicó entre aproximadamente 0,62 y 0,99.

Esta amplitud tiene una consecuencia interpretativa directa: **las diferencias entre atributos deben leerse de manera descriptiva y no como un ranking estadísticamente exacto**. Varios de los intervalos de confianza de atributos con V media distinta se superponen ampliamente entre sí, por lo que no es posible afirmar, por ejemplo, que Liderazgo (V media 0,722) y Comunicación (V media 0,733) resulten estadísticamente distinguibles entre sí solo a partir de este indicador.

14.5. Recomendaciones globales de los especialistas

Para cada atributo, los cinco especialistas emitieron una recomendación global categórica: mantener, ajustes menores, ajustes mayores o reformular. La distribución completa de las **50 recomendaciones atributo $\times$ especialista** fue la siguiente:

Tabla 11. Recomendaciones globales de los especialistas

Atributo	Mantener	Ajustes menores	Ajustes mayores	Reformular	n
Comunicación	2	3	0	0	5
Diseño	0	3	2	0	5
Economía y gestión	2	2	1	0	5
Ética y profesionalismo	2	2	1	0	5
Teoría de innovación y emprendimiento	0	3	2	0	5
Trabajo inter y multidisciplinario	3	2	0	0	5
Liderazgo	2	2	0	1	5
Seguridad y riesgos	2	2	1	0	5

Atributo	Mantener	Ajustes menores	Ajustes mayores	Reformular	n
Trabajo grupal e individual	1	3	1	0	5
Interacción con usuarios reales	1	2	2	0	5

Dos atributos —**Diseño y Teoría de innovación y emprendimiento**— no recibieron ninguna recomendación de “mantener”, patrón coherente con su mayor necesidad posterior de revisión. Liderazgo fue el único atributo que recibió una recomendación explícita de **reformular**; este voto singular no se trató como decisión automática, sino como una señal que debía interpretarse junto con las otras cuatro recomendaciones, la V de Aiken y los comentarios abiertos.

La distribución categórica es un insumo complementario de triangulación. No constituye un estadístico de validez, no reemplaza el análisis por criterio y no se convierte en una regla de mayoría para decidir la arquitectura final del mapa.

15. Resultados del análisis cualitativo

15.1. Corpus analizado

El análisis cualitativo, tras la deduplicación descrita en la sección 13.2, reunió aproximadamente **142 unidades de significado procedentes de 40 comentarios fuente** (comentarios de experto × atributo, más los comentarios generales sobre el conjunto del sistema). Debe quedar explícito que esta cifra no debe leerse como un recuento de posiciones a favor o en contra: **142 unidades de significado no equivalen a 142 votos**, ni el número de unidades identificadas en un atributo determinado equivale directamente al número de especialistas que comentaron sobre él, dado que un mismo comentario podía segmentarse en varias unidades.

15.2. Temas transversales

El análisis identificó varios temas que se repitieron, con distinta intensidad, en más de un atributo: la **definición de la variable progresiva** —en varios mapas, los especialistas cuestionaron si la variable progresiva formulada capturaba efectivamente el eje central del atributo—; la **claridad** de la redacción, consistente con el resultado cuantitativo de la sección 14.3; el **nivel inicial de la progresión** (desarrollado en la

sección 15.3); la **progresión y diferenciación de waypoints** —en algunos mapas, la transición entre dos waypoints adyacentes no representaba con suficiente claridad un cambio cualitativo, sino más bien una diferencia de grado o de cantidad—; la **unidad del constructo** (sección 15.4); las **fronteras entre atributos** (sección 15.5); y **fairness y exigencia de conocimientos o experiencias previas** (sección 15.6). Estos temas no se distribuyeron de manera uniforme entre los diez atributos: como se detalla en la sección 17, cada mapa presentó una combinación particular de estos temas, con distinta intensidad relativa.

15.3. Nivel inicial de las progresiones

Un tema recurrente y metodológicamente importante fue la advertencia de que el primer waypoint (W1) de un Construct Map **no debería representar simplemente ausencia, desconocimiento, ingenuidad o déficit**. El caso mejor documentado de esta tensión corresponde a Teoría de innovación y emprendimiento: el panel observó que el nivel inicial de ese mapa debía representar una comprensión mínima pero **significativa** de innovación y emprendimiento —no una comprensión ingenua o meramente asociada a la novedad—, y que, en su formulación inicial, el nivel inferior se aproximaba a describirse en términos de déficit más que como una manifestación sustantiva y genuina del constructo.

No se generaliza aquí esta observación a la totalidad de los diez atributos: como se estableció en la sección 8.8, la mayoría de los mapas ya formulaba explícitamente su primer waypoint como una manifestación inicial observable y no como ausencia; la evidencia cualitativa reunida en esta etapa confirma que, para al menos uno de los atributos, esa intención inicial no se había logrado plenamente en la redacción sometida a juicio.

15.4. Unidad del constructo

Esta categoría —directamente vinculada al criterio C3 de la evaluación experta (sección 11.4) — examinó observaciones relativas a la posible mezcla de habilidades diferentes dentro de una

misma progresión, la presencia de más de una variable dentro de un mismo continuo, cambios en el eje de progreso entre waypoints sucesivos, o la aparición de componentes nuevos únicamente en los niveles superiores del mapa, sin que estuvieran anticipados en los niveles inferiores.

Esta categoría resultó especialmente relevante para dos atributos que se examinan en detalle en la sección 17: **Diseño**, donde la evidencia cuantitativa (V mínima en Orden y progresión, la más baja de todo el panel para ese criterio) y cualitativa convergieron de manera consistente en cuestionar si una única variable de "regulación del proceso" podía representar adecuadamente actuaciones cualitativamente distintas —proponer una solución, delimitar mediante criterios, explorar alternativas y regular mediante evidencia—; y **Liderazgo**, donde los comentarios plantearon una tensión entre el alcance de la influencia individual, por un lado, y la contribución a la capacidad de acción colectiva, por otro, como posibles ejes distintos de una misma progresión. No se adelantan aquí las soluciones que estos hallazgos motivaron; ese desarrollo corresponde a la Parte V.

15.5. Fronteras conceptuales

El panel identificó, para varios pares de atributos, posibles solapamientos que ya habían sido objeto de una delimitación explícita en la construcción inicial de los mapas (sección 8.10), pero que, a juicio de los especialistas, no quedaban completamente resueltos en la redacción sometida a evaluación. Estos comentarios resultan particularmente relevantes porque el propósito del sistema de medición es producir inferencias **diferenciadas** por atributo: si dos mapas comparten, en la práctica, evidencia observable equivalente, el sistema no estaría en condiciones de distinguir el desarrollo de un atributo del desarrollo del otro.

Entre los solapamientos señalados se cuentan, de manera consistente con lo ya identificado en la construcción inicial: la frontera entre Trabajo grupal e individual y Liderazgo, particularmente en los waypoints superiores de ambos mapas; la frontera entre Interacción con usuarios reales y Diseño, en torno a qué corresponde específicamente a cada atributo cuando una misma situación involucra tanto la obtención de evidencia de usuarios como la generación de una solución; y la frontera entre Trabajo grupal e

individual y Trabajo inter y multidisciplinario, en torno a la diferencia entre coordinación social del equipo e integración de conocimientos de distintas áreas.

15.6. Fairness y oportunidades previas

Una parte relevante de los comentarios cualitativos abordó riesgos de que el desempeño observable en los niveles superiores de ciertos mapas reflejara, más que un mayor desarrollo del atributo en sí, diferencias en las oportunidades formativas previas de los estudiantes. Estos riesgos se distinguen explícitamente de la definición sustantiva del atributo: no cuestionan qué es el constructo, sino si su medición podría verse contaminada por factores irrelevantes a él.

Entre las observaciones de este tipo se cuentan: la dependencia de los niveles superiores de Economía y gestión respecto de la trayectoria escolar específica del estudiante (la asignatura eventualmente pertinente es electiva, y la gestión financiera o administrativa aparece con mayor especificidad en la modalidad Técnico-Profesional); una dependencia curricular similar señalada para Seguridad y riesgos; la dependencia de los niveles superiores de Interacción con usuarios reales respecto de oportunidades previas de indagación directa con personas, no necesariamente comunes a toda la cohorte; y, para Liderazgo, una preocupación expresada por más de un especialista sobre el riesgo de que el atributo, tal como estaba formulado, favoreciera implícitamente patrones de dominancia o centralidad en la interacción grupal —potencialmente asociados a diferencias de género u otras características no pertinentes al constructo— por sobre las formas de contribución más distribuidas o menos visibles que también podrían constituir liderazgo genuino. Una preocupación de naturaleza similar —el riesgo de un sesgo hacia representaciones estereotipadas del emprendimiento— fue señalada también para Teoría de innovación y emprendimiento.

16. Triangulación cuantitativa–cualitativa

16.1. Principio de triangulación

Las decisiones sobre cada Construct Map no se adoptaron a partir de una sola fuente de evidencia. La lógica seguida integró: **V de Aiken**

+ intervalos de confianza + dispersión y severidad relativa del panel + recomendación global + comentarios cualitativos + coherencia sustantiva con la arquitectura del mapa y con los principios de construct modelling introducidos en la Parte III, para producir, en cada caso, un **diagnóstico integrado del Construct Map**.

Es importante aclarar que esta integración no consistió en sumar mecánicamente estos indicadores. La sección 12.4 ya estableció por qué no se utilizó un punto de corte automático sobre la V de Aiken; el mismo principio se extiende aquí a la triangulación completa: una V relativamente baja acompañada de comentarios que señalan únicamente problemas de redacción conduce a una decisión distinta que una V similar acompañada de comentarios que cuestionan la unidad misma del constructo. La sección 17 desarrolla, para cada atributo, cómo se combinó efectivamente esta evidencia.

16.2. Tipos de decisiones derivadas

De la triangulación surgió una tipología descriptiva de decisiones, aplicada de manera diferenciada según la evidencia disponible para cada atributo: **mantener** (no aparecen problemas sustantivos que justifiquen cambiar la arquitectura del mapa); **ajustar / revisión focalizada** (la variable progresiva y la arquitectura general se mantienen, pero se requieren cambios de redacción, claridad o delimitación de fronteras en aspectos puntuales); **refinar conceptualmente / revisión conceptual** (se mantiene la estructura general de una única progresión, pero es necesario revisar la definición, la variable progresiva, algún waypoint específico o las fronteras con otros atributos); **deliberar conceptualmente** (la evidencia no converge claramente hacia mantener ni hacia una revisión estructural, y se requiere una ponderación cuidadosa entre componentes del atributo que podrían, en principio, no compartir plenamente una misma progresión); y **revisión estructural focalizada** (la evidencia cuestiona aspectos de la arquitectura misma del mapa —por ejemplo, su unidimensionalidad—, sin que ello implique todavía haber determinado la solución definitiva).

16.3. No confundir prioridad con calidad absoluta

Ordenar los diez atributos según su prioridad de revisión —como se hace en las secciones 14.2 y 18— no equivale a afirmar que "el mapa con mayor V está validado" ni que "el mapa con menor V es incorrecto". La priorización indica, exclusivamente, **dónde la combinación de evidencia disponible justifica invertir un mayor esfuerzo de revisión antes de continuar** con las etapas siguientes del sistema de medición. Un atributo con V media relativamente alta y prioridad baja —como Trabajo inter y multidisciplinario— continúa siendo, en este momento del proyecto, una hipótesis sustantiva pendiente de evidencia empírica adicional, no un constructo ya validado; y un atributo con prioridad muy alta —como Teoría de innovación y emprendimiento o Diseño— no fue descartado por el panel, sino identificado como el que requería mayor inversión de trabajo conceptual antes de continuar.

17. Diagnóstico por atributo

Cada subsección presenta, de manera compacta, la señal cuantitativa, la evidencia cualitativa principal y el diagnóstico integrado resultante de la triangulación para cada uno de los diez atributos, ordenados según la prioridad de revisión resultante. No se presentan todavía, en ninguna de estas subsecciones, los Construct Maps rediseñados; ese desarrollo corresponde a la Parte V.

17.1. Teoría de innovación y emprendimiento

Señal cuantitativa. V media 0,589 (la más baja del panel); V mínima 0,467 en Claridad; media de panel 2,77; ninguna recomendación de "mantener".

Evidencia cualitativa. Los comentarios convergieron en observar que el nivel inicial de la progresión debía representar una comprensión mínima pero significativa —no ingenua— de innovación y emprendimiento (sección 15.3); que la progresión no lograba equilibrar suficientemente ambos componentes del atributo (innovación y emprendimiento) a lo largo de sus cuatro waypoints; que la noción de creación de valor debía entenderse de manera amplia, no

restringida a lo económico o comercial; y que la formulación corría el riesgo de aproximarse a una representación estereotipada del "emprendedor" asociada principalmente a startups tecnológicas, con la consiguiente preocupación de fairness señalada en la sección 15.6.

Diagnóstico. Revisión conceptual prioritaria.

Prioridad de refinamiento. Muy alta.

17.2. Diseño

Señal cuantitativa. V media 0,644; V mínima 0,533 en Claridad, con el criterio de Orden y progresión registrando también la valoración comparativamente más desfavorable de todo el panel para ese criterio específico; media de panel 2,93; ninguna recomendación de "mantener" (0 mantener, 2 ajustes mayores, 3 ajustes menores).

Evidencia cualitativa. El panel cuestionó que el punto de inicio de la progresión, centrado en proponer una solución, omitiera la comprensión y delimitación previa del desafío; señaló que la generación divergente de alternativas —la exploración de opciones antes de comparar— requería mayor visibilidad propia dentro del mapa, en lugar de aparecer únicamente como insumo de la comparación; y planteó la necesidad de diferenciar con mayor claridad la evaluación mediante criterios explícitos de la revisión basada en evidencia obtenida al poner a prueba una decisión. Esta evidencia —cuantitativa y cualitativa— convergió de manera consistente en cuestionar si una única variable de regulación del proceso de diseño podía representar adecuadamente actuaciones cualitativamente distintas (sección 15.4).

Diagnóstico. Revisión estructural focalizada. No se presenta en esta parte ninguna arquitectura alternativa; la evidencia aquí documentada estableció la necesidad de revisar la arquitectura del mapa, pero su desarrollo corresponde a la Parte V. **Prioridad de refinamiento.** Muy alta.

17.3. Liderazgo

Señal cuantitativa. V media 0,722; V mínima 0,667 en C2 Claridad y C3 Coherencia/unidad; media de panel 3,17.

Evidencia cualitativa. Los comentarios plantearon una tensión entre dos posibles ejes de la progresión: el alcance de la influencia ejercida por el estudiante, por un lado, y la regulación de

esa influencia junto con la responsabilidad y la contribución a la capacidad de acción colectiva, por otro (sección 15.4). El waypoint superior, formulado en torno a ceder o distribuir influencia, fue señalado como difícil de observar empíricamente sin más orientación. Se planteó además una preocupación de fairness relativa a que la formulación pudiera favorecer implícitamente patrones de dominancia o centralidad en la interacción grupal, potencialmente confundidos con mayor desarrollo del atributo (sección 15.6).

Diagnóstico. Revisión conceptual focalizada.

Prioridad de refinamiento. Alta.

17.4. Economía y gestión

Señal cuantitativa. V media 0,789; V mínima 0,600 en Claridad —una debilidad localizada, dado que el resto de los criterios de este atributo se ubicó en un rango más favorable, incluyendo la V máxima absoluta de todo el panel (0,933) en al menos un criterio—; media de panel 3,37.

Evidencia cualitativa. Los comentarios señalaron que varios descriptores de los waypoints incluían un número elevado de elementos simultáneos (recursos, costos, beneficios, tiempos, restricciones), dificultando su reconocimiento como una progresión clara; y retomaron, de manera consistente con lo ya anticipado en la propia construcción inicial del mapa (sección 8.5), la pregunta sobre si economía y gestión —dos nociones combinadas en la denominación institucional del atributo— compartían efectivamente una misma capacidad dominante a lo largo de los cuatro waypoints. Se señaló también la dependencia curricular de los niveles superiores respecto de trayectorias formativas específicas (sección 15.6), la más marcada entre los diez atributos evaluados.

Diagnóstico. Revisión focalizada prioritaria.

Prioridad de refinamiento. Alta.

17.5. Trabajo grupal e individual

Señal cuantitativa. V media 0,778; V mínima 0,667 en C1 Relevancia/cobertura; media de panel 3,33.

Evidencia cualitativa. Se observó una posible desconexión entre la denominación institucional del atributo —que incluye explícitamente "individual"— y el contenido efectivo de la

progresión, centrada casi exclusivamente en la contribución al trabajo colectivo, sin que ningún waypoint abordara de manera diferenciada un componente propiamente individual. Se señaló, además, la ausencia de una dimensión explícita relativa al manejo de desacuerdos o de desajustes en la distribución de la carga de trabajo dentro del equipo. Los comentarios señalaron también que la frontera entre los waypoints superiores de este atributo y los del atributo Liderazgo resultaba porosa, particularmente en torno a la regulación de la dinámica del equipo (sección 15.5).

Diagnóstico. Revisión conceptual focalizada. **Prioridad de refinamiento.** Media-alta.

17.6. Comunicación

Señal cuantitativa. V media 0,733; V mínima 0,667 en C3 Coherencia/unidad y C4 Orden/progresión; media de panel 3,20.

Evidencia cualitativa. Se observó que la progresión formulada era predominantemente **productiva** (centrada en construir y adaptar el mensaje emitido por el estudiante), mientras que su dimensión receptiva o dialógica —interpretar y responder a la interacción con otras personas— aparecía únicamente de manera instrumental en el waypoint superior, en lugar de estar integrada a lo largo de toda la progresión. Se señaló también cierta ambigüedad en la frontera entre los dos waypoints intermedios de la progresión inicial.

Diagnóstico. Revisión focalizada. **Prioridad de refinamiento.** Media.

17.7. Interacción con usuarios reales

Señal cuantitativa. V media 0,800; V mínima 0,667 en C3 Coherencia/unidad; media de panel 3,40.

Evidencia cualitativa. Los comentarios coincidieron en que el eje central del atributo debía formularse explícitamente como el **grado en que la evidencia de usuarios llega a influir en la comprensión y las decisiones del estudiante**, y no como la cantidad o frecuencia de interacción directa con personas. Se señaló la dependencia de los waypoints superiores respecto de oportunidades curriculares previas de indagación directa (sección 15.6), y una frontera todavía no completamente resuelta con el atributo Diseño en situaciones donde ambos tipos de evidencia —sobre usuarios y sobre decisiones de

diseño— podrían producirse simultáneamente (sección 15.5).

Diagnóstico. Revisión conceptual focalizada. **Prioridad de refinamiento.** Media-alta.

17.8. Seguridad y riesgos

Señal cuantitativa. V media 0,778; V mínima 0,667 en C6 Adecuación al perfil/contexto; media de panel 3,33. Este atributo mostró, en cambio, la mayor variabilidad global entre los seis criterios de entre los diez mapas evaluados.

Evidencia cualitativa. Se planteó si el waypoint superior —centrado en revisar la efectividad y las limitaciones de los controles de seguridad y el riesgo residual— resultaba plausible para un estudiante que recién ingresa a la universidad, o si se aproximaba más bien a una forma de gestión del riesgo propia de un desempeño profesional. Se señaló también la necesidad de mantener con claridad la distinción entre razonar sobre seguridad y riesgo, por un lado, y exhibir una conducta segura observada, por otro; y una dependencia curricular relevante respecto de la trayectoria Técnico-Profesional (sección 15.6).

Diagnóstico. Mantener arquitectura con revisión focalizada. **Prioridad de refinamiento.** Media.

17.9. Ética y profesionalismo

Señal cuantitativa. V media 0,767; V mínima 0,667 en C6 Adecuación al perfil/contexto; media de panel 3,30.

Evidencia cualitativa. Los comentarios examinaron, de manera consistente con lo ya anticipado en la construcción inicial del mapa (sección 8.5), si ética y profesionalismo —dos nociones combinadas en la denominación institucional del atributo— se articulaban suficientemente en una progresión común, o si el componente de responsabilidad profesional requería un tratamiento diferenciado del razonamiento ético propiamente tal. Se señaló, además, el riesgo de deseabilidad social en la evaluación de este atributo en particular —la posibilidad de que una respuesta refleje la opción socialmente esperada más que un razonamiento genuino— como una condición de fairness especialmente relevante para las etapas futuras de diseño de tareas.

Diagnóstico. Deliberación conceptual. **Prioridad de refinamiento.** Media.

17.10. Trabajo inter y multidisciplinario

Señal cuantitativa. V media 0,878 (la más alta del panel); V mínima 0,867 en C1, C2, C3, C4 y C6; media de panel 3,63. La dispersión entre los cinco especialistas fue, además, la más reducida de los diez atributos.

Evidencia cualitativa. El panel valoró este mapa como el más sólido en su conjunto, sin observaciones que cuestionaran su unidad conceptual ni su progresión general. La observación principal se concentró en el waypoint superior, sobre el cual se planteó si su exigencia

—evaluar y reconfigurar críticamente la integración entre perspectivas— resultaba plenamente calibrada para el perfil de ingreso, y en la conveniencia de hacer más explícita la distinción entre una fase inicial de aportes diferenciados por área (multidisciplinariedad) y una fase posterior de integración en que esos aportes se modifican mutuamente (interdisciplinariedad).

Diagnóstico. Mantener con ajustes focalizados. **Prioridad de refinamiento.** Baja.

18. Matriz global de priorización

Tabla 12. Matriz global de priorización

Atributo	V media	V mínima y criterio(s)	Evidencia cualitativa dominante	Recomendaciones (M / m / A / R)	Diagnóstico	Prioridad
Teoría de innovación y emprendimiento	0,589	0,467 · C2 Claridad	Equilibrio innovación/emprendimiento; nivel inicial como déficit; riesgo de estereotipo	0 / 3 / 2 / 0	Revisión conceptual prioritaria	Muy alta
Diseño	0,644	0,533 · C2 Claridad	Punto de partida centrado en solución; ideación poco visible; unidad del constructo cuestionada	0 / 3 / 2 / 0	Revisión estructural focalizada	Muy alta
Liderazgo	0,722	0,667 · C2 Claridad; C3 Coherencia/unidad	Influencia vs. capacidad colectiva; nivel superior; sesgo por dominancia	2 / 2 / 0 / 1	Revisión conceptual focalizada	Alta
Economía y gestión	0,789	0,600 · C2 Claridad	Descriptores sobrecargados; posible doble capacidad; dependencia curricular	2 / 2 / 1 / 0	Revisión focalizada prioritaria	Alta
Trabajo grupal e individual	0,778	0,667 · C1 Relevancia/coertura	Integración de la contribución individual; desacuerdo/carga; frontera con Liderazgo	1 / 3 / 1 / 0	Revisión conceptual focalizada	Media-alta
Interacción con usuarios reales	0,800	0,667 · C3 Coherencia/unidad	Influencia de la evidencia, no cantidad de contacto; frontera con Diseño	1 / 2 / 2 / 0	Revisión conceptual focalizada	Media-alta
Comunicación	0,733	0,667 · C3 Coherencia/unidad; C4 Orden/progresión	Progresión predominantemente productiva; dimensión receptiva subdesarrollada	2 / 3 / 0 / 0	Revisión focalizada	Media
Ética y profesionalismo	0,767	0,667 · C6 Adecuación al perfil/contexto	Posible doble capacidad; deseabilidad social	2 / 2 / 1 / 0	Deliberación conceptual	Media
Seguridad y riesgos	0,778	0,667 · C6 Adecuación al perfil/contexto	Calibración del nivel superior; razonamiento vs. conducta; dependencia TP	2 / 2 / 1 / 0	Mantener arquitectura con revisión focalizada	Media
Trabajo inter y multidisciplinario	0,878	0,867 · C1, C2, C3, C4 y C6	Mapa más sólido; calibración de IM4; multi- vs. interdisciplinariedad	3 / 2 / 0 / 0	Mantener con ajustes focalizados	Baja

Nota. M = mantener; m = ajustes menores; A = ajustes mayores; R = reformular. La **V media** es un promedio descriptivo de seis V atributo × criterio, no una V inferencial independiente del mapa. La prioridad de revisión se deriva de la triangulación y no de un punto de corte automático.

La Figura 15 sintetiza visualmente la triangulación de evidencia y la prioridad de revisión resultante para los diez atributos. La prioridad representa una decisión de trabajo

derivada de la combinación de señales cuantitativas, comentarios cualitativos y recomendaciones del panel; no constituye un ranking métrico de “calidad” de los mapas.

Atributo	Señal cuantitativa	Comentarios cualitativos	Recomendación global	Prioridad de revisión
Teoría de innovación y emprendimiento	●	●	●	Muy alta
Diseño	●	●	●	Muy alta
Liderazgo	●	●	●	Muy alta
Economía y gestión	●	●	●	Alta
Trabajo grupal e individual	●	●	●	Alta
Interacción con usuarios reales	●	●	●	Alta
Comunicación	●	●	○	Media
Ética y profesionalismo	○	○	○	Media
Seguridad y riesgos	○	○	○	Media
Trabajo inter y multidisciplinario	○	○	○	Media

● Fuerte / presente ● Parcial / moderado ○ Débil / ausente

Figura 15. Síntesis de la triangulación de evidencia por atributo y prioridad de revisión resultante. La prioridad indica dónde la evidencia disponible justificó un mayor esfuerzo de revisión conceptual o estructural. No corresponde a una puntuación global calculada mediante una fórmula única ni implica que los mapas de prioridad baja se encuentren validados.

19. Interpretación global del juicio experto

El juicio experto no debe leerse como una instancia en la que "los mapas fueron validados por expertos". Su función, y su resultado efectivo, fue distinto: **el juicio experto aportó evidencia de contenido que permitió discriminar entre los diez Construct Maps según distintos tipos y grados de necesidad de revisión**. Esta evidencia no se utilizó para aceptar o rechazar automáticamente ninguno de los mapas, sino para identificar, de manera diferenciada por atributo, problemas específicos en la definición, la variable progresiva, el orden de los waypoints, la unidad del constructo y las fronteras conceptuales, orientando así decisiones de refinamiento distintas para cada caso —y, en al menos un caso (Diseño), abriendo explícitamente la pregunta de si la arquitectura misma del mapa requería reespecificarse—.

Este resultado es coherente, a partir de la evidencia empírica propia del proyecto, con una característica central del enfoque de construct modelling introducido en la sección 2: **los Construct Maps deben tratarse como**

hipótesis revisables, no como definiciones cerradas. Ningún atributo emergió de esta etapa como una arquitectura definitivamente cerrada; incluso el atributo con mejor señal cuantitativa y cualitativa —Trabajo inter y multidisciplinario— fue diagnosticado como pendiente de ajustes focalizados, no como validado.

20. Transición hacia el refinamiento de los Construct Maps

La evidencia reunida y triangulada en esta parte —cuantitativa, cualitativa, y su combinación diferenciada por atributo— condujo a un análisis focalizado de cada uno de los diez mapas. En algunos casos, como se ha documentado en la sección 17, la evidencia disponible apunta hacia ajustes de formulación y claridad, sin cuestionar la arquitectura general del mapa. En otros, la evidencia lleva a revisar con mayor profundidad la variable progresiva, algún waypoint específico o las fronteras con atributos vecinos. En al menos un caso —Diseño—, y con matices relevantes en otros, la evidencia condujo a reconsiderar la arquitectura misma del constructo, incluyendo la

hipótesis inicial de unidimensionalidad introducida en la sección 8.5.

La Parte V de este reporte mostrará, atributo por atributo, la cadena completa: **mapa inicial → evidencia → diagnóstico → decisión → mapa revisado**. Esta parte no desarrolla todavía esos resultados; su contribución se limita a establecer, con la evidencia aquí documentada, por qué cada atributo requería el tipo y la profundidad de revisión que se abordará a continuación.

Referencias de la PARTE IV

- Aiken, L. R. (1985). Three coefficients for analyzing the reliability and validity of ratings. *Educational and Psychological Measurement*, 45(1), 131-142. <https://doi.org/10.1177/0013164485451012>
- American Educational Research Association, American Psychological Association, & National Council on Measurement in Education. (2014). *Standards for educational and psychological testing*. American Educational Research Association.
- Elo, S., & Kyngäs, H. (2008). The qualitative content analysis process. *Journal of Advanced Nursing*, 62(1), 107-115. <https://doi.org/10.1111/j.1365-2648.2007.04569.x>
- Graneheim, U. H., & Lundman, B. (2004). Qualitative content analysis in nursing research: Concepts, procedures and measures to achieve trustworthiness. *Nurse Education Today*, 24(2), 105-112. <https://doi.org/10.1016/j.nedt.2003.10.001>
- Haynes, S. N., Richard, D. C. S., & Kubany, E. S. (1995). Content validity in psychological assessment: A functional approach to concepts and methods. *Psychological Assessment*, 7(3), 238-247. <https://doi.org/10.1037/1040-3590.7.3.238>
- Hsieh, H.-F., & Shannon, S. E. (2005). Three approaches to qualitative content analysis. *Qualitative Health Research*, 15(9), 1277-1288. <https://doi.org/10.1177/1049732305276687>
- Lynn, M. R. (1986). Determination and quantification of content validity. *Nursing Research*, 35(6), 382-385. <https://doi.org/10.1097/00006199-198611000-00017>
- Miles, M. B., Huberman, A. M., & Saldaña, J. (2014). *Qualitative data analysis: A methods sourcebook* (3rd ed.). SAGE.
- Morse, J. M. (2015). Critical analysis of strategies for determining rigor in qualitative inquiry. *Qualitative Health Research*, 25(9), 1212-1222. <https://doi.org/10.1177/1049732315588501>
- Morse, J. M., Barrett, M., Mayan, M., Olson, K., & Spiers, J. (2002). Verification strategies for establishing reliability and validity in qualitative research. *International Journal of Qualitative Methods*, 1(2), 13-22. <https://doi.org/10.1177/160940690200100202>
- Penfield, R. D., & Giacobbi, P. R., Jr. (2004). Applying a score confidence interval to Aiken's item content-relevance index. *Measurement in Physical Education and Exercise Science*, 8(4), 213-225. https://doi.org/10.1207/s15327841mpee0804_3
- Rubio, D. M., Berg-Weger, M., Tebb, S. S., Lee, E. S., & Rauch, S. (2003). Objectifying content validity: Conducting a content validity study in social work research. *Social Work Research*, 27(2), 94-104. <https://doi.org/10.1093/swr/27.2.94>
- Sánchez-Mendiola, M., Manzano-Patiño, A. P., García-Minjares, M., Buzo Casanova, E., Herrera Penilla, C. J., Goytia-Rodríguez, K., & Martínez-González, A. (2023). Large-scale diagnostic assessment in first-year university students: Pre- and transpandemic comparison. *Educational Assessment, Evaluation and Accountability*, 35, 503-523. <https://doi.org/10.1007/s11092-023-09410-9>
- Schreier, M. (2012). *Qualitative content analysis in practice*. SAGE.
- Sireci, S., & Faulkner-Bond, M. (2014). Validity evidence based on test content. *Psicothema*, 26(1), 100-107. <https://doi.org/10.7334/psicothema2013.256>
- Wilson, M. (2023). *Constructing measures: An item response modeling approach* (2nd ed.). Routledge. <https://doi.org/10.4324/9781003286929>
- Wilson, M., & Gochyyev, P. (2013). Psychometrics. In T. Teo (Ed.), *Handbook of quantitative methods for educational research* (pp. 3-30). Sense Publishers. https://doi.org/10.1007/978-94-6209-404-8_1

PARTE V

REFINAMIENTO Y REESPECIFICACIÓN DE LOS CONSTRUCT MAPS

Esta parte presenta la **arquitectura de medición actualmente vigente** para los diez atributos institucionales. A diferencia de las versiones iniciales presentadas en la Parte III —sometidas a juicio experto pero todavía no examinadas a la luz de esa evidencia—, los diez Construct Maps que se desarrollan a continuación incorporan ya el refinamiento o la reespecificación derivados de la evidencia de contenido documentada en la Parte IV. Siguen siendo, en su totalidad, **hipótesis sustantivas pendientes de contraste empírico**, y así se presentan de manera consistente a lo largo de esta parte.

21. Lógica general del refinamiento

23. Teoría de innovación y emprendimiento

25. Liderazgo

27. Trabajo grupal e individual

29. Interacción con usuarios reales

31. Ética y profesionalismo

33. Arquitectura resultante de los diez atributos

35. Transición hacia la siguiente fase

22. Trazabilidad global de los cambios

24. Diseño

26. Economía y gestión

28. Comunicación

30. Seguridad y riesgos

32. Trabajo inter y multidisciplinario

34. Implicaciones metodológicas del refinamiento

21. Lógica general del refinamiento

21.1. Los Construct Maps como hipótesis revisables

Un Construct Map es una hipótesis sustantiva sobre la variable que se pretende medir y sobre las diferencias cualitativas que pueden observarse entre personas respecto de ella —principio introducido en la sección 2.5 y utilizado de manera consistente en las Partes III y IV—. Por su propia naturaleza de hipótesis, el juicio experto documentado en la Parte IV no podía limitarse a corregir la redacción de los diez mapas iniciales: la evidencia reunida podía conducir, según el caso, a reconsiderar la definición del constructo, la variable progresiva misma, el orden de los waypoints, el contenido de uno o más waypoints, la lógica de las transiciones, las fronteras conceptuales frente a otros atributos, o —en los casos de mayor cuestionamiento— la propia estructura dimensional del constructo.

Esta parte del reporte documenta, para cada uno de los diez atributos, cómo se utilizó esa evidencia para producir la versión revisada actualmente vigente.

21.2. Niveles de intervención sobre los mapas

Las decisiones adoptadas no tuvieron la misma profundidad para los diez atributos. Se distinguen cuatro niveles de intervención, utilizados de manera diferenciada según lo efectivamente decidido para cada mapa:

A. Ajuste de formulación. Se mantienen la definición, la variable progresiva y la progresión general del mapa, pero se mejora la claridad, la precisión terminológica, la observabilidad o la delimitación de uno o más descriptores.

B. Refinamiento conceptual. Se mantiene la arquitectura general de una única progresión, pero se modifica la definición, la variable progresiva, uno o más waypoints, o el foco sustantivo que organiza el continuo.

C. Reorganización de la progresión. Los componentes principales del mapa se mantienen, pero cambia el orden entre ellos, la relación entre waypoints, o la forma de interpretar la progresión.

D. Reespecificación estructural. La evidencia cuestiona la propia hipótesis de unidimensionalidad sustantiva formulada en la construcción inicial (sección 8.5) y conduce a separar componentes o a formular más de una progresión (strands) dentro de un mismo atributo.

Como se detallará en las secciones 23 a 32, cuatro de los diez atributos —Teoría de innovación y emprendimiento, Diseño, Economía y gestión, y Comunicación— recibieron una intervención de tipo D; los seis restantes recibieron intervenciones de tipo A o B, según el caso.

21.3. Evidencia utilizada para decidir

Cada decisión de refinamiento se fundamentó en la convergencia de varias fuentes de evidencia, y no en una sola de ellas: la señal cuantitativa del juicio experto (V de Aiken y sus intervalos, sección 14); los comentarios cualitativos, examinando convergencias, divergencias y casos negativos (sección 15); literatura específica de dominio, cuando fue incorporada de manera focalizada tras el juicio experto (sección 21.4); la coherencia de las alternativas de modelamiento con los principios de construct modelling introducidos en la sección 2; y la plausibilidad de cada alternativa para el perfil de ingreso a Ingeniería, no para el perfil de egreso.

Ninguna decisión se adoptó bajo la lógica de "un especialista señaló X, por tanto se cambió X". La evidencia experta se interpretó siempre en conjunto con la literatura disponible y con la lógica interna del constructo, tal como se muestra en el desarrollo de cada atributo en las secciones 23 a 32.

21.4. Revisión focalizada de literatura y triangulación documental

Después del juicio experto se desarrolló un **procedimiento documental focalizado, dirigido por problemas de modelamiento**. No se diseñó como una revisión sistemática exhaustiva de diez dominios, sino como una estrategia para contrastar preguntas concretas surgidas del panel. El punto de partida de cada búsqueda fue el diagnóstico específico obtenido para cada Construct Map mediante la triangulación de las valoraciones cuantitativas, las recomendaciones globales y los comentarios cualitativos deduplicados por experto $\times$ atributo.

La revisión comprendió **11 documentos sustantivos para Diseño y 5 documentos para cada uno de los otros nueve atributos**, complementados por matrices de segmentos priorizados y síntesis de triangulación. La profundidad de la revisión no fue idéntica para todos los atributos: el muestreo documental fue focal y proporcional al problema conceptual que debía resolverse; Diseño requirió el corpus más amplio, mientras los demás atributos se contrastaron mediante corpus más acotados.

El procedimiento siguió siete operaciones articuladas:

1. **Delimitación del problema de revisión.** Las observaciones del panel se transformaron en preguntas sustantivas de decisión relativas a la variable progresiva, la unidad del constructo, la diferenciación entre waypoints, la calibración del extremo superior, las fronteras conceptuales o los riesgos de fairness.
2. **Formulación de hipótesis alternativas de modelamiento.** Cuando el problema lo requería, se explicitaron alternativas antes de adoptar una solución: mantener la arquitectura, redefinir la variable progresiva, reorganizar la progresión o separar componentes en strands relacionados.
3. **Búsqueda documental dirigida.** Se localizó literatura específicamente pertinente para contrastar esas preguntas. El corpus reunió 11 documentos sustantivos para Diseño y 5 para cada uno de los otros nueve atributos; la mayor amplitud de Diseño respondió a la profundidad del cuestionamiento estructural identificado para ese mapa.
4. **Extracción y priorización de segmentos.** Los documentos se segmentaron y se identificaron pasajes directamente relacionados con las preguntas de decisión. Las herramientas de búsqueda y codificación se utilizaron para organizar y recuperar evidencia, no para decidir por frecuencia ni para sustituir la lectura sustantiva.
5. **Contraste entre evidencia experta y literatura.** Los segmentos documentales se examinaron junto con los comentarios originales del panel, atendiendo a convergencias, divergencias y casos negativos. Los comentarios repetidos por la estructura de

la base se contabilizaron una sola vez por experto × atributo.

6. Deliberación mediante criterios comunes.

Las alternativas se compararon considerando los criterios explicitados en la sección 21.5: unidad sustantiva, monotonicidad, diferenciación entre waypoints, observabilidad futura, plausibilidad para estudiantes de ingreso, fronteras con otros atributos, fairness y parquedad.

7. Registro de la decisión y de su estatus.

La solución adoptada se documentó como ajuste de formulación, refinamiento conceptual o reespecificación estructural. Cuando se formularon varios strands, estos se mantuvieron explícitamente como **hipótesis sustantivas provisionales**, pendientes de contraste mediante tareas, procesos de respuesta y estructura interna.

La lógica de uso de esta evidencia fue: **observación experta → problema conceptual → literatura focalizada → interpretación → decisión**. La literatura funcionó como **evidencia sustantiva para hacer plausibles y contrastar hipótesis de modelamiento**, no como prueba psicométrica de dimensionalidad. Para reforzar la trazabilidad de esta etapa, las subsecciones por atributo incorporan extractos breves y verificables de comentarios de especialistas y de la literatura focalizada. Estos extractos ilustran evidencia considerada dentro de un corpus más amplio; no constituyen votos, no sustituyen la deliberación completa y ninguna cita individual se presenta como prueba de dimensionalidad. En los cuatro mapas reespecificados como multidimensionales, la estructura final continúa siendo una **hipótesis sustantiva provisional** que deberá evaluarse mediante tareas, procesos de respuesta y estructura interna de datos estudiantiles.

21.5. Criterios comunes utilizados para evaluar una reespecificación

Antes de desarrollar los diez atributos, conviene explicitar los criterios que orientaron, de manera común, la evaluación de cada alternativa de modelamiento considerada durante el refinamiento: **unidad sustantiva** (los waypoints representan la misma variable o, cuando ello no resulta sostenible, la multidimensionalidad queda explícita y justificada); **monotonicidad** (existe una transformación cualitativa interpretable

desde formas menos desarrolladas hacia formas más desarrolladas); **distinción** (cada waypoint agrega algo cualitativamente diferente respecto del anterior); **observabilidad** (las diferencias entre waypoints pueden, en principio, elicitar mediante tareas futuras); **plausibilidad al ingreso** (ningún nivel exige, necesariamente, formación universitaria previa); **fronteras** (el constructo se distingue razonablemente de los atributos institucionales vecinos); **fairness** (la progresión evita depender innecesariamente de experiencias previas desigualmente distribuidas entre estudiantes); y **parquedad** (no se incorporan componentes o dimensiones adicionales cuando una variable más simple explica adecuadamente la progresión observada). Estos criterios no constituyen una rúbrica externa

estandarizada, sino una **síntesis operativa de principios** de construct modelling, argumentación de validez, evidencia de contenido y equidad: una variable debe ser sustantivamente interpretable, sus posiciones deben representar diferencias cualitativas observables, las inferencias deben corresponder al propósito y población de uso, y una mayor complejidad estructural debe justificarse por evidencia y no introducirse por defecto (AERA, APA, & NCME, 2014; Kane, 2013; Sireci & Faulkner-Bond, 2014; Wilson & Gochyyev, 2013; Wilson, 2023).

22. Trazabilidad global de los cambios

Tabla 13. Trazabilidad global de los cambios

Atributo	Diagnóstico tras el juicio experto	Tipo de intervención	Estructura inicial	Estructura revisada	Estado actual
Teoría de innovación y emprendimiento	Revisión conceptual prioritaria	D — Reespecificación estructural	Unidimensional (IE1–IE4)	Multidimensional provisional (dos progresiones relacionadas)	Hipótesis revisada, pendiente de nueva evidencia
Diseño	Revisión estructural focalizada	D — Reespecificación estructural	Unidimensional (DI1–DI4)	Multidimensional provisional (tres strands interdependientes)	Hipótesis revisada, pendiente de nueva evidencia
Liderazgo	Revisión conceptual focalizada	B — Refinamiento conceptual	Unidimensional (LG1–LG4), eje: alcance/regulación de la influencia	Unidimensional refinado, eje: contribución a la capacidad de acción colectiva	Hipótesis revisada
Economía y gestión	Revisión focalizada prioritaria	D — Reespecificación estructural	Unidimensional (EG1–EG4)	Multidimensional provisional (dos strands interdependientes)	Hipótesis revisada, pendiente de nueva evidencia
Trabajo grupal e individual	Revisión conceptual focalizada	B — Refinamiento conceptual	Unidimensional (TG1–TG4)	Unidimensional refinado, eje: integración y regulación de la contribución individual	Hipótesis revisada
Comunicación	Revisión focalizada	D — Reespecificación estructural	Unidimensional (COM1–COM4)	Multidimensional provisional (dos strands interdependientes)	Hipótesis revisada, pendiente de nueva evidencia
Interacción con usuarios reales	Revisión conceptual focalizada	B — Refinamiento conceptual	Unidimensional (UR1–UR4)	Unidimensional refinado, eje: influencia de la evidencia de usuarios sobre decisiones	Hipótesis revisada
Seguridad y riesgos	Mantener arquitectura con revisión focalizada	A — Ajuste de formulación (con ampliación de alcance)	Unidimensional (SR1–SR4)	Unidimensional, alcance ampliado a sistemas socio-técnicos	Hipótesis mantenida con ajustes
Ética y profesionalismo	Deliberación conceptual	B — Refinamiento conceptual	Unidimensional (EP1–EP4)	Unidimensional refinado, profesionalismo como condición transversal	Hipótesis revisada
Trabajo inter y multidisciplinario	Mantener con ajustes focalizados	A — Ajuste de formulación	Unidimensional (IM1–IM4)	Unidimensional, recalibración del waypoint superior	Hipótesis mantenida con ajustes

Nota: ningún atributo se presenta como "validado". Todos, incluidos los seis que mantuvieron una estructura unidimensional, continúan siendo hipótesis de medición pendientes de evidencia empírica adicional (procesos de respuesta, pilotaje y análisis psicométrico), tal como se retomará en la Parte VI.

La Figura 16 sintetiza esta clasificación para los diez atributos a la vez.



Figura 16. Clasificación de los diez atributos según el tipo de intervención de refinamiento recibida a partir de la evidencia de contenido reunida en la Parte IV.

23. Teoría de innovación y emprendimiento

23.1. Punto de partida

El mapa inicial, presentado en detalle en la Parte III, definía el atributo como la capacidad de un estudiante que ingresa a Ingeniería para distinguir idea, innovación y emprendimiento, relacionar necesidades u oportunidades con implementación y creación de valor, y comprender que estas relaciones pueden modificarse frente a evidencia y cambios de contexto. Su variable progresiva inicial se formuló como la "coherencia conceptual de la representación de innovación y emprendimiento", organizada en una única progresión de cuatro waypoints: reconocer innovación y emprendimiento principalmente por su novedad (IE1); diferenciar idea, innovación e implementación (IE2); analizar iniciativas desde la creación de valor (IE3); y evaluar innovación y

emprendimiento como procesos adaptativos sujetos a evidencia e incertidumbre (IE4).

23.2. Evidencia cuantitativa

Este atributo obtuvo la **V de Aiken media más baja de los diez mapas evaluados** (0,589), con una valoración mínima de 0,467 concentrada en el criterio de Claridad, y una media de panel de 2,77 en la escala de 1 a 4 —también la más baja del conjunto—. Ninguno de los cinco especialistas recomendó mantener el mapa sin observaciones. En conjunto, esta es la señal cuantitativa menos favorable entre los diez atributos, aunque, como se estableció en la sección 12.3, el intervalo de confianza asociado a esta V mínima es amplio y no debe leerse como una medición de alta precisión.

23.3. Evidencia cualitativa

El análisis de los comentarios convergió en varios problemas específicos. **Nivel inicial.** Los especialistas coincidieron en que el primer waypoint se aproximaba a describir una comprensión ingenua o incluso deficitaria de

innovación y emprendimiento —asociada casi exclusivamente a la novedad—, en lugar de representar una manifestación mínima pero genuinamente significativa del constructo, principio general establecido en la construcción inicial de los mapas (sección 8.8) que, en este caso, no se había logrado plenamente. **Equilibrio entre innovación y emprendimiento.** Se observó que, en la formulación inicial, el componente de innovación aparecía más desarrollado a lo largo de la progresión que el componente de emprendimiento, generando una asimetría no deseada dentro de un atributo que institucionalmente integra ambas nociones en pie de igualdad. **Creación de valor.** Los comentarios señalaron la necesidad de entender la creación de valor en sentido amplio —social, ambiental, cultural, organizacional y no exclusivamente económico o comercial—, evitando que la progresión privilegiara implícitamente una noción restringida de valor. **Riesgo de reducir el emprendimiento a una figura estereotipada.** Varios especialistas advirtieron sobre el riesgo de que la formulación se aproximara a la figura del "emprendedor héroe" o se limitara a contextos de startups tecnológicas, dejando fuera formas de emprendimiento social, comunitario o público igualmente pertinentes.

23.4. Contraste con literatura

La revisión focalizada se apoyó en **cinco documentos** y examinó evidencia sobre comprensión de innovación, comprensión de emprendimiento, relación entre ambos procesos y creación de valor. Entre los referentes utilizados se encuentran el **Oslo Manual** (OECD/Eurostat, 2018) y **EntreComp** (Bacigalupo et al., 2016), complementados por literatura específica sobre innovación, emprendimiento y creación de valor.

La triangulación mostró convergencia fuerte entre comentarios expertos y literatura en problemas centrales: definir emprendimiento más allá de crear una empresa o startup; diferenciar idea, invención e innovación; examinar si innovación y emprendimiento podían sostener una sola variable o requerían progresiones propias; equilibrar ambos componentes; usar creación de valor en sentido amplio; y evitar que experiencia empresarial, intención de emprender o la figura del "emprendedor héroe" funcionaran como sustitutos del constructo.

La literatura no decidió automáticamente entre una o dos progresiones. Hizo plausibles alternativas estructurales que fueron deliberadas junto con la señal cuantitativa y los comentarios del panel. La decisión de separar comprensión de innovación y comprensión de emprendimiento se mantiene, por tanto, como **hipótesis estructural provisional**, no como dimensionalidad psicométrica demostrada.

Trazabilidad textual de la decisión

Comentarios de especialistas

E5. "Por otra parte hay una capacidad dominante, que parece ser la innovación, pero la definición promete distinguir idea, innovación y emprendimiento y los waypoints no desarrollan simétricamente esos tres conceptos."

E2. "Considero que el IE1 del mapa esta un descrita como una concepción inicial o ingenua de innovación que la competencia para reconocerla. Me parece más pertinente que el nivel inicial partiera de una comprensión conceptual mínima pero significativa de lo que es innovar o una idea de emprendimiento."

Literatura focalizada

OECD/Eurostat (2018, p. 249). "Innovation activities can result in an innovation, be ongoing, postponed or abandoned."

Bacigalupo et al. (2016, p. 12). "This definition focuses on value creation, no matter what type of value or context."

Interpretación para el refinamiento. La convergencia entre la asimetría señalada por el panel, la necesidad de un nivel inicial sustantivo y la diferenciación conceptual de innovación,

emprendimiento y creación de valor hizo defendible separar el atributo en **dos progresiones relacionadas: comprensión de innovación y comprensión de emprendimiento**. Esta estructura sigue siendo una hipótesis sustantiva provisional y no una demostración psicométrica de dimensionalidad.

23.5. Decisión de refinamiento

La evidencia reunida no cuestionó que innovación y emprendimiento compartan un anclaje conceptual común —ambos responden a una necesidad u oportunidad y se orientan hacia la creación de valor—, pero sí mostró que intentar sostenerlos como una única progresión de cuatro waypoints producía una asimetría difícil de resolver sin subordinar uno de los dos componentes al otro. Por ello, la decisión adoptada fue **reespecificar el atributo en dos progresiones relacionadas pero diferenciables** —comprensión de la innovación y comprensión del emprendimiento—, cada una con su propia variable progresiva y sus propios cuatro waypoints, conectadas por elementos comunes (necesidad u oportunidad, contexto y creación de valor) sin que estos elementos comunes constituyan, por sí mismos, una tercera progresión independiente. Esta decisión constituye una **hipótesis estructural provisional**, no una dimensionalidad ya demostrada empíricamente, y deberá contrastarse con nueva evidencia de contenido, procesos de respuesta y análisis psicométrico antes de sostener inferencias diferenciadas por progresión.

23.6. Construct Map revisado

Nombre para medición. Comprensión conceptual de innovación y emprendimiento.

Definición. Capacidad del estudiante para construir una representación conceptual de la innovación y el emprendimiento, distinguiendo ideas, innovaciones e iniciativas, y relacionándolas con necesidades u oportunidades, implementación y creación de valor.

Estructura. Dos progresiones relacionadas, cada una con cuatro waypoints propios; no se establece todavía un nivel global único del atributo.

Progresión — Comprensión de la innovación (variable progresiva: grado de diferenciación, integración y fundamentación con que el

estudiante comprende la innovación como una idea nueva o mejorada que llega a implementarse y a generar o preservar valor en un contexto):

- **Reconocer innovación en contexto.** Reconoce ejemplos de innovación vinculados con una necesidad, problema u oportunidad y con la introducción de algo nuevo o mejorado.
- **Diferenciar idea e innovación.** Distingue una idea o invención de una innovación, reconociendo que la novedad por sí sola no basta y que la implementación o puesta en uso es relevante.
- **Explicar la innovación como proceso de creación de valor.** Relaciona novedad o mejora, implementación o adopción, personas beneficiadas, creación de valor y contexto para explicar una iniciativa de innovación.
- **Evaluar una interpretación de innovación.** Utiliza evidencia sobre implementación, uso, resultados o valor generado para mantener o revisar su juicio acerca de si una iniciativa constituye innovación en un contexto determinado.

Progresión — Comprensión del emprendimiento (variable progresiva: grado de diferenciación, integración y fundamentación con que el estudiante comprende el emprendimiento como acción organizada sobre ideas u oportunidades mediante la movilización de personas y recursos para crear valor):

- **Reconocer emprendimiento en contexto.** Reconoce iniciativas en las que personas o grupos actúan frente a una necesidad u oportunidad con el propósito de generar valor.
- **Diferenciar emprendimiento de idea o empresa.** Distingue emprendimiento de tener una idea, expresar intención de emprender o crear formalmente una empresa, reconociendo la importancia de actuar y movilizar medios frente a una oportunidad.
- **Explicar el emprendimiento como proceso de creación de valor.** Relaciona oportunidad, personas o grupos, acciones, recursos, contexto y creación de valor para explicar una iniciativa emprendedora.
- **Evaluar una interpretación de emprendimiento.** Utiliza evidencia sobre oportunidad, acciones realizadas, movilización de recursos, actores, resultados o valor

generado para mantener o revisar su interpretación de una iniciativa emprendedora.

Relación entre ambas progresiones. No representan etapas rígidas ni requieren posiciones equivalentes: un estudiante puede mostrar una comprensión más desarrollada de innovación que de emprendimiento, o viceversa. La necesidad u oportunidad puede constituir el punto de entrada contextual de ambos procesos; la creación de valor conecta ambas progresiones sin convertirlas en una sola variable ni en una tercera progresión independiente. No se establece todavía un nivel global del atributo; el resultado diagnóstico deberá conservar el perfil diferenciado por progresión hasta contar con evidencia que justifique una eventual combinación.

Qué incluye. Comprensión conceptual de innovación; diferenciación entre idea, invención e innovación; relevancia de la implementación o adopción; comprensión del emprendimiento como acción organizada frente a oportunidades; movilización de personas y recursos; creación de valor en sentido amplio; y evaluación conceptual de iniciativas mediante evidencia y contexto.

Qué no mide directamente. Intención de emprender, creatividad general, protagonismo personal, creación formal de empresas, elaboración de modelos de negocio, éxito comercial, experiencia previa en startups, ni dominio de terminología empresarial especializada.

Fronteras con otros atributos. Se distingue de Diseño (centrado en problematización, ideación y regulación de decisiones de diseño, no en comprensión conceptual de innovación); de Economía y gestión (centrada en razonamiento de viabilidad y organización de la implementación, no en comprensión conceptual); de Interacción con usuarios reales (que puede aportar casos con usuarios, pero cuyo foco es conceptual en este atributo); de Liderazgo (el emprendimiento no se equipara con liderazgo personal); y de Trabajo grupal e individual (la movilización de recursos o personas en el emprendimiento se interpreta aquí de manera conceptual, no como desempeño colaborativo observado).

La Figura 17 representa visualmente las dos progresiones de este atributo, siguiendo la plantilla gráfica común introducida en la Figura 2.




Figura 17. Construct Map revisado de Teoría de innovación y emprendimiento: dos progresiones relacionadas —comprensión de la innovación y comprensión del emprendimiento—, conectadas por un anclaje contextual común. Hipótesis vigente, pendiente de contraste empírico.

23.7. Qué cambió respecto del mapa inicial

Tabla 14. Qué cambió respecto del mapa inicial — Teoría de innovación y emprendimiento

Elemento	Versión inicial	Versión revisada	Razón del cambio
Estructura	Una progresión unidimensional (IE1–IE4)	Dos progresiones relacionadas (comprensión de la innovación; comprensión del emprendimiento)	La evidencia mostró que ambos componentes no podían sostenerse en equilibrio dentro de una única progresión sin subordinar uno al otro
Nivel inicial	Reconocimiento asociado principalmente a novedad, creatividad o iniciativa	Reconocimiento de innovación o emprendimiento vinculado explícitamente a una necesidad u oportunidad en contexto	Evitar que el nivel inicial se aproxime a una comprensión ingenua o deficitaria
Creación de valor	Mencionada como parte de niveles superiores, sin ampliación explícita	Explícitamente entendida en sentido amplio (económico, social, público, ambiental, cultural) y presente como elemento conector entre ambas progresiones	Evitar una interpretación restringida a lo comercial
Nivel superior	Evaluar innovación y emprendimiento como procesos adaptativos, en una sola progresión	Evaluar una interpretación de innovación e, independientemente, evaluar una interpretación de emprendimiento, cada una mediante evidencia y contexto	Preservar la posibilidad de que el desarrollo de ambos componentes difiera entre estudiantes
Riesgo de estereotipo	No abordado explícitamente	Explícitamente excluido como evidencia central ("qué no mide directamente")	Responder a la observación experta sobre el riesgo de reducir emprendimiento a la figura del "emprendedor héroe" o a contextos de startups tecnológicas

23.8. Hipótesis pendientes

Que comprensión de la innovación y comprensión del emprendimiento constituyan progresiones sustantivamente distinguibles pero relacionadas, y no una única variable artificialmente separada. Que, dentro de cada progresión, los cuatro waypoints formen un orden cualitativo empíricamente plausible para estudiantes de ingreso. Que sea posible, mediante tareas breves propias de un diagnóstico de ingreso, generar evidencia diferenciada sobre ambas progresiones sin que una domine sistemáticamente a la otra. Que la creación de valor funcione efectivamente como elemento conector entre ambas progresiones sin requerir, en el futuro, tratarse como una tercera progresión independiente.

24. Diseño

24.1. Punto de partida

El mapa inicial, presentado en la Parte III, definía Diseño como la capacidad de transformar una necesidad o problema en un desafío de diseño, identificar condiciones y criterios, explorar alternativas y utilizar evidencia para evaluar y

mejorar una propuesta, organizada en una única progresión de cuatro waypoints: proponer una solución inicial a partir de una comprensión inmediata del problema (DI1); delimitar el desafío mediante criterios explícitos (DI2); explorar y comparar alternativas de solución (DI3); y regular iterativamente el diseño mediante evidencia (DI4). El continuo inicial comenzaba, por tanto, con la producción de una solución, y solo después incorporaba la delimitación explícita del desafío.

24.2. Evidencia cuantitativa del juicio experto

Diseño obtuvo la **segunda V de Aiken media más baja** del conjunto (0,644), con una valoración mínima de 0,533 en el criterio de Claridad, y registró además la valoración comparativamente más desfavorable de todo el panel en el criterio de Orden y progresión —la peor posición relativa entre los diez atributos para ese criterio específico—. La media de panel se ubicó en 2,93. Ningún especialista recomendó mantener el mapa sin observaciones: la distribución de recomendaciones fue de cero "mantener", dos "ajustes mayores" y tres "ajustes menores". Un análisis de robustez, que examinó si esta señal desfavorable dependía de la valoración de un único especialista, mostró que se mantenía de

manera consistente al excluir, uno a la vez, a cualquiera de los cinco integrantes del panel.

24.3. Evidencia cualitativa

Problematicación **insuficientemente representada.** Varios especialistas señalaron que el punto de partida de la progresión —proponer una solución— omitía una fase previa indispensable: comprender, observar, situar y delimitar el problema antes de comprometerse con una respuesta. Una de las observaciones más influyentes, formulada por una especialista con formación en diseño, propuso explícitamente reorganizar la lógica completa de la progresión en torno a la secuencia "comprender y delimitar → explorar → evaluar → iterar y reformular", desplazando el punto de partida desde la solución hacia la comprensión del desafío. **Ideación** **insuficientemente representada.** Se observó que generar una única solución no representa adecuadamente la exploración del espacio de alternativas: la generación divergente de ideas —proponer y diferenciar varias posibilidades antes de comparar— aparecía en el mapa inicial únicamente como insumo de la comparación (DI3), sin constituir una función visible por derecho propio. **Evaluación mediante criterios frente a revisión mediante evidencia.** Los comentarios señalaron la necesidad de distinguir con mayor claridad dos operaciones que el mapa inicial tendía a fusionar: comparar alternativas mediante criterios explícitos, por un lado, y revisar decisiones utilizando evidencia obtenida mediante pruebas, observación o retroalimentación, por otro. Esta distinción resultó especialmente relevante para diferenciar los dos waypoints superiores de la progresión inicial (DI3 y DI4). **Iteración.** Se advirtió que la iteración no debía entenderse simplemente como "producir otra versión" de una solución, sino como la modificación fundamentada de decisiones de diseño —incluyendo, eventualmente, la reformulación del problema mismo— a partir de evidencia. **Unidad del constructo.** En conjunto, estas observaciones convergieron en cuestionar si los componentes del mapa inicial —proponer, delimitar, explorar/comparar y regular mediante evidencia— representaban efectivamente el desarrollo de una misma variable, o si correspondían a funciones cualitativamente diferentes del proceso de diseño (problematizar, idear y evaluar/regular) que el mapa inicial

forzaba artificialmente dentro de una sola progresión.

24.4. Literatura focalizada sobre Diseño

La revisión focalizada de Diseño fue la más extensa del conjunto y reunió **11 documentos sustantivos**. Incluyó trabajos sobre problem framing y coevolución problema-solución, enseñanza y aprendizaje del diseño informado, pensamiento de diseño en ingeniería, generación de alternativas, pruebas de prototipos con usuarios o actores relevantes y marcos de innovación y diseño. Entre las fuentes ya incorporadas al reporte se encuentran Dorst y Cross (2001) y Crismond y Adams (2012).

La evidencia convergió en que el razonamiento de diseño no se representa adecuadamente como un único trayecto lineal desde "tener una solución" hasta "mejorarla". El corpus distinguió de manera recurrente funciones relativas a: (a) construir, delimitar y revisar la representación del desafío; (b) ampliar, diferenciar y reorganizar el espacio de alternativas; y (c) evaluar decisiones mediante criterios, pruebas, prototipos, retroalimentación u otras formas de evidencia. La literatura sobre coevolución y reframing respalda, además, que problematización e ideación pueden retroalimentarse, mientras la evidencia de prueba puede modificar tanto una solución como la propia comprensión del problema.

Esta revisión **no demuestra que existan exactamente tres dimensiones psicométricas**. Su función fue mostrar que la hipótesis unidimensional inicial resultaba sustantivamente insuficiente y que una arquitectura de **tres strands interdependientes** constituía una representación más defendible para avanzar al diseño de evidencia.

Trazabilidad textual de la decisión

Comentarios de especialistas

E2. “El punto de partida de la progresión del mapa: se está considerando que la primera manifestación de la competencia de diseño es producir una solución, cuando, desde una perspectiva de diseño, parecería más pertinente situar el inicio en la capacidad de comprender y delimitar el desafío.”

E3. “Sugiero que DI4 exija explícitamente la generación de evidencia mediante prueba, prototipo o verificación, y que DI3 quede acotado a la comparación sin puesta a prueba.”

Literatura focalizada

Crismond y Adams (2012, p. 748). “Delay making design decisions in order to explore, comprehend and frame the problem better.”

Design Council (2019, sección “The process: using the Double Diamond”). “Making and testing very early stage ideas can be part of discovery.”

Interpretación para el refinamiento. La evidencia convergió en distinguir tres funciones que la progresión inicial comprimía: construir y revisar el desafío, ampliar el espacio de alternativas y regular decisiones mediante criterios y evidencia. Sobre esa base se formuló provisionalmente una arquitectura de **tres strands interdependientes: problematización, ideación y evaluación/regulación mediante evidencia**. La separación es una hipótesis sustantiva pendiente de contraste empírico.

24.5. Decisión estructural

La convergencia entre la evidencia cuantitativa (el criterio de Orden y progresión como el más

desfavorable de todo el panel para este atributo), la evidencia cualitativa (ausencia de “mantener” entre las recomendaciones; propuesta explícita de reorganizar la secuencia completa; cuestionamiento de si DI3 y DI4 correspondían a la misma variable) y la literatura de dominio (que distingue funciones de comprensión del problema, generación de alternativas y evaluación/regulación mediante evidencia como capacidades relacionadas pero no reductibles entre sí) condujo a la decisión de **abandonar, de manera provisional, la progresión única DI1-DI4 y formular tres strands interdependientes: Problematización, Ideación, y Evaluación y regulación mediante evidencia**.

En este estudio, un strand corresponde a una dimensión o subconstructo distinguible dentro de un constructo multidimensional más amplio, representado mediante una progresión propia (Wilson, 2023).

Esta reespecificación constituye una **hipótesis estructural provisional**, no una dimensionalidad psicométricamente demostrada. Su sostenibilidad deberá contrastarse con nueva evidencia de contenido, de procesos de respuesta y de análisis psicométrico antes de utilizarse como base de inferencias diagnósticas.

24.6. Strand 1 — Problematización

Definición del strand. Capacidad para construir, delimitar, estructurar y revisar la representación de un problema, necesidad u oportunidad como desafío de diseño. Su objeto es el espacio del problema, no las soluciones.

Variable progresiva. Grado de estructuración, fundamentación y revisabilidad con que el estudiante representa un desafío de diseño.

- **P1 — Reconoce y sitúa.** Identifica una necesidad, problema u oportunidad susceptible de diseño y la vincula con elementos observables de su contexto.
- **P2 — Delimita.** Formula explícitamente qué se pretende abordar, considerando actores o usuarios, necesidades y condiciones relevantes.
- **P3 — Estructura.** Relaciona necesidades, requerimientos, criterios y restricciones relevantes para construir una representación fundamentada del desafío.

- **P4 — Reencuadra.** Revisa y reformula su representación cuando nuevas perspectivas, alternativas o evidencia revelan supuestos, relaciones o restricciones previamente no consideradas.

Elemento cualitativo distintivo. El salto superior está en la revisabilidad de la propia representación del problema: pasar de usarla como marco fijo a tratarla como hipótesis revisable.

24.7. Strand 2 — Ideación

Definición del strand. Capacidad para construir y explorar un espacio de alternativas de solución, evitando reducir el diseño a producir rápidamente una primera idea. Su objeto no es la calidad final del producto, sino el espacio de posibilidades que el estudiante es capaz de construir y reorganizar.

Variable progresiva. Grado de amplitud, diferenciación y reorganización deliberada del espacio de alternativas de solución.

- **I1 — Formula una alternativa pertinente.** Propone una posibilidad de solución coherente con el desafío reconocido.
- **I2 — Diversifica.** Genera varias alternativas significativamente diferentes para abordar el mismo desafío.
- **I3 — Diferencia enfoques.** Organiza alternativas a partir de principios, estrategias o maneras cualitativamente diferentes de abordar el desafío.
- **I4 — Reconfigura.** Combina, transforma o reorganiza deliberadamente alternativas y enfoques, generando nuevas configuraciones posibles.

Elemento cualitativo distintivo. El nivel superior no equivale a producir una solución "más original"; supone mayor control sobre la representación del espacio de posibilidades.

24.8. Strand 3 — Evaluación y regulación mediante evidencia

Definición del strand. Capacidad para juzgar y regular decisiones de diseño mediante razones, criterios y evidencia, utilizando lo aprendido durante el proceso para sostener o modificar dichas decisiones.

Variable progresiva. Grado de regulación de las decisiones de diseño mediante criterios explícitos y evidencia.

- **E1 — Justifica una decisión.** Explicita razones pertinentes para seleccionar una alternativa o una característica de diseño.
- **E2 — Evalúa mediante criterios.** Compara alternativas o decisiones utilizando criterios, requerimientos o restricciones explícitos.
- **E3 — Contrasta mediante evidencia.** Utiliza información obtenida mediante observación, prueba, retroalimentación o verificación para juzgar decisiones de diseño.
- **E4 — Regula mediante evidencia.** Utiliza los resultados de la evaluación para mantener, modificar o reformular deliberadamente decisiones de diseño.

Elemento cualitativo distintivo. La diferencia crítica entre E3 y E4 es que obtener evidencia no equivale todavía a aprender de ella; el nivel superior exige utilizarla para transformar las decisiones.

24.9. Relación entre los tres strands

Problematización, Ideación, y Evaluación y regulación mediante evidencia **no constituyen tres etapas rígidamente secuenciales**. La literatura de coevolución entre problema y solución examinada en la sección 24.4 respalda que: nuevas alternativas exploradas pueden revelar información que obliga a precisar o estructurar mejor el desafío (Ideación → Problematización); la comparación mediante criterios y la evidencia obtenida pueden transformar el espacio de soluciones consideradas (Evaluación → Ideación); y la evidencia puede mostrar que no solo la solución era insuficiente, sino que el propio problema estaba mal encuadrado, motivando un reencuadre (Evaluación → Problematización). Un nuevo encuadre del desafío, a su vez, puede abrir un espacio de soluciones completamente diferente (Problematización → Ideación).

Por ello, los tres strands se conciben como **diferenciables para efectos de medición, pero interdependientes durante el desempeño de diseño**. No se plantea que P1 corresponda necesariamente a I1 y a E1 como un mismo "nivel global": un estudiante puede, por ejemplo,

estructurar razonablemente bien el problema (P3), generar solo un par de alternativas (I2) y sostener sus decisiones todavía con evidencia limitada (E1) —un perfil desigual entre strands que sería precisamente lo que la reespecificación multidimensional busca preservar en lugar de promediar u ocultar.

24.10. Ausencia provisional de un nivel global de Diseño

No debe suponerse todavía que una combinación particular de posiciones en los tres strands —por ejemplo, P3 + I2 + E4— equivalga a un "nivel X de

Diseño" en un sentido global y ya validado. Hasta contar con evidencia empírica sobre las relaciones reales entre los tres strands: deben puntuarse de manera distinguible entre sí; no debe imponerse prematuramente un nivel global único de Diseño; y la eventual construcción de una puntuación general —si la evidencia futura llegara a justificarla— constituye una hipótesis para etapas posteriores del proyecto, no una decisión ya adoptada.

La Figura 18 presenta el Construct Map revisado de este atributo.




Figura 18. Construct Map revisado de Diseño: tres strands —Problematización, Ideación, Evaluación y regulación mediante evidencia— diferenciables para la medición pero interdependientes durante el desempeño de diseño. No se establece un nivel global de Diseño. Hipótesis vigente, pendiente de contraste empírico.

24.11. Trazabilidad del cambio

Tabla 15. Trazabilidad del cambio — Diseño

Problema inicial	Evidencia experta	Evidencia documental	Cambio realizado
El continuo comenzaba proponiendo una solución, sin problematización previa visible	Convergencia en que comprender y delimitar el desafío debía preceder a proponer una solución; propuesta explícita de reordenar la secuencia	Literatura sobre coevolución problema-solución; matrices de enseñanza del diseño que distinguen comprender el problema como función propia	Se formuló un strand independiente de Problematización (P1–P4), con su propia variable progresiva
La generación de alternativas solo aparecía como insumo de la comparación (DI3)	Observación de que la exploración divergente de alternativas requería mayor visibilidad propia	Literatura que distingue generar alternativas como función propia del proceso de diseño	Se formuló un strand independiente de Ideación (I1–I4)
DI3 y DI4 fusionaban comparación mediante criterios y revisión mediante evidencia empírica	Observación de que ambas operaciones debían diferenciarse con mayor claridad	Literatura que distingue evaluar/decidir de poner a prueba y revisar soluciones	Se formuló un strand independiente de Evaluación y regulación mediante evidencia (E1–E4), separando explícitamente E2 (criterios) de E3–E4 (evidencia)
La iteración se interpretaba de manera ambigua, sin distinguir una nueva versión de una modificación fundamentada	Advertencia experta sobre esta ambigüedad	Literatura de coevolución iterativa	La iteración se reinterpretó como relación transversal (retroalimentación) entre los tres strands, no como un nivel final de una progresión única

24.12. Hipótesis pendientes

Que Problematización, Ideación y Evaluación/regulación mediante evidencia constituyan funciones sustantivamente distinguibles pero interdependientes dentro de un mismo constructo multidimensional, y no tres constructos completamente independientes ni, en sentido contrario, tres facetas de una única variable. Que, dentro de cada strand, los cuatro waypoints formen un orden cualitativo empíricamente plausible para estudiantes de ingreso. Que las relaciones de acoplamiento hipotetizadas entre strands puedan observarse empíricamente en el desempeño de estudiantes de ingreso. Que sea posible diseñar tareas capaces de generar evidencia diferenciada sobre los tres strands sin que una misma actuación se compute de manera redundante o solapada entre ellos. Que, eventualmente, exista o no fundamento suficiente para construir un nivel global de Diseño a partir de los tres strands.

25. Liderazgo

25.1. Punto de partida

El mapa inicial definía Liderazgo como la capacidad para ejercer influencia intencional y responsable sobre la acción colectiva, movilizándolo iniciativa, clarificando metas, facilitando participación y decisiones, y adaptando la forma de influir a las necesidades del grupo. Su variable

progresiva inicial se formuló centrada en el **alcance y la regulación de la influencia** que el estudiante ejerce sobre la acción colectiva, organizada en una progresión de cuatro waypoints: movilizar una acción puntual (LG1); orientar la acción colectiva hacia una meta compartida (LG2); facilitar la acción colectiva promoviendo participación (LG3); y regular y distribuir la influencia según las necesidades del grupo (LG4).

25.2. Evidencia cuantitativa

Liderazgo obtuvo una V de Aiken media de 0,722, con una valoración mínima de 0,667 compartida entre más de un criterio, entre ellos Claridad y Coherencia y unidad del constructo, y una media de panel de 3,17. Esta señal se ubica en una posición intermedia entre los atributos con mayor y menor necesidad de revisión relativa entre los diez evaluados.

25.3. Evidencia cualitativa

Los comentarios examinaron de manera específica la tensión entre **influencia**, como mecanismo central del atributo, y su **regulación** a lo largo de la progresión; la incorporación de **responsabilidad** como condición asociada a esa influencia; el papel de la **facilitación** y la **participación** de otras personas, particularmente en los waypoints intermedios; y la noción de **capacidad colectiva** como posible eje alternativo, distinto del alcance de la influencia individual. Se planteó una preocupación de

fairness relativa al riesgo de que la formulación favoreciera implícitamente patrones de **dominancia** o **centralidad** en la interacción grupal, que podrían confundirse con mayor desarrollo del atributo sin serlo genuinamente. El waypoint superior de la versión inicial —regular y distribuir la influencia— fue señalado como difícil de observar empíricamente sin mayor orientación sobre qué evidencia lo haría reconocible. Finalmente, se examinó la **frontera con Trabajo grupal e individual**, en torno a distinguir cumplir eficazmente la propia tarea colaborativa (Trabajo grupal) de orientar o fortalecer deliberadamente la capacidad de acción del colectivo (Liderazgo).

25.4. Hipótesis estructurales consideradas

El análisis triangulado consideró explícitamente más de una hipótesis alternativa sobre cómo debía organizarse este atributo, sin seleccionar entre ellas por simple frecuencia de mención: **H1 — Mantener alcance y regulación de la influencia individual** (conservar la variable progresiva inicial); **H2 — Redefinir el eje hacia la contribución a la capacidad de acción colectiva** (mantener una estructura unidimensional, pero reformular la variable progresiva como la contribución intencional y responsable del estudiante a orientar y fortalecer la capacidad de acción del colectivo, de modo que la influencia individual pase a entenderse como un mecanismo al servicio de ese propósito, y no como el eje mismo de la progresión); y **H3 — Separar componentes o strands** (descomponer el atributo en más de una progresión, análogamente a lo decidido para Diseño).

La evidencia cuantitativa, cualitativa y documental disponible no convergió hacia H3 con la misma fuerza con que lo hizo para Diseño: no se identificó una evidencia comparable de inestabilidad en el orden y la progresión, ni una recomendación mayoritaria de reformulación estructural. Se descartó, en consecuencia, la separación en componentes independientes como hipótesis a adoptar en esta etapa.

25.5. Literatura focalizada

La revisión focalizada reunió **cinco documentos** sobre liderazgo y examinó, entre otros temas, diferenciación entre los waypoints superiores, unidad del constructo, regulación y adaptación, influencia como mecanismo de liderazgo,

liderazgo compartido o distribuido, facilitación de la participación y de las decisiones, responsabilidad y frontera con Trabajo grupal e individual.

Un hallazgo especialmente relevante fue que mayor liderazgo no puede equipararse con mayor centralidad, dominancia, cargo formal o cantidad de habla. La literatura hizo plausible reformular la variable desde el **alcance de la influencia individual** hacia la **contribución intencional y responsable a la capacidad de acción colectiva**, manteniendo la influencia como mecanismo pero no como criterio de “más liderazgo”.

Se deliberaron alternativas unidimensionales y multicomponentes; la decisión de conservar una sola progresión organizada por capacidad colectiva fue sustantiva y permanece pendiente de contraste con actuaciones de estudiantes.

Trazabilidad textual de la decisión

Comentarios de especialistas

E5. “Esto puede favorecer formas culturalmente masculinizadas de ejercer liderazgo, como tomar la palabra, decidir, conducir o imponerse, e invisibilizar otras formas igualmente relevantes, como facilitar la participación, integrar perspectivas, construir acuerdos, sostener la coordinación o generar condiciones para que otras personas asuman iniciativa.”

E2. “El mayor desarrollo no consiste en concentrar más poder o conducir a más personas, sino en saber cuándo intervenir y cuándo ceder espacio para que otras personas asuman iniciativa o conducción, fortaleciendo la autonomía y capacidad colectiva del grupo.”

Literatura focalizada

DeRue (2011, p. 144). "I have hopefully made a compelling case for not equating leadership with formal power or supervision."

Interpretación para el refinamiento. La evidencia respaldó conservar una única progresión, pero redefinir su variable como **contribución intencional y responsable a la capacidad de acción colectiva**, evitando usar dominancia, visibilidad o poder formal como indicadores indirectos de mayor desarrollo.

25.6. Decisión

La decisión adoptada fue **H2**: se conserva una estructura unidimensional de cuatro waypoints, pero se reformula sustantivamente la variable progresiva. La influencia sigue siendo un mecanismo importante del liderazgo, pero el progreso ya no se interpreta como "cada vez más influencia individual" sobre el grupo; el eje de la progresión pasa a centrarse en la **contribución intencional y responsable a la orientación, participación y capacidad de acción del colectivo**. Bajo esta reformulación, ceder centralidad o abrir espacio para que otras personas asuman iniciativa deja de leerse como una reducción del liderazgo y pasa a interpretarse, cuando es una decisión deliberada y fortalece la acción colectiva, como su forma más desarrollada.

25.7. Construct Map revisado

Nombre para medición. Liderazgo en la acción colectiva.

Definición. Capacidad del estudiante para contribuir intencional y responsablemente a la acción colectiva, movilizándolo al grupo, orientándolo hacia un propósito compartido, facilitando la participación y las decisiones, y favoreciendo progresivamente que otras personas puedan asumir iniciativa y conducción.

Variable progresiva. Grado en que el estudiante contribuye intencional y responsablemente a

orientar y fortalecer la capacidad del grupo para actuar colectivamente.

- **LG1 — Moviliza una acción necesaria.** Toma iniciativa ante una necesidad del grupo mediante una propuesta, apoyo o intervención pertinente que contribuye a iniciar, continuar o recuperar la acción colectiva. La intervención no depende de poseer un cargo o autoridad formal.
- **LG2 — Orienta la acción colectiva.** Ayuda al grupo a clarificar un propósito compartido, identificar prioridades y relacionar acciones o decisiones necesarias con el avance hacia ese propósito.
- **LG3 — Facilita participación y decisiones.** Facilita el avance promoviendo la participación, integrando diferentes perspectivas y ayudando al grupo a construir acuerdos o tomar decisiones, sin depender de la imposición o autoridad personal.
- **LG4 — Fortalece y distribuye la capacidad colectiva.** Regula su propia forma de influir según las necesidades del grupo, favorece que otras personas asuman iniciativa o conducción, y contribuye a que el colectivo pueda decidir, actuar y reorganizarse con menor dependencia de una sola persona.

Responsabilidad como condición transversal.

La responsabilidad no constituye un waypoint ni un strand separado; acompaña toda la progresión. En ningún nivel una actuación se considera más desarrollada por ser más visible, dominante o central, sino por su pertinencia para el propósito colectivo y por su capacidad de favorecer que otras personas también puedan participar, decidir y actuar. Esta decisión evita interpretar LG4 como mera reducción de participación: ceder conducción constituye evidencia de mayor desarrollo solo cuando es una decisión intencional que fortalece la acción colectiva, no cuando corresponde a desentendimiento, pasividad o ausencia.

Fronteras con otros atributos. Se distingue de Trabajo grupal e individual (cumplimiento, coordinación e integración de la propia contribución al trabajo colectivo, no orientación o fortalecimiento de la capacidad de acción del grupo); de Comunicación (comunicar con eficacia no equivale por sí solo a orientar la acción colectiva); de Interacción con usuarios reales

(obtención e incorporación de perspectivas de personas usuarias o afectadas); de Diseño (problematización, ideación y regulación de decisiones de diseño); de Economía y gestión (razonamiento sobre recursos, viabilidad, planificación e implementación); y de Ética y profesionalismo (juicio sobre consecuencias,

deberes, responsabilidades y límites de actuación).

La Figura 19 presenta el Construct Map revisado de este atributo.




Figura 19. Construct Map revisado de Liderazgo en la acción colectiva: progresión única de cuatro waypoints, con la responsabilidad como condición transversal. El waypoint superior representa fortalecer y distribuir la capacidad colectiva, no una disminución de protagonismo. Hipótesis vigente, pendiente de contraste empírico.

25.8. Hipótesis pendientes

Que LG1 sea observable de manera confiable sin depender de que el estudiante tenga oportunidad estructural de tomar la iniciativa dentro de una

tarea grupal breve. Que la separación entre Liderazgo y Trabajo grupal e individual resulte sostenible empíricamente, y no se superponga sistemáticamente en la evidencia recogida por tareas futuras. Que la regulación de la propia

influencia (el eje central de la variable progresiva) pueda distinguirse, en la práctica, de la simple ausencia de intervención. Que LG4 —fortalecer y distribuir la capacidad colectiva— se comporte empíricamente como el nivel más desarrollado, y no resulte sistemáticamente más difícil de observar que los niveles intermedios por razones ajenas al constructo. El orden empírico completo de los cuatro waypoints, todavía no contrastado con datos de estudiantes.

26. Economía y gestión

26.1. Mapa inicial

Definición inicial: capacidad para reconocer recursos, costos, beneficios, tareas, tiempos y restricciones asociados a una iniciativa, organizarlos para visualizar su implementación, comparar alternativas, y revisar decisiones de viabilidad y ejecución frente a cambios e incertidumbre. Variable progresiva inicial: grado en que el estudiante organiza y revisa la viabilidad de una iniciativa integrando recursos y condiciones de ejecución, en una progresión única de cuatro waypoints (EG1-EG4). La propia construcción inicial del mapa (sección 8.5) ya incorporaba una pregunta abierta dirigida al panel sobre si economía y gestión —dos nociones combinadas en la denominación institucional del atributo— compartían efectivamente una misma capacidad dominante.

26.2. Evidencia cuantitativa

V de Aiken media de 0,789 —una de las más favorables del conjunto en promedio—, pero con una V mínima de 0,600 concentrada específicamente en el criterio de Claridad, mientras el resto de los criterios de este atributo se ubicó en un rango favorable, incluyendo la V máxima absoluta de todo el panel (0,933) en al menos un criterio. Media de panel: 3,37. La señal cuantitativa global es, por tanto, favorable, pero con una debilidad claramente localizada.

26.3. Evidencia cualitativa

Los comentarios señalaron que varios descriptores de los waypoints incluían un número elevado de elementos simultáneos —recursos, costos, beneficios, tiempos, restricciones—, dificultando reconocer con claridad qué cambiaba específicamente entre un nivel y el siguiente. Se

retomó, de manera consistente con la pregunta ya planteada en la construcción inicial, si economía y gestión compartían efectivamente una misma capacidad dominante o si correspondían a dos funciones relacionadas pero distinguibles: razonar sobre la viabilidad de una iniciativa, por un lado, y organizar y ajustar su implementación, por otro. Se señaló además que el lenguaje de algunos descriptores se aproximaba a vocabulario técnico-financiero, con el consiguiente riesgo de medir familiaridad terminológica más que razonamiento sustantivo; y se observó una dependencia curricular relevante de los niveles superiores respecto de trayectorias formativas específicas (asignaturas electivas y modalidad Técnico-Profesional), la más marcada entre los diez atributos evaluados.

26.4. Literatura focalizada

La revisión focalizada reunió **cinco documentos** para Economía y gestión. La codificación documental identificó **328 segmentos** relacionados con economía/viabilidad, **175** con gestión/implementación y evidencia explícita sobre la relación entre ambas funciones en cuatro de los cinco documentos. El corpus incluyó marcos de atributos de ingeniería, gestión de proyectos en educación superior, decisiones de trade-off y referentes de sostenibilidad y viabilidad.

La triangulación mostró convergencias fuertes en dos familias de actuación: por un lado, razonar sobre recursos, restricciones, costos, beneficios y consecuencias para juzgar viabilidad; por otro, organizar acciones, responsables, tiempos, dependencias y seguimiento para implementar y replanificar. También convergió la necesidad de utilizar lenguaje accesible y evitar que vocabulario empresarial, experiencia familiar en empresas o cálculo financiero funcionaran como ventajas irrelevantes al constructo.

Esta evidencia hizo más defendible la hipótesis de **dos strands interdependientes** —Razonamiento económico y viabilidad; Gestión de la implementación— que una única progresión que cambiara de eje entre ambos. La interdependencia es sustantiva: las restricciones económicas modifican la planificación y, a su vez, la planificación o la ejecución pueden revelar información que obliga a reevaluar la viabilidad. Esta estructura sigue siendo provisional hasta contar con datos de respuesta.

Trazabilidad textual de la decisión

Comentarios de especialistas

E3. “La capacidad dominante sigue siendo doble en el contenido: estimar costos, beneficios y valor es un razonamiento distinto de secuenciar tareas, tiempos y responsables, y un estudiante puede ser competente en uno y no en el otro.”

E5. “Conviene que los ítems del instrumento no reduzcan la economía y gestión a contextos empresariales, financieros o de negociación, sino que incorporen distintas situaciones de organización de recursos, tiempos, tareas y restricciones.”

Literatura focalizada

Goldstein et al. (2021, p. 28). “Optimization often requires making trade-offs among competing criteria.”

Nijhuis (2012, p. 10). “The Process Group, Planning (Chapter 3.4) incorporates Scope, Time, Cost, Purchasing, Quality, Personnel, Communication, and Risk.”

Interpretación para el refinamiento. La convergencia mostró dos familias de razonamiento relacionadas pero no reducibles entre sí: juzgar viabilidad mediante recursos, restricciones y consecuencias, y organizar/reajustar la implementación. Se adoptaron provisionalmente **dos strands interdependientes: razonamiento económico y viabilidad; y gestión de la implementación.**

26.5. Diagnóstico

La combinación de la debilidad localizada en claridad, la pregunta de unidad del constructo ya planteada desde la construcción inicial y reforzada por los comentarios del panel, y la coherencia de esa distinción con la literatura revisada, condujo a un diagnóstico de **revisión focalizada prioritaria**, con foco específico en resolver la tensión entre razonamiento de viabilidad y gestión de la implementación.

26.6. Decisión

Se decidió **reespecificar el atributo en dos strands interdependientes:** razonamiento económico y viabilidad, y gestión de la implementación. Esta decisión constituye una hipótesis sustantiva derivada de la triangulación entre juicio experto y literatura focalizada, no una dimensionalidad psicométrica demostrada.

26.7. Construct Map revisado

Nombre para medición. Economía y gestión de iniciativas.

Definición. Capacidad del estudiante para considerar recursos, restricciones y consecuencias al juzgar la viabilidad de una iniciativa, y para organizar y ajustar las acciones necesarias para llevarla adelante.

Estructura. Dos strands interdependientes, cada uno con cuatro waypoints propios.

Strand 1 — Razonamiento económico y viabilidad (variable progresiva: grado en que el estudiante relaciona recursos, restricciones y consecuencias para juzgar y revisar la viabilidad de una iniciativa):

- **EV1 — Reconoce condiciones de viabilidad.** Identifica recursos o restricciones relevantes y reconoce que pueden afectar la posibilidad de llevar adelante una iniciativa.
- **EV2 — Relaciona recursos y consecuencias.** Relaciona recursos disponibles, esfuerzos, costos o beneficios relevantes para formular un juicio inicial de viabilidad.
- **EV3 — Compara alternativas de viabilidad.** Compara alternativas considerando ventajas, desventajas, restricciones y compensaciones relevantes para fundamentar una decisión.

- **EV4 — Reevalúa la viabilidad.** Revisa su juicio sobre la viabilidad de una iniciativa cuando cambian recursos, restricciones, resultados o supuestos.

Strand 2 — Gestión de la implementación (variable progresiva: grado en que el estudiante organiza y ajusta acciones, recursos, responsabilidades y tiempos para hacer posible una iniciativa):

- **GI1 — Identifica necesidades de implementación.** Reconoce acciones o recursos necesarios para llevar adelante una iniciativa.
- **GI2 — Organiza la implementación.** Ordena acciones, recursos, responsables o tiempos en una planificación básica coherente con el propósito de la iniciativa.
- **GI3 — Coordina condiciones de ejecución.** Relaciona acciones, prioridades y dependencias, anticipando restricciones que pueden afectar la implementación.
- **GI4 — Replanifica ante cambios.** Modifica deliberadamente acciones, recursos, responsabilidades o tiempos cuando cambian las condiciones o los resultados de la implementación.

Relación entre strands. Una decisión de viabilidad condiciona lo que puede planificarse (Viabilidad → Gestión); al organizar acciones, tiempos y recursos pueden revelarse restricciones o consecuencias no consideradas inicialmente (Gestión → Viabilidad); y un cambio de condiciones puede provocar simultáneamente una reevaluación de viabilidad y una replanificación de la implementación. No se establece todavía un nivel global de Economía y gestión.

Qué incluye. Reconocimiento de recursos y restricciones; relaciones entre esfuerzos, costos, beneficios y consecuencias; comparación de alternativas; juicio y revisión de viabilidad; identificación y organización de acciones; asignación básica de recursos, responsables y tiempos; coordinación de dependencias; seguimiento y replanificación ante cambios.

Qué no mide directamente. Conocimientos avanzados de economía, contabilidad o finanzas; dominio de herramientas profesionales de gestión de proyectos; elaboración de presupuestos formales; rentabilidad empresarial; intención emprendedora; experiencia laboral; éxito comercial; ni calidad global de una solución de diseño. El principio transversal del mapa entiende "recursos" en sentido amplio —tiempo, materiales, información, esfuerzo, trabajo de personas y recursos monetarios cuando corresponda— para evitar reducir el atributo a vocabulario financiero o a experiencia empresarial previa.

Fronteras con otros atributos. Se distingue de Teoría de innovación y emprendimiento (comprensión conceptual, no razonamiento de viabilidad ni gestión de implementación); de Diseño (que no puntúa viabilidad económica ni calidad del producto); de Liderazgo (asignar responsables o secuenciar tareas no constituye por sí mismo liderazgo); de Trabajo grupal e individual (planificar responsabilidades no equivale a evaluar desempeño colaborativo); y de Ética y profesionalismo (valorar consecuencias económicas no sustituye el razonamiento ético).

La Figura 20 presenta el Construct Map revisado de este atributo.




Figura 20. Construct Map revisado de Economía y gestión de iniciativas: dos strands interdependientes —razonamiento económico y viabilidad; gestión de la implementación—. Hipótesis vigente, pendiente de contraste empírico.

26.8. Cambios respecto del inicial

Tabla 16. Cambios respecto del inicial — Economía y gestión

Elemento	Versión inicial	Versión revisada	Razón del cambio
Estructura	Progresión única (EG1–EG4)	Dos strands interdependientes (viabilidad; gestión de la implementación)	La evidencia de contenido y la literatura respaldaron distinguir razonar sobre viabilidad de organizar la implementación como funciones diferenciables
Descriptores	Waypoints con múltiples elementos simultáneos (recursos, costos, tiempos, restricciones)	Descriptores más acotados por strand, cada uno centrado en su propia variable	Responder a la observación de claridad y facilitar el reconocimiento de qué cambia entre niveles
Alcance de "recursos"	Riesgo de interpretación restringida a vocabulario financiero	Definido explícitamente en sentido amplio (tiempo, materiales, información, esfuerzo, trabajo de personas, dinero)	Reducir dependencia de lenguaje técnico-financiero especializado
Nivel superior	Reconfigurar viabilidad y ejecución en una sola progresión	EV4 (reevaluar viabilidad) y GI4 (replanificar) como niveles superiores independientes de cada strand	Preservar la posibilidad de que ambos componentes se desarrollen de manera desigual en un mismo estudiante

26.9. Hipótesis pendientes

Que razonamiento económico/viabilidad y gestión de la implementación constituyan funciones sustantivamente distinguibles pero interdependientes, y no una variable artificialmente dividida. Que ambos strands puedan observarse sin requerir cálculo financiero especializado ni herramientas profesionales de gestión de proyectos. Que la dependencia curricular de los niveles superiores, señalada como la más marcada de los diez atributos, pueda mitigarse mediante el diseño de tareas futuras. El orden empírico de los waypoints dentro de cada strand, todavía no contrastado con datos de estudiantes.

27. Trabajo grupal e individual

27.1. Mapa inicial

Definición inicial: capacidad para aportar de manera responsable a una tarea colectiva, coordinar la propia contribución con la de otras personas, integrar perspectivas y regular interdependencias para sostener un resultado compartido. Variable progresiva inicial: grado de regulación de la propia contribución dentro de una estructura de interdependencias, en una progresión única de cuatro waypoints (TG1-TG4).

27.2. Evidencia cuantitativa

V de Aiken media de 0,778, con V mínima de 0,667 y media de panel de 3,33 —una señal moderadamente favorable, similar a la de Seguridad y riesgos—.

27.3. Evidencia cualitativa

Se observó una posible desconexión entre la denominación institucional del atributo —que incluye explícitamente "individual"— y el contenido efectivo de la progresión inicial, centrada casi exclusivamente en la contribución al trabajo colectivo, sin que ningún waypoint abordara de manera diferenciada un componente propiamente individual del trabajo. Se señaló la ausencia de una dimensión explícita relativa al manejo de desacuerdos o de desajustes en la distribución de la carga de trabajo dentro del equipo, aspectos considerados situaciones auténticas del trabajo colectivo y no fallas

externas al constructo. Se examinó, además, la frontera con Liderazgo, particularmente porosa en los waypoints superiores de ambos mapas, en torno a la regulación de la dinámica del equipo; y la frontera con Trabajo inter y multidisciplinario, en torno a distinguir la integración de personas de la integración de conocimientos disciplinares.

27.4. Literatura focalizada

La revisión focalizada reunió **cinco documentos** sobre colaboración, coordinación, regulación de la contribución, negociación y conflicto de tarea. La síntesis documental identificó una base amplia sobre colaboración y coordinación, junto con evidencia específica sobre regulación de la contribución y manejo de diferencias.

La convergencia principal respaldó una progresión centrada en **cómo el estudiante integra y regula su propia contribución en relación con el trabajo colectivo**, y no en la calidad global del producto del grupo. La literatura también respaldó tratar el desacuerdo y los desajustes de carga como oportunidades auténticas de evidencia: negociar, modificar el propio aporte y sostener interdependencias puede ser más diagnóstico que observar un equipo sin tensiones visibles. Se reforzó, además, la frontera con Liderazgo: coordinar e integrar la propia contribución no equivale a orientar o fortalecer deliberadamente la capacidad de acción del colectivo.

Trazabilidad textual de la decisión

Comentarios de especialistas

E3. “No aparece el manejo de discrepancias o conflicto —negociación de desacuerdos, distribución desigual de la carga—, que es un aspecto central de la experiencia real de trabajo en equipo al ingreso.”

E5. “Capacidad del/la estudiante que ingresa a ingeniería para integrar progresivamente su contribución individual al trabajo colectivo, coordinándose con otras personas y ajustando su actuación para construir y sostener un resultado compartido.”

Literatura focalizada

Stevens y Campion (1994, p. 507). “Some researchers have concluded that moderate levels of conflict are evidence of healthy relationships among team members.”

Interpretación para el refinamiento. La evidencia no exigió separar el atributo en varios strands; apoyó centrarlo en la **integración y regulación de la contribución individual al trabajo colectivo**, haciendo explícitos la negociación de diferencias y los desajustes de carga como manifestaciones relevantes del continuo.

27.5. Diagnóstico

Revisión conceptual focalizada, centrada en clarificar el eje de la progresión —sin requerir un componente “individual” separado— e incorporar explícitamente la negociación de diferencias como evidencia relevante.

27.6. Decisión

Se decidió **mantener la estructura unidimensional**: el componente “individual” no requiere un strand separado, sino que funciona como la unidad desde la cual se observa cómo una persona aporta, coordina, integra y regula su actuación dentro de un proceso interdependiente. Se reformuló la variable progresiva para hacer explícita esta lógica y se incorporó la negociación de diferencias dentro de los waypoints superiores.

27.7. Construct Map revisado

Nombre para medición. Integración de la contribución individual al trabajo colectivo.

Definición. Capacidad del estudiante para integrar su contribución individual al trabajo colectivo, coordinándose con otras personas, incorporando sus aportes y ajustando su propia actuación para construir y sostener un resultado compartido.

Variable progresiva. Grado en que el estudiante integra y regula su contribución individual en función del trabajo colectivo.

- **TG1 — Contribuye al trabajo colectivo.** Realiza un aporte pertinente a la tarea compartida y cumple una responsabilidad asumida, reconociendo que su contribución forma parte del trabajo del grupo.
- **TG2 — Coordina su contribución con otros.** Ajusta su trabajo considerando las tareas, aportes y necesidades de otras personas, comparte información y coordina acciones para avanzar hacia el resultado común.
- **TG3 — Integra aportes y negocia diferencias.** Integra diferentes aportes y perspectivas en el trabajo conjunto y participa constructivamente en la resolución de desacuerdos o desajustes en responsabilidades y cargas de trabajo.
- **TG4 — Regula su contribución según las necesidades del colectivo.** Revisa y ajusta deliberadamente su aporte, rol o forma de colaboración cuando cambian las necesidades, dificultades o distribución del trabajo del grupo.

Desacuerdo y distribución de carga. El desacuerdo y los desajustes de carga se incorporan como situaciones auténticas del trabajo colectivo, no como fallas externas al constructo; se hacen especialmente relevantes en TG3 y TG4. La regulación de la propia contribución pertenece a este atributo; la regulación de la participación o conducción de otras personas pertenece principalmente a Liderazgo.

Fronteras con otros atributos. Se distingue de Liderazgo (orientar, facilitar o fortalecer deliberadamente la capacidad de acción del

colectivo); de Trabajo inter y multidisciplinario (integración de conocimientos y perspectivas disciplinares, no de contribuciones de personas); de Comunicación (comunicar bien no equivale por sí solo a coordinar o integrar el trabajo); de

Interacción con usuarios reales; de Diseño; y de Economía y gestión.

La Figura 21 presenta el Construct Map revisado de este atributo.




Figura 21. Construct Map revisado de Integración de la contribución individual al trabajo colectivo: progresión única de cuatro waypoints. Se distingue de Liderazgo en que regula la propia contribución, no la participación o conducción de otras personas. Hipótesis vigente, pendiente de contraste empírico.

27.8. Cambios respecto del inicial

Tabla 17. Cambios respecto del inicial — Trabajo grupal e individual

Elemento	Versión inicial	Versión revisada	Razón del cambio
Variable progresiva	Regulación de la propia contribución dentro de interdependencias	Integración y regulación de la contribución individual en función del trabajo colectivo	Precisar explícitamente que el componente individual es la unidad de observación, no una dimensión separada
Manejo de desacuerdo	No incorporado explícitamente	Incorporado como evidencia relevante de TG3 y TG4	Responder a la observación experta sobre la ausencia de esta dimensión
Frontera con Liderazgo	Mencionada de forma general	Regla explícita: regulación de la propia contribución (TG) vs. regulación de la participación/conducción de otros (Liderazgo)	Reducir la porosidad señalada por el panel entre los waypoints superiores de ambos atributos

27.9. Hipótesis pendientes

Que la integración y negociación (TG3) y la regulación de la propia contribución (TG4) resulten empíricamente distinguibles entre sí y no una misma manifestación observada en momentos distintos. Que la frontera con Liderazgo, ahora delimitada de manera explícita, se sostenga en evidencia observada y no solo en la formulación del mapa. Que el desacuerdo y los desajustes de carga, cuando aparezcan en tareas futuras, generen evidencia interpretable y no ruido no controlado.

28. Comunicación

28.1. Mapa inicial

Definición inicial: capacidad para expresar y organizar información e ideas con un propósito reconocible, adaptar el mensaje a la situación y a la audiencia, y regular la comunicación a partir de la interacción y la retroalimentación. Variable progresiva inicial: grado de control intencional sobre el mensaje según propósito, audiencia e interacción, en una progresión única de cuatro waypoints (COM1-COM4).

28.2. Evidencia cuantitativa

V de Aiken media de 0,733, con V mínima de 0,667 en los criterios de coherencia y unidad del constructo y de orden y progresión, y media de panel de 3,20.

28.3. Evidencia cualitativa

Se observó que la progresión inicial era predominantemente **productiva**: centrada en cómo el estudiante construye y adapta el mensaje que emite, mientras que su dimensión **receptiva**

o dialógica —interpretar y responder a la interacción con otras personas— aparecía únicamente de manera instrumental en el waypoint superior (COM4), en lugar de estar presente a lo largo de toda la progresión. Se señaló también cierta ambigüedad en la frontera entre los dos waypoints intermedios de la versión inicial (organizar según un propósito, y adaptar al contexto y la audiencia).

28.4. Literatura focalizada

La revisión focalizada reunió **cinco documentos** y distinguió evidencia abundante sobre **recepción/escucha** (225 segmentos), **interacción/regulación** (100) y **producción/adaptación del mensaje** (57), además de evidencia explícita sobre la relación entre producción y recepción. Las fuentes permitieron examinar adaptación a audiencia y contexto, organización según propósito y la función de la regulación de la interacción.

La triangulación mostró que la progresión inicial concentraba la dimensión receptiva o dialógica casi exclusivamente en el extremo superior. La literatura, en cambio, permitió tratar **construcción y adaptación del mensaje y recepción y regulación de la interacción** como funciones relacionadas que pueden manifestarse a distintos niveles. También respaldó evitar indicadores sustitutos como cantidad de habla, dominancia, extroversión, seguridad escénica o corrección formal aislada, y mantener la argumentación como evidencia contextual posible, no como un tercer strand establecido.

Sobre esta base se adoptó la hipótesis de **dos strands interdependientes**. La revisión sustantiva hace plausible esa separación, pero no constituye demostración psicométrica de dos dimensiones.

Trazabilidad textual de la decisión

Comentarios de especialistas

E3. “COM4 no representa un grado mayor de “control intencional” sino un cambio de naturaleza, de la adaptación anticipada a la regulación en línea durante la interacción.”

E4. “Al hablar de comunicación efectiva se entiende que también consideramos la respuesta del receptor del mensaje que se intenta comunicar. En ese sentido se sugiere incorporar de manera transversal la actitud del receptor, una opción puede ser a través del monitoreo de la respuesta del receptor.”

Literatura focalizada

Leydens y Lucena (2009, p. 363). “Listening is a critical skill for engineers.”

Interpretación para el refinamiento. La evidencia hizo plausible distinguir dos componentes recíprocamente relacionados: construir/adaptar el mensaje y recibir/interpretar respuestas para regular la interacción. Se adoptaron provisionalmente **dos strands interdependientes: construcción y adaptación del mensaje; y recepción y regulación de la interacción.**

28.5. Diagnóstico

Revisión focalizada, orientada a resolver el desequilibrio entre producción y recepción detectado por el panel.

28.6. Decisión

Se decidió **reespecificar el atributo en dos strands interdependientes: construcción y adaptación del mensaje, y recepción y regulación de la interacción.** La evidencia mostró que la

arquitectura original era predominantemente productiva y concentraba la recepción y el diálogo únicamente en el nivel superior, por lo que se optó por distinguir dos líneas de progresión relacionadas, en lugar de forzar ambas funciones dentro de una sola.

28.7. Construct Map revisado

Nombre para medición. Comunicación: construcción, adaptación y regulación de la interacción.

Definición. Capacidad del estudiante para construir y adaptar mensajes según propósito, audiencia y contexto, e interpretar las respuestas de otras personas para regular la interacción y favorecer el entendimiento.

Estructura. Dos strands interdependientes, cada uno con cuatro waypoints propios.

Strand 1 — Construcción y adaptación del mensaje (variable progresiva: grado de control intencional con que el estudiante selecciona, organiza y adapta un mensaje según su propósito, audiencia y contexto):

- **P1 — Comunica información pertinente.**
Selecciona y expresa información relevante para comunicar una idea, situación o propuesta de manera comprensible.
- **P2 — Organiza según un propósito.**
Organiza y relaciona la información para construir un mensaje coherente con un propósito comunicativo explícito.
- **P3 — Adapta a audiencia y contexto.**
Modifica contenido, lenguaje, énfasis o forma de presentación considerando características relevantes de la audiencia y del contexto.
- **P4 — Ajusta estratégicamente el mensaje.**
Reconfigura deliberadamente contenido, lenguaje, énfasis o forma de presentación cuando cambian el propósito, la audiencia o las condiciones comunicativas.

Strand 2 — Recepción y regulación de la interacción (variable progresiva: grado en que el estudiante interpreta las contribuciones y respuestas de otras personas y las utiliza para sostener y regular el intercambio comunicativo):

- **R1 — Atiende a la respuesta del otro.**
Reconoce información, preguntas o señales

relevantes provenientes de otras personas durante el intercambio.

- **R2 — Interpreta la respuesta del interlocutor.** Identifica qué ha comprendido, necesita o plantea el interlocutor y relaciona esa respuesta con el intercambio en curso.
- **R3 — Integra aportes y retroalimentación.** Incorpora preguntas, perspectivas o retroalimentación de otras personas para ampliar, aclarar o ajustar el intercambio.
- **R4 — Regula la interacción para sostener el entendimiento.** Modifica deliberadamente su forma de comunicar o responder cuando detecta diferencias de interpretación, dificultades de comprensión o nuevas necesidades durante la interacción.

Relación entre strands. La forma de organizar y adaptar un mensaje condiciona qué puede comprender, preguntar o responder la audiencia (Construcción → Recepción); preguntas, señales y retroalimentación pueden exigir aclarar, reorganizar o reconfigurar el mensaje (Recepción → Construcción); y en interacción, interpretar la respuesta del otro y ajustar estratégicamente el mensaje pueden ocurrir de manera recíproca (P4 ↔ R4). No se establece todavía un nivel global de Comunicación.

Qué incluye. Selección de información pertinente; organización del mensaje según un propósito; adaptación a audiencia y contexto; atención e interpretación de respuestas; escucha; integración de preguntas y retroalimentación;

ajuste del mensaje durante la interacción; construcción de entendimiento.

Qué no mide directamente. Cantidad de habla, protagonismo, extroversión, seguridad escénica, dominio disciplinar, sofisticación retórica, corrección gramatical u ortográfica considerada aisladamente, ni capacidad argumentativa como dimensión independiente. El principio transversal del mapa es que la competencia comunicativa no se reduce a hablar más, escribir sin errores o exhibir seguridad; el criterio central es la pertinencia y regulación funcional de la comunicación en relación con propósito, audiencia e interacción.

Fronteras con otros atributos. Se distingue de Trabajo grupal e individual (integración y regulación de la propia contribución al trabajo colectivo; comunicarse durante el trabajo grupal no equivale por sí mismo a desempeño colaborativo); de Liderazgo (contribución a orientar y fortalecer la capacidad de acción colectiva); de Diseño (problematización, ideación y regulación de decisiones de diseño); de Trabajo inter y multidisciplinario (traducir o explicar perspectivas puede generar evidencia de Comunicación, pero la integración disciplinar pertenece a ese atributo); y de Ética y profesionalismo (comunicar de forma persuasiva no sustituye la calidad del razonamiento ético).

La Figura 22 presenta el Construct Map revisado de este atributo.




Figura 22. Construct Map revisado de Comunicación: dos strands interdependientes —construcción y adaptación del mensaje; recepción y regulación de la interacción—. Hipótesis vigente, pendiente de contraste empírico.

28.8. Cambios respecto del inicial

Tabla 18. Cambios respecto del inicial — Comunicación

Elemento	Versión inicial	Versión revisada	Razón del cambio
Estructura	Progresión única (COM1–COM4), predominantemente productiva	Dos strands interdependientes (construcción/adaptación; recepción/regulación)	Corregir el desequilibrio entre producción y recepción detectado por el panel
Recepción/interacción	Presente solo en el waypoint superior (COM4)	Progresión propia de cuatro waypoints (R1–R4), paralela a la de construcción del mensaje	Dar visibilidad propia a la dimensión dialógica de la comunicación
Nivel superior	Regular la comunicación mediante la interacción, en una sola progresión	P4 (ajuste estratégico) y R4 (regulación de la interacción) como niveles superiores independientes de cada strand	Preservar que ambas capacidades puedan desarrollarse de manera desigual en un mismo estudiante

28.9. Hipótesis pendientes

Que construcción/adaptación del mensaje y recepción/regulación de la interacción constituyan funciones sustantivamente distinguibles pero

interdependientes. Que ambos strands puedan observarse mediante tareas escritas, orales, gráficas o multimodales sin privilegiar un único canal. Que la argumentación, cuando aparezca como evidencia contextual, no termine

constituyéndose en un tercer strand no previsto. El orden empírico de los waypoints dentro de cada strand, todavía no contrastado con datos de estudiantes.

29. Interacción con usuarios reales

29.1. Mapa inicial

Definición inicial: capacidad para reconocer a las personas afectadas por una situación o solución, comprender necesidades y experiencias mediante evidencia, indagar directamente cuando es posible, y utilizar lo aprendido para revisar supuestos, criterios o propuestas iniciales. Variable progresiva inicial: grado en que la comprensión de usuarios y problemas está regulada por evidencia procedente de interacción con personas, en una progresión única de cuatro waypoints (UR1-UR4).

29.2. Evidencia cuantitativa

V de Aiken media de 0,800 y V mínima de 0,667, con media de panel de 3,40 —una de las señales cuantitativas más favorables del conjunto—.

29.3. Evidencia cualitativa

Los comentarios coincidieron en que el eje del atributo debía formularse explícitamente como el **grado en que la evidencia de usuarios llega a influir en la comprensión y las decisiones del estudiante**, y no como la cantidad o frecuencia de interacción directa con personas —un estudiante con más "contacto" no debería, por ese solo hecho, ubicarse en una posición más desarrollada—. Se señaló la dependencia de los waypoints superiores respecto de oportunidades curriculares previas de indagación directa, no necesariamente comunes a toda la cohorte de ingreso. Se examinó, además, una frontera todavía no completamente resuelta con Diseño, en situaciones donde una misma actuación podría generar evidencia simultánea sobre ambos atributos.

29.4. Literatura focalizada

La revisión focalizada reunió **cinco documentos** sobre interacción, indagación con personas, diseño centrado en las personas e incorporación de evidencia de usuarios en decisiones. La codificación identificó **155 segmentos** sobre indagación/interacción y **65** sobre usuarios,

personas afectadas o stakeholders, además de evidencia específica sobre comprensión de perspectivas e incorporación de esa evidencia en decisiones.

La convergencia entre expertos y literatura fue especialmente clara en que **tener contacto directo no constituye por sí mismo un nivel superior**. La progresión debía distinguir reconocer quiénes usan o son afectados, interpretar evidencia sobre necesidades y contexto, contrastar supuestos y, finalmente, utilizar esa evidencia para modificar o justificar decisiones. La participación o interacción funciona como un **medio para producir evidencia**, no como el fin del constructo.

La revisión hizo plausible conservar una sola progresión funcional —desde reconocer perspectivas hasta incorporarlas en decisiones— en vez de separar comprensión/indagación e incorporación en dos strands. Esta decisión sigue pendiente de evidencia empírica sobre la distinguibilidad de UR2-UR4.

Trazabilidad textual de la decisión

Comentarios de especialistas

E5. “Esto es importante porque la variable que progresa es la influencia de la evidencia de usuarios en la comprensión y en la toma de decisiones.”

E3. “UR3 y UR4 requieren haber tenido ocasión de interactuar directamente con usuarios, experiencia que no está distribuida homogéneamente entre establecimientos de educación media.”

Literatura focalizada

Zoltowski et al. (2012, p. 32). “Designers gather information from and about their users through a variety of methods.”

Interpretación para el refinamiento. La evidencia respaldó conservar una sola progresión, pero redefinirla según el **grado en que la evidencia de usuarios modifica la comprensión y las decisiones**, evitando que la interacción directa previa funcione como requisito o proxy de mayor desarrollo.

29.5. Diagnóstico

Revisión conceptual focalizada, centrada en reformular el eje de la progresión sin alterar su estructura unidimensional.

29.6. Decisión

Se decidió **mantener la estructura unidimensional**, reformulando la variable progresiva para centrarla explícitamente en la influencia creciente de la evidencia de usuarios sobre la comprensión y las decisiones del estudiante, y no en la cantidad de interacción. La interacción directa se conserva como un medio posible para producir evidencia, no como una condición suficiente de mayor competencia.

29.7. Construct Map revisado

Nombre para medición. Incorporación de perspectivas de usuarios y personas afectadas.

Definición. Capacidad del estudiante para reconocer e incorporar progresivamente las perspectivas y evidencia de personas usuarias o afectadas, utilizándolas para comprender una situación, contrastar sus propios supuestos y fundamentar la revisión de decisiones o propuestas.

Variable progresiva. Grado en que la comprensión y las decisiones del estudiante se fundamentan y modifican a partir de perspectivas y evidencia de usuarios o personas afectadas.

- **UR1 — Reconoce usuarios y personas afectadas.** Identifica quiénes usan, experimentan o pueden verse afectados por una situación o posible solución, y reconoce

que sus perspectivas son relevantes para comprenderla.

- **UR2 — Comprende mediante evidencia de usuarios.** Interpreta información disponible sobre necesidades, experiencias o condiciones de usuarios y personas afectadas para ampliar o precisar su comprensión de la situación.
- **UR3 — Contrasta y revisa su comprensión.** Utiliza evidencia obtenida o proporcionada mediante observación, preguntas, interacción o retroalimentación para contrastar supuestos y revisar su comprensión de necesidades, experiencias o contexto.
- **UR4 — Incorpora evidencia en sus decisiones.** Utiliza evidencia de usuarios o personas afectadas para justificar mantener, modificar o reconsiderar una decisión o propuesta.

Interacción directa e interpretación. La interacción directa puede ser una fuente valiosa de evidencia, pero no constituye por sí misma un waypoint superior; la medición distingue entre haber tenido contacto y ser capaz de interpretar, contrastar e incorporar lo aprendido, reduciendo así la dependencia de oportunidades previas desiguales entre estudiantes.

Fronteras con otros atributos. Se distingue de Diseño (estructurar el desafío, explorar alternativas y regular decisiones de diseño); de Comunicación (escuchar o preguntar puede ser medio de este atributo cuando produce evidencia sobre usuarios, pero no toda interacción comunicativa pertenece a él); de Trabajo grupal e individual; de Liderazgo; y de Ética y profesionalismo (considerar personas afectadas no equivale por sí solo a razonamiento ético) y de Teoría de innovación y emprendimiento (que puede usar casos con usuarios, pero con foco conceptual, no en la incorporación de evidencia concreta de personas).

La Figura 23 presenta el Construct Map revisado de este atributo.

Interacción con usuarios reales




Figura 23. Construct Map revisado de Incorporación de perspectivas de usuarios y personas afectadas: progresión única de cuatro waypoints, centrada en la influencia de la evidencia sobre la comprensión y las decisiones, no en la cantidad de interacción directa. Hipótesis vigente, pendiente de contraste empírico.

29.8. Cambios respecto del inicial

Tabla 19. Cambios respecto del inicial — Interacción con usuarios reales

Elemento	Versión inicial	Versión revisada	Razón del cambio
Variable progresiva	Comprensión de usuarios y problemas regulada por evidencia de interacción	Grado en que comprensión y decisiones se fundamentan y modifican a partir de evidencia de usuarios	Precisar que el eje es la influencia de la evidencia, no la cantidad de interacción
Interacción directa	Waypoint UR3 centrado en interacción directa como tal	Interacción directa reformulada explícitamente como un medio posible, no un requisito	Reducir dependencia de oportunidades previas desiguales (fairness)

Elemento	Versión inicial	Versión revisada	Razón del cambio
Nivel superior	Regular la comprensión mediante evidencia	Incorporar evidencia en las decisiones o propuestas	Precisar que el nivel superior regula decisiones, no solo comprensión

29.9. Hipótesis pendientes

Que el uso de evidencia auténtica proporcionada en una tarea (sin interacción directa) genere resultados comparables al uso de evidencia obtenida mediante interacción directa, tal como el mapa hipotetiza. Que la frontera con Diseño resulte sostenible cuando una misma actuación produzca evidencia relevante para ambos atributos. El orden empírico de los cuatro waypoints, todavía no contrastado con datos de estudiantes.

30. Seguridad y riesgos

30.1. Mapa inicial

Definición inicial: capacidad para reconocer peligros, explicar condiciones de exposición y daño, comparar riesgos, seleccionar medidas de prevención o control, y revisar decisiones considerando riesgo residual e incertidumbre. Variable progresiva inicial: grado en que el estudiante representa relaciones entre peligro, exposición y daño, compara riesgos y selecciona o revisa medidas de control, en una progresión única de cuatro waypoints (SR1–SR4).

30.2. Evidencia cuantitativa

V de Aiken media de 0,778 y V mínima de 0,667, con media de panel de 3,33. Este atributo registró, adicionalmente, la **mayor variabilidad global entre sus seis criterios** de los diez mapas evaluados, sin concentrarse en un único criterio particularmente débil.

30.3. Evidencia cualitativa

Se examinó si el waypoint superior —centrado en revisar la efectividad y las limitaciones de los controles de seguridad y el riesgo residual— resultaba plausible para un estudiante recién ingresado a la universidad, o si se aproximaba más bien a una forma de gestión del riesgo propia de un desempeño profesional. Se insistió en mantener con claridad la distinción entre razonar sobre seguridad y riesgo, por un lado, y exhibir

una conducta segura observada, por otro —el atributo debía medir razonamiento, no comportamiento—. Se señaló una dependencia curricular relevante respecto de la trayectoria Técnico-Profesional. Se examinó también la frontera con Ética y profesionalismo, en torno a distinguir el análisis causal del riesgo técnico del juicio normativo general.

30.4. Literatura focalizada

La revisión focalizada reunió **cinco documentos** sobre conceptualización del riesgo, relación entre peligro, exposición y daño, selección de controles, incertidumbre y nueva información, calibración del nivel superior y distinción entre razonamiento y conducta segura observada. Se consideró literatura de análisis de riesgo y seguridad en contextos de ingeniería y educación, además de los referentes normativos utilizados en el mapa inicial.

La convergencia apoyó conservar una única variable de **estructuración y revisión del razonamiento sobre riesgo**, pero ampliar su alcance desde una lectura predominantemente ocupacional hacia daños posibles a personas, entorno, sistemas, información e infraestructura. También apoyó que el nivel superior no exija una gestión profesional del “riesgo residual”: basta con reconocer límites de los controles y revisar el juicio cuando cambian las condiciones o aparece nueva información.

Así, la literatura sustentó una **recalibración de alcance**, no una separación en strands. El orden y la separabilidad de SR1–SR4 deberán verificarse posteriormente con respuestas estudiantiles.

Trazabilidad textual de la decisión

Comentarios de especialistas

E1. “A las dimensiones de seguridad, riesgos y medidas de control, se debería incorporar también el concepto de “impacto”, asimismo, se deben visualizar las personas (en sus roles) / el entorno en la situación observada, no es razonable descontextualizar el riesgo, daño, etc.”

E5. “Se sugiere reformular SR4 hacia el reconocimiento de los límites de los controles y la necesidad de revisar su adecuación cuando cambian las condiciones, evitando aproximarlos demasiado a un desempeño profesional.”

Literatura focalizada

Aven (2016, p. 5). “Uncertainty is a key concept in risk conceptualisation and risk assessments.”

Interpretación para el refinamiento. La evidencia apoyó **mantener la progresión unidimensional**, ampliar explícitamente su alcance sociotécnico y recalibrar SR4 para que la revisión de controles e incertidumbre sea plausible al ingreso, sin convertir el waypoint superior en gestión profesional del riesgo.

30.5. Diagnóstico

Mantener arquitectura con revisión focalizada: la evidencia no cuestionó la progresión general del mapa, sino que orientó ajustes de calibración y de alcance.

30.6. Decisión

Se decidió **conservar la estructura unidimensional de cuatro waypoints**, ampliando explícitamente el alcance del daño considerado —personas, entorno, sistemas, información e infraestructura, no solo seguridad ocupacional— y precisando que el nivel superior no exige gestión profesional del riesgo residual, sino reconocer que los controles tienen límites y

revisar la valoración cuando cambian las condiciones o aparece nueva información.

30.7. Construct Map revisado

Nombre para medición. Razonamiento sobre seguridad y riesgos.

Definición. Capacidad del estudiante para reconocer peligros, analizar cómo pueden producir daño a personas, entorno o sistemas, comparar riesgos y valorar medidas de control, revisando su juicio cuando cambian las condiciones o aparece nueva información.

Variable progresiva. Grado de estructuración y revisión con que el estudiante relaciona peligro, exposición, posibles daños y medidas de control para razonar sobre el riesgo.

- **SR1 — Reconoce peligros y posibles afectados.** Identifica una fuente o condición capaz de producir daño y reconoce quiénes o qué podrían verse afectados.
- **SR2 — Explica cómo puede producirse el daño.** Relaciona un peligro con condiciones de exposición y consecuencias plausibles para explicar por qué existe riesgo.
- **SR3 — Compara riesgos y valora controles.** Compara riesgos atendiendo a sus posibles consecuencias y condiciones de ocurrencia, y selecciona o justifica medidas orientadas a reducirlos.
- **SR4 — Revisa el riesgo y la adecuación de los controles.** Reconoce que los controles tienen límites y revisa su valoración del riesgo o las medidas propuestas cuando cambian las condiciones o aparece nueva información.

Alcance ampliado. El dominio no se restringe a seguridad ocupacional; una situación puede involucrar daños sobre personas, comunidades, ambiente, datos, infraestructura u otros componentes de un sistema. La conducta segura observada no constituye la variable progresiva: el constructo mide razonamiento sobre riesgo, no comportamiento observado.

Fronteras con otros atributos. Se distingue de Ética y profesionalismo (justificar responsabilidades y decisiones éticas, mientras Seguridad se centra en peligro, riesgo, daño y controles); de Diseño; de Economía y gestión; de Interacción con usuarios reales; de Comunicación;

y de Trabajo inter y multidisciplinario (puede usar información de varias áreas, pero no mide la integración disciplinar en sí).

La Figura 24 presenta el Construct Map revisado de este atributo.



Figura 24. Construct Map revisado de Razonamiento sobre seguridad y riesgos: progresión única de cuatro waypoints, con alcance ampliado del daño considerado (personas, entorno, sistemas, información, infraestructura). Mide razonamiento, no conducta observada. Hipótesis vigente, pendiente de contraste empírico.

30.8. Cambios respecto del inicial

Tabla 20. Cambios respecto del inicial — Seguridad y riesgos

Elemento	Versión inicial	Versión revisada	Razón del cambio
Alcance del daño	Formulación más próxima a seguridad ocupacional	Explícitamente ampliado a personas, entorno, sistemas, información e infraestructura	Precisar que el atributo es socio-técnico y no exclusivamente ocupacional

Elemento	Versión inicial	Versión revisada	Razón del cambio
Nivel superior (SR4)	Revisar la gestión del riesgo	Reevaluar riesgo y controles ante límites, cambios o nueva información, explícitamente no equivalente a gestión profesional del riesgo residual	Calibrar la exigencia al perfil de ingreso
Razonamiento vs. conducta	Riesgo de ambigüedad entre ambos	Explícitamente delimitado: se mide razonamiento, no comportamiento observado	Responder a la observación experta sobre esta distinción

30.9. Hipótesis pendientes

Que SR4, tal como fue recalibrado, resulte efectivamente plausible y observable para estudiantes de ingreso sin depender de experiencia previa en seguridad. Que el alcance ampliado del daño (más allá de lo ocupacional) pueda representarse mediante tareas accesibles sin requerir conocimiento técnico especializado por dominio. El orden empírico de los cuatro waypoints, todavía no contrastado con datos de estudiantes.

31. Ética y profesionalismo

31.1. Mapa inicial

Definición inicial: capacidad para reconocer preocupaciones éticas o de responsabilidad, identificar personas afectadas, derechos y deberes, comparar cursos de acción, y justificar decisiones responsables reconociendo tensiones, límites e incertidumbre. Variable progresiva inicial: grado en que el estudiante identifica dimensiones éticas y profesionales, considera afectados y responsabilidades, compara cursos de acción y justifica decisiones revisables, en una progresión única de cuatro waypoints (EP1-EP4). La construcción inicial (sección 9.10 de la Parte III) ya incorporaba una pregunta abierta al panel sobre si ética y profesionalismo se articulaban en una progresión suficientemente común.

31.2. Evidencia cuantitativa

V de Aiken media de 0,767, con V mínima de 0,667 en el criterio de adecuación al perfil de ingreso y al contexto, y media de panel de 3,30.

31.3. Evidencia cualitativa

Los comentarios retomaron la pregunta ya planteada en la construcción inicial: si ética y profesionalismo —dos nociones combinadas en la denominación institucional del atributo— compartían una progresión común, o si el

componente de responsabilidad profesional (honestidad, transparencia, conflictos de interés, límites de competencia) requería un tratamiento diferenciado del razonamiento ético propiamente tal. Se señaló, además, un riesgo particular de **deseabilidad social** en la evaluación de este atributo —que una respuesta refleje la opción socialmente esperada más que un razonamiento genuino—, condición de fairness especialmente relevante para el diseño futuro de tareas.

31.4. Literatura focalizada

La revisión focalizada reunió **cinco documentos** sobre razonamiento ético y responsabilidad profesional en ingeniería. El corpus incluyó trabajos sobre razonamiento ético en la formación de ingenieros, orientación al bien público, relaciones entre razonamiento moral e intuiciones y marcos de responsabilidad profesional. La triangulación mostró convergencia en la necesidad de distinguir **reconocer una cuestión ética**, considerar afectados, consecuencias y responsabilidades, comparar cursos de acción y justificar o revisar decisiones.

La revisión también permitió resolver la tensión “ética versus profesionalismo”. Honestidad, transparencia, responsabilidad, conflictos de interés y reconocimiento de límites de competencia pueden aparecer en distintos niveles del juicio según el caso; la evidencia no exigía convertirlos en un segundo continuo independiente. Por ello se trataron como **condiciones transversales del juicio ético-profesional**, mientras la variable progresiva se centró en la amplitud, integración, fundamentación y revisión del razonamiento.

La literatura reforzó además el riesgo de **deseabilidad social**: la evaluación futura deberá exigir justificación y deliberación ante tensiones, no premiar simplemente la opción normativamente esperada.

Trazabilidad textual de la decisión

Comentarios de especialistas

E3. “La solución adoptada me parece adecuada, porque ética y profesionalismo comparten la misma estructura de razonamiento (afectados, deberes, consecuencias, justificación) y no constituyen dominios de contenido separados.”

E5. “El mapa presenta una progresión compatible con una creciente complejidad del juicio moral, desde el reconocimiento de una preocupación ética hacia la consideración de responsabilidades, la evaluación de alternativas y la deliberación frente a tensiones e incertidumbre.”

Literatura focalizada

Hess et al. (2019, p. 84). “Cognitive models of development are particularly relevant for initiatives in ethics education addressing ethical reasoning.”

Interpretación para el refinamiento. La evidencia respaldó una sola progresión de **juicio ético-profesional responsable**, mientras el profesionalismo se trata como condición transversal —responsabilidad, límites de competencia y deberes— y no como una segunda progresión independiente.

31.5. Diagnóstico

Deliberación conceptual: la evidencia no convergió de manera concluyente hacia mantener sin cambios ni hacia una separación estructural, requiriendo una ponderación cuidadosa de la evidencia disponible.

31.6. Decisión

Se decidió **mantener la estructura unidimensional de cuatro waypoints**, resolviendo la pregunta de unidad del constructo mediante el tratamiento del profesionalismo como una condición transversal a la progresión de juicio ético, en lugar de reespecificar el atributo en dos strands. Se reformuló la variable progresiva para hacerla explícita como la amplitud, integración y fundamentación del juicio ético-profesional.

31.7. Construct Map revisado

Nombre para medición. Juicio ético-profesional responsable.

Definición. Capacidad del estudiante para reconocer cuestiones éticas y responsabilidades profesionales, considerar a las personas afectadas y las consecuencias de distintas decisiones, justificar cursos de acción y revisar su juicio frente a tensiones, incertidumbre o límites de su propia competencia.

Variable progresiva. Grado de amplitud, integración y fundamentación con que el estudiante construye y revisa un juicio ético-profesional.

- **EP1 — Reconoce una cuestión ética.** Identifica que una situación involucra consecuencias, responsabilidades o intereses de otras personas que requieren consideración ética.
- **EP2 — Analiza afectados y responsabilidades.** Relaciona personas afectadas, posibles consecuencias y responsabilidades relevantes para comprender con mayor precisión qué está éticamente en juego.
- **EP3 — Compara y justifica cursos de acción.** Compara alternativas considerando razones éticamente relevantes — consecuencias, responsabilidades, derechos, cuidado o compromisos profesionales— y fundamenta una decisión.
- **EP4 — Delibera y revisa su juicio.** Reconsidera una decisión cuando existen razones en tensión, incertidumbre o límites en su propia competencia, explicitando qué información, apoyo o revisión requiere.

Profesionalismo transversal. El profesionalismo no se reduce a un nivel separado. Honestidad, transparencia, responsabilidad, conflictos de interés y límites de competencia pueden hacerse relevantes en diferentes puntos de la progresión según la situación; lo que cambia cualitativamente es la forma en que esas consideraciones se integran y fundamentan en el juicio. La progresión tampoco presupone una única teoría moral: consecuencias, responsabilidades, derechos, cuidado u otros compromisos pueden constituir razones legítimas según la situación; la medición debe valorar la amplitud, pertinencia, coherencia y revisabilidad del razonamiento, no la adhesión a un marco moral particular.

Fronteras con otros atributos. Se distingue de Seguridad y riesgos (analizar peligros, exposición, daño y controles, mientras Ética se centra en responsabilidades y justificación ética de decisiones); de Liderazgo; de Interacción con usuarios reales (considera sus intereses y consecuencias en el juicio ético, pero no equivale a incorporar su evidencia); de Diseño; y de Comunicación (expresar una justificación no equivale al razonamiento ético que la sustenta).

La Figura 25 presenta el Construct Map revisado de este atributo.




Figura 25. Construct Map revisado de Juicio ético-profesional responsable: progresión única de cuatro waypoints, con el profesionalismo como condición transversal. Hipótesis vigente, pendiente de contraste empírico.

31.8. Cambios respecto del inicial

Tabla 21. Cambios respecto del inicial — Ética y profesionalismo

Elemento	Versión inicial	Versión revisada	Razón del cambio
Variable progresiva	Identificación de dimensiones éticas/profesionales, afectados y justificación de decisiones revisables	Amplitud, integración y fundamentación del juicio ético-profesional	Precisar un único eje de progreso que integre explícitamente ambos componentes institucionales
Profesionalismo	Riesgo de tratarse como componente separado no resuelto	Explícitamente transversal a toda la progresión	Resolver la pregunta de unidad del constructo planteada desde la construcción inicial
Deseabilidad social	No abordada explícitamente	Reconocida como condición de fairness a controlar en el diseño futuro de tareas	Responder a la observación experta sobre este riesgo

31.9. Hipótesis pendientes

Que el profesionalismo funcione efectivamente como condición transversal observable en distintos puntos de la progresión, y no requiera, en evidencia futura, tratarse como dimensión separada. Que la deseabilidad social pueda controlarse mediante el diseño de situaciones con alternativas defendibles, tal como se hipotetiza. Que EP4 resulte plausible para estudiantes de ingreso y no se aproxime a un estándar de juicio profesional experto. El orden empírico de los cuatro waypoints, todavía no contrastado con datos de estudiantes.

32. Trabajo inter y multidisciplinario

32.1. Mapa inicial

Definición inicial: capacidad para reconocer que un problema puede requerir diferentes tipos de conocimiento, diferenciar sus aportes, integrarlos en una comprensión o solución común, y revisar críticamente esa integración. Variable progresiva inicial: grado en que el estudiante reconoce, relaciona, integra y revisa aportes provenientes de diferentes perspectivas de conocimiento, en una progresión única de cuatro waypoints (IM1-IM4).

32.2. Evidencia cuantitativa

V de Aiken media de 0,878 —la **más alta de los diez atributos**—, con V mínima de 0,867 y media de panel de 3,63. Este atributo mostró, además, la menor dispersión entre los cinco especialistas de todo el panel.

32.3. Evidencia cualitativa

El panel valoró este mapa como el más sólido en su conjunto, sin observaciones que cuestionaran su unidad conceptual ni su progresión general. La observación principal se concentró en el waypoint superior (IM4): si su exigencia —evaluar y reconfigurar críticamente la integración entre perspectivas— resultaba plenamente calibrada para el perfil de ingreso, sin aproximarse a una sofisticación epistemológica propia de un desempeño profesional. Se planteó también la conveniencia de hacer más explícita la distinción entre una fase de aportes diferenciados por área (multidisciplinariedad) y una fase de integración en que esos aportes se modifican mutuamente (interdisciplinariedad), y de precisar que el desempeño no debe inferirse por el número de disciplinas mencionadas ni por la composición formal del grupo, sino por la calidad de la articulación entre perspectivas —evitando así medir familiaridad con nombres de carreras en lugar de integración de conocimiento—.

32.4. Literatura focalizada

La revisión focalizada reunió **cinco documentos** sobre educación interdisciplinaria en ingeniería, integración de perspectivas, diferencias entre multidisciplinariedad e interdisciplinariedad y tensiones o límites entre aportes de distintas áreas.

La convergencia apoyó mantener una única variable de **conexión, integración y revisión de aportes provenientes de distintas áreas**, con dos precisiones. Primero, IM2 puede representar

una relación principalmente multidisciplinaria — aportes diferenciados que contribuyen de forma complementaria—, mientras IM3 representa el salto hacia una integración interdisciplinaria en la que los aportes se modifican mutuamente. Segundo, IM4 debía recalibrarse para que revisar vacíos, tensiones o limitaciones fuera plausible en estudiantes de ingreso, sin exigir sofisticación epistemológica profesional.

La transdisciplinariedad se mantuvo fuera de las exigencias del Hito 0. La literatura respaldó esta calibración y la distinción multi/inter, pero no convierte por sí misma la progresión en una escala empíricamente validada.

Trazabilidad textual de la decisión

Comentarios de especialistas

E3. “El título del atributo la contiene y el mapa la incorpora de hecho (IM2 corresponde a la yuxtaposición de aportes, IM3 a su modificación mutua), pero no se nombra en ningún punto.”

E5. “Quizás el IM4 es demasiado abstracto para un hito 0, es importante que en el instrumento mida más bien si puede darse cuenta de que los distintos aportes también pueden entrar en tensión y revisar cómo se están combinando, antes que aspectos epistemológicos.”

Literatura focalizada

Choi y Pak (2006, p. 351). “Interdisciplinarity analyzes, synthesizes and harmonizes links between disciplines into a coordinated and coherent whole.”

Interpretación para el refinamiento. La evidencia respaldó **mantener una progresión unidimensional**, interpretar IM2 como relación principalmente multidisciplinaria e IM3 como integración interdisciplinaria, y recalibrar IM4

para evitar exigir sofisticación epistemológica propia de etapas universitarias avanzadas.

32.5. Diagnóstico

Mantener con ajustes focalizados: el mapa con mayor respaldo relativo del conjunto, sin necesidad de revisión conceptual ni estructural.

32.6. Decisión

Se decidió **conservar la estructura unidimensional de cuatro waypoints**, con dos ajustes focalizados: recalibrar la exigencia del waypoint superior para mantenerlo accesible al perfil de ingreso, y hacer explícita la lectura de multidisciplinariedad e interdisciplinariedad como posiciones distintas dentro de una misma variable de integración, en lugar de dos strands separados.

32.7. Construct Map revisado

Nombre para medición. Integración de perspectivas inter y multidisciplinarias.

Definición. Capacidad del estudiante para reconocer aportes pertinentes de distintas áreas de conocimiento, relacionarlos e integrarlos para comprender o abordar una situación, y revisar esa integración cuando aparecen vacíos, tensiones o limitaciones.

Variable progresiva. Grado de conexión, integración y revisión con que el estudiante articula aportes provenientes de diferentes áreas de conocimiento.

- **IM1 — Reconoce aportes de diferentes áreas.** Identifica que una situación puede requerir perspectivas o conocimientos diferentes y reconoce qué puede aportar cada uno.
- **IM2 — Relaciona aportes complementarios.** Explica cómo aportes provenientes de distintas áreas pueden contribuir de manera complementaria a comprender o abordar una situación.
- **IM3 — Integra perspectivas.** Combina aportes de diferentes áreas de modo que se relacionen y modifiquen mutuamente para construir una comprensión o respuesta común.
- **IM4 — Revisa críticamente la integración.** Identifica vacíos, tensiones o limitaciones en la forma en que se han combinado distintas

perspectivas y ajusta su integración para mejorar la comprensión o respuesta.

De multidisciplinariedad a interdisciplinariedad. IM2 puede interpretarse como una forma principalmente multidisciplinaria —aportes diferenciados y complementarios alrededor de una situación común—; IM3 representa el salto hacia integración interdisciplinaria, porque los aportes dejan de ser paralelos y comienzan a influirse mutuamente. La transdisciplinariedad no se exige en el diagnóstico de ingreso.

Fronteras con otros atributos. Se distingue de Trabajo grupal e individual (integrar y regular contribuciones de personas al trabajo colectivo, mientras este atributo integra conocimientos y perspectivas de diferentes áreas); de Diseño; de Interacción con usuarios reales (sus perspectivas pueden participar en una tarea, pero no equivalen por sí solas a integración disciplinar); de Comunicación; de Economía y gestión; y de Liderazgo.

La Figura 26 presenta el Construct Map revisado de este atributo.

Trabajo inter y multidisciplinario




Figura 26. Construct Map revisado de Integración de perspectivas inter y multidisciplinarias: progresión única de cuatro waypoints, con un punto de inflexión conceptual entre una lectura multidisciplinaria (IM1-IM2) y una interdisciplinaria (IM3-IM4). Hipótesis vigente, pendiente de contraste empírico.

32.8. Cambios respecto del inicial

Tabla 22. Cambios respecto del inicial — Trabajo inter y multidisciplinario

Elemento	Versión inicial	Versión revisada	Razón del cambio
Waypoint superior (IM4)	Evaluar y reconfigurar críticamente la integración, sin mayor precisión sobre su alcance	Explícitamente delimitado: no exige análisis epistemológico avanzado ni experiencia profesional interdisciplinaria	Calibrar la exigencia al perfil de ingreso
Multi- vs. interdisciplinaria	Implícita en la progresión	Explicitada como lectura de IM2 (multidisciplinaria) e IM3 (interdisciplinaria) dentro de la misma variable	Responder a la observación experta sobre hacer más visible esta distinción
Criterio de desempeño	Riesgo de asociarse al número de disciplinas mencionadas	Explícitamente centrado en la calidad de la articulación, no en el conteo de disciplinas ni en la composición del grupo	Evitar medir familiaridad con nombres de carreras en lugar de integración de conocimiento

32.9. Hipótesis pendientes

Que multidisciplinaria e interdisciplinaria se comporten empíricamente como posiciones distintas de una misma variable, y no requieran, en evidencia futura, tratarse como strands separados. Que IM4, tal como fue recalibrado, resulte observable sin exigir sofisticación

epistemológica ni experiencia profesional. El orden empírico de los cuatro waypoints, todavía no contrastado con datos de estudiantes.

33. Arquitectura resultante de los diez atributos

Tabla 23. Arquitectura resultante de los diez atributos

Atributo	Nombre para medición	Variable progresiva (síntesis)	Estructura	N.º de progresiones	N.º de waypoints	Estado
Comunicación	Comunicación: construcción, adaptación y regulación de la interacción	Control del mensaje (construcción) e interpretación/regulación de la interacción (recepción)	Multidimensional provisional	2	4 + 4	Hipótesis revisada, pendiente de nueva evidencia
Trabajo grupal e individual	Integración de la contribución individual al trabajo colectivo	Integración y regulación de la contribución individual dentro de interdependencias	Unidimensional refinado	1	4	Hipótesis revisada
Interacción con usuarios reales	Incorporación de perspectivas de usuarios y personas afectadas	Influencia de la evidencia de usuarios sobre comprensión y decisiones	Unidimensional refinado	1	4	Hipótesis revisada
Diseño	Diseño: problematización, ideación y regulación mediante evidencia	Estructuración del problema; amplitud del espacio de alternativas; regulación de decisiones mediante evidencia	Multidimensional provisional	3	4 + 4 + 4	Hipótesis revisada, pendiente de nueva evidencia
Teoría de innovación y emprendimiento	Comprensión conceptual de innovación y emprendimiento	Coherencia conceptual de innovación; coherencia conceptual de emprendimiento	Multidimensional provisional	2	4 + 4	Hipótesis revisada, pendiente de nueva evidencia
Seguridad y riesgos	Razonamiento sobre seguridad y riesgos	Estructuración y revisión del razonamiento sobre peligro, exposición, daño y control	Unidimensional, alcance ampliado	1	4	Hipótesis mantenida con ajustes
Liderazgo	Liderazgo en la acción colectiva	Contribución a orientar y fortalecer la capacidad de acción colectiva	Unidimensional refinado	1	4	Hipótesis revisada
Economía y gestión	Economía y gestión de iniciativas	Razonamiento de viabilidad; organización y ajuste de la implementación	Multidimensional provisional	2	4 + 4	Hipótesis revisada, pendiente de nueva evidencia

Atributo	Nombre para medición	Variable progresiva (síntesis)	Estructura	N.º de progresiones	N.º de waypoints	Estado
Ética y profesionalismo	Juicio ético-profesional responsable	Amplitud, integración y fundamentación del juicio ético-profesional	Unidimensional refinado	1	4	Hipótesis revisada
Trabajo inter y multidisciplinario	Integración de perspectivas inter y multidisciplinarias	Conexión, integración y revisión de aportes de distintas áreas	Unidimensional, recalibrado	1	4	Hipótesis mantenida con ajustes

Nota: ningún atributo se describe como "validado" en esta tabla. Los términos "hipótesis revisada", "hipótesis mantenida con ajustes" y "pendiente de nueva evidencia" reflejan el estado epistemológico real de cada mapa al cierre de esta etapa del proyecto.

33.1. Patrones de cambio observados

De los diez atributos, **cuatro** —Comunicación, Diseño, Teoría de innovación y emprendimiento, y Economía y gestión— recibieron una intervención de tipo D (reespecificación estructural), pasando de una progresión única a dos o tres progresiones relacionadas. **Cuatro** —Liderazgo, Trabajo grupal e individual, Interacción con usuarios reales, y Ética y profesionalismo— recibieron una intervención de tipo B (refinamiento conceptual): conservaron una estructura unidimensional, pero modificaron sustantivamente su variable progresiva, redefiniendo el eje de la progresión. **Dos** —Seguridad y riesgos, y Trabajo inter y multidisciplinario— recibieron una intervención de tipo A (ajuste de formulación): conservaron tanto su estructura como su variable progresiva original, con ajustes focalizados de alcance o calibración.

Un patrón que se repitió en varios de los atributos reespecificados estructuralmente (Diseño, Economía y gestión, Comunicación) fue que la evidencia cuantitativa señalaba una debilidad relativamente localizada —frecuentemente en el criterio de Claridad o en el de Orden y progresión— que, examinada junto con los comentarios cualitativos, orientó un examen más profundo de la unidad del constructo. **La V de Aiken no se interpretó, por sí sola, como evidencia de dimensionalidad:** la decisión de formular más de una progresión constituye una hipótesis de modelamiento derivada de la triangulación entre evidencia experta, coherencia sustantiva y contraste conceptual, no de un umbral cuantitativo. En Teoría de innovación y emprendimiento, en cambio, la señal cuantitativa desfavorable fue la más generalizada de los diez mapas, afectando de manera más uniforme al conjunto de criterios. No se convierte esta observación en una comparación estadística entre los cambios de los distintos atributos, dado que las

intervenciones no son directamente equiparables entre sí en su naturaleza ni en su magnitud.

33.2. El nivel inicial como manifestación sustantiva

El refinamiento buscó, de manera consistente en los diez atributos, que el primer waypoint (o, en los mapas multidimensionales, el primer waypoint de cada progresión) no representara ausencia, error, desconocimiento o ingenuidad pura, sino una **manifestación mínima pero interpretable** del constructo correspondiente. El caso más explícito de ajuste en esta dirección fue Teoría de innovación y emprendimiento, donde el panel señaló directamente que el nivel inicial se aproximaba a una formulación en términos de déficit; la versión revisada reformuló ese nivel para representar un reconocimiento situado en una necesidad u oportunidad concreta, en lugar de una asociación genérica con la novedad. En el resto de los atributos, este principio se mantuvo como criterio de revisión aplicado de manera transversal, sin que ello implique que todos hayan requerido el mismo grado de ajuste en este punto específico.

33.3. El extremo superior como diferenciador dentro del perfil de ingreso

De manera igualmente consistente, el waypoint superior de cada progresión —o de cada strand, en los mapas multidimensionales— fue revisado para asegurar que no representara desempeño profesional, dominio disciplinar universitario, ni una expectativa universal para toda la cohorte de ingreso, sino una manifestación relativamente sofisticada pero **observable en algunos estudiantes** al momento de ingresar a la universidad. Este criterio motivó ajustes explícitos de calibración en al menos dos atributos que conservaron su estructura unidimensional: Seguridad y riesgos (donde el nivel superior se precisó para no exigir gestión profesional del riesgo residual) y Trabajo inter y

multidisciplinario (donde el nivel superior se precisó para no exigir sofisticación epistemológica).

33.4. Fronteras entre atributos después del refinamiento

El proceso de refinamiento no solo ajustó cada mapa de manera individual; también precisó, de

manera explícita y recíproca, las fronteras entre pares de atributos que habían sido señaladas como porosas durante el juicio experto (sección 15.5):

Tabla 24. Fronteras entre atributos después del refinamiento

Evidencia observada	Constructo principal	No interpretar automáticamente como
El estudiante cumple su tarea asignada y coordina su aporte con el de otros integrantes del grupo	Trabajo grupal e individual	Liderazgo (a menos que exista, además, orientación o fortalecimiento intencional de la capacidad de acción del colectivo)
El estudiante propone una acción, orienta al grupo hacia una meta o facilita que otros decidan y actúen	Liderazgo	Trabajo grupal e individual (a menos que la evidencia se limite a cumplir y coordinar la propia tarea)
El estudiante identifica o describe la participación de usuarios en un caso	Interacción con usuarios reales	Diseño (a menos que, además, existan decisiones de problematización, ideación o regulación de una solución)
El estudiante propone, explora o regula una solución mediante criterios y evidencia	Diseño	Interacción con usuarios reales (a menos que, además, se incorpore explícitamente evidencia de personas usuarias o afectadas)
El estudiante combina aportes de distintas áreas de conocimiento en una respuesta común	Trabajo inter y multidisciplinario	Trabajo grupal e individual (que se centra en la coordinación de personas, no en la integración de conocimientos)
El estudiante organiza tareas, tiempos o responsables de una iniciativa	Economía y gestión (strand de gestión de la implementación)	Liderazgo (asignar responsables o secuenciar tareas no constituye, por sí mismo, liderazgo)
El estudiante identifica peligros o analiza consecuencias de una decisión técnica	Seguridad y riesgos	Ética y profesionalismo (a menos que la evidencia verse sobre responsabilidades, deberes o juicio normativo, no sobre el mecanismo de daño)
El estudiante reconoce responsabilidades, afectados o límites de su propia competencia	Ética y profesionalismo	Seguridad y riesgos (a menos que la evidencia verse específicamente sobre peligro, exposición y control técnico del daño)
El estudiante comunica con claridad una propuesta o una justificación	Comunicación	El atributo cuyo contenido está siendo comunicado (Diseño, Ética, Economía y gestión, etc.), que debe evaluarse por la calidad de su propio razonamiento, no por la elocuencia con que se expresa

Esta síntesis de fronteras no agota todas las combinaciones posibles entre los diez atributos; recoge las que fueron efectivamente examinadas durante el juicio experto y el refinamiento posterior, y constituye un insumo directo para el diseño futuro de tareas (Items Design), que deberá evitar que una misma actuación se

compute automáticamente como evidencia de más de un atributo sin una regla explícita de decisión.

La Figura 27 sintetiza esta arquitectura para los diez atributos en conjunto.




Figura 27. Arquitectura final de los diez atributos institucionales tras el refinamiento: seis con estructura unidimensional y cuatro con estructura multidimensional provisional. La multidimensionalidad no implica mayor desarrollo ni mayor jerarquía; responde a la naturaleza sustantiva de cada constructo, según la evidencia disponible al cierre de esta etapa.

34. Implicaciones metodológicas del refinamiento

34.1. De etiquetas a variables

Al inicio de este reporte (sección 1), los diez atributos existían como declaraciones institucionales del perfil de egreso, sin una variable subyacente explícita para cada uno. Tras el proceso documentado en esta parte, los diez atributos cuentan ahora con una definición delimitada, una variable progresiva (o, en cuatro casos, más de una), un conjunto de waypoints ordenados, límites explícitos sobre qué queda dentro y fuera de cada constructo, y una primera formulación de qué evidencia futura permitiría observarlos. Los atributos dejaron de funcionar únicamente como nombres institucionales y pasaron a operar como hipótesis de medición articuladas.

34.2. De progresiones asumidas a hipótesis explícitas

Un efecto metodológico central de este proceso es que ahora es posible formular, y eventualmente contrastar empíricamente, afirmaciones que antes ni siquiera estaban explicitadas con suficiente precisión como para someterse a prueba: por ejemplo, que P2 precede sustantivamente a P3 dentro del strand de Problematicación de Diseño, o que LG3 y LG4 constituyen posiciones

cualitativamente distinguibles dentro de Liderazgo. Antes de la construcción de los Construct Maps documentada en la Parte III y de su refinamiento en esta parte, estas hipótesis no estaban formuladas de manera suficientemente explícita como para ser evaluadas por nadie —ni por el equipo del proyecto, ni por especialistas externos, ni, en el futuro, mediante datos de estudiantes—.

34.3. Implicación para la evaluación

Los diez Construct Maps revisados permiten ahora avanzar de manera coherente hacia los componentes siguientes del sistema de medición: diseño de ítems o tareas (Items Design), definición de espacios de resultados y reglas de puntuación (Outcome Space), y contraste empírico mediante un modelo de medición (Measurement Model). La tarea que sigue ya no consiste en "inventar preguntas para Liderazgo" o "diseñar una rúbrica para Diseño", sino en **diseñar situaciones capaces de generar evidencia diferenciadora** respecto de las posiciones específicas hipotetizadas en cada mapa —por ejemplo, situaciones capaces de distinguir LG1 de LG2 de LG3 de LG4, o de generar evidencia diferenciada sobre los tres strands de Diseño sin que una misma actuación se compute de manera redundante entre ellos—. Este desplazamiento —desde diseñar instrumentos hacia diseñar evidencia para una variable ya especificada— es la

consecuencia metodológica central de todo el trabajo documentado en las Partes III, IV y V de este reporte.

35. Transición hacia la siguiente fase

La reespecificación de los diez constructos documentada en esta parte no completa todavía un sistema de medición diagnóstica operativo. Los Construct Maps revisados son hipótesis sustantivas mejor fundamentadas que su versión inicial, pero continúan siendo, en su totalidad, hipótesis: incluso los seis atributos que conservaron una estructura unidimensional deben todavía contrastarse con evidencia empírica sobre el funcionamiento real de sus waypoints; los cuatro atributos reespecificados estructuralmente requieren, además, evidencia sobre la sostenibilidad misma de su multidimensionalidad.

El desafío siguiente consiste en transformar estas progresiones en: oportunidades concretas de observación; tareas y escenarios capaces de elicitar evidencia a lo largo de cada continuo; respuestas esperadas para cada waypoint; categorías de puntuación coherentes con la progresión hipotetizada; reglas de decisión para situaciones ambiguas o mixtas; y, finalmente, un modelo de medición capaz de contrastar empíricamente la estructura aquí propuesta. La parte siguiente de este reporte desarrollará estas implicaciones y la hoja de ruta general del sistema.

Referencias de la PARTE V

- American Educational Research Association, American Psychological Association, & National Council on Measurement in Education. (2014). Standards for educational and psychological testing. American Educational Research Association.
- Aven, T. (2016). Risk assessment and risk management: Review of recent advances on their foundation. *European Journal of Operational Research*, 253(1), 1–13. <https://doi.org/10.1016/j.ejor.2015.12.023>
- Bacigalupo, M., Kampylis, P., Punie, Y., & Van den Brande, G. (2016). *EntreComp: The entrepreneurship competence framework*. Publications Office of the European Union. <https://doi.org/10.2791/593884>
- Choi, B. C. K., & Pak, A. W. P. (2006). Multidisciplinarity, interdisciplinarity and transdisciplinarity in health research, services, education and policy: 1. Definitions, objectives, and evidence of effectiveness. *Clinical and Investigative Medicine*, 29(6), 351–364.
- Crismond, D. P., & Adams, R. S. (2012). The informed design teaching and learning matrix. *Journal of Engineering Education*, 101(4), 738–797. <https://doi.org/10.1002/j.2168-9830.2012.tb01127.x>
- DeRue, D. S. (2011). Adaptive leadership theory: Leading and following as a complex adaptive process. *Research in Organizational Behavior*, 31, 125–150. <https://doi.org/10.1016/j.riob.2011.09.007>
- Design Council. (2019). Framework for Innovation. <https://www.designcouncil.org.uk/resources/framework-for-innovation/>
- Dorst, K., & Cross, N. (2001). Creativity in the design process: Co-evolution of problem-solution. *Design Studies*, 22(5), 425–437. [https://doi.org/10.1016/S0142-694X\(01\)00009-6](https://doi.org/10.1016/S0142-694X(01)00009-6)
- Goldstein, M. H., Adams, R. S., & Purzer, S. (2021). Understanding informed design through trade-off decisions with an empirically-based protocol for students and design educators. *Journal of Pre-College Engineering Education Research*, 11(2), 25–41. <https://doi.org/10.7771/2157-9288.1279>
- Hess, J. L., Beever, J., Zoltowski, C. B., Kisselburgh, L., & Brightman, A. O. (2019). Enhancing engineering students' ethical reasoning: Situating reflexive principlism within the SIRA framework. *Journal of Engineering Education*, 108(1), 82–102. <https://doi.org/10.1002/jee.20249>
- Kane, M. T. (2013). Validating the interpretations and uses of test scores. *Journal of Educational Measurement*, 50(1), 1–73. <https://doi.org/10.1111/jedm.12000>
- Leydens, J. A., & Lucena, J. C. (2009). Listening as a missing dimension in engineering education: Implications for sustainable community development efforts. *IEEE Transactions on Professional Communication*, 52(4), 359–376. <https://doi.org/10.1109/TPC.2009.2032383>
- Nijhuis, S. (2012). Learning for project management in a higher education curriculum. Paper presented at the PMI Research and Education Conference, Limerick, Ireland. Project Management Institute.
- OECD/Eurostat. (2018). Oslo Manual 2018: Guidelines for collecting, reporting and using data on innovation (4th ed.). OECD Publishing. <https://doi.org/10.1787/9789264304604-en>
- Sireci, S., & Faulkner-Bond, M. (2014). Validity evidence based on test content. *Psicothema*, 26(1), 100–107. <https://doi.org/10.7334/psicothema2013.256>
- Stevens, M. J., & Campion, M. A. (1994). The knowledge, skill, and ability requirements for teamwork: Implications for human resource management. *Journal of Management*, 20(2), 503–530. <https://doi.org/10.1177/014920639402000210>
- Wilson, M. (2023). *Constructing measures: An item response modeling approach* (2nd ed.). Routledge. <https://doi.org/10.4324/9781003286929>

Wilson, M., & Gochyyev, P. (2013). Psychometrics. In T. Teo (Ed.), *Handbook of quantitative methods for educational research* (pp. 3-30). Sense Publishers. https://doi.org/10.1007/978-94-6209-404-8_1

Zoltowski, C. B., Oakes, W. C., & Cardella, M. E. (2012). Students' ways of experiencing human-centered design. *Journal of Engineering Education*, 101(1), 28-59. <https://doi.org/10.1002/j.2168-9830.2012.tb00040.x>

PARTE VI

DESARROLLO DE LA NUEVA MEDICIÓN Y AGENDA DE VALIDACIÓN

36. De los Construct Maps a la evidencia observable

38. Outcome Space

40. Procesos de respuesta

42. Measurement Model

44. Diseño del reporte de resultados del Hito 0

46. Hoja de ruta

48. Estado actual del sistema

37. Items Design

39. Consideraciones especiales para Diseño

41. Pilotaje de la nueva medición

43. Análisis psicométricos del pilotaje

45. Agenda de validación

47. Riesgos metodológicos a controlar

49. Conclusión de la Parte VI

36. De los Construct Maps a la evidencia observable

La Parte V documentó cómo los diez Construct Maps iniciales fueron refinados o reespecificados a partir del juicio experto, el análisis cualitativo y la revisión focalizada de literatura. Disponer de esos mapas revisados permite responder, con un fundamento mucho más sólido que al inicio del proyecto, la pregunta **qué se pretende medir** para cada uno de los diez atributos institucionales. Sin embargo, esa pregunta resuelta no resuelve todavía una segunda pregunta, distinta y igualmente indispensable: **cómo obtener evidencia suficiente para ubicar a un**

estudiante —o, en el caso de evidencia grupal, a un grupo— sobre esa variable.

Contar con una definición, una variable progresiva y cuatro waypoints por atributo (o por strand, en los cuatro atributos reespecificados) no constituye todavía un instrumento. La siguiente etapa del sistema consiste en transformar cada progresión en **oportunidades de observación** concretas: situaciones, tareas o escenarios capaces de provocar una actuación de la que pueda inferirse razonablemente la posición del estudiante sobre la variable.

Este desplazamiento de la pregunta debe quedar explícito, porque organiza todo el desarrollo de esta parte del reporte. Antes de la Parte V, la pregunta relevante era:

"¿qué significa Liderazgo?"

A partir de esta parte, con el Construct Map de Liderazgo ya especificado, la pregunta relevante pasa a ser:

"¿qué situación debe enfrentar un estudiante para que su respuesta permita distinguir entre LG1, LG2, LG3 y LG4?"

La misma transformación aplica a los otros nueve atributos, incluidos los cuatro que ahora se organizan mediante más de una progresión: para Diseño, por ejemplo, la pregunta relevante ya no es "¿qué es Diseño?", sino "¿qué situación permite generar evidencia diferenciada sobre Problematicación, Ideación, y Evaluación y regulación mediante evidencia, sin confundir unas con otras?".

36.1. Principio de alineamiento

El desarrollo futuro del sistema debe asegurar una cadena explícita entre ocho eslabones, ninguno de los cuales puede omitirse sin debilitar la interpretación final de los resultados:

**Constructo → waypoint → evidencia esperada
→ demanda de la tarea → respuesta**

observable → categoría de puntuación → modelo → interpretación.

Como se estableció en el diagnóstico de la Parte II, una debilidad central de la primera aproximación del Hito 0 fue que varios de estos eslabones no estaban explicitados: existía una asociación directa entre atributo declarado e ítem o criterio, pero no una cadena completa que permitiera justificar, para cada respuesta observada, por qué constituye evidencia de una posición determinada sobre una variable definida. La nueva arquitectura de medición debe construirse, desde su origen, asegurando que cada uno de estos ocho eslabones quede explícito y documentado para cada atributo.

36.2. No todos los atributos requieren el mismo formato

Un riesgo real en el desarrollo de un sistema de medición para diez atributos distintos es que la búsqueda de eficiencia operativa —aplicar el mismo instrumento, con el mismo formato, a los diez— termine imponiéndose sobre la naturaleza específica de cada constructo. Este riesgo debe evitarse explícitamente.

Distintos tipos de evidencia resultan más o menos compatibles con la naturaleza de cada constructo:

- **cuestionarios basados en escenarios**, apropiados cuando la evidencia relevante consiste en decisiones o interpretaciones que un estudiante puede producir individualmente frente a información escrita o audiovisual;
- **selección múltiple simple**, apropiada solo cuando existe una respuesta correcta identificable y la demanda cognitiva relevante es de reconocimiento o identificación —como mostró la Parte II, este formato por sí solo resultó insuficiente para representar progresiones cualitativas complejas—;
- **Ordered Multiple Choice (OMC)**, cuando es posible diseñar opciones que representen, de manera teóricamente fundamentada, distintas posiciones de una progresión (sección 37.4);
- **respuestas breves justificadas**, cuando interesa observar el razonamiento del estudiante y no solo su elección final;
- **situaciones de desempeño**, individuales o grupales, cuando la evidencia relevante involucra interacción, negociación, coordinación o actuación observable en tiempo real (sección 37.5);
- **tareas de interacción con usuarios o personas afectadas**, cuando el constructo exige observar cómo el estudiante incorpora evidencia externa a su comprensión o a sus decisiones;
- **productos o secuencias de decisiones sucesivas**, cuando interesa observar cómo evoluciona una decisión a lo largo de un proceso, y no solo su estado final; y
- **combinaciones de formatos**, cuando un mismo atributo —o un mismo strand— requiere

más de un tipo de evidencia para cubrir adecuadamente su rango de waypoints.

Todavía no se ha definido un formato definitivo para cada uno de los diez atributos; esa decisión corresponde a la siguiente etapa de desarrollo. El principio que debe orientarla es el siguiente:

la arquitectura de tareas debe derivarse de la naturaleza del constructo y de la evidencia que sus waypoints requieren, no de la conveniencia operativa de aplicar un formato único a los diez atributos.

37. Items Design

Items Design es el segundo componente del BEAR Assessment System, introducido conceptualmente en la Parte I. Esta sección desarrolla su aplicación proyectada al Hito 0.

37.1. Función de Items Design

Items Design no consiste simplemente en redactar preguntas. Su función es diseñar **situaciones capaces de elicitar evidencia relevante sobre posiciones diferentes de una variable** ya especificada en el Construct Map correspondiente. Una tarea adecuadamente diseñada debe cumplir, como mínimo, cinco condiciones: ofrecer una oportunidad real de manifestar el constructo (no una oportunidad meramente nominal); permitir diferenciar respuestas cualitativamente distintas, coherentes con los waypoints hipotetizados; reducir al mínimo las demandas irrelevantes al constructo (conocimiento disciplinar no pertinente, vocabulario especializado innecesario, dependencia de experiencias previas desiguales); ser plausible para estudiantes que recién ingresan a Ingeniería, sin exigir formación universitaria previa; y permitir, en principio, una puntuación coherente con la progresión definida en el Construct Map.

37.2. Evidencia requerida por waypoint

Para cada atributo —y, cuando corresponda, para cada strand— deberá construirse, como paso metodológico intermedio entre el Construct Map y el diseño efectivo de tareas, una matriz de evidencia por waypoint:

Tabla 25. Evidencia requerida por waypoint

Waypoint	Evidencia que debería observarse	Condición necesaria de la tarea
LG1 — Moviliza una acción necesaria	Una propuesta, apoyo o intervención pertinente que responda a una necesidad del grupo sin depender de autoridad formal	La tarea debe generar un momento en que el grupo necesite comenzar, continuar o retomar la acción
LG4 — Fortalece y distribuye la capacidad colectiva	El estudiante ajusta deliberadamente su propia influencia y habilita a otras personas para asumir iniciativa o conducción	La tarea debe incluir más de un momento de decisión y ofrecer a varias personas posibilidades legítimas de influir

Esta matriz constituye el puente metodológico entre el Construct Map (qué se pretende medir) y el Items Design propiamente tal (cómo generar evidencia sobre ello). Estas matrices todavía deben completarse para las progresiones —o strands— de los diez atributos. El ejemplo presentado es ilustrativo del procedimiento y no constituye un resultado ya alcanzado. Su elaboración será el paso previo al diseño efectivo de las tareas.

37.3. Diseño basado en escenarios

Para atributos cuya evidencia relevante pueda producirse mediante decisiones e interpretaciones individuales —por ejemplo, aspectos de Teoría de innovación y emprendimiento, Ética y profesionalismo, Economía y gestión, o Seguridad y riesgos—, un formato prometedor es el de **escenarios breves y contextualizados**. Un escenario de este tipo puede presentar un problema, una iniciativa, evidencia incompleta, personas usuarias, alternativas, restricciones, consecuencias o información adicional, y solicitar al estudiante que elija entre opciones, ordene elementos, justifique una decisión, compare alternativas, identifique información faltante, o revise una decisión previa a la luz de nueva evidencia.

Este formato resulta potencialmente superior a solicitar únicamente definiciones o descripciones abstractas del atributo, porque permite observar cómo el estudiante razona ante una situación concreta —más cercana a la evidencia que los Construct Maps efectivamente hipotetizan como manifestación del constructo— en lugar de observar únicamente si conoce o puede repetir una definición.

37.4. Ordered Multiple Choice

El **Ordered Multiple Choice (OMC)** constituye una alternativa metodológicamente prometedora para varios de los atributos del Hito 0, aunque su

aplicación efectiva todavía debe someterse a pilotaje antes de asumirse como definitiva. Su lógica difiere de la selección múltiple convencional: en lugar de clasificar cada opción simplemente como correcta o incorrecta, un ítem OMC presenta opciones diseñadas para representar **formas cualitativamente diferentes de razonamiento**, alineadas con distintos waypoints de la progresión —por ejemplo, una opción asociada a una comprensión más limitada del problema, una opción parcialmente diferenciada, una opción que integra varios elementos relevantes, y una opción evaluativa o contextualizada que incorpora revisión o incertidumbre—.

Debe quedar enfatizada una advertencia metodológica fundamental sobre este formato:

una opción diseñada teóricamente para representar un waypoint no puede asumirse empíricamente equivalente a ese waypoint hasta comprobar, mediante datos reales, que efectivamente ocupa esa posición en el continuo.

Es decir, que el equipo de diseño haya construido una opción con la intención de representar, por ejemplo, IE3, no garantiza que los estudiantes que la seleccionan efectivamente razonen del modo hipotetizado para ese nivel, ni que esa opción se comporte empíricamente como más difícil que la opción diseñada para representar IE2. Esta comprobación empírica corresponde a las etapas de procesos de respuesta (sección 40) y de modelamiento psicométrico del pilotaje (sección 42.4).

37.5. Situaciones de desempeño

Ciertos constructos del Hito 0 probablemente requerirán evidencia producida mediante actuación observada, y no únicamente mediante

respuestas escritas individuales. Entre los candidatos más claros se cuentan aspectos de Trabajo grupal e individual, Liderazgo, el strand de recepción y regulación de la interacción dentro de Comunicación, Interacción con usuarios reales, y aspectos de los tres strands de Diseño. Una situación de desempeño bien diseñada debe permitir observar decisiones, interacción, adaptación, contribuciones individuales dentro de una tarea colectiva, revisión de una posición previa, y uso efectivo de evidencia durante el desempeño.

Es indispensable, al diseñar estas situaciones, evitar repetir el problema documentado en la Parte II respecto de la primera aproximación del Hito 0: **un criterio de apreciación global no debe transformarse automáticamente en la medición completa de un atributo**. Una situación de desempeño puede generar evidencia rica y auténtica, pero esa evidencia debe traducirse en categorías de puntuación explícitamente vinculadas a los waypoints del Construct Map correspondiente (sección 38), no en una impresión general del evaluador sobre "qué tan bien lo hizo el grupo".

37.6. Evidencia individual y evidencia grupal

Esta distinción, ya introducida en el diagnóstico de la Parte II, debe incorporarse desde el diseño mismo de las nuevas tareas, y no corregirse después de recolectados los datos. La nueva arquitectura debe distinguir explícitamente:

Evidencia del producto o desempeño grupal, es decir, lo que el grupo logró o produjo colectivamente, sin que ello permita, por sí solo, atribuir una posición a cada integrante.

Evidencia del estudiante, es decir, lo que cada estudiante individual hizo, decidió, explicó, propuso o reguló dentro de una situación —incluso si esa situación es grupal—.

Si el propósito institucional del Hito 0 incluye reportar posiciones a nivel de estudiante individual para alguno de los diez atributos —y no únicamente patrones agregados de grupo, sección o cohorte—, debe existir, para ese atributo, una fuente de evidencia individual suficientemente defendible: por ejemplo, un registro individual del razonamiento (una reflexión breve, una decisión atribuible a una persona, una intervención identificable), y no solamente una puntuación

asignada al grupo en su conjunto. Una puntuación grupal no debe convertirse automáticamente en una puntuación individual mediante ningún procedimiento —ni asignar a todos los integrantes la misma nota del grupo, ni inferir contribuciones individuales sin evidencia que las respalde—.

37.7. Diseño eficiente para aplicación masiva

El Hito 0 debe ser viable para su aplicación a cohortes completas de ingreso, no solo a muestras reducidas. Este requisito introduce una tensión real que el diseño de tareas deberá resolver de manera explícita, no ignorar:

riqueza de evidencia ↔ viabilidad operacional.

Entre los factores que deberán considerarse al equilibrar esta tensión se cuentan: el número de estudiantes de cada cohorte; el tiempo de aplicación disponible dentro de la planificación de la asignatura utilizada; el número de docentes o evaluadores disponibles para tareas que requieran puntuación humana; la necesidad de capacitación y calibración de esos evaluadores; el tiempo de corrección por estudiante o por grupo; las posibilidades de automatización, cuando el formato lo permita; la consistencia de la aplicación entre distintas secciones y momentos; y la infraestructura tecnológica disponible.

El principio que debe gobernar estas decisiones, sin embargo, es claro y no debe subordinarse a la conveniencia operativa:

la eficiencia no debe lograrse sacrificando la posibilidad de observar el constructo.

Un instrumento eficiente que no logra generar evidencia interpretable sobre la variable que pretende medir no constituye una solución válida, por más viable que resulte operativamente aplicarlo a una cohorte completa.

38. Outcome Space

Outcome Space es el tercer componente del BEAR Assessment System.

38.1. Función del Outcome Space

El Outcome Space responde a la pregunta: ¿cómo se interpretarán y clasificarán las respuestas

efectivamente producidas por los estudiantes? Su función es conectar la **respuesta observable** —lo que el estudiante efectivamente dijo, escribió, decidió o hizo— con una **posición sobre la variable** hipotetizada en el Construct Map. Sin un Outcome Space explícito, dos evaluadores podrían interpretar de manera distinta una misma respuesta, o un mismo evaluador podría aplicar criterios inconsistentes entre un estudiante y otro —precisamente el tipo de problema que la Parte II documentó respecto de la sensibilidad de las distribuciones a la composición del cuerpo de evaluadores en la primera aproximación—.

38.2. Waypoint no equivale automáticamente a categoría de puntuación

Esta distinción debe enfatizarse porque constituye una de las confusiones metodológicas más frecuentes al desarrollar un sistema de este tipo. Un **waypoint** es una hipótesis sustantiva sobre una posición cualitativamente distinguible de una variable. Una **categoría de puntuación** es una regla operativa aplicada a una actuación observable, que debe construirse y validarse a partir de evidencia empírica sobre cómo efectivamente se distribuyen las respuestas.

Por tanto:

W1, W2, W3 y W4 no deben convertirse automáticamente en 0, 1, 2 y 3 sin examinar primero cómo se manifiestan empíricamente las respuestas de los estudiantes.

Es enteramente posible, y deberá examinarse durante el pilotaje, que exista más de una categoría de respuesta asociada a un mismo waypoint; que aparezca evidencia que se ubica entre dos waypoints hipotetizados; que dos categorías inicialmente distintas deban fusionarse por resultar empíricamente indistinguibles; o que el orden empírico observado entre categorías no coincida exactamente con el orden hipotetizado en el Construct Map, obligando a revisar este último.

38.3. Scoring guides

Para las tareas abiertas o de desempeño deberán desarrollarse **scoring guides** (guías de puntuación) explícitas, que establezcan: qué evidencia observable corresponde a cada categoría; los criterios sustantivos que distinguen una categoría de la adyacente; reglas de decisión

para casos ambiguos; ejemplos de aplicación; y casos limítrofes documentados, que sirvan como referencia para evaluadores futuros. El lenguaje de estas guías debe describir **calidad de la evidencia observada** —qué hizo, dijo o decidió el estudiante, y por qué eso corresponde a un nivel determinado—, no impresiones generales del evaluador sobre el desempeño global.

38.4. Rúbricas analíticas

Cuando una misma tarea produzca evidencia relevante sobre más de un constructo o sobre más de un strand dentro de un mismo atributo, resultará preferible una **rúbrica analítica** —que puntúa cada dimensión relevante por separado— frente a una rúbrica holística que resuma la actuación en un único juicio global. El caso más claro dentro de este proyecto es Diseño: una misma tarea de diseño podría producir, simultáneamente, evidencia sobre Problematicación, Ideación, y Evaluación y regulación mediante evidencia. La tarea puede ser común a los tres strands, pero la puntuación debe preservar sus diferencias: un desempeño que muestra una estructuración sólida del problema (posición alta en Problematicación) junto con una exploración limitada de alternativas (posición baja en Ideación) debe registrarse como tal, y no promediarse en una calificación general que oculte esa diferencia.

38.5. Anchor exemplars

El desarrollo futuro del sistema deberá incorporar, para cada categoría relevante de puntuación, **ejemplos ancla** (anchor exemplars): respuestas reales —o cuidadosamente construidas, cuando todavía no existan respuestas reales suficientes— que muestren de manera concreta qué evidencia específica justifica esa puntuación. Estos ejemplos pueden contribuir de manera importante a: la capacitación de evaluadores; la calibración de criterios entre distintos evaluadores y secciones; la consistencia de la aplicación a lo largo del tiempo; y la revisión posterior de las categorías mismas, cuando la comparación entre ejemplos revele ambigüedades no anticipadas.

38.6. Evidencia parcialmente solapada

Un problema relevante para los diez atributos del Hito 0, ya anticipado en las fronteras conceptuales desarrolladas en la Parte V (sección 33.4), es que una misma actuación puede producir evidencia

pertinente para más de un constructo. Esto no significa necesariamente que esa actuación deba puntuarse de la misma manera en todos los constructos a los que aporta evidencia. Por ejemplo: que un estudiante escuche a una persona usuaria y registre su necesidad puede aportar evidencia sobre Interacción con usuarios reales; que ese mismo estudiante utilice esa información para modificar una propuesta de solución puede aportar evidencia, adicionalmente, sobre el strand de Evaluación y regulación mediante evidencia de Diseño. Ambas inferencias pueden ser legítimas simultáneamente, siempre que exista una regla explícita que indique **qué aspecto específico de la actuación sustenta cada inferencia** —de modo que no se compute, por ejemplo, la misma frase del estudiante como evidencia idéntica y automática de dos atributos sin distinguir qué parte de ella corresponde a cada uno—.

38.7. Decision rules

El desarrollo del Outcome Space deberá incluir reglas de decisión explícitas para situaciones que, en la práctica, resultan frecuentes y que un sistema de puntuación mal especificado tiende a resolver de manera inconsistente entre evaluadores: una respuesta parcialmente consistente con dos categorías adyacentes; evidencia contradictoria dentro de una misma respuesta; ausencia de evidencia suficiente para clasificar; desempeño alto en una parte de la tarea y bajo en otra; una respuesta ambigua o de difícil interpretación; y evidencia insuficiente para sostener cualquier clasificación sustantiva.

Para este último caso, resulta metodológicamente necesario introducir una categoría explícita de **"sin evidencia suficiente"**, que **no debe confundirse automáticamente con el waypoint más bajo de la progresión**: la ausencia de evidencia observable no equivale a evidencia de un desarrollo mínimo del constructo, sino a la imposibilidad de emitir un juicio informado a partir de esa tarea en particular. Confundir ambas categorías repetiría, en la nueva arquitectura, un error de interpretación que la Parte II identificó como una de las reglas críticas a evitar: no interpretar ausencia de evidencia como ausencia de capacidad del estudiante.

39. Consideraciones especiales para Diseño

Dado que Diseño fue reespecificado mediante tres strands interdependientes (Parte V, sección 24), su Items Design y Outcome Space requieren consideraciones adicionales, específicas de su arquitectura multidimensional.

39.1. Una tarea puede producir evidencia para varios strands

No es necesario, ni previsiblemente eficiente, diseñar tres actividades completamente independientes —una para Problematicación, otra para Ideación, otra para Evaluación y regulación mediante evidencia—. Una situación de diseño auténtica y suficientemente rica puede permitir observar, dentro de una misma tarea, cómo el estudiante comprende y delimita el desafío, cómo explora el espacio de alternativas, y cómo evalúa y regula sus decisiones mediante criterios y evidencia. Lo que resulta indispensable, sin embargo, es que la evidencia producida se **codifique por separado** para cada strand, de acuerdo con lo establecido en la sección 38.4 sobre rúbricas analíticas: una tarea común, con puntuación diferenciada.

39.2. No imponer un nivel global prematuro

Mientras no exista evidencia empírica suficiente sobre las relaciones reales entre los tres strands de Diseño —evidencia que solo podrá obtenerse mediante pilotaje y análisis psicométrico posterior—, el desarrollo del sistema debe evitar: suponer que las posiciones en los tres strands pueden sumarse de manera simple; promediar automáticamente las tres posiciones en un único indicador; o afirmar la existencia de un nivel global único de Diseño. El pilotaje futuro deberá informar si existe fundamento empírico para sostener un perfil diferenciado por strand, una puntuación general adicional, ambas cosas de manera complementaria, o una estructura distinta a las anteriores —posibilidad que tampoco puede descartarse de antemano—.

40. Procesos de respuesta

Los procesos de respuesta constituyen una fuente de evidencia de validez todavía no producida en

este proyecto, introducida conceptualmente en la Parte I (sección 2.2) como una de las fuentes de evidencia reconocidas por los Standards para sustentar las interpretaciones y usos previstos de las puntuaciones.

40.1. Propósito

Antes de interpretar psicométricamente una respuesta como evidencia de un constructo, debe verificarse que el estudiante haya comprendido y abordado la tarea de la manera que el diseño previó. Una tarea puede parecer, desde la perspectiva de quien la diseñó, capaz de generar evidencia clara sobre un waypoint determinado; solo el examen directo de cómo los estudiantes efectivamente interpretan y responden a esa tarea permite confirmar —o poner en duda— ese supuesto.

40.2. Entrevistas cognitivas

El desarrollo futuro del sistema deberá incorporar técnicas de entrevista cognitiva: protocolos de pensamiento en voz alta (think-aloud) mientras el estudiante resuelve una tarea; entrevistas retrospectivas inmediatamente después de completarla; preguntas de sondeo sobre por qué se seleccionó una opción o se tomó una decisión determinada; y análisis específico de cómo se comprenden las consignas y se interpretan las alternativas disponibles. Estas técnicas pueden ayudar a detectar interpretaciones inesperadas de una tarea, ambigüedades en su redacción, estrategias de respuesta ajenas al constructo que se pretende medir (por ejemplo, resolver por descarte en lugar de razonar sustantivamente), pistas involuntarias contenidas en la formulación de la tarea, dificultades de comprensión lectora o lingüística no relacionadas con el constructo, y la intrusión de conocimiento especializado irrelevante al atributo evaluado.

40.3. Procesos de respuesta en Ordered Multiple Choice

Para el formato OMC en particular, la evidencia de procesos de respuesta debe examinar explícitamente si los estudiantes que eligen una opción determinada lo hacen efectivamente por el razonamiento que, en su diseño, se atribuyó teóricamente a esa opción. Una alternativa puede haber sido diseñada para representar, por ejemplo, el nivel IE3 de comprensión de innovación, pero un estudiante podría

seleccionarla por una razón completamente distinta a la prevista —por ejemplo, por eliminación de las demás opciones, por familiaridad superficial con parte de su redacción, o por una interpretación alternativa de la tarea—. Por esta razón, ningún ítem OMC debe asumirse como válidamente interpretado antes de someterse a evidencia de procesos de respuesta que confirme esa correspondencia.

40.4. Procesos de respuesta en tareas de desempeño

Para tareas grupales u observacionales, el examen de procesos de respuesta deberá considerar: si la consigna fue efectivamente comprendida por el grupo en su conjunto; si surgió una distribución espontánea de roles que pudiera limitar las oportunidades de observación de algunos integrantes; si existieron oportunidades reales, y no solo teóricas, para que cada estudiante manifestara el constructo evaluado; el grado de dependencia del desempeño individual respecto de la dinámica particular del grupo asignado; la posible influencia del propio evaluador sobre el desarrollo de la tarea; y si el tiempo disponible resultó suficiente para que la progresión completa del constructo pudiera manifestarse.

41. Pilotaje de la nueva medición

El pilotaje no tiene únicamente el propósito de comprobar que una plataforma o un procedimiento de aplicación funcionan correctamente. Su función central es obtener evidencia empírica sobre las tareas diseñadas, las categorías de puntuación propuestas, la progresión hipotetizada en cada Construct Map, la focalización de las tareas respecto de la población de ingreso, la precisión de las estimaciones resultantes, la dimensionalidad efectivamente observada, y posibles efectos de método asociados al formato de las tareas.

41.1. Propósito del pilotaje

El pilotaje debe permitir revisar simultáneamente los tres componentes desarrollados hasta ese punto —Construct Maps, Items Design y Outcome Spaces— antes de que pueda considerarse estable cualquier arquitectura de medición para el Hito 0. Ninguno de estos tres componentes debe tratarse como definitivo antes de esa revisión conjunta.

41.2. Muestra piloto

El tamaño de la muestra piloto aún no ha sido definido y deberá establecerse en función de los propósitos analíticos de esta etapa. Los principios que deberán orientar la definición de la muestra piloto son: suficiente diversidad de desempeño entre los participantes, de modo que sea posible observar tanto respuestas menos desarrolladas como más desarrolladas; representación razonable de la población objetivo del Hito 0 (estudiantes de ingreso a Ingeniería); posibilidad efectiva de observar los extremos hipotetizados del continuo, no solo su zona intermedia; y registro de variables pertinentes para el análisis futuro de fairness (sección 43.6), limitado a lo estrictamente necesario para ese propósito.

41.3. Evidencia que debe recogerse

Según el tipo de instrumento utilizado en cada tarea, el pilotaje deberá recoger: las respuestas mismas; el tiempo empleado; justificaciones o explicaciones cuando la tarea las solicite; trazas de navegación o de interacción con la tarea, cuando resulten útiles para interpretar el proceso de respuesta; las puntuaciones asignadas por evaluadores, cuando corresponda; comentarios de los propios evaluadores sobre la aplicación; evidencia de procesos de respuesta (sección 40); y datos sociodemográficos estrictamente necesarios para los análisis de fairness proyectados, evitando recoger información adicional no justificada por un propósito analítico específico.

42. Measurement Model

El Measurement Model es el cuarto componente del BEAR Assessment System.

42.1. El modelo debe seguir al constructo

El principio metodológico central de esta etapa, ya introducido en la Parte I y reafirmado aquí, es que **no debe seleccionarse un modelo estadístico primero y adaptar después el constructo para que encaje en él**. El modelo de medición apropiado para cada atributo —o para cada strand— deberá seleccionarse en función del tipo de respuesta efectivamente producida por las tareas, de la estructura del Construct Map correspondiente, del Outcome Space desarrollado,

de la dimensionalidad observada empíricamente, y del propósito de reporte que se pretenda sostener.

42.2. Rasch dicotómico

Un modelo Rasch dicotómico —el mismo tipo de modelo utilizado para diagnosticar la prueba individual de la primera aproximación, según se documentó en la Parte II— puede resultar pertinente para tareas cuya respuesta sea efectivamente dicotómica (correcta/incorrecta). Permitirá examinar, para las nuevas tareas: la dificultad de cada ítem, la focalización de esas dificultades respecto de la población de ingreso, el ajuste del modelo a los datos observados, la precisión de las estimaciones resultantes, y el funcionamiento diferencial entre subgrupos relevantes. No debe afirmarse, en esta etapa del proyecto, que este será necesariamente el modelo final para ningún atributo en particular; su pertinencia dependerá de cómo se comporten efectivamente los datos del pilotaje.

42.3. Partial Credit Model

Un modelo de crédito parcial —también ya utilizado para diagnosticar la situación de desempeño grupal de la primera aproximación— podrá resultar apropiado cuando existan categorías ordinales con estructuras de paso propias de cada ítem o criterio, como es previsible para varias de las tareas de desempeño y de las rúbricas analíticas proyectadas en la sección 38. Permitirá examinar las probabilidades de respuesta por categoría, los parámetros de paso, la dificultad relativa de cada criterio, la focalización de los umbrales acumulativos y el ajuste general del modelo. La evaluación del funcionamiento de categorías deberá apoyarse en este conjunto de evidencias y no únicamente en el orden de umbrales derivados.

42.4. Ordered Multiple Choice

Las respuestas producidas mediante el formato OMC podrán eventualmente modelarse como categorías ordenadas, pero únicamente si la evidencia empírica respalda ese orden. Como se enfatizó en la sección 37.4, el orden conceptual con que fueron diseñadas las opciones debe comprobarse empíricamente antes de asumirse en el modelo de medición. Si las categorías de un ítem OMC no se ordenan de la manera prevista en los datos reales, podrá ser necesario revisar los distractores, fusionar categorías que resulten

empíricamente indistinguibles, modificar el Construct Map si la falta de orden revela un problema conceptual más profundo, o replantear directamente la tarea.

42.5. Modelos multidimensionales

Para los cuatro atributos reespecificados en más de una progresión —Comunicación, Diseño, Teoría de innovación y emprendimiento, y Economía y gestión—, el desarrollo futuro del Measurement Model deberá estudiar la pertinencia de modelos multidimensionales, incluyendo la posibilidad de modelar los strands como dimensiones correlacionadas entre sí, u otras representaciones que la evidencia empírica del pilotaje sugiera como apropiadas. No se selecciona de antemano, en este reporte, un modelo multidimensional específico para ninguno de estos cuatro atributos; esa decisión depende de evidencia todavía no producida.

42.6. Evaluadores

Para toda tarea puntuada por personas —previsiblemente, la mayoría de las tareas de desempeño y varias de las tareas de respuesta abierta—, el diseño futuro deberá permitir estudiar de manera adecuada: la consistencia de la corrección entre distintos evaluadores; la severidad relativa de cada evaluador; posibles interacciones entre evaluador y tarea específica; efectos asociados a la sección o al momento de aplicación; y el efecto de los procesos de capacitación y calibración sobre la consistencia observada. Para que estos análisis sean posibles, será necesario un **diseño con cruce suficiente** entre evaluadores y respuestas —es decir, que un número relevante de respuestas sea calificado por más de un evaluador, o que cada evaluador califique un número suficiente de casos en común con otros evaluadores—. El problema documentado en la Parte II respecto de la primera aproximación —un cruce insuficiente entre evaluadores y grupos, que impidió estimar un modelo formal de severidad y obligó a limitar el análisis a indicadores puramente descriptivos de sensibilidad— **no debe repetirse** en el diseño de la nueva medición.

43. Análisis psicométricos del pilotaje

Los análisis proyectados para la etapa de pilotaje se organizan en seis grupos.

43.1. Funcionamiento de ítems

Deberá examinarse, para cada tarea: su dificultad; su capacidad de discriminación, cuando el modelo de medición seleccionado lo permita; su ajuste al modelo utilizado; la información que aporta a lo largo del continuo; y la presencia de patrones de respuesta inesperados que sugieran un funcionamiento no previsto.

43.2. Funcionamiento de categorías

Deberá examinarse la frecuencia de uso de cada categoría de puntuación; las **curvas de probabilidad de categoría** y la región del continuo en que cada categoría resulta más probable; los parámetros de paso adyacentes cuando el modelo los incluya; las medidas o posiciones asociadas a las observaciones de cada categoría; y la existencia de categorías escasamente utilizadas o empíricamente poco distinguibles. Los umbrales Thurstonianos podrán utilizarse adicionalmente para interpretar los cortes acumulativos y la focalización sobre la escala, pero su orden creciente no se tratará, por sí solo, como prueba de funcionamiento adecuado de las categorías.

43.3. Focalización persona-ítem

Deberá examinarse si el conjunto de tareas cubre adecuadamente los niveles bajos, medios y altos del continuo de desarrollo esperable al ingreso a Ingeniería. Un objetivo explícito de esta etapa es **evitar repetir la concentración de dificultades en la zona fácil del continuo** que la Parte II documentó respecto de la prueba individual de la primera aproximación —donde todas las dificultades Rasch resultaron negativas y casi uno de cada diez estudiantes obtuvo el puntaje máximo—.

43.4. Precisión

Deberá examinarse la confiabilidad de las estimaciones resultantes; los errores estándar de medición; la precisión condicionada por nivel del continuo (que puede no ser uniforme a lo largo de

toda la escala); y la capacidad efectiva del instrumento para diferenciar posiciones relevantes para el propósito diagnóstico del Hito 0.

43.5. Estructura interna

Deberá examinarse la dimensionalidad efectivamente observada en los datos, contrastándola con la estructura hipotetizada en cada Construct Map (unidimensional en seis atributos, multidimensional provisional en los otros cuatro); la dependencia local entre ítems o tareas; la relación empírica entre strands, en los atributos que los incorporan; la estructura interna específica de cada atributo; y posibles efectos de método asociados al formato de las tareas, que pudieran generar covariación espuria entre ítems no atribuible al constructo.

43.6. Fairness

Cuando el tamaño de la muestra piloto lo permita, deberá estudiarse el funcionamiento diferencial de ítems o tareas entre subgrupos relevantes: por lenguaje o comprensión lectora, por modalidad escolar (científico-humanista o técnico-profesional), por trayectoria formativa previa, por sexo o género u otras variables pertinentes, y por experiencia previa relevante para atributos específicos (por ejemplo, experiencia previa de interacción con usuarios reales, o de participación en actividades de diseño). Este análisis debe estar **guiado por hipótesis** derivadas de las observaciones de fairness ya documentadas en el juicio experto (Parte IV, sección 15.6) y en el refinamiento de los mapas (Parte V), no por una búsqueda indiscriminada de cualquier diferencia estadísticamente detectable entre grupos.

44. Diseño del reporte de resultados del Hito 0

44.1. Reporte criterial y no normativo

El propósito principal del reporte de resultados del Hito 0 no es ordenar a los estudiantes unos respecto de otros, sino interpretar sus respuestas en relación con las formas de actuación cualitativamente definidas en los Construct Maps. Esta orientación criterial, y no normativa, es coherente con el propósito diagnóstico y formativo

del Hito 0 establecido desde la Parte I de este reporte.

44.2. Nivel de reporte

El desarrollo futuro del sistema deberá distinguir explícitamente distintos niveles posibles de reporte, cuya pertinencia dependerá de la precisión y de la evidencia disponible para cada uno: a nivel de **cohorte**, describiendo patrones generales de ingreso; a nivel de **carrera**, cuando existan diferencias descriptivas útiles para la planificación curricular; a nivel de **atributo**, describiendo la distribución de posiciones observadas; a nivel de **strand**, cuando corresponda —como en Diseño y los otros atributos reespecificados—; y a nivel de **estudiante individual**, únicamente cuando exista evidencia suficiente para sostener inferencias a ese nivel de desagregación.

44.3. Evitar falsas precisiones

El reporte de resultados no debe presentar cifras que sugieran una precisión no respaldada por la evidencia disponible —por ejemplo, afirmaciones del tipo "el estudiante tiene 63,4 % de Liderazgo", que carecen de una interpretación sustantiva defendible bajo el enfoque de construct modelling adoptado en este proyecto—. El reporte debe priorizar, en cambio: posiciones cualitativas dentro de la progresión hipotetizada; perfiles, especialmente en los atributos multidimensionales; patrones descriptivos a nivel agregado; evidencia observable concreta que respalde cada posición reportada; e intervalos de incertidumbre, cuando la precisión de la estimación lo haga necesario y el nivel de reporte lo permita.

44.4. Uso formativo de la información

Los resultados del Hito 0, una vez desarrollada la nueva arquitectura de medición, podrán orientar decisiones formativas de distinto tipo: la planificación docente de la asignatura donde se aplique el diagnóstico; el diseño de apoyos iniciales para estudiantes con posiciones menos desarrolladas en atributos específicos; el diseño de actividades curriculares orientadas a los patrones observados en una cohorte; y la revisión continua del propio sistema de medición, en la lógica iterativa del BEAR Assessment System introducida en la Parte I. Debe evitarse explícitamente que el diagnóstico se transforme

en un mecanismo de etiquetamiento de estudiantes, de ranking entre ellos, o de selección —usos ajenos al propósito institucional del Hito 0 establecido desde el inicio de este reporte.

45. Agenda de validación

La validación del nuevo sistema de medición debe organizarse, de manera coherente con el enfoque de acumulación progresiva de evidencias introducido en la Parte I, como un proceso continuo y no como un evento único.

45.1. Evidencia de contenido

Estado. Parcialmente desarrollada. **Evidencia ya existente:** la construcción sustantiva de los diez Construct Maps (Parte III), el juicio experto (Parte IV), la triangulación cuantitativa-cualitativa y el refinamiento o reespecificación de los mapas (Parte V). **Pendiente:** una eventual nueva ronda de revisión de los mapas ya reespecificados, cuando corresponda, y la revisión de contenido específica de las tareas y Outcome Spaces que se desarrollen a partir de ellos —evidencia de contenido distinta, referida ya no al Construct Map sino a la tarea concreta que pretende operacionalizarlo—.

45.2. Procesos de respuesta

Estado. Pendiente; corresponde al próximo ciclo de desarrollo. **Métodos previstos:** entrevistas cognitivas, protocolos de pensamiento en voz alta, entrevistas retrospectivas con preguntas de sondeo, y análisis de la interpretación efectiva de consignas y opciones (sección 40).

45.3. Estructura interna

Estado. Pendiente, aplicable a la nueva versión de los instrumentos una vez pilotados. **Propósito:** contrastar empíricamente las hipótesis de unidimensionalidad (en seis atributos) y de multidimensionalidad provisional (en los cuatro atributos reespecificados), examinar la relación efectivamente observada entre strands, y examinar la estructura de las puntuaciones resultantes.

45.4. Precisión

Estado. Pendiente. **Aspectos a examinar:** confiabilidad de las estimaciones, errores de medición, información aportada por el conjunto de

tareas, y precisión diferenciada por nivel del continuo.

45.5. Funcionamiento de categorías

Estado. Pendiente. **Aspectos a examinar:** si las categorías propuestas en los Outcome Spaces son efectivamente utilizadas por los datos reales, si están ordenadas empíricamente como se hipotetizó, si distinguen respuestas cualitativamente diferentes, y si reflejan la progresión definida en el Construct Map correspondiente.

45.6. Fairness

Estado. Pendiente. **Amenazas a examinar,** derivadas directamente de las observaciones ya documentadas en el juicio experto y el refinamiento (Parte IV, sección 15.6; Parte V, diversas secciones): dependencia del lenguaje especializado; dependencia de experiencias formativas previas desiguales; dependencia de la modalidad escolar (científico-humanista o técnico-profesional); intrusión de conocimiento irrelevante al constructo; oportunidades desiguales de observación entre estudiantes; y condiciones de aplicación no equivalentes entre secciones o momentos.

45.7. Evaluadores

Estado. Pendiente, cuando corresponda según el formato final de cada tarea. **Aspectos a examinar:** capacitación y calibración de evaluadores; consistencia de la corrección; y, cuando el diseño lo permita mediante un cruce suficiente entre evaluadores y respuestas (sección 42.6), modelos de facetas u otros análisis apropiados para separar la severidad del evaluador de las características de la respuesta evaluada.

45.8. Consecuencias y utilidad diagnóstica

Estado. Pendiente; corresponde a una etapa posterior a la implementación operativa del sistema. **Aspectos a examinar en el futuro:** cómo utilizan efectivamente los equipos docentes la información producida por el Hito 0; qué decisiones curriculares o de apoyo inicial genera esa información; si los reportes son interpretados correctamente por sus destinatarios institucionales; la existencia de posibles efectos no previstos de la aplicación del diagnóstico; y la

utilidad efectiva del sistema para su propósito diagnóstico y formativo.

46. Hoja de ruta

Tabla 26. Hoja de ruta

Fase	Producto esperado	Evidencia buscada	Estado
Construct Maps	Progresiones refinadas o reespecificadas para los diez atributos	Evidencia de contenido	Realizado (versión revisada provisional; pendiente de nueva evidencia empírica)
Items Design	Matrices de evidencia por waypoint; prototipos preliminares de tareas	Alineamiento constructo–tarea	Próxima etapa; aún no desarrollada sistemáticamente
Outcome Space	Scoring guides, rúbricas analíticas y reglas de decisión	Coherencia entre respuesta observable y variable	Próxima etapa; condicionada al avance de Items Design
Procesos de respuesta	Hallazgos de entrevistas cognitivas y sondeos	Interpretación efectiva de las tareas por los estudiantes	Pendiente
Pilotaje	Datos de una muestra piloto de estudiantes	Funcionamiento preliminar de tareas y categorías	Pendiente
Measurement Model	Modelos de medición calibrados por atributo o strand	Estructura interna y precisión	Pendiente
Aplicación institucional ampliada	Sistema operativo del Hito 0 para cohortes completas	Utilidad diagnóstica y formativa sostenida	Posterior, condicionada a las etapas anteriores

46.1. Ciclo iterativo

El desarrollo futuro del sistema no debe entenderse como una secuencia estrictamente lineal de las fases anteriores, sino como un ciclo iterativo entre sus cuatro componentes centrales:

Construct Map ↔ Items Design ↔ Outcome Space ↔ Measurement Model

retroalimentado continuamente por evidencia de contenido, de procesos de respuesta, de estructura interna, de precisión y de fairness, de acuerdo con la lógica del BEAR Assessment System introducida en la Parte I. Debe quedar

claro que este ciclo no avanza en un solo sentido: **una anomalía psicométrica detectada durante el pilotaje o el modelamiento puede llevar a revisar no solo la tarea o la categoría de puntuación involucradas, sino, cuando la evidencia lo justifique, el propio Construct Map** —tal como ya ocurrió, en la etapa documentada en la Parte V, con Diseño, Comunicación, Teoría de innovación y emprendimiento, y Economía y gestión a partir de evidencia de contenido y juicio experto, antes incluso de contar con datos de pilotaje—.

La Figura 28 sitúa esta agenda dentro del recorrido completo de validación.




Figura 28. Hoja de ruta para el desarrollo de la nueva medición del Hito 0. Las etapas posteriores a los Construct Maps permanecen sujetas a revisión iterativa a partir de la evidencia que produzcan.

47. Riesgos metodológicos a controlar

El diagnóstico de la primera aproximación del Hito 0 (Parte II) permitió identificar un conjunto de riesgos metodológicos concretos que la nueva arquitectura de medición debe controlar explícitamente, y no solo evitar por buenas intenciones generales:

Un solo ítem o criterio por atributo. La primera aproximación asoció varios atributos a un único ítem o criterio, impidiendo cualquier estimación diferenciada. La nueva arquitectura debe asegurar, para cada waypoint de cada progresión, oportunidades de observación suficientes.

Tareas demasiado fáciles, con dificultades concentradas en la zona baja del continuo. Documentado explícitamente en la Parte II para el instrumento virtual de la primera aproximación. El pilotaje futuro (sección 43.3) debe examinar activamente la focalización de las nuevas tareas para evitar este patrón.

Coberturas desiguales entre atributos. Algunos atributos de la primera aproximación no contaban con representación alguna en uno de los dos instrumentos. La planificación de Items Design debe asegurar cobertura explícita y documentada para los diez atributos.

Criterios con demandas ambiguas respecto de su etiqueta declarada. El caso más documentado en este proyecto es el ítem cuya etiqueta declaraba Trabajo grupal e individual pero cuya demanda efectiva correspondía a Trabajo inter y multidisciplinario (Parte II). La verificación de alineamiento (sección 36.1) debe aplicarse sistemáticamente a cada tarea nueva antes de su uso.

Evidencia grupal utilizada como si fuera individual. Riesgo abordado explícitamente en la sección 37.6 de esta parte.

Categorías de puntuación no ligadas explícitamente a una progresión sustantiva. Riesgo abordado explícitamente en la sección 38.2 de esta parte.

Evaluadores insuficientemente cruzados con las respuestas evaluadas. Riesgo abordado explícitamente en la sección 42.6 de esta parte.

Tareas contaminadas por conocimientos previos irrelevantes al constructo. Riesgo transversal a los diez Construct Maps revisados en la Parte V, cada uno de los cuales incorpora explícitamente condiciones para evitar depender de formación curricular desigual.

Confusión entre consistencia global de un instrumento y medición diferenciada de cada atributo. Distinción establecida explícitamente en la Parte II (secciones 4.4, 5.4 y 6.4) y que debe mantenerse como principio interpretativo permanente en todas las etapas futuras.

Imposición prematura de un puntaje total o de un nivel global. Riesgo abordado explícitamente para Diseño en la sección 39.2, y aplicable, con los mismos fundamentos, a los otros tres atributos reespecificados en más de una progresión.

La nueva arquitectura de medición, tal como se ha desarrollado en esta parte del reporte, busca prevenir estos riesgos desde el diseño mismo del sistema —mediante el alineamiento explícito entre constructo, evidencia y tarea (sección 36.1), la distinción rigurosa entre waypoint y categoría de puntuación (sección 38.2), y el diseño de evaluadores con cruce suficiente (sección 42.6)—, y no mediante correcciones aplicadas después de recolectados los datos.

48. Estado actual del sistema

Tabla 27. Estado actual del sistema

Componente	Estado	Próxima decisión
Antecedentes institucionales y propósito del Hito 0	Completado	Mantener como marco de interpretación

Componente	Estado	Próxima decisión
Diagnóstico de la primera aproximación institucional	Completado	Utilizar sus hallazgos como restricciones de diseño
Construct Maps iniciales y juicio experto	Completado	Conservar trazabilidad de las decisiones de refinamiento
Construct Maps revisados	Refinados; pendientes de contraste empírico	Priorizar el desarrollo de Items Design por atributo y strand
Items Design	Pendiente	Completar matrices de evidencia y desarrollar prototipos de tareas
Outcome Space	Pendiente	Construir scoring guides y reglas de decisión a partir de las tareas
Procesos de respuesta	Pendiente	Diseñar y aplicar entrevistas cognitivas sobre prototipos
Pilotaje	Pendiente	Definir muestra, protocolo y conjunto de tareas
Measurement Model	Pendiente	Seleccionar y contrastar modelos con los datos piloto
Reporte operativo de resultados	Pendiente	Definirlo según la precisión e interpretabilidad alcanzadas

Debe quedar explícito, como cierre de esta síntesis, que **la existencia de Construct Maps revisados no significa que el instrumento definitivo del Hito 0 esté validado o terminado**. Al cierre de esta etapa existe una arquitectura conceptual de medición más explícita y acompañada de evidencia sistemática de contenido; todavía falta producir evidencia empírica sobre su funcionamiento cuando se traduzca en tareas y se aplique a estudiantes.

49. Conclusión de la Parte VI

El trabajo documentado en las Partes III, IV y V de este reporte permitió pasar de una primera aproximación basada principalmente en asociaciones directas entre atributo institucional e ítem o criterio, hacia una arquitectura de medición explícita que articula:

constructo → evidencia → tarea → puntuación → modelo → interpretación.

Esta parte ha mostrado que ese avance, aunque sustantivo, no completa todavía el desarrollo del sistema: falta producir evidencia empírica sobre los instrumentos que todavía deben diseñarse a partir de los Construct Maps revisados. El objetivo de las etapas siguientes no es, por tanto, simplemente "aplicar una nueva prueba" que reemplace a la de la primera aproximación, sino

construir y contrastar iterativamente una medición diagnóstica defendible, mediante el ciclo entre Construct Map, Items Design, Outcome Space y Measurement Model descrito en la sección 46.1, acumulando de manera progresiva las fuentes de evidencia de validez organizadas en la agenda de la sección 45.

PARTE VII

CIERRE INSTITUCIONAL: APRENDIZAJES, LIMITACIONES, RECOMENDACIONES Y CONCLUSIONES

50. Síntesis del proceso desarrollado

52. Qué cambió en la arquitectura del Hito 0

54. Implicaciones para la Facultad

56. Hoja de ruta consolidada

58. Qué no debería hacerse

60. Conclusiones generales

51. Principales aprendizajes del proceso

53. Limitaciones del trabajo realizado

55. Recomendaciones institucionales

57. Criterios para considerar el sistema
preparado para una aplicación ampliada

59. Contribución institucional del proyecto

61. Estado final del proyecto al cierre del reporte

50. Síntesis del proceso desarrollado

El proyecto documentado en este reporte partió de una primera aproximación institucional del Hito 0 construida sobre correspondencias relativamente directas entre los diez atributos de innovación y emprendimiento, un conjunto de ítems de un instrumento virtual individual y un conjunto de criterios de una situación de desempeño grupal presencial. Esa arquitectura permitió obtener una primera experiencia de aplicación a escala de cohorte, pero el diagnóstico retrospectivo de su evidencia mostró limitaciones sustantivas de cobertura, de focalización, de estructura interna, de precisión, de diferenciación entre atributos y de interpretación de la evidencia grupal, además de un diseño de evaluación que no permitía separar con rigor la severidad de los evaluadores de las características de los grupos evaluados.

Ese diagnóstico condujo a una reorientación metodológica: en lugar de ajustar incrementalmente el instrumento existente, el proyecto retrocedió hasta la definición misma de los constructos. Se construyeron diez Construct Maps, se sometieron a juicio de un panel de especialistas, se analizó cuantitativa y cualitativamente esa evidencia, y se refinó o reespecificó cada mapa según lo que esa evidencia, triangulada con literatura focalizada, permitía sostener.

El estado alcanzado al cierre de este reporte es el siguiente: los diez atributos institucionales cuentan ahora con una definición explícita como variables de medición, con progresiones cualitativas hipotetizadas, con fronteras conceptuales delimitadas frente a atributos vecinos, con evidencia de contenido acumulada mediante juicio experto, con decisiones de refinamiento diferenciadas para cada caso, y con una arquitectura conceptual —todavía por desarrollar en su totalidad— para las etapas siguientes de diseño de tareas, espacios de resultados y modelamiento de medición.

La idea central que debe quedar establecida en este cierre es la siguiente: **el principal resultado del proyecto hasta esta etapa no es un nuevo test terminado, sino una arquitectura de medición mucho más explícita y defendible sobre la cual construirlo.** Esta distinción

organiza todo el desarrollo de las secciones siguientes.

51. Principales aprendizajes del proceso

51.1. Un atributo institucional no constituye automáticamente una variable de medición

Este es, posiblemente, el aprendizaje más central de todo el proyecto. Que la Facultad declare que valora Liderazgo, Diseño, Comunicación o Ética y profesionalismo como atributos del perfil de egreso —y que espere observar sus manifestaciones iniciales en el perfil de ingreso— no establece todavía qué característica varía entre distintos estudiantes respecto de cada uno de ellos, qué cuenta como evidencia pertinente sobre esa característica, cómo se ordenan formas cualitativamente diferentes de desempeño, ni cómo se distingue ese atributo de los demás atributos institucionales con los que podría confundirse. El paso de **atributo institucional** a **constructo de medición** no es automático ni trivial: exige un trabajo explícito de modelamiento sustantivo, del tipo desarrollado en las Partes III y V de este reporte.

51.2. Un ítem no equivale a un atributo

La primera aproximación del Hito 0 operó, en gran medida, bajo el supuesto implícito de que declarar que "esta pregunta mide Liderazgo" bastaba para sostener inferencias sobre Liderazgo. El diagnóstico retrospectivo mostró que esa correspondencia administrativa no es suficiente: sostener una inferencia sobre un constructo exige demostrar una cadena completa entre constructo, demanda de la tarea, evidencia efectivamente producida, puntuación y, finalmente, interpretación. Cuando cualquiera de esos eslabones falta o resulta débil —como ocurrió, por ejemplo, con el ítem cuya etiqueta declaraba un atributo y cuya demanda efectiva correspondía a otro—, la inferencia pretendida deja de estar respaldada, independientemente de cuán razonable pareciera la asociación original entre el ítem y el atributo.

51.3. Más confiabilidad global no significa mejor medición diferenciada

Uno de los hallazgos más importantes para la propia institución es que un instrumento puede

exhibir cierta consistencia interna global, una estructura factorial aparentemente interpretable, o índices de ajuste favorables en un modelo confirmatorio, sin que ello demuestre que ese instrumento está diferenciando correctamente entre los distintos atributos que declara medir. La situación de desempeño grupal de la primera aproximación ilustró este punto con particular claridad: una consistencia global alta convivió con un ajuste unidimensional insuficiente y con una omega jerárquica considerablemente menor que la omega total, señal de que la estabilidad del conjunto no equivalía a una medición diferenciada y confiable de cada atributo por separado. El aprendizaje institucional es directo: **un buen indicador global no reemplaza la evidencia sobre el significado específico de cada variable que se pretende medir.**

51.4. Los Construct Maps son instrumentos de razonamiento, no descripciones definitivas

La utilidad de los Construct Maps como herramienta metodológica quedó demostrada precisamente por el hecho de que varios de ellos debieron modificarse tras el juicio experto: algunos se mantuvieron con ajustes de formulación, otros requirieron un refinamiento conceptual de su variable progresiva, y otros fueron reespecificados en su arquitectura estructural. Que un mapa cambie sustancialmente entre su versión inicial y su versión revisada no representa una falla del procedimiento ni de quienes lo construyeron inicialmente; representa, por el contrario, el funcionamiento esperado de un enfoque en el que los constructos se tratan explícitamente como **hipótesis revisables**, sometidas a evidencia y no protegidas de ella.

51.5. La multidimensionalidad no debe suponerse ni evitarse por conveniencia

La arquitectura revisada, desarrollada en la Parte V, mostró que algunos atributos pudieron sostenerse razonablemente como progresiones unidimensionales, mientras que otros —Comunicación, Diseño, Teoría de innovación y emprendimiento, y Economía y gestión— requirieron, a la luz de la evidencia disponible, más de una progresión relacionada. Esta diferencia no fue una decisión de conveniencia operativa en ninguno de los dos sentidos: no se forzó a los diez atributos hacia una única progresión por simplicidad, ni se fragmentaron

atributos en múltiples strands por prurito de sofisticación metodológica. La decisión, en cada caso, dependió de la unidad sustantiva observable en el constructo, de la plausibilidad de su progresión, de la evidencia cuantitativa y cualitativa disponible, y de la interpretabilidad resultante —no de la conveniencia de producir, en todos los casos, un único puntaje.

51.6. El punto inferior también debe representar aprendizaje

La revisión transversal de los waypoints iniciales de los diez atributos —y, de manera particularmente explícita, en el caso de Teoría de innovación y emprendimiento— mostró que el nivel inferior de una progresión no debe formularse, ni interpretarse, automáticamente como ignorancia, ausencia, error o incapacidad del estudiante. Para que un Construct Map resulte útil con fines diagnósticos, su extremo inferior debe representar una **manifestación mínima pero sustantivamente interpretable** del atributo correspondiente: una posición genuina sobre la variable, no la negación de esa variable.

51.7. El perfil de ingreso requiere calibración propia

Una progresión formulada para caracterizar desempeños avanzados o profesionales no puede trasladarse sin ajuste al momento de ingreso a la universidad. A lo largo de la construcción y el refinamiento de los diez Construct Maps, este principio se tradujo en un criterio explícito y recurrente: los niveles superiores de cada mapa deben constituir **diferenciadores plausibles dentro de la población de estudiantes que ingresan a Ingeniería**, no estándares de desempeño profesional ni resultados que deba alcanzar la totalidad de la cohorte. Varios ajustes documentados en la Parte V —la recalibración del nivel superior de Seguridad y riesgos, o la de Trabajo inter y multidisciplinario— respondieron directamente a este principio.

51.8. Las fronteras entre atributos son parte de la validez

Definir un constructo no consiste únicamente en especificar qué evidencia cuenta a su favor; consiste también en decidir explícitamente qué evidencia **no** debe interpretarse como evidencia de ese atributo, para evitar que una misma actuación se compute indiscriminadamente como

respaldo de inferencias sobre varios atributos distintos. El trabajo de refinamiento documentado en este reporte estableció, entre otras, distinciones como: coordinar eficazmente la propia tarea dentro de un equipo no equivale, por sí solo, a Liderazgo; comunicar con claridad no equivale a la calidad del razonamiento ético que sustenta lo comunicado; incorporar evidencia de usuarios no equivale, por sí sola, a Diseño; e integrar a distintas personas en un equipo no equivale a integrar conocimientos de distintas disciplinas. No se reproduce aquí la matriz completa de fronteras desarrollada en la Parte V; estos ejemplos ilustran únicamente el principio.

51.9. La evidencia grupal exige cautela para inferencias individuales

El diagnóstico de la primera aproximación mostró con claridad que un desempeño evaluado a nivel de grupo no puede trasladarse automáticamente a cada uno de sus integrantes sin evidencia adicional que respalde esa desagregación. Este aprendizaje tiene consecuencias directas y ya incorporadas en la arquitectura futura desarrollada en la Parte VI: para el diseño de tareas, que debe distinguir explícitamente evidencia de producto grupal de evidencia de contribución individual; para las rúbricas y scoring guides, que deben especificar qué observación corresponde a cada nivel; para la asignación y capacitación de evaluadores; y para

el reporte de resultados, que solo debe desagregarse a nivel de estudiante individual cuando exista una fuente de evidencia individual suficientemente defendible.

51.10. La validación es acumulativa

El proyecto ya produjo, de manera sustantiva, evidencia de validez basada en el contenido: mediante la construcción fundamentada de los Construct Maps y mediante el juicio experto sistemático documentado en la Parte IV. Pero esa fuente de evidencia es solo una entre varias que un sistema de medición defendible requiere acumular progresivamente. El aprendizaje institucional que se desprende de este recorrido es que **no existe un momento único en que un instrumento "queda validado"**; la interpretación de sus resultados se fortalece —o, cuando corresponde, se debilita— mediante la acumulación progresiva de evidencia de contenido, de procesos de respuesta, de estructura interna, de precisión, de funcionamiento de categorías, de fairness y de consecuencias, en la lógica ya introducida en la Parte I de este reporte.

52. Qué cambió en la arquitectura del Hito 0

52.1. Antes y ahora

Tabla 28. Antes y ahora

Primera aproximación	Arquitectura actual
Atributo asociado directamente a una pregunta o criterio	Atributo especificado mediante un Construct Map explícito
Correspondencia ítem–atributo declarada administrativamente	Correspondencia constructo–evidencia–tarea, sujeta a verificación
Cobertura limitada, con varios atributos representados por un único ítem o criterio	Diseño orientado, en su planificación futura, a múltiples oportunidades de observación por waypoint
Puntuaciones ya disponibles antes de haber definido completamente la variable subyacente	Variable progresiva definida antes de proyectar el sistema de puntuación
Un formato de instrumento aplicado de manera relativamente uniforme a varios atributos	Formato de tarea a determinar según la naturaleza de la evidencia que cada constructo requiere
Evidencia grupal con riesgo de interpretarse individualmente	Distinción explícita, incorporada al diseño futuro, entre evidencia de producto grupal y evidencia de contribución individual
Categorías de rúbrica sin relación explícita con una progresión sustantiva	Outcome Space proyectado para derivarse explícitamente de cada Construct Map
El puntaje total como resultado principal a reportar	Interpretación sustantiva de posiciones y perfiles, con el puntaje total subordinado a esa interpretación

Primera aproximación	Arquitectura actual
Modelo estadístico aplicado después de construido el instrumento	Modelo de medición a seleccionar en función del constructo y del tipo de respuesta, una vez disponibles los datos

Varias de las columnas de la derecha describen **decisiones de arquitectura ya fundamentadas**, no procedimientos ya ejecutados con datos reales. La cadena constructo-evidencia-tarea está conceptualmente establecida para los diez atributos, pero la evidencia específica, las tareas y sus condiciones de aplicación todavía deben diseñarse y pilotarse, como se estableció en la Parte VI.

Tabla 29. Arquitectura actual de los diez atributos

Estructura	Atributos
Unidimensional, refinada o mantenida con ajustes	Trabajo grupal e individual; Interacción con usuarios reales; Seguridad y riesgos; Liderazgo; Ética y profesionalismo; Trabajo inter y multidisciplinario
Multidimensional provisional	Comunicación (dos strands); Diseño (tres strands); Teoría de innovación y emprendimiento (dos strands); Economía y gestión (dos strands)

Esta arquitectura no se presenta como definitiva. Como se ha reiterado a lo largo de este reporte, tanto las progresiones únicas como las estructuras multidimensionales constituyen hipótesis sustantivas pendientes de contraste empírico; la tabla anterior describe el estado de la hipótesis vigente, no un resultado ya demostrado.

53. Limitaciones del trabajo realizado

Las limitaciones que siguen no se presentan como una lista defensiva, sino como una delimitación explícita del alcance de las inferencias que el estado actual del proyecto permite sostener.

53.1. Tamaño del panel experto

El juicio experto se apoyó en un panel de cinco especialistas. Este tamaño permitió obtener evidencia cualificada y complementaria entre distintas áreas de experiencia, pero produjo, como se documentó en la Parte IV, intervalos de confianza relativamente amplios para las V de Aiken calculadas. En consecuencia, esos coeficientes —y las diferencias observadas entre atributos a partir de ellos— deben interpretarse de manera descriptiva, y no como estimaciones de alta precisión ni como un ranking

52.2. Arquitectura actual de los diez atributos

El refinamiento y la reespecificación documentados en la Parte V produjeron una arquitectura mixta, en la que conviven atributos que conservaron una progresión única y atributos que requirieron más de una:

estadísticamente concluyente entre los diez mapas.

53.2. Los mapas revisados todavía no han sido contrastados con respuestas de estudiantes

Esta es la limitación central de todo el trabajo documentado en este reporte. Los Construct Maps revisados son sustantivamente mejor fundamentados que su versión inicial, gracias a la evidencia de contenido acumulada mediante el juicio experto y la revisión focalizada de literatura. Pero el orden empírico de sus waypoints, la dimensionalidad efectivamente observable, la capacidad de las tareas futuras para diferenciar entre niveles adyacentes, y la observabilidad práctica de cada waypoint en una situación real de aplicación, todavía deben contrastarse con evidencia empírica que este proyecto, en su estado actual, no ha producido.

53.3. Reespecificaciones estructurales todavía provisionales

Los cuatro atributos reespecificados en más de una progresión —Comunicación, Diseño, Teoría de innovación y emprendimiento, y Economía y gestión— deben tratarse con especial cautela interpretativa. La existencia de dos o tres strands en cada uno de estos casos constituye una

hipótesis derivada del análisis sustantivo, del juicio experto y de la literatura focalizada disponible; no constituye todavía una estructura psicométrica demostrada mediante datos de estudiantes. Es posible que evidencia empírica futura confirme esta multidimensionalidad, la modifique, o incluso la ponga en cuestión.

53.4. Literatura desigual entre atributos

La profundidad de la revisión documental focalizada realizada tras el juicio experto no fue equivalente para los diez atributos. Diseño, en particular, recibió la revisión más extensa del conjunto, coherente con la magnitud de su reespecificación estructural; otros atributos se apoyaron en una revisión más acotada. Esta diferencia constituye una oportunidad legítima para fortalecer progresivamente la fundamentación documental de los mapas restantes en etapas futuras, y una oportunidad de profundización en los ciclos siguientes del proyecto.

53.5. Falta de evidencia de procesos de respuesta

Todavía no se ha comprobado, para ninguno de los diez atributos, cómo interpretarán efectivamente los estudiantes las consignas y opciones de las tareas que se diseñen a partir de los Construct Maps revisados, qué estrategias de respuesta utilizarán, ni si las opciones o categorías proyectadas —particularmente en un eventual formato de Ordered Multiple Choice— representarán efectivamente el razonamiento que se les atribuyó en su diseño. Esta evidencia, según se estableció en la Parte VI, corresponde a una etapa todavía no iniciada.

53.6. Falta de evidencia psicométrica de la nueva arquitectura

Los análisis psicométricos realizados sobre la primera aproximación del Hito 0 (Parte II) diagnosticaron esa primera aproximación; no validan, ni pueden validar, la arquitectura revisada que surge de este proyecto. La nueva arquitectura deberá generar sus propios datos, mediante el pilotaje descrito en la Parte VI, para examinar focalización, precisión, orden empírico de los waypoints, dimensionalidad, funcionamiento de categorías y fairness, sin poder asumir por extensión ninguno de los resultados

obtenidos sobre los instrumentos de la primera aproximación.

53.7. Limitaciones para inferencias individuales

Hasta contar con suficientes oportunidades de observación por atributo, con precisión adecuada para el nivel de reporte pretendido, y con evidencia de estabilidad de las estimaciones resultantes, el sistema debe ser prudente y evitar producir diagnósticos individuales excesivamente específicos. Esta prudencia aplica con particular fuerza a los atributos cuya evidencia probablemente provenga, al menos en parte, de situaciones de desempeño grupal, según lo desarrollado en la sección 51.9.

54. Implicaciones para la Facultad

54.1. El Hito 0 como línea base diagnóstica

Debe reafirmarse, al cierre de este reporte, el propósito institucional del Hito 0 establecido desde su primera parte: se trata de una medición **diagnóstica y formativa**, destinada a establecer una línea base sobre el perfil de ingreso. No debe transformarse, en ninguna etapa futura de su desarrollo, en un mecanismo de selección, exclusión, ranking entre estudiantes o certificación.

54.2. La medición debe informar decisiones curriculares

La utilidad institucional del sistema, una vez completado su desarrollo, radica en permitir observar qué formas de razonamiento o actuación aparecen efectivamente al ingreso, cuáles resultan menos frecuentes en una cohorte determinada, qué atributos presentan perfiles heterogéneos entre estudiantes, y en qué ámbitos podría requerirse mayor apoyo o énfasis curricular temprano. Esta utilidad es de naturaleza descriptiva y orientadora; este reporte no promete, ni puede prometer, relaciones causales entre las posiciones diagnosticadas al ingreso y resultados formativos posteriores, cuestión que excede la evidencia producida hasta esta etapa.

54.3. El reporte debe conservar la multidimensionalidad cuando sea necesaria

La institución debe evitar la tentación de reducir automáticamente los resultados del Hito 0 a un único puntaje global de innovación y emprendimiento. Cuando la evidencia respalde una estructura multidimensional —como ocurre, provisionalmente, en cuatro de los diez atributos—, el reporte institucional debe conservar esa estructura: perfiles por atributo, perfiles por strand cuando corresponda, patrones por cohorte, y eventualmente posiciones por estudiante individual únicamente cuando la precisión disponible lo permita.

54.4. Interpretabilidad antes que simplicidad

Una puntuación simple solo resulta útil institucionalmente si puede interpretarse correctamente por quienes la reciben. En consecuencia, el sistema debe privilegiar reportes sustantivamente comprensibles —que expliquen qué evidencia respalda una posición determinada— aunque ello implique una arquitectura de medición y de reporte algo más compleja que un promedio o un porcentaje único.

54.5. Gobernanza de los Construct Maps

Se propone que los diez Construct Maps se mantengan, hacia adelante, como documentos institucionales controlados y explícitamente revisables, y no como formulaciones fijas una vez completado este ciclo de refinamiento. Cualquier modificación futura a un mapa —motivada por evidencia de pilotaje, por análisis psicométrico posterior, o por nueva evidencia de contenido— debería registrar de manera trazable: el problema detectado, la evidencia que lo motiva, el cambio efectivamente introducido, la nueva hipótesis resultante, y el resultado del contraste posterior que esa nueva hipótesis eventualmente reciba. No se propone aquí ningún sistema informático particular para sostener esta gobernanza; se trata de un principio de trazabilidad institucional, no de una especificación técnica.

54.6. Capacitación de evaluadores y docentes

Cuando la arquitectura futura incorpore tareas abiertas o situaciones de desempeño evaluadas por personas, será necesario desarrollar scoring guides explícitas, ejemplos ancla, procesos de

capacitación y calibración, y mecanismos de revisión periódica de esos criterios, según lo desarrollado en la Parte VI. La formación de docentes y evaluadores involucrados en la aplicación del Hito 0 debe enfatizar, como principio central, que **observar un comportamiento puntual no implica automáticamente inferir el desarrollo completo de un atributo**: la inferencia depende de la cadena completa entre constructo, evidencia, tarea y puntuación desarrollada en este reporte, no de la impresión general que un comportamiento particular pueda producir.

55. Recomendaciones institucionales

1. Consolidar los Construct Maps revisados.

Realizar una revisión final de consistencia interna del conjunto de los diez mapas y, cuando corresponda —particularmente para los atributos reespecificados estructuralmente—, una segunda ronda focalizada de revisión de contenido antes de avanzar a la etapa siguiente.

2. Avanzar hacia Items Design desde las progresiones, no desde los nombres de los atributos.

Evitar que el diseño de tareas retroceda a la lógica de la primera aproximación, construyendo preguntas directamente a partir del nombre institucional de un atributo en lugar de partir de su Construct Map revisado.

3. Construir los Outcome Spaces antes de la aplicación de cualquier tarea nueva.

Evitar diseñar rúbricas o reglas de puntuación después de observar respuestas reales, sin haber formulado previamente una hipótesis explícita de puntuación derivada del Construct Map correspondiente.

4. Pilotar antes de cualquier aplicación institucional ampliada.

El pilotaje debe entenderse como parte constitutiva del desarrollo de la medición —generador de evidencia sobre tareas, categorías y estructura—, no únicamente como una prueba logística de la plataforma de aplicación.

5. Incorporar evidencia de procesos de respuesta antes de interpretar psicométricamente las tareas.

Esta recomendación resulta especialmente relevante para un eventual formato de Ordered Multiple Choice, para los escenarios contextualizados, y

para cualquier tarea de mayor complejidad interpretativa.

6. Diseñar con rigor la evaluación de desempeños grupales o individuales evaluados por personas. Asegurando evidencia individual suficientemente defendible cuando el propósito sea reportar a ese nivel, y un cruce adecuado entre evaluadores y respuestas cuando el propósito sea estudiar consistencia y severidad.

7. Mantener un enfoque criterial en la interpretación de resultados. Las posiciones de los estudiantes deben interpretarse respecto de las progresiones definidas en los Construct Maps, no únicamente respecto del rendimiento relativo del grupo de referencia o de la cohorte.

8. Construir reportes orientados a la acción formativa. El resultado del Hito 0 debe ayudar a la coordinación y al cuerpo docente a comprender qué requieren los estudiantes al momento de ingresar, y cómo puede responder el diseño curricular a esas condiciones iniciales —no limitarse a producir una cifra de reporte administrativo.

Estas recomendaciones se circunscriben exclusivamente al desarrollo y uso del Hito 0; este reporte no las extiende a otros hitos evaluativos del sistema de seguimiento del perfil de egreso.

56. Hoja de ruta consolidada

Tabla 30. Hoja de ruta consolidada

Etapas	Producto principal	Evidencia esperada	Decisión resultante
1. Consolidación de los Construct Maps	Construct Maps revisados, estabilizados	Evidencia de contenido	Arquitectura sustantiva de referencia para las etapas siguientes
2. Items Design	Prototipos de tareas alineados con las progresiones	Alineamiento entre constructo, waypoint y demanda de la tarea	Selección de las tareas a incorporar al pilotaje
3. Outcome Space	Scoring guides y reglas de puntuación	Coherencia entre respuesta observable y variable	Sistema preliminar de puntuación, sujeto a revisión
4. Procesos de respuesta	Evidencia cognitiva sobre la interpretación de las tareas	Correspondencia entre razonamiento esperado y razonamiento efectivo	Revisión de consignas, opciones o escenarios
5. Pilotaje	Respuestas de una muestra de estudiantes	Funcionamiento preliminar de tareas y categorías	Revisión de Construct Maps, tareas o categorías, según corresponda
6. Modelamiento de medición	Modelos calibrados por atributo o strand	Estructura interna y precisión	Arquitectura de puntuación e interpretación aplicable a cohortes completas
7. Implementación institucional ampliada	Hito 0 operativo para cohortes de ingreso	Utilidad diagnóstica y consecuencias del uso	Ajustes institucionales y eventual nuevo ciclo de revisión

Esta hoja de ruta debe leerse como un **ciclo**, no como una secuencia irreversible de etapas independientes: tal como ya ocurrió con Diseño, Comunicación, Teoría de innovación y emprendimiento y Economía y gestión —reespecificados a partir de evidencia de contenido, antes incluso de llegar a la etapa de pilotaje—, si la evidencia producida en cualquiera de las etapas 2 a 6 contradice un supuesto de un Construct Map, ese mapa puede y debe revisarse, retrocediendo el ciclo hasta la etapa 1 para el atributo correspondiente.

57. Criterios para considerar el sistema preparado para una aplicación ampliada

Antes de escalar la nueva arquitectura de medición a una aplicación institucional amplia —es decir, a cohortes completas de ingreso, más allá de un pilotaje— debería existir, como mínimo, evidencia razonable sobre los siguientes puntos,

evaluados **en conjunto** y no mediante un umbral psicométrico único o automático:

- Construct Maps suficientemente estabilizados, sin observaciones pendientes de naturaleza estructural.
- Tareas efectivamente alineadas con los Construct Maps que pretenden operacionalizar.
- Evidencia de procesos de respuesta que respalde la interpretación prevista de esas tareas.
- Outcome Spaces funcionales, aplicados de manera consistente por distintos evaluadores cuando corresponda.
- Categorías de puntuación interpretables y empíricamente distinguibles entre sí.
- Capacitación adecuada de los evaluadores involucrados, cuando la arquitectura incluya tareas puntuadas por personas.
- Evidencia inicial sobre la dimensionalidad efectiva de cada atributo, contrastada con la hipótesis vigente.
- Focalización suficiente de las tareas respecto del rango de desarrollo esperable en la población de ingreso.
- Precisión compatible con el nivel de interpretación que se pretenda sostener (cohorte, carrera, atributo, strand o estudiante individual).
- Ausencia de problemas graves de fairness detectables con la evidencia disponible hasta ese momento.
- Un sistema de reporte coherente con el propósito diagnóstico y formativo del Hito 0, y no con fines de selección o clasificación.

Ningún criterio aislado —por ejemplo, un coeficiente de confiabilidad determinado— debe considerarse suficiente por sí solo para autorizar el escalamiento del sistema; la decisión debe fundamentarse en la evaluación conjunta de estos criterios, análoga a la lógica de triangulación ya aplicada en este proyecto para decidir sobre cada Construct Map.

58. Qué no debería hacerse

Como salvaguarda institucional derivada directamente de lo aprendido en este proyecto:

- No volver a asumir que un solo ítem o criterio por atributo constituye evidencia suficiente para una inferencia diagnóstica.
- No interpretar la consistencia global de un instrumento como evidencia de que mide de manera diferenciada los diez atributos institucionales.
- No utilizar una puntuación asignada a un grupo como si fuera una puntuación individual, sin evidencia adicional que respalde esa desagregación.
- No confundir categorías de una rúbrica con los waypoints de un Construct Map sin una correspondencia explícita y justificada entre ambas.
- No imponer un puntaje total a un constructo reespecificado como multidimensional sin evidencia empírica que respalde esa combinación.
- No tratar los Construct Maps revisados en este reporte como si ya estuvieran psicométricamente validados.
- No escalar institucionalmente una nueva versión del Hito 0 sin haber completado, como mínimo, un ciclo de pilotaje sobre la arquitectura propuesta.

59. Contribución institucional del proyecto

¿Qué ha producido realmente este proyecto para la Facultad? La respuesta puede organizarse en tres planos.

Plano conceptual. Los diez atributos de innovación y emprendimiento, que al inicio de este reporte existían como declaraciones institucionales del perfil de egreso, cuentan ahora con una especificación explícita como variables de medición: definición, variable progresiva, waypoints, fronteras conceptuales y, en cuatro casos, una estructura multidimensional provisional debidamente fundamentada.

Plano metodológico. El proyecto estableció, y aplicó efectivamente sobre su primer componente, una arquitectura de desarrollo de la medición organizada según el ciclo **Construct Map → Items Design → Outcome Space → Measurement Model**, junto con una agenda explícita de acumulación de evidencias de validez que excede largamente lo que la primera aproximación había considerado.

Plano institucional. Existe ahora una base sustantiva para construir un sistema de diagnóstico interpretable, formativo, revisable, acumulativo en su lógica de validación, y alineado con el sello propio de la Facultad de Ingeniería en

innovación y emprendimiento —una base que, antes de este proyecto, no estaba disponible en un formato suficientemente explícito como para orientar decisiones de diseño coherentes entre sí.

Esta contribución debe reconocerse en sus justos términos, sin lenguaje celebratorio que exceda lo efectivamente alcanzado: se trata de una base metodológica considerablemente más sólida, no de un sistema de medición ya terminado.

La Figura 29 sintetiza el recorrido completo del proyecto Hito 0 descrito en este reporte.




Figura 29. Síntesis institucional del proceso de reconstrucción del Hito 0: desde la primera aproximación diagnóstica hacia una arquitectura de medición explícita y una agenda de validación todavía en desarrollo.

60. Conclusiones generales

La principal dificultad de la primera aproximación del Hito 0 no era, en su origen, únicamente una dificultad psicométrica. Los coeficientes de confiabilidad limitados, el ajuste factorial insuficiente o la escasa cobertura del continuo documentados en la Parte II fueron, en gran medida, síntomas de un problema anterior: una dificultad de **especificación de los constructos** que esos instrumentos pretendían medir. Ningún ajuste puramente estadístico —agregar ítems, cambiar un formato, ensayar otro modelo— podía resolver esa dificultad de raíz, porque ninguno de esos ajustes respondía la pregunta que permanecía sin resolver: qué variable representa realmente cada atributo y cómo se espera que

difiera cualitativamente entre estudiantes que ingresan a Ingeniería.

El análisis retrospectivo desarrollado en este proyecto permitió, precisamente, identificar con precisión los límites de las inferencias que los instrumentos iniciales permitían sostener —y, con la misma precisión, identificar aquellas que no permitían sostener—, evitando tanto la sobreinterpretación de resultados parciales como la descalificación genérica de un esfuerzo institucional legítimo en su origen. Sobre esa base, la construcción de los diez Construct Maps hizo explícitas variables, progresiones y fronteras conceptuales que, hasta ese momento, permanecían implícitas en la sola declaración de los atributos institucionales.

El juicio experto que siguió a esa construcción aportó evidencia sistemática de contenido para distinguir, de manera diferenciada y no mediante una regla mecánica, qué mapas podían mantenerse con ajustes menores, cuáles requerían un refinamiento conceptual más profundo de su variable progresiva, y cuáles —Comunicación, Diseño, Teoría de innovación y emprendimiento y Economía y gestión— necesitaban una reespecificación de su propia arquitectura estructural. El refinamiento resultante de ese proceso produjo una arquitectura más rica y más honesta con la evidencia disponible, en la que no todos los atributos institucionales necesitan asumir la misma estructura dimensional para ser medidos con rigor.

Ese avance, sin embargo, no debe confundirse con haber completado la validación del sistema. Como se ha reiterado a lo largo de este cierre, los diez Construct Maps revisados constituyen hipótesis sustantivas mejor fundamentadas, no estructuras psicométricamente demostradas; la fase siguiente del proyecto debe trasladar cuidadosamente estas progresiones hacia evidencia observable —tareas concretas, Outcome Spaces explícitos y, finalmente, modelos de medición contrastados con datos reales de estudiantes—, sin atajos que repitan la lógica que el diagnóstico inicial de este mismo reporte identificó como insuficiente.

El valor institucional final del Hito 0 dependerá de su capacidad para producir información que sea,

simultáneamente, interpretable, suficientemente precisa para el nivel de reporte que se pretenda sostener, equitativa entre distintos grupos de estudiantes, y útil para orientar decisiones formativas concretas dentro de la Facultad. Ninguna de estas condiciones se da por completa en el estado actual del proyecto; todas ellas constituyen la agenda de trabajo que las partes anteriores de este reporte han dejado explícitamente documentada.

El avance principal de este proyecto, en síntesis, consiste en haber desplazado el problema desde "cómo asignar una puntuación a diez atributos" hacia una pregunta metodológicamente más adecuada y más exigente: qué significa cada atributo, cómo puede variar entre los estudiantes que ingresan a Ingeniería, qué evidencia permite observar responsablemente esas diferencias, y qué interpretaciones puede sostener esa evidencia sin exceder lo que ella misma respalda. Sobre esa base, y solo sobre esa base, puede construirse de manera iterativa y acumulativa una medición diagnóstica institucional verdaderamente defendible.

61. Estado final del proyecto al cierre del reporte

Tabla 31. Estado final del proyecto al cierre del reporte

Componente	Estado al cierre	Próxima evidencia necesaria
Diagnóstico de la primera aproximación institucional	Completado	—
Construct Maps iniciales	Completados	Sustituídos, en cuatro casos, por versiones estructuralmente revisadas; en los seis restantes, por versiones conceptualmente refinadas
Evidencia de contenido (juicio experto)	Completada para esta ronda de revisión	Nueva ronda focalizada, cuando corresponda, sobre los mapas ya reespecificados
Construct Maps revisados	Disponibles como hipótesis vigentes	Evidencia de procesos de respuesta y contraste empírico con datos de estudiantes
Items Design	En etapa de desarrollo conceptual	Matrices de evidencia por waypoint y prototipos de tareas
Outcome Space	Pendiente de desarrollo sistemático	Tareas ya diseñadas, sobre las cuales construir scoring guides
Procesos de respuesta	No producidos	Tareas y Outcome Spaces preliminares sobre los cuales aplicar entrevistas cognitivas
Pilotaje	No realizado	Tareas, Outcome Spaces y protocolo de procesos de respuesta ya disponibles

Componente	Estado al cierre	Próxima evidencia necesaria
Measurement Model de la nueva arquitectura	Pendiente	Datos del pilotaje
Reporte institucional definitivo del Hito 0	Versión integrada con resumen ejecutivo y figuras en revisión editorial	Maquetación final, revisión de referencias cruzadas y cierre editorial